IFT 603-712 : Devoir 1

Travail par équipe de 3

Remettez votre solution aux numéros 1 et 2 en format pdf ou manuscript (et scanné) via <u>turninweb</u>. Même chose pour le code.

1. [1 point] Démontrez la propriété de l'entropie suivante :

$$H[x,y] = H[y|x] + H[x]$$

Vous pouvez faire la démonstration pour le cas discret ou continu.

2. [1.5 points] Démontrez la propriété de l'information mutuelle suivante :

$$I[x,y] = H[x] - H[x|y]$$

Vous pouvez faire la démonstration pour le cas discret ou continu.

3. [1 point] Démontrez la propriété suivante :

$$Cov[x,y] = E_{xy}[xy] - E[x]E[y]$$

où Cov est la fonction de covariance et E est l'espérance mathématique. Vous pouvez faire la démonstration pour le cas discret ou continu.

- 4. **[0.5 point]** Soit une variable aléatoire binaire x ayant produit la séquence d'observations suivante : {0,0,0,1,0,1,0,0,0,1}. Partant de ces observations, donnez (a) la distribution P(x) également appelée « l'évidence » (b) l'espérance mathématique de x, (c) la variance de x et (d) l'entropie de x. Précisez vos calculs.
- 5. **[6 points]** Programmez les algorithmes de régression linéaire et non linéaire polynomial vus aux chapitres 1 et 3 ainsi que la recherche d'hyperparamètre « k-fold cross-validation » vu au chapitre 1. Pour ce faire, vous devez télécharger le fichier **devoir1.zip** du site web du cours.

L'algorithme doit être implémenté via la classe **Regression**. Votre implémentation de cette classe doit être placée dans le fichier **solution_regression.py** qui contient déjà une ébauche. Veuillez vous référer aux commentaires sous la signature de chaque méthode de la classe **Regression** afin de savoir quoi implémenter. Votre implémentation doit être efficace et utiliser les fonctionnalités de la librairie Numpy. Les fonctions qu'il vous faut compléter sont identifiées par le commentaire « AJOUTER CODE ICI ».

NOTE: dans le fichier pdf que vous remettrez, inclure <u>un résultat graphique</u> illustrant un cas de sur-apprentissage ainsi qu'un cas de sous-apprentissage. Dans les deux cas, veuillez préciser les paramètres utilisés.

Note 1: bien que vide, le code de la classe **Regression** s'exécute déjà. Pour vous en convaincre, vous n'avez qu'à taper la commande suivante dans un terminal linux :

python regression.py tanh 100 20 0.0 1 0.000001 --sklearn

En tappant:

vous verrez à quoi correspondent les arguments de ce programme.

Note 2 : le code des devoirs a été testé avec de versions de python 3.5 et 3.6. Pour faire fonctionner votre code sur les ordinateurs du département, vous devez

- 1. démarrer une session linux (ubuntu)
- 2. démarrer un terminal
- 3. activer (ou créer) un environnement virtuel python et y installer les packages requis
- 3. normalement, si vous démarrez une session ipython (tappez ipython dans le terminal) vous verrez « Python 3.5.2 ».

Note 3 : il est recommandé de rédiger son code dans un ide comme spyder ou pycharm.

Note 4 : pour exécuter le code des notebooks disponibles sur le site web du cours, vous devez tapper la commande « jupyter notebook » dans un terminal.