

Méthodes d'apprentissage  
IFT603-712

Formulation probabiliste

Par  
Pierre-Marc Jodoin  
et  
Hugo Larochelle

---

---

---

---

---

---

---

Illustration au tableau des probabilités  
**marginales, jointes et conditionnelles**

---

---

---

---

---

---

---

Variable aléatoire

- La théorie des probabilités est l'outil idéal pour formaliser nos **hypothèses et incertitudes** par rapport à nos données
- On va traiter nos données comme des **variables aléatoires**
  - la valeur d'une variable aléatoire est incertaine (avant de l'observer)
  - la loi de probabilité de la variable aléatoire caractérise notre incertitude par rapport à sa valeur

---

---

---

---

---

---


---

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (groupe 1)

$$x \sim N(\mu = 40, \sigma = 10)$$



4

---

---

---

---

---

---

---


---

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (groupe 2)

$$x \sim N(\mu = 80, \sigma = 7)$$



5

---

---

---

---

---

---

---


---

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (toute la classe)

$$x \sim \frac{1}{2} N(\mu = 40, \sigma = 10) + \frac{1}{2} N(\mu = 80, \sigma = 7)$$



6

---

---

---

---

---

---

---


---

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (toute la classe)

$$x \sim \frac{1}{2} N(\mu = 40, \sigma = 10) + \frac{1}{2} N(\mu = 80, \sigma = 7)$$



Données  
étiquetées


7

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (toute la classe)

$$x \sim \frac{1}{2} N(\mu = 40, \sigma = 10) + \frac{1}{2} N(\mu = 80, \sigma = 7)$$



Résultat d'un  
entraînement


8

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (toute la classe)

$$x \sim \frac{1}{2} N(\mu = 40, \sigma = 10) + \frac{1}{2} N(\mu = 80, \sigma = 7)$$



Très confiant que le nouvel  
étudiant ayant eu la note de  
82% (●) est issu du groupe 2


9

## Variable aléatoire

$$x \sim P(X)$$

Exemple, résultats à un examen (toute la classe)

$$x \sim \frac{1}{2} N(\mu = 50, \sigma = 10) + \frac{1}{2} N(\mu = 70, \sigma = 6)$$



Incertain que le nouvel étudiant ayant eu la note de 67% (●) est issu du groupe 2

10

## Variable aléatoire

- Soient  $X$  et  $T$  des variables aléatoires **discrètes**

➤  $X$  peut prendre comme valeurs  $x_1, \dots, x_M$

➤  $T$  peut prendre comme valeurs  $t_1, \dots, t_M$

- La **probabilité jointe** qu'on observe  $X = x_i$  et  $T = t_j$  est notée

$$P(X = x_i, T = t_j)$$


et se lit comme la « probabilité d'observer à **la fois**  $x_i$  et  $t_j$  ».

- Note:

$$P(X = x_i, T = t_j) = P(T = t_j, X = x_i)$$

## Probabilité jointe

Exemple  $X$ : forme,  $Y$ : couleur



$$P(X = \text{carré}) = 6/16$$

$$P(Y = \text{rouge}) = 8/16$$

$$P(X = \text{carré}, Y = \text{rouge}) = 2/16$$

## Probabilité marginale

Une **probabilité marginale** est lorsqu'on ne s'intéresse pas à toutes les variables aléatoires qu'on a défini

Exemple : la probabilité marginale d'observer  $X = x_i$

$$P(X = x_i) = \sum_{j=1}^N P(X = x_i, T = t_j)$$

---

---

---

---

---


---

---

---

## Probabilité jointe

**Exemple**  $X$  : forme,  $Y$  : couleur



$$P(X = carré) = \sum_{couleur} P(X = carré, Y = couleur)$$

---

---

---

---

---


---

---

---

## Probabilité jointe

**Exemple**  $X$  : forme,  $Y$  : couleur



$$\begin{aligned} P(X = carré) &= P(X = carré, Y = rouge) + P(X = carré, Y = noir) \\ &= \frac{2}{16} + \frac{4}{16} \\ &= \frac{6}{16} \end{aligned}$$

---

---

---

---

---

---

---

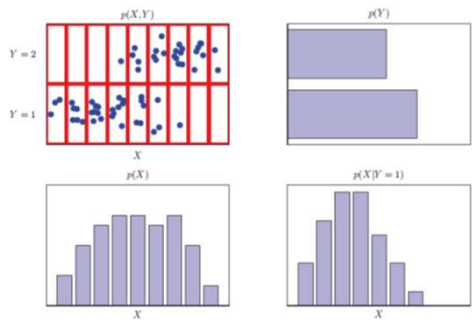
---

Une **probabilité conditionnelle** est lorsqu'on s'intéresse la valeur d'une variable aléatoire «étant donnée» une valeur assignée à d'autres variables

## Probabilité conditionnelle

## Produit des probabilités

## Probabilités jointes, marginale et conditionnelles



Credit : Bishop

---

---

---

---

---

---

---

---

## Bayes

La **règle de Bayes** permet d'inverser l'ordre de la conditionnelle

$$P(T | X) = \frac{P(X | T)P(T)}{P(X)}$$

$p(T)$  est appelée loi de probabilité a priori (*prior*)

$p(T | X)$  est appelée loi de probabilité a posteriori (*posterior*)

---

---

---

---

---

---

---

---

## Indépendance

Deux variables aléatoires  $X$  et  $T$  sont indépendantes si

- $P(X, T) = P(X)P(T)$  ou
- $P(X | T) = P(X)$  ou
- $P(T | X) = P(T)$

➤ Observer la valeur d'une variable ne nous apprend rien sur la valeur de l'autre

---

---

---

---

---

---

---

---

## Variable aléatoire continue

Soit  $X$  une **variable aléatoire continue**

- $X$  peut prendre un nombre infini de valeurs possibles (e.g.  $\mathbb{R}$ )
- $X$  est associée à une **fonction de densité** de probabilité  $p(x)$

la probabilité que  $X$  appartienne à un intervalle  $(a,b)$  est

$$p(x \in (a,b)) = \int_a^b p(x)dx$$

---

---

---

---

---

---

---

---


## Variables aléatoires continues

Soit  $X$  une **variable aléatoire continue**

- la fonction de densité doit satisfaire

$$p(x) \geq 0$$
$$\int_{-\infty}^{\infty} p(x)dx = 1$$

à noter que, contrairement aux probabilités d'une variable discrète, la fonction de densité peut être  $> 1$ .



---

---

---

---

---

---

---

---

## Variables aléatoires continues

Soit  $X$  une **variable aléatoire continue**

la **fonction de répartition**  $P(z)$  (*cumulative distribution function*) donne la probabilité que  $X$  appartienne à l'intervalle  $(-\infty, z)$

$$P(x = z) = \int_{-\infty}^z p(x)dx$$

---

---

---

---

---

---

---

---



## Variables aléatoires continues

Soient  $X$  et  $T$  deux **variables aléatoires continues**

➤ elles sont associées à une **fonction de densité jointe**  $p(x,t)$  telle que :

$$p(x \in [a,b], t \in [c,d]) = \int_a^b \int_c^d p(x,t) dx dt$$

---

---

---

---

---

---

---

## Variables aléatoires continues

Soient  $X$  et  $T$  deux **variables aléatoires continues**

➤ La **fonction de densité marginale** s'obtient en intégrant l'autre variable

$$p(x) = \int p(x,t) dt$$

➤ La **fonction de densité conditionnelle** s'obtient comme auparavant

$$p(t|x) = \frac{p(x,t)}{p(x)}$$

---

---

---

---

---

---

---

## Expérance mathématique

L'**espérance** d'une **variable  $X$**  est la moyenne qu'on obtient si on répète un grand nombre de fois une expérience

$$E[X] = \sum_x xp(x) \quad (\text{cas discret})$$

$$E[X] = \int xp(x) dx \quad (\text{cas continu})$$

---

---

---

---

---

---

---

## Espérance mathématique

L'**espérance** d'une **fonction  $f(x)$**  est la moyenne qu'on obtient si on génère un grand nombre de valeurs pour cette fonction

$$E[f] = \sum_x f(x)p(x) \quad (\text{cas discret})$$

$$E[f] = \int f(x)p(x)dx \quad (\text{cas continu})$$

---

---

---

---

---

---

---

## Variance

- La **variance** d'une **variable  $X$**  est

$$\text{var}[X] = E[(X - E[X])^2]$$

- La **variance** d'une **fonction  $f(x)$**  est

$$\text{var}[f] = E[(f(x) - E[f(x)])^2]$$

La variance mesure à quel point les valeurs varient autour de l'espérance

---

---

---

---

---

---

---

## Propriétés de l'espérance et de la variance

**Transformation linéaire** de l'espérance

$$\begin{aligned} E_{xy}[ax + by] &= \sum_x \sum_y (ax + by)p(x, y) & a, b \text{ sont réels} \\ &= aE[x] + bE[y] & \text{Si } x, y \text{ indépendants} \end{aligned}$$

**Transformation linéaire** de la variance

$$\text{var}[ax + by] = a^2 \text{var}[x] + b^2 \text{var}[y] \quad \text{Si } x, y \text{ indépendants}$$

---

---

---

---

---

---

---

## Espérance et variance conditionnelles

L'espérance et la variance se généralisent au cas **conditionnel** :

$$\begin{aligned}E[x | y] &= \sum_x x p(x | y) \\ E[f(x) | y] &= \sum_x f(x) p(x | y)\end{aligned}$$

$$\begin{aligned}\text{var}[x | y] &= E[(x - E[x | y])^2] \\ \text{var}[f(x) | y] &= E[(f(x) - E[f(x) | y])^2]\end{aligned}$$

---

---

---

---

---

---

---

## Covariance

La covariance entre 2 variables aléatoires X et Y

$$\begin{aligned}\text{cov}[x, y] &= E_{xy}[(x - E_x[x])(y - E_y[y])] \\ &= E_{xy}[xy] - E_x[x]E_y[y]\end{aligned}$$

mesure à quel point on peut prédire X à partir de Y (linéairement), et vice-versa  
si X et Y sont indépendantes, alors la covariance est 0

---

---

---

---

---

---

---

## Variables aléatoires multidimensionnelles

Une variable aléatoire peut être un vecteur

L'espérance d'un vecteur est le vecteur des espérances

$$E[\vec{x}] = (E[x_1], \dots, E[x_D])^T$$

Et la covariance de deux vecteurs est

$$\text{cov}[\vec{x}, \vec{y}] = E_{\vec{x}\vec{y}}[\vec{x}\vec{y}^T] - E_{\vec{x}}[\vec{x}]E_{\vec{y}}[\vec{y}]$$

---

---

---

---


---

---

---

## Loi de probabilité gaussienne

$$N(x | \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$




Moyenne :  $E[x] = \int_{-\infty}^{\infty} N(x; \mu, \sigma) x dx = \mu$

Variance :  $\text{var}[x] = \int_{-\infty}^{\infty} N(x; \mu, \sigma) (x - \mu)^2 dx = \sigma^2$

Écart type :  $\sqrt{\text{var}[x]} = \sigma$

## Loi de probabilité gaussienne



$\sigma$	68.268949213711%
$2\sigma$	95.44997361036%
$3\sigma$	99.73002039367%

## Gaussienne multivariée


$$N(\vec{x} | \vec{\mu}, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu})\right\}$$

Moyenne :  $E[\vec{x}] = \vec{\mu}$

Variance :  $\text{cov}[\vec{x}] = \Sigma$

## Gaussienne multivariée

Exemple :  $\vec{x} = (x_1, x_2)$



---

---

---

---

---

---


---

---

## Gaussienne multivariée

Exemple :  $\vec{x} = (x_1, x_2)$

Courbes de niveaux de  $N(\vec{x} | \vec{\mu}, \Sigma)$



---

---

---

---

---

---


---

---

## Gaussienne multivariée

Exemple :  $\vec{x} = (x_1, x_2)$

Courbes de niveaux de  $N(\vec{x} | \vec{\mu}, \Sigma)$



---

---

---

---

---

---


---

---

## Gaussienne multivariée

Exemple :  $\vec{x} = (x_1, x_2)$

Courbes de niveaux de  $N(\vec{x} | \vec{\mu}, \Sigma)$



---

---

---

---

---

---

---

---

## Gaussienne multivariée

Une **combinaison linéaire** de variables aléatoires gaussiennes est également gaussienne

- Exemple

- soit  $x$  une variable gaussienne de moyenne  $\mu_1$  et variance  $\sigma_1^2$
- soit  $t$  une variable gaussienne de moyenne  $\mu_2$  et variance  $\sigma_2^2$
- alors  $ax + bt$  suit une loi gaussienne de moyenne  $a\mu_1 + b\mu_2$  et variance  $a^2\sigma_1^2 + b^2\sigma_2^2$  ( $x$  et  $y$  sont indépendantes)

---

---

---

---

---

---

---

---

## Introduction au tableau

Maximum de vraisemblance  
vs  
Maximum a posteriori

43

---

---

---

---

---

---

---

---

## Théorie de l'information

58

---

---

---

---

---

---

---

## Théorie de l'information

- Les probabilités sont également utiles pour **quantifier l'information** présente dans des données  
exemple : quel est le nombre minimum de bits nécessaire pour encoder un message ?
- Cette question est intimement liée à la **probabilité d'observer ce message**  
plus le message est «surprenant» (improbable), plus on aura besoin de bits

59

---

---

---

---

---

---

---

## Théorie de l'information

Codage de Huffman :

- façon optimale d'encoder des symboles indépendants de façon binaire
- plus un symbole est «fréquent» (probable), plus son code sera court

'a'	'b'	'c'	'd'
0.4	0.05	0.2	0.35

---

---

---

---

---


---

---

## Théorie de l'information

Codage de Huffman :

- façon optimale d'encoder des symboles indépendants de façon binaire
- plus un symbole est «fréquent» (probable), plus son code sera court



---

---

---

---

---

---


---

---

## Théorie de l'information

Codage de Huffman :

- façon optimale d'encoder des symboles indépendants de façon binaire
- plus un symbole est «fréquent» (probable), plus son code sera court



---

---

---

---

---

---


---

---

## Théorie de l'information

Codage de Huffman :

- façon optimale d'encoder des symboles indépendants de façon binaire
- plus un symbole est «fréquent» (probable), plus son code sera court



---

---

---

---

---

---

---


---



# Théorie de l'information

## Codage de Huffman :

- façon optimale d'encoder des symboles indépendants de façon binaire
- plus un symbole est «fréquent» (probable), plus son code sera court



Symbole	Code	Prob
'a'	0	40%
'b'	100	5%
'c'	101	20%
'd'	11	35%

## Entropie

Symbole	Code	Prob
'a'	0	40%
'b'	100	5%
'c'	101	20%
'd'	11	35%

- Soit  $p(x)$  la probabilité d'observer le symbole  $x$

la taille moyenne du code d'un symbole est

$$0.4 \times 1 + 0.05 \times 3 + 0.2 \times 3 + 0.35 \times 2 = \underline{1.85 \text{ (bits)}}$$

- Entropie :

$$H[x] = -\sum_x p(x) \log_2 p(x) \approx \underline{1.739 \text{ (bits)}}$$

Claude Shannon a démontré qu'il est impossible de compresser l'information dans un plus petit code moyen **sans perte d'information**

$-\log_2 p(x)$  est l'information contenue par  $x$

## Entropie

Plus  $p(x)$  est proche d'une **loi uniforme**, plus l'**entropie** est élevée

exemple :  $x \in \{a, b, c, d, e, f, g, h\}$



$$H[x] = -\sum_x p(x) \log_2 p(x)$$

$$= -\left(\frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right) + \frac{1}{8} \log_2 \left(\frac{1}{8}\right)\right)$$


$$= -8 \left(\frac{1}{8} \log_2 \left(\frac{1}{8}\right)\right)$$

$$= 3 \text{ bits}$$

## Entropie

Plus  $q(x)$  est proche d'une loi uniforme, plus l'entropie est élevée

exemple :  $x \in \{a, b, c, d, e, f, g, h\}$



$$H[x] = -\sum_x q(x) \log_2 q(x)$$

$$= -\left(\frac{1}{2} \log_2 \left(\frac{1}{2}\right) - \left(\frac{1}{4} \log_2 \left(\frac{1}{4}\right)\right) - \left(\frac{1}{8} \log_2 \left(\frac{1}{8}\right)\right) - \left(\frac{1}{16} \log_2 \left(\frac{1}{16}\right)\right) - \left(\frac{1}{32} \log_2 \left(\frac{1}{32}\right)\right) - 3 \left(\frac{1}{64} \log_2 \left(\frac{1}{64}\right)\right)\right)$$

$$= 2.06 \text{ bits}$$

## Entropie

L'entropie se généralise aux variables continues

$$H[x] = - \int_{-\infty}^{\infty} p(x) \log_2 p(x) dx$$

## Entropie relative et divergence de Kullback-Leibler

- Si on ne connaît pas  $p(x)$ , on va vouloir l'estimer
- Si  $q(x)$  est notre estimation, on définit la **divergence de Kullback-Leibler** (K-L) comme suit :

$$KL(p(x) \parallel q(x)) = -\sum_x p(x) \log_2 q(x) - \left( -\sum_x p(x) \log_2 p(x) \right)$$

$$= \sum_x p(x) \log_2 \frac{p(x)}{q(x)}$$

➤ correspond au **nombre de bits additionnels** par rapport à ce qui serait optimal

## Entropie jointe

L'entropie est une fonction d'une loi de probabilité

- elle reflète l'incertitude représentée par la loi
- si  $p(x) = 1$  pour une seule valeur de  $x$ , l'entropie est 0

On peut généraliser l'entropie à **plusieurs variables**

$$H[x, y] = - \sum_x \sum_y p(x, y) \log_2 p(x, y)$$

---

---

---

---

---

---

---

---

## Entropie conditionnelle

L'entropie conditionnelle quantifie l'**information additionnelle** qu'apporte une **nouvelle observation  $y$**

$$H[x | y] = - \sum_x \sum_y p(x, y) \log_2 p(x | y)$$

On peut démontrer que

$$H[x, y] = H[y | x] + H[x]$$

---

---

---

---

---

---

---

---

## Information mutuelle

- Mesure à quel point deux variables sont indépendantes

$$\begin{aligned} I(x, y) &= KL(p(x, y) \| p(x)p(y)) \\ &= \sum_{x, y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)} \end{aligned}$$

- On appelle cette mesure l'**information mutuelle**

---

---

---

---

---

---

---

---

## Autre exemple concret de l'utilité des probabilités

73

---

---

---

---

---

---


---

---

## Comprendre la théorie des probabilité à l'aide d'images

Un **histogramme** représente le nombre de pixels appartenant à chaque niveau de gris (ou couleur) pouvant être représenté dans l'image.

$$H(c) = \text{Nb pixels d'intensité "c"}$$



74

---

---

---

---

---

---

---

---

## Quelques définitions


Parfois l'histogramme est normalisé par le nombre de pixels dans l'image:

$$H'(c) = P(c) = \frac{\text{Nb pixels d'intensité } c}{\text{Nb total de pixels dans l'image}}$$

Ainsi défini,  $P(c)$  donne une idée de la probabilité d'occurrence d'un pixel de niveau de gris "c".

$$\sum_{c=0}^{255} P(c) = 1$$

Si je tire un pixel au hasard dans l'image, j'ai 1% de chance qu'il soit d'intensité 113.




---

---

---

---


---

---

---

---

## Quelques définitions



$P(x_s)$  Distribution des niveaux de gris dans l'image  $x$ .

$P(x_s = a)$  Peut se lire : probabilité d'observer un pixel de niveau de gris «  $a$  » dans l'image  $y$ .

exemple: si  $P(x_s = 15) = 0.09$  alors

si je tire au hasard un pixel dans l'image  $x$ , j'aurai 9 pourcents de chance qu'il soit d'intensité 15



## Quelques définitions

$P(x_s = a)$  probabilité d'observer un pixel de niveau de gris  $a$  dans l'image  $x$ .

$P(x_s = a, mer)$  est une **probabilité jointe** qui se lit : la probabilité d'observer un pixel de niveau de gris  $a$  dans l'image  $x$  **ET** faisant partie de la classe mer.

$P(mer)$  Probabilité **a priori** d'observer un pixel appartenant à la classe mer.


$$P(x_s = a, mer) = P(mer)P(x_s = a | mer)$$

$P(x_s = a | mer)$  est une **probabilité conditionnelle** qui se lit : la probabilité d'observer un pixel de niveau de gris  $a$  dans l'image  $x$  **ÉTANT DONNÉ** qu'il appartienne à la classe mer.

78

## Quelques définitions


$$P(x_s, y_s) = P(y_s) \times P(x_s | y_s)$$



$$y_s \in \{mer, terre\}$$

79

## Quelques définitions




$P(x_s, terre)$  Distribution des niveaux de gris des pixels « terre »

$P(x_s, mer)$  Distribution des niveaux de gris des pixels « mer »

80


## Quelques définitions



$$P(x_s) = P(x_s, mer) + P(x_s, terre)$$

81

## Quelques définitions




$$P(x_s) = P(x_s, mer) + P(x_s, terre)$$

Exemple

$P(x_s = 15, mer) = 0.08$  si je tire au hasard un pixel dans l'image x, j'ai 8 pourcents de chance qu'il soit d'intensité 15 **ET** qu'il appartienne à la classe **mer**

82

## Quelques définitions



Exemple

$P(x_s = 15, terre) = 0.01$  si je tire au hasard un pixel dans l'image x, j'ai 1 pourcent de chance qu'il soit d'intensité 15 **ET** qu'il appartienne à la classe **terre**

83

---

---

---

---


---

---

---

---

## Quelques définitions



Exemple

$$P(x_s = 15) = P(x_s = 15, mer) + P(x_s = 15, terre)$$

$$0.09 = 0.08 + 0.01$$

84

---

---

---

---


---

---

---

---

## Quelques définitions



Exemple

$$P(x_s = 15) = P(x_s = 15, mer) + P(x_s = 15, terre)$$

$$0.09 = 0.08 + 0.01$$

85

---

---

---

---

---

---

---

---

## Quelques définitions

Ceci est un exemple de marginalisation de la variable  $y$

$$P(x_s = 15) = P(x_s = 15, mer) + P(x_s = 15, terre)$$

$$0.09 = 0.08 + 0.01$$

$$P(x_s) = \sum_{y_s} P(x_s, y_s)$$

86

---

---

---

---

---

---

---

---

## Quelques définitions

Ceci est un exemple de marginalisation de la variable  $x$

$$P(y_s = mer) = \sum_{x_s} P(x_s, y_s = mer)$$

$$= 0.4$$

87

---

---

---

---

---

---

---


---

## Bayes

Lorsqu'on segmente une image, on cherche à déterminer pour chaque pixel, quelle classe est la plus probable. En d'autres mots, trouver l'étiquette de classe qui maximise

$$P(y_s | x_s)$$

Étant donné  $x_s$  on veut savoir quelle classe est la plus probable



$$P(y_s = terre | x_s) \text{ ou } P(y_s = mer | x_s)?$$

$x$

88

---

---

---

---

---

---

---


---



## Bayes

Suivant la règle de Bayes

$$P(y_s | x_s) = \frac{P(x_s | y_s)P(y_s)}{P(x_s)} = \frac{P(x_s, y_s)}{P(x_s)}$$



89

---

---

---

---

---

---

---