

Réseaux de neurones

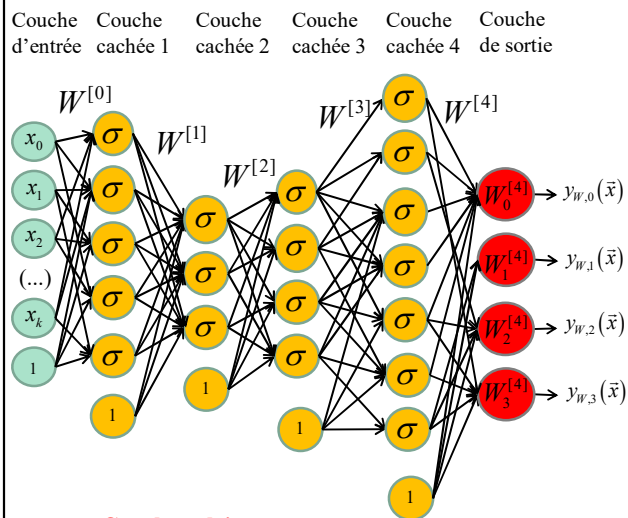
IFT 780

Réseaux à convolution

Par
Pierre-Marc Jodoin

1

kD, 4 Classes, Réseau à 4 couches cachées




Hinge loss


**Couches pleinement
connectées
(fully-connected layers)**

$$y_w(\vec{x}) = W^{[4]} \sigma \left(W^{[3]} \sigma \left(W^{[2]} \sigma \left(W^{[1]} \sigma \left(W^{[0]} \vec{x} \right) \right) \right) \right)$$

2

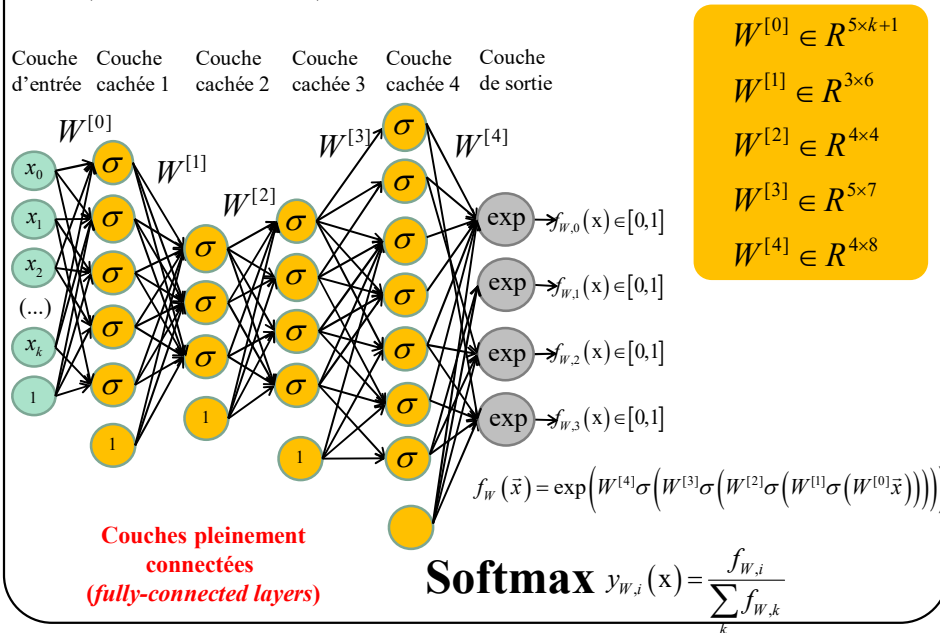


3



4

kD, 4 Classes, Réseau à 4 couches cachées



5

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût

→ Taux d'apprentissage ou "learning rate".

Descente de gradient stochastique

Initialiser \mathbf{w}
 $k=0$
 FAIRE $k=k+1$
 FOR $n = 1$ to N
 $\mathbf{w} = \mathbf{w} - \eta^{[k]} \nabla E(\vec{x}_n)$
 JUSQU'À ce que toutes les données
 soient bien classées ou $k = \text{MAX_ITER}$

Optimisation par Batch

Initialiser \mathbf{w}
 $k=0$
 FAIRE $k=k+1$
 $\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_i \nabla E(\vec{x}_i)$
 JUSQU'À ce que toutes les données
 soient bien classées ou $k = \text{MAX_ITER}$

Parfois $\eta^{[k]} = \text{cst} / k$

6

Les bonnes pratiques

7

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût

→ Taux d'apprentissage ou “learning rate”.

Essentiel
au TP4

Optimisation par **mini-batch**

Initialiser \mathbf{w}
 $k=0$
FAIRE $k=k+1$

FAIRE $n=0$ à N par sauts de MBS /*Mini-batch size*/

$$\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\tilde{\mathbf{x}}_i)$$

JUSQU'À ce que toutes les données soient bien classées ou
 $k=MAX_ITER$

} Itération

8

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût

→ Taux d'apprentissage ou "learning rate".

Optimisation par *mini-batch*

Initialiser \mathbf{w}

$k=0$

FAIRE $k=k+1$

FAIRE $n=0$ à N par sauts de *MBS* /*Mini-batch size*/

$$\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\tilde{\mathbf{x}}_i)$$


JUSQU'À ce que toutes les données sont bien classées ou
 $k=MAX_ITER$

} Epoch


9

Mini-batch = **vectorisation** de la
propagation avant et de la rétro-
propagation

10



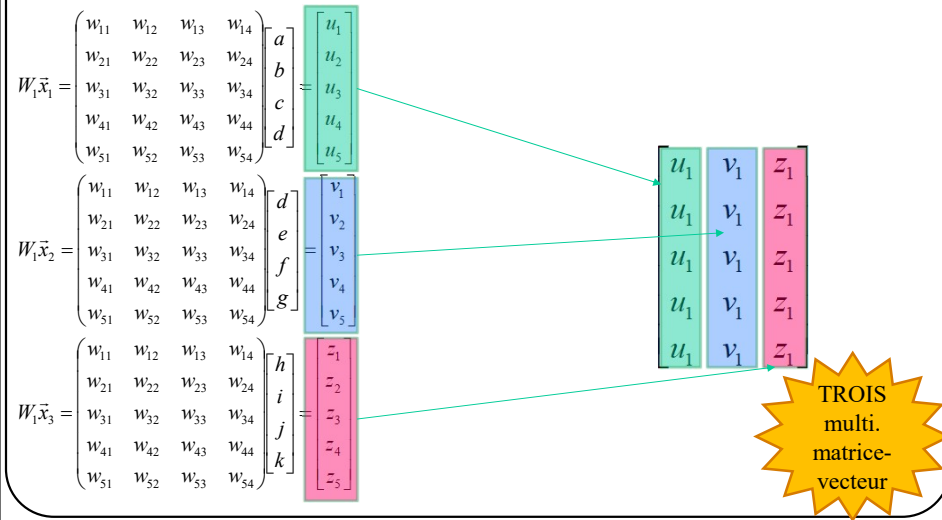
11



12

Solution

Il est plus efficace d'effectuer **UNE** multiplication matricielle que **PLUSIEURS** multiplications matrice-vecteur (exemple de la 2^e étape, batch de 3)



13

Solution

Il est plus efficace d'effectuer **UNE** multiplication matricielle que **PLUSIEURS** matrice-vecteur (exemple de la 2^e étape, batch de 3)

$$W_1 X = \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \\ w_{41} & w_{42} & w_{43} & w_{44} \\ w_{51} & w_{52} & w_{53} & w_{54} \end{pmatrix} \begin{bmatrix} a & d & h \\ b & e & i \\ c & f & j \\ d & g & k \end{bmatrix} = \begin{bmatrix} u_1 & v_1 & z_1 \\ u_2 & v_2 & z_2 \\ u_3 & v_3 & z_3 \\ u_4 & v_4 & z_4 \\ u_5 & v_5 & z_5 \end{bmatrix}$$



14

$$\vec{W}_3^T(h(W_2h(W_1\vec{x})))$$

Solution

Il est plus efficace d'effectuer UNE multiplication matricielle que **PLUSIEURS** produits scalaires (exemple de la 6^e étape, batch de 3)

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = (w_1a + w_2b + w_3c)$$

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} d \\ e \\ f \end{pmatrix} = (w_1d + w_2e + w_3f)$$

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} g \\ h \\ i \end{pmatrix} = (w_1g + w_2h + w_3i)$$

$$\begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix} = Y$$

TROIS
produits
scalaires

15

Solution

Il est plus efficace d'effectuer **UNE** multiplication matricielle que PLUSIEURS produits scalaires (exemple de la 6^e étape, batch de 3)

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix} = Y$$

UNE
multiplication
matricielle

16

Conclusion

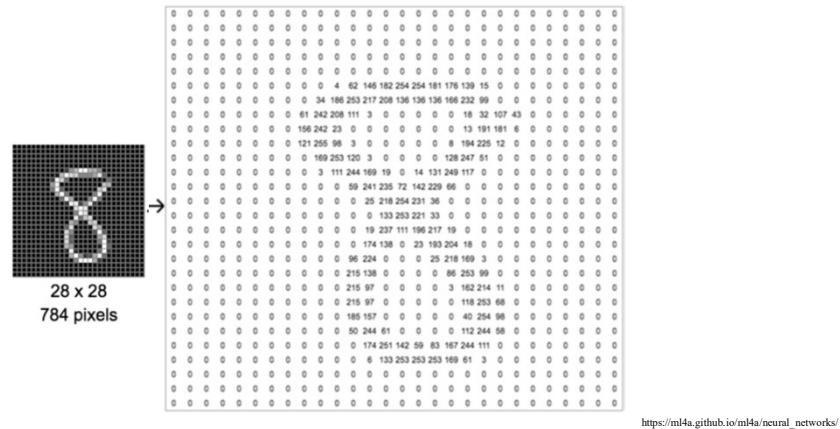
100% du temps, on combine ensemble les données dans des **mini-batch** de 2 à 32 données.

17

Les réseaux à convolution


18

Comment classifier des images?




19

Comment classifier des images?



20

Beaucoup de paramètres (7850 dans la couche 1)



21

Beaucoup trop de paramètres (655,370 dans la couche 1)




Image médicale (IRM de cerveau)

22

Beaucoup **TROP** de paramètres
(160M dans la couche 1)




Image médicale 3D (IRM de cerveau)

23

Comment réduire le nombre de connections?




24

24

Comment réduire le nombre de connections?


Les **couches pleinement connectées** (*fully-connected layers*) sont problématiques lorsque le **nombre de neurones est élevé**.



150-D en entrée avec **150 neurones** dans la 1ère couche => **22,200 paramètres** dans la couche d'entrée!!

25


Solution : connexions partielles



150-D en entrée avec **148 neurones** dans la 1ère couche => **444 paramètres** dans la première couche!!

26

Paramètres partagés : les neurones de la couche 1 partagent les mêmes poids



150-D en entrée avec 148 neurones dans la 1ère couche \Rightarrow 3 paramètres dans la couche d'entrée!!

Faible nombre de paramètres = on peut augmenter la profondeur!

27

**Convolution
et
couche convolutionnelle
1D**

28

Exemple 1D de la convolution

$$(f * W)(v) = \sum_{u=-\infty}^{\infty} f(u)W(v-u)$$

(signal d'entrée)

$f(u)$

10 20 -30 40 -50

(filtre)

$W(u)$

.1 .2 .3

(filtre)

$W(-u)$

.3 .2 .1

$(f * W)(1)$

10 20 -30 40 -50

× × ×
.3 .2 .1

3+4+-3

4

$(f * W)(2)$

10 20 -30 40 -50

× × ×
.3 .2 .1

6-6+4

4 4

$(f * W)(3)$

10 20 -30 40 -50

× × ×
.3 .2 .1

-9+8+-5

4 4 -6

29

29

En gros

convolution = **produit scalaire** + **translation**

30

$(f * W)(v) = \sum_{u=-\infty}^{\infty} f(u)W(v+u)$

La convolution des réseaux de neurones = corrélation

(signal d'entrée)
 $f(u)$

10	20	-30	40	-50
----	----	-----	----	-----

(filtre)
 $W(u)$

.1	.2	.3
----	----	----

(filtre)
 $W(+u)$

.1	.2	.3
----	----	----

$(f*W)(1)$

10	20	-30	40	-50
x	x	x		
.1	.2	.3		

1+4-9

↓

-4		
----	--	--

$(f*W)(2)$

10	20	-30	40	-50
	x	x	x	
	.1	.2	.3	

2-6+12

↓

-4	8	
----	---	--

$(f*W)(3)$

10	20	-30	40	-50
		x	x	x
		.1	.2	.3

-3+8-15

↓

-4	8	-10
----	---	-----

31


31

L'opération de la page précédente est équivalente à

32

32

L'opération de la page précédente est équivalente à




Fonction
d'activation
(ex. ReLU)

33

33


Représentation graphique courante (simple)



34

34


Représentation graphique courante (encore plus simple)



35

35


Représentation graphique courante (vraiment ultra simple)



36

36


Représentation graphique courante (eehhh...)



37

37


Apprentissage = apprendre les poids w_i des filtres convolutifs



38

38


Stride et calcul de la taille de la carte d'activation



39

39

Stride et calcul de la taille de la carte d'activation




Stride = 1

40

40


Stride et calcul de la taille de la carte d'activation



41

41


Stride et calcul de la taille de la carte d'activation



42


42

Stride et calcul de la taille de la carte d'activation



43

Stride et calcul de la taille de la carte d'activation




44

43

44

Stride et calcul de la taille de la carte d'activation




Taille de la carte d'activation = **7**

45

45


Stride et calcul de la taille de la carte d'activation



46

46

Stride et calcul de la taille de la carte d'activation




Stride = 1

47

47


Stride et calcul de la taille de la carte d'activation



48

48


Stride et calcul de la taille de la carte d'activation



49

49

Stride et calcul de la taille de la carte d'activation




Taille de la carte d'activation = **5**

50

50


Stride et calcul de la taille de la carte d'activation



51

51

Stride et calcul de la taille de la carte d'activation




Stride = 1

52

52

Stride et calcul de la taille de la carte d'activation




Taille de la carte d'activation = **3**

53

53


Stride et calcul de la taille de la carte d'activation



54

54

Stride et calcul de la taille de la carte d'activation




Stride = 2

55

55

Stride et calcul de la taille de la carte d'activation




Taille de la carte d'activation = **3**

56

56


Stride et calcul de la taille de la carte d'activation



57

57

Stride et calcul de la taille de la carte d'activation




Stride = 3

58

58

Stride et calcul de la taille de la carte d'activation



ERREUR! Combinaison D-F-S invalide

59

59

Stride et calcul de la taille de la carte d'activation

Taille de la carte d'activation = **$(D-F)/S+1$**



60

60

Parfois on souhaite que le **nombre de neurones** dans la carte d'activation soit **le même** que la couche précédente

$$\begin{array}{c} ? \begin{array}{|c|c|c|c|c|} \hline 10 & 20 & 30 & 40 & 50 \\ \hline \end{array} \\ \times \quad \times \quad \times \\ \begin{array}{|c|c|c|} \hline .1 & .2 & .3 \\ \hline \end{array} \end{array}$$

Comment gérer les bords?

Option 1 : Ajout de zéros (« *zero padding* » remplacer ? par 0)

$$\begin{array}{c} f(u) \\ \begin{array}{|c|c|c|c|c|c|} \hline 0 & 10 & 20 & 30 & 40 & 50 & 0 \\ \hline \end{array} \end{array} \quad \begin{array}{c} (f*W)(u) \\ \begin{array}{|c|c|c|c|} \hline 8 & -4 & 8 & -10 & -6 \\ \hline \end{array} \end{array}$$

Option 2 : Réflexion (« *reflexion padding* »)

$$\begin{array}{c} f(u) \\ \begin{array}{|c|c|c|c|c|c|} \hline 20 & 10 & 20 & 30 & 40 & 50 & 40 \\ \hline \end{array} \end{array} \quad \begin{array}{c} (f*W)(u) \\ \begin{array}{|c|c|c|c|} \hline 10 & -4 & 8 & -10 & 2 \\ \hline \end{array} \end{array}$$

Option 3 : Étirement (« *stretching padding* »)

$$\begin{array}{c} f(u) \\ \begin{array}{|c|c|c|c|c|c|} \hline 10 & 10 & 20 & 30 & 40 & 50 & 50 \\ \hline \end{array} \end{array} \quad \begin{array}{c} (f*W)(u) \\ \begin{array}{|c|c|c|c|} \hline 9 & -4 & 8 & -10 & -21 \\ \hline \end{array} \end{array}$$

61

61

Parfois on souhaite que le **nombre de neurones** dans la carte d'activation soit **le même** que la couche précédente

$$\begin{array}{c} ? \begin{array}{|c|c|c|c|c|} \hline 10 & 20 & 30 & 40 & 50 \\ \hline \end{array} \\ \times \quad \times \quad \times \\ \begin{array}{|c|c|c|} \hline .1 & .2 & .3 \\ \hline \end{array} \end{array}$$

Comment gérer les bords?

Option 1 : Ajout de zéros (« *zero padding* » remplacer ? par 0)

$$\begin{array}{c} f(u) \\ \begin{array}{|c|c|c|c|c|c|} \hline 0 & 10 & 20 & 30 & 40 & 50 & 0 \\ \hline \end{array} \end{array} \quad \begin{array}{c} (f*W)(u) \\ \begin{array}{|c|c|c|c|} \hline 8 & -4 & 8 & -10 & -6 \\ \hline \end{array} \end{array}$$


Option 2 : Réflexion (« *reflexion padding* »)

De loin l'option la plus utilisée


$$\begin{array}{c} f(u) \\ \begin{array}{|c|c|c|c|c|c|} \hline 10 & 10 & 20 & 30 & 40 & 50 & 50 \\ \hline \end{array} \end{array} \quad \begin{array}{c} (f*W)(u) \\ \begin{array}{|c|c|c|c|} \hline 9 & -4 & 8 & -10 & -21 \\ \hline \end{array} \end{array}$$

62

62




63



64

Il est possible d'apprendre **plusieurs filtres par couche**


(ex. 5 filtres donnant 5 cartes d'activation)



65

Taille de filtre = 5

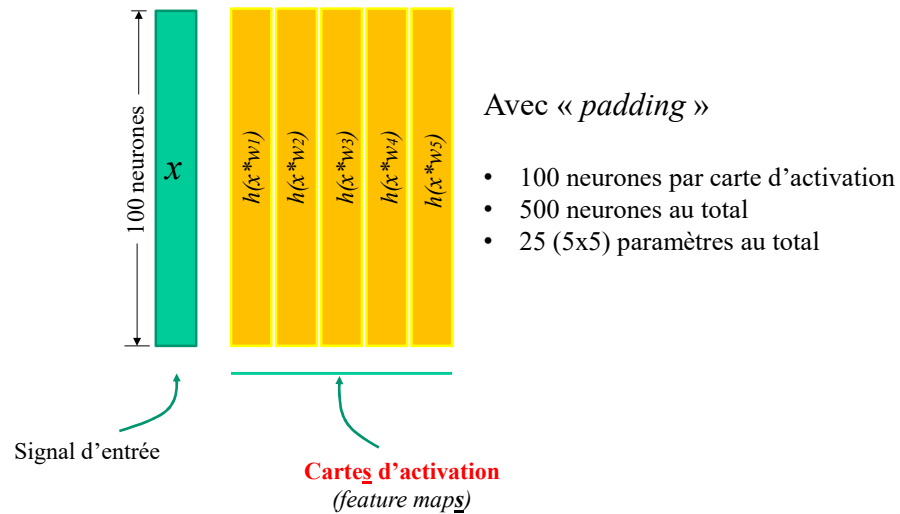
(ex. 5 filtres donnant 5 cartes d'activation)



66

Taille de filtre = 5

(ex. 5 filtres donnant 5 cartes d'activation)



67


Convolution et couche convolutionnelle **2D**

68

Filtage 2D

(sans flip de filtre)

$$(x * W)(i, j) = \sum_u \sum_v f(i + u, j + v) W(u, v)$$




$$\begin{aligned} (x * W)(i, j) = & w_1 x(i-1, j-1) + w_2 x(i, j-1) + w_3 x(i+1, j-1) \\ & + w_4 x(i-1, j) + w_5 x(i, j) + w_6 x(i+1, j) \\ & + w_7 x(i-1, j+1) + w_8 x(i, j+1) + w_9 x(i+1, j+1) \end{aligned}$$

69

Convolution 2D


Filtre = 3x3
Stride = 1



70

Convolution 2D


Filtre = 3x3
Stride = 1



71

Convolution 2D

Filtre = 3x3
Stride = 1




72

Convolution 2D

Filtre = 3x3

Stride = 1




73

Convolution 2D

Filtre = 3x3

Stride = 1




Taille de la carte d'activation (pour stride 1) = **5x5**

74

Convolution 2D


Filtre = 3x3
Stride = 2



75

Convolution 2D


Filtre = 3x3
Stride = 2



76

Convolution 2D

Filtre = 3x3
Stride = 2




Taille de la carte d'activation (pour stride 2) = **3x3**

77

Convolution 2D

Filtre = 3x3
Stride = 3




78

Convolution 2D

Filtre = 3x3

Stride = 3




79

Convolution 2D

Filtre = 3x3


Stride = 2



Combinaison D-F-S invalide!

80


Convolution 2D



Taille de la carte d'activation :
 $(D1-F1)/S+1 \times (D2-F2)/S+1$


81

Différents filtres = différentes cartes d'activation




82

4 filtres = Couche convolutive avec **4 cartes d'activation**




83

K filtres = Couche convolutive avec **K cartes d'activation**



84


Ex.: taille de filtre : 5x5, 5 cartes d'activation, convolution « same »



- 10,000 neurones par carte d'activation
- 50,000 neurones au total
- $5 \times 5 \times 5 = 125$ paramètres au total


85

Représentation schématique
(1 filtre et 1 carte d'activation, convolution « same »)



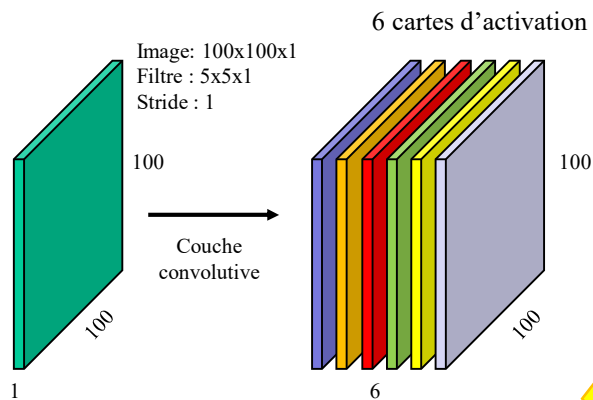
86

Représentation schématique
(2 filtres et 2 cartes d'activation, convolution « same »)



87


Représentation schématique
(6 filtres et 6 cartes d'activation, convolution « same »)



Combien de neurones
et de paramètres
au total?


88

Représentation schématique
(6 filtres et 6 cartes d'activation, convolution « *same* »)



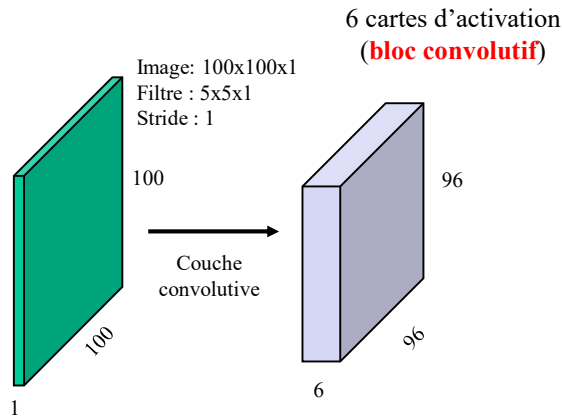
89

Représentation schématique simplifiée
(6 filtres et 6 cartes d'activation, convolution « *same* »)



90

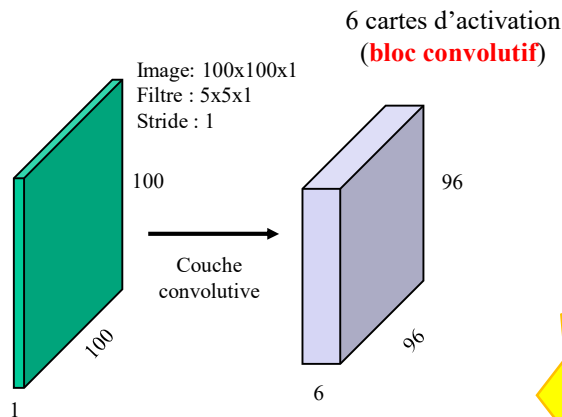
Représentation schématique simplifiée
(6 filtres et 6 cartes d'activation, convolution « valid »)



Combien de neurones
et de paramètres
au total?

91

Représentation schématique simplifiée
(6 filtres et 6 cartes d'activation, convolution « valid »)




$96 \times 96 \times 6 = 55,296$ neurones
 $6 \times 5 \times 5 \times 1 = 150$ paramètres

92

Représentation schématique images couleur
(ex.: images RGB de CIFAR10
convolution « same »)




Exemples cifar10



Combien de neurones
et de paramètres
au total?

93

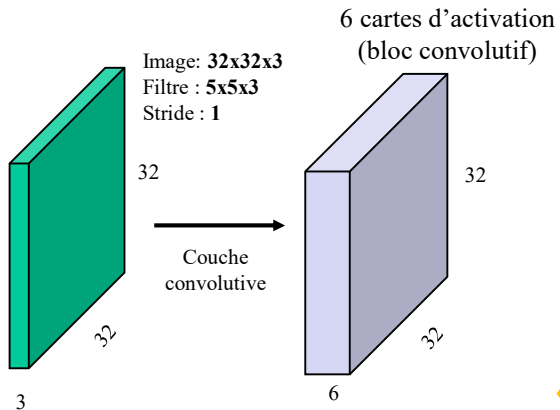
Représentation schématique images couleur
(ex.: images RGB de CIFAR10
convolution « same »)



$32 \times 32 \times 6 = 6,144$ neurones
 $6 \times 5 \times 5 \times 3 = 450$ paramètres

94


Représentation schématique images couleur
(ex.: images RGB de CIFAR10
convolution « *same* »)



Qu'arrivera-t-il si on
utilise une stride de 3?

95


Représentation schématique images couleur
(ex.: images RGB de CIFAR10
convolution « *same* »)



$$\begin{aligned} & (D-F)/S+1 \\ & = \\ & (32-5)/3+1=10 \end{aligned}$$

96

Représentation schématique images couleur
(ex.: images RGB de CIFAR10
convolution « valid »)




6 cartes d'activation
(bloc convolutif)

$10 \times 10 \times 6 = 600$ neurones
 $6 \times 5 \times 5 \times 3 = 450$ paramètres

97

Exemple

Volume en entrée : $32 \times 32 \times 3$
10 filtres 5×5 avec **stride** = 1
et convolution « *same* »




Combien y a-t-il de paramètres dans cette couche?

98

Exemple

Volume en entrée : $32 \times 32 \times 3$
10 filtres 5×5 avec **stride = 1**
et convolution « **same** »




Combien y a-t-il de paramètres dans cette couche?

Chaque filtre a $5 \times 5 \times 3 = 75$ paramètres
Comme il y a **10 filtres** : **750** paramètres

99

Exemple

Volume en entrée : $32 \times 32 \times 3$
10 filtres 5×5 avec **stride = 1**
et convolution « **same** ».




Combien y a-t-il de paramètres dans cette couche **si on ajoute un biais**?

Chaque filtre a $5 \times 5 \times 3 + 1 = 76$ paramètres (+1 pour le biais)
Comme il y a **10 filtres** : **760** paramètres

100

Exemple

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « **valid** »




Combien de paramètres dans cette couche?

101

Exemple

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « **valid** »




Combien de paramètres dans cette couche?

Même chose, cela ne change pas la conformité des filtres

102

Exemple

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « **valid** »




Combien de **neurones** dans les cartes d'activations?

103

Exemple

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « **valid** »




Combien de **neurones** dans les cartes d'activations?

$$(32-5+1) \times (32-5+1) \times 10 = 7,840$$

104

Des filtres 1x1? Oui ça marche



105

Exemple simple d'un filtre 1x1



$$\begin{bmatrix} 1 & 1 & 1 \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{bmatrix}$$

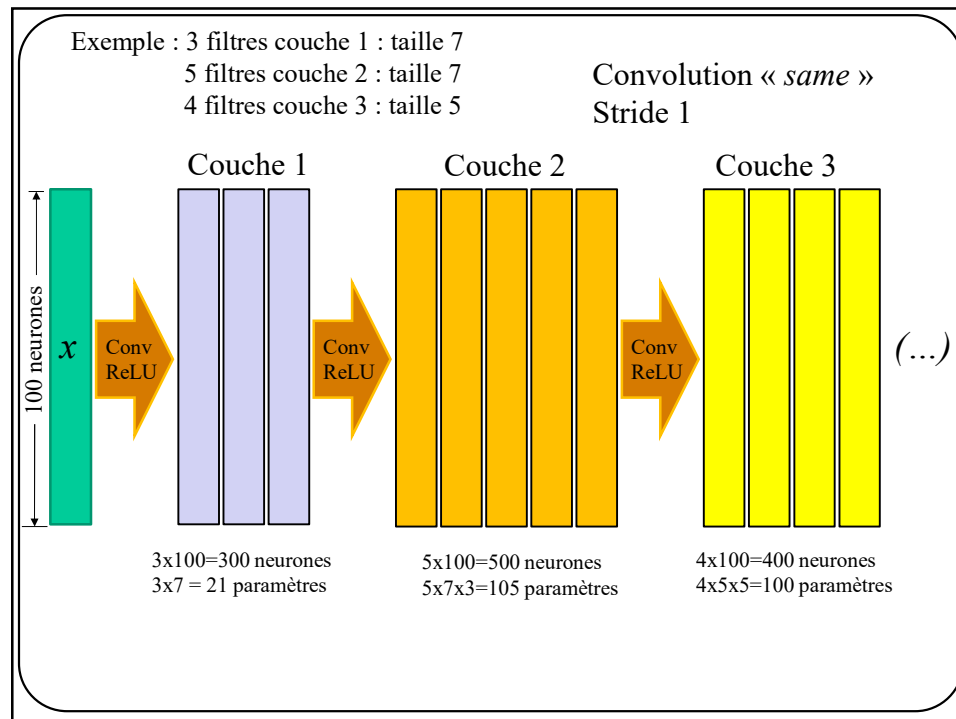


Filtre moyennant les canaux **rouge**, **vert**, **bleu** d'une image couleur.
Résultat, une image en **niveau de gris**.

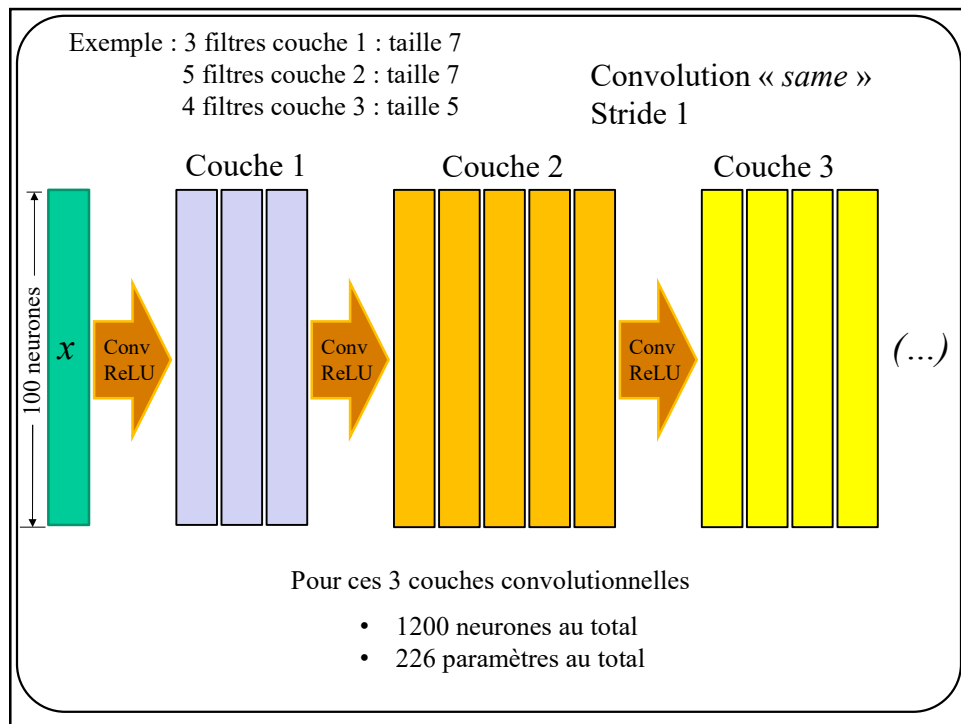
106

Tout comme un Perceptron
multi-couches, un réseau à
convolution contient **plusieurs
couches consécutives**


107




108




109




110




111



112




113



114

Image RGB : couche 1 : 3 filtres de taille 7x7
 couche 2 : 5 filtres de taille 9x9
 couche 3 : 4 filtres de taille 11x11
 convolution « valid »

Image: 32x32x3
 Stride : 1




3,904 neurones au total
 4,076 paramètres au total


115

Tout comme un perceptron multi-couches, un réseau à convolution se termine par une **couche de sortie** avec **1 neurone par variable prédite**


116




117




118




119




120




121





122



123




124



Réseaux à convolution VS Réseaux **pleinement** convolutifs

127



128

Exemple 1d

(convolution « valid »)

$$\begin{array}{c}
 \xleftarrow{9} \quad \quad \quad \xleftarrow{3} \quad \quad \quad \xleftarrow{7} \\
 \boxed{40} \boxed{50} \boxed{70} \boxed{80} \boxed{90} \boxed{10} \boxed{20} \boxed{30} \boxed{40} * \boxed{.2} \boxed{-.3} \boxed{.4} = \boxed{21} \boxed{21} \boxed{26} \boxed{-7} \boxed{23} \boxed{8} \boxed{11}
 \end{array}$$

129

Exemple 1d


(convolution « valid »)

$$\begin{array}{c}
 \xleftarrow{9} \quad \quad \quad \xleftarrow{5} \quad \quad \quad \xleftarrow{5} \\
 \boxed{40} \boxed{50} \boxed{70} \boxed{80} \boxed{90} \boxed{10} \boxed{20} \boxed{30} \boxed{40} * \boxed{.2} \boxed{-.3} \boxed{.4} \boxed{-.5} \boxed{.6} = \boxed{35} \boxed{-18} \boxed{33} \boxed{1} \boxed{32}
 \end{array}$$

130


Exemple 1d

(convolution « valid »)




131

Taille filtre = nb de neurones couche précédente




132

Signal d'entrée de **taille 9** convolué avec un filtre « same » de **taille 9** correspond à une **couche pleinement connectée**



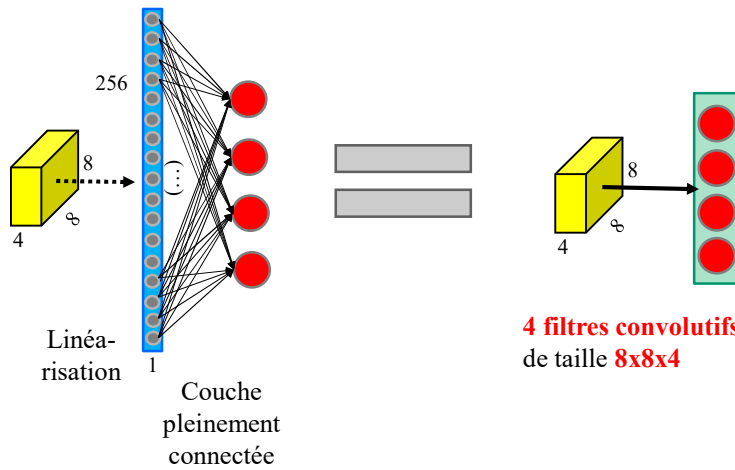
133

Même chose pour une **convolution 2D**




134


Même chose pour une **convolution 2D**



135



136



137

Configurations équivalentes

couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
couche 4 pleinement connectée 256x4
Softmax

couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
couche 4 : 4 filtres de taille 8x8
Softmax

En fait, presque équivalent ...

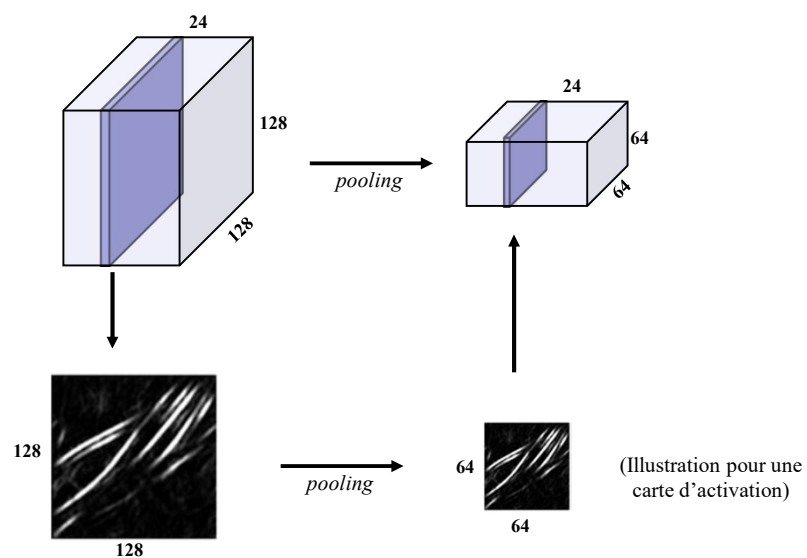
Question : qu'arrive-t-il si on remplace l'image 32x32x3 par une image 64x64x3?

138

Pooling

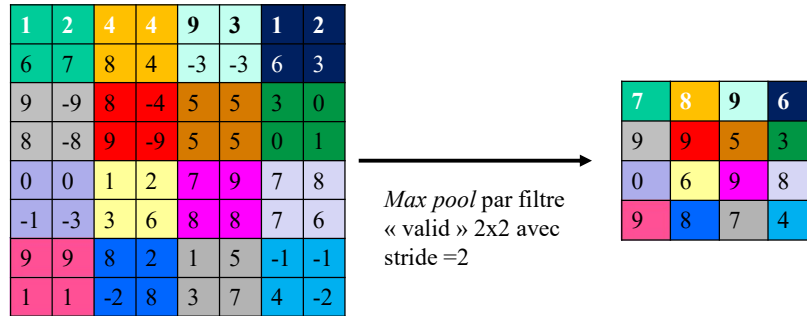
139

Réduction de la taille des cartes d'activation



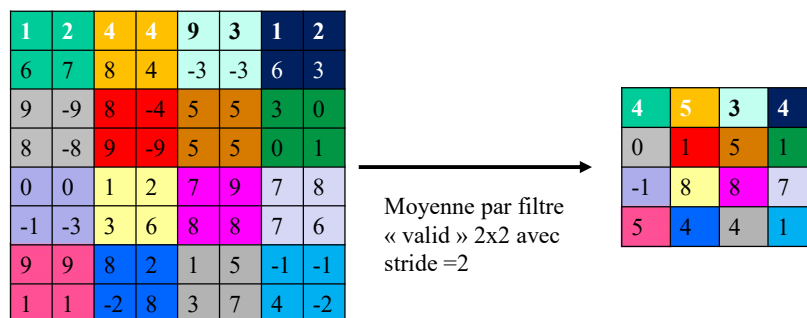
140

Max pooling



141

Mean pooling



142

Max pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2



Max pooling 2x2
avec **stride = 1**



143

Max pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2




Max pooling 3x3
avec **stride = 2**



144

Illustration d'un CNN complet



145

Multiplication matricielle parcimonieuse

<https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215>

147

Il est **plus rapide** de multiplier des matrices que de les convoluer.

Ex.: convolution « valid », un canal d'entrée et une carte d'activation, filtre 3x3

Entrée		Filtre			
X0	X1	X2	X3		
X4	X5	X6	X7	*	
X8	X9	X10	X11		
X12	X13	X14	X15		

W0	W1	W2			
W3	W4	W5	=		
W6	W7	W8			

Y1	Y2
Y3	Y4

148

Il est **plus rapide** de multiplier des matrices que de les convoluer.

Ex.: convolution « valid », un canal d'entrée et une carte d'activation, filtre 3x3

Entrée		Filtre			
X0	X1	X2	X3		
X4	X5	X6	X7	*	
X8	X9	X10	X11		
X12	X13	X14	X15		

W0	W1	W2			
W3	W4	W5	=		
W6	W7	W8			

Y0	Y1
Y2	Y3

On peut **remplacer** une **convolution** par une **multiplication matrice-matrice** ou **matrice-vecteur**

en **linéarisant** le filtre et en « **matriquant** » l'entrée

149

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

W0	W1	W2	X3
W3	W4	W5	X7
W6	W7	W8	X11
X12	X13	X14	X15

Y0	Y1
Y2	Y3

$$\mathbf{Y0} = W0.X0 + W1.X1 + W2.X2 + W3.X4 + W4.X5 + W5.X6 + W6.X8 + W7.X9 + W8.X10$$

150

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

X0	W0	W1	W2
X4	W3	W4	W5
X8	W6	W7	W8
X12	X13	X14	X15

Y0	Y1
Y2	Y3

$$\mathbf{Y1} = W0.X1 + W1.X2 + W2.X3 + W3.X5 + W4.X6 + W5.X7 + W6.X9 + W7.X10 + W8.X11$$

151

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

X0	X1	X2	X3
W0	W1	W2	X7
W3	W4	W5	X11
W6	W7	W8	X15

Y0	Y1
Y2	Y3

$$\mathbf{Y2} = W0.X4 + W1.X5 + W2.X6 + W3.X8 + W4.X9 + W5.X10 + W6.X12 + W7.X13 + W8.X14$$

152

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

X0	X1	X2	X3
X4	W0	W1	W2
X8	W3	W4	W5
X12	W6	W7	W8

Y0	Y1
Y2	Y3

$$\mathbf{Y3} = W0.X5 + W1.X6 + W2.X7 + W3.X9 + W4.X10 + W5.X11 + W6.X13 + W7.X14 + W8.X15$$

153

Autrement dit...

W0	W1	W2	X3
W3	W4	W5	X7
W6	W7	W8	X11
X12	X13	X14	X15

X0
X1
X2
X4
X5
X6
X8
X9
X10

Y0

154

Autrement dit...

X0	W0	W1	W2
X4	W3	W4	W5
X8	W6	W7	W8
X12	X13	X14	X15

X0	X1
X1	X2
X2	X3
X4	X5
X5	X6
X6	X7
X8	X9
X9	X10
X10	X11

Y0	Y1
----	-----------

155

Autrement dit...

X0	X1	X2	X3
W0	W1	W2	X7
W3	W4	W5	X11
W6	W7	W8	X15

X0	X1	X4
X1	X2	X5
X2	X3	X6
X4	X5	X8
X5	X6	X9
X6	X7	X10
X8	X9	X11
X9	X10	X12
X10	X11	X13

Y0	Y1
Y2	

156

Autrement dit...

X0	X1	X2	X3
X4	W0	W1	W2
X8	W3	W4	W5
X12	W6	W7	W8

X0	X1	X4	X5
X1	X2	X5	X6
X2	X3	X6	X7
X4	X5	X8	X9
X5	X6	X9	X10
X6	X7	X10	X11
X8	X9	X11	X13
X9	X10	X12	X14
X10	X11	X13	X15

Y0	Y1
Y2	Y3

157

Convolution « valid » en **linéarisant le filtre** et en
« **matriçant** » l'entrée

$$\begin{array}{|c|c|c|c|c|c|c|c|c|} \hline W_0 & W_1 & W_2 & W_3 & W_4 & W_5 & W_6 & W_7 & W_8 \\ \hline \end{array} \times \begin{array}{|c|c|c|c|} \hline X_0 & X_1 & X_4 & X_5 \\ \hline X_1 & X_2 & X_5 & X_6 \\ \hline X_2 & X_3 & X_6 & X_7 \\ \hline X_4 & X_5 & X_8 & X_9 \\ \hline X_5 & X_6 & X_9 & X_{10} \\ \hline X_6 & X_7 & X_{10} & X_{11} \\ \hline X_8 & X_9 & X_{11} & X_{13} \\ \hline X_9 & X_{10} & X_{12} & X_{14} \\ \hline X_{10} & X_{11} & X_{13} & X_{15} \\ \hline \end{array} = \begin{array}{|c|c|c|c|} \hline Y_0 & Y_1 & Y_2 & Y_3 \\ \hline \end{array}$$

158

Autre exemple

conv « valid », mini-batch de 2 entrées

2 données en entrée

X0	X1	X2	X3
X4	X5	X6	X7
X8	X9	X10	X11
X12	X13	X14	X15
X16	X17	X18	X19
X20	X21	X22	X23
X24	X25	X26	X27
X28	X29	X30	X31

*

Filtre

W0	W1	W2
W3	W4	W5
W6	W7	W8


=

Y0	Y1
Y2	Y3
Y4	Y5
Y6	Y7

159

Autre exemple


conv « valid », mini-batch de 2 entrées



160

Autre exemple

conv « valid », une entrée, deux filtres



161

conv « valid », une entrée, deux filtres

The diagram shows the dot product of two vectors. On the left is a 2x8 matrix of light blue squares containing labels W0 through W17. In the middle is an 8x4 matrix of light purple squares containing labels X0 through X15. To the right of the purple matrix is a multiplication symbol 'x'. Further right is an equals sign '='. To the right of the equals sign is a 2x4 matrix of light yellow squares containing labels Y0 through Y7.

162

conv « valid », une entrée avec deux canaux, un filtre

The diagram illustrates the dot product operation between two matrices, **Entrée** and **Filtre**, resulting in a matrix **Y**.

Entrée (8x4 matrix):

X0	X1	X2	X3
X4	X5	X6	X7
X8	X9	X10	X11
X12	X13	X14	X15
X16	X17	X18	X19
X20	X21	X22	X23
X24	X25	X26	X27
X28	X29	X30	X31

Filtre (8x3 matrix):

W0	W1	W2
W3	W4	W5
W6	W7	W8
W9	W10	W11
W12	W13	W14
W15	W16	W17

Y (8x2 matrix):

Y0	Y1
Y2	Y3

The operation is represented as: **Entrée** * **Filtre** = **Y**.

163

Autre exemple

conv « valid », une entrée avec deux canaux, un filtre

W0	W1	W2	W3	(...)	W5	W6	W7	W8	W9	W10	W11	W12	W13	W14	W15	W16	W17
----	----	----	----	-------	----	----	----	----	----	-----	-----	-----	-----	-----	-----	-----	-----

X

X0	X1	X4	X5
X1	X2	X5	X6
X2	X3	X6	X7
X4	X5	X8	X9
(...)	(...)	(...)	(...)
X22	X23	X26	X27
X24	X25	X27	X29
X25	X26	X28	X30
X26	X27	X29	X31

=


Y0	Y1	Y2	Y3
----	----	----	----

164

Exemples d'architectures connues

165

LeNet-1



Une des plus vieilles architectures faites pour la reconnaissance de caractères.


- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
SOFTMAX

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

166

LeNet-1



Une des plus vieilles architectures faites pour la reconnaissance de caractères.

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes


Input
CONV
POOL
CONV
POOL
FC
SOFTMAX

Combien de neurones?
Combien de paramètres?

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

167

LeNet-5



Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes


Input
|
CONV
|
POOL
|
CONV
|
POOL
|
FC
|
FC
|
FC
|
SOFTMAX

LeCun, Y.; Bottou, L.; Bengio, Y. & Haffner, P. (1998).

Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11): 2278 - 232

168

LeNet-5



Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes

Input
|
CONV
|
POOL
|
CONV
|
POOL
|
FC
|
FC
|
FC
|
SOFTMAX

Combien de neurones?
Combien de paramètres?

169

Classification d'images





Image: <http://cs231n.stanford.edu/slides/2018>

170

170

Classification d'images

AlexNet [Krizhevsky et al, 2012]





Image: <http://cs231n.stanford.edu/slides/2018>

171

171

AlexNet




- Premier CNN à bien performer sur ImageNet (amélioration de 10% par rapport aux autres)
- Utilisation de techniques aujourd’hui fréquemment utilisées: **ReLU**, **data augmentation** and **dropout**
- Utilisation de **GPUs** (2 dans leur cas)
- Point de départ de la **révolution du “deep learning”** en vision par ordinateur

Image: Krizhevsky et al. "Imagenet classification with deep convolutional neural networks," NIPS 2012.

172

AlexNet



Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3


Couche 1 (CONV1): 96 filtres de taille 11x11 avec stride de 4 et conv “valid”

Quelle est la taille des cartes d’activation?

Réponse: $(227-11)/4+1 = 55$

173

AlexNet



Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3


Couche 1 (CONV1): 96 filtres de taille 11x11 avec stride de 4 et conv "valid"

Cartes d'activation : 96 x 55 x 55

Q: Quel est le nombre de paramètres?

174

AlexNet



Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3


Couche 1 (CONV1): 96 filtres de taille 11x11 avec stride de 4 et conv "valid"

Cartes d'activation : 96 x 55 x 55

Paramètres : $11 \times 11 \times 96 \times 3 = 34,848$

175

AlexNet



ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55


Couche 2 MaxPool : 3x3 stride stride 2

Quelle est la taille des cartes d'activation?

Réponse: $(55-3)/2+1 = 27$

176

AlexNet



ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55


Couche 2 MaxPool : 3x3 stride stride 2
 27 x 27 x 96

Combien y a-t-il de paramètres?

Réponse: 0!

177

AlexNet



ENTRÉE : 227x227x3


CONV1: 55 x 55 x 96

MAX POOL1: 27 x 27 x 96

...

178

AlexNet



ENTRÉE 227 x 227 x 3

96 filtres 11x11, stride 4, pad 0, **CONV1** 55 x 55 x 96

filtre 3x3, stride 2, **MAX POOL1** 27 x 27 x 96

normalisation par couche, **NORM1** 27 x 27 x 96

256 filtres 5x5, stride 1, pad 2, **CONV2** 27 x 27 x 256

filtre 3x3, stride 2, **MAX POOL2** 13 x 13 x 256

normalisation par couche, **NORM2** 13 x 13 x 256

384 filtres 3x3, stride 1, pad 1, **CONV3** 13 x 13 x 384

384 filtres 3x3, stride 1, pad 1, **CONV4** 13 x 13 x 384

256 filtres 3x3, stride 1, pad 1, **CONV5** 13 x 13 x 256

filtre 3x3, stride 2, **MAX POOL3** 6 x 6 x 256


FC6 4096

FC7 4096

FC8 1000

179

AlexNet




ENTRÉE 227 x 227 x 3
CONV1 55 x 55 x 96
MAX POOL1 27 x 27 x 96
NORM1 27 x 27 x 96
CONV2 27 x 27 x 256
MAX POOL2 13 x 13 x 256
NORM2 13 x 13 x 256
CONV3 13 x 13 x 384
CONV4 13 x 13 x 384
CONV5 13 x 13 x 256
MAX POOL3 6 x 6 x 256
FC6 4096
FC7 4096
FC8 1000

Notes additionnelles:

Fonction d'activation **ReLU**
Augmentation de données
LayerNorm : peu utilisé aujourd'hui
Dropout 0.5
Batch_size 128
SGD + momentum
Taux d'apprentissage 0.01 avec
 réduction par plateau d'un facteur 10
~68 millions de paramètres

180

AlexNet



ENTRÉE 227 x 227 x 3
CONV1 55 x 55 x 96
MAX POOL1 27 x 27 x 96
NORM1 27 x 27 x 96
CONV2 27 x 27 x 256
MAX POOL2 13 x 13 x 256
NORM2 13 x 13 x 256
CONV3 13 x 13 x 384
CONV4 13 x 13 x 384
CONV5 13 x 13 x 256
MAX POOL3 6 x 6 x 256
FC6 4096
FC7 4096
FC8 1000


Notes additionnelles:

Utilisation de **2 GPUs**
Fait voter un ensemble de 7 CNN:
 18.2% -> 15.4

181

Classification d'images

VGGNet [Simonyan and Zisserman, 2014]




Karen Simonyan, Andrew Zisserman "Very Deep Convolutional Networks for Large-Scale Image Recognition", ICLR 2015

Image: <http://cs231n.stanford.edu/slides/2018>

182

182

VGGNet



Ce qui caractérise VGGNet par rapport à ses prédécesseurs:

- Uniquement des **filtres 3x3, stride 1, pad 1**
- **Plus profond**

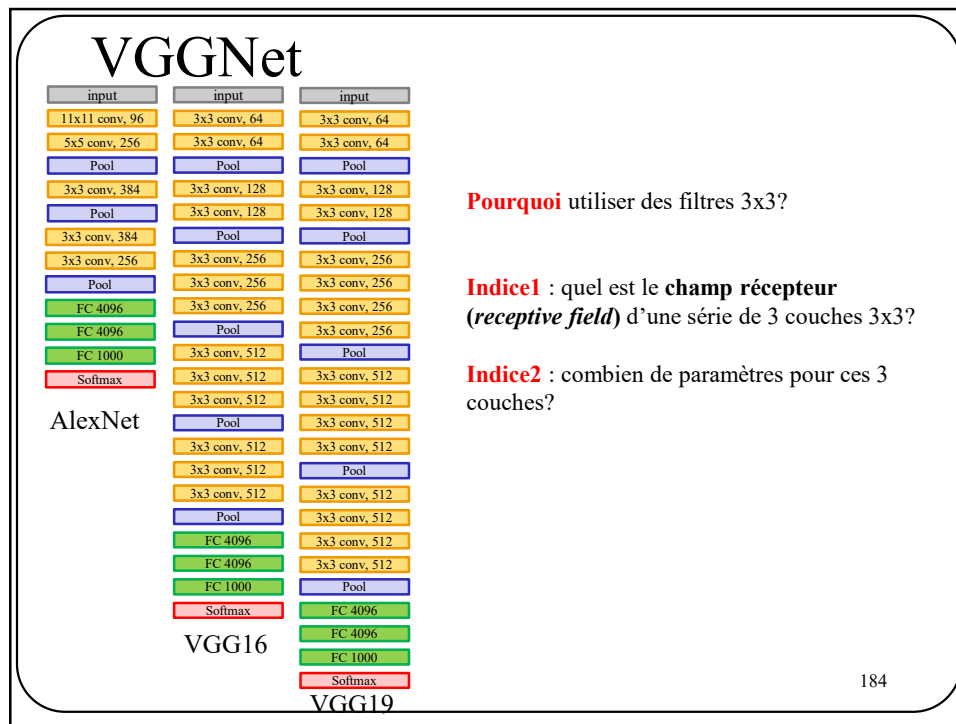
AlexNet : 8 couches

VGGNet : 16 ou 19 couches

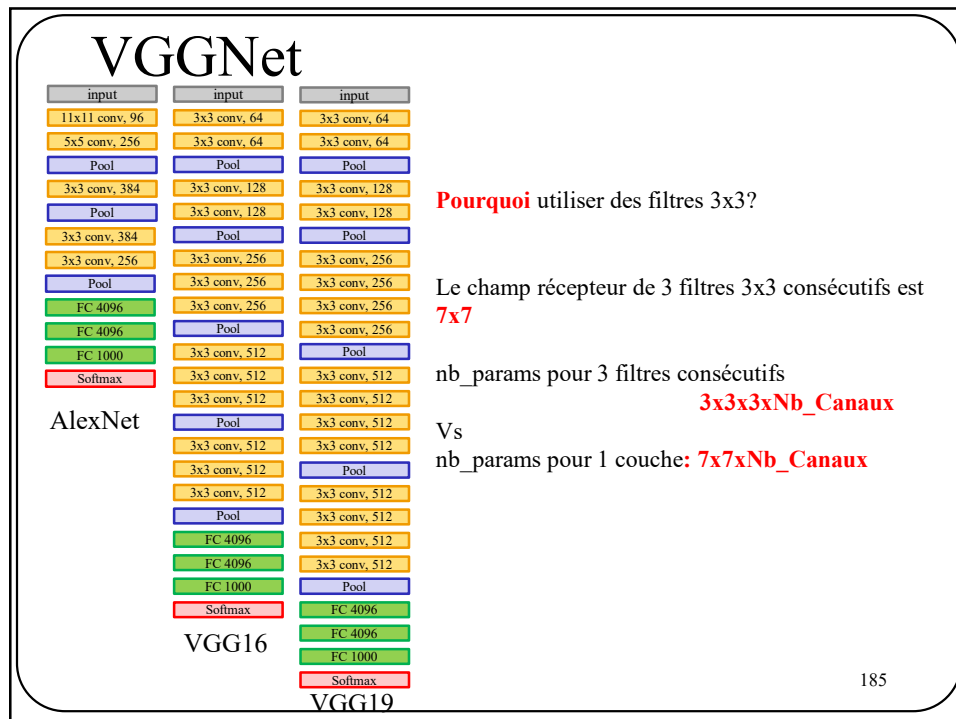
7.3% d'erreur contre 11.7% pour ZFNet

183

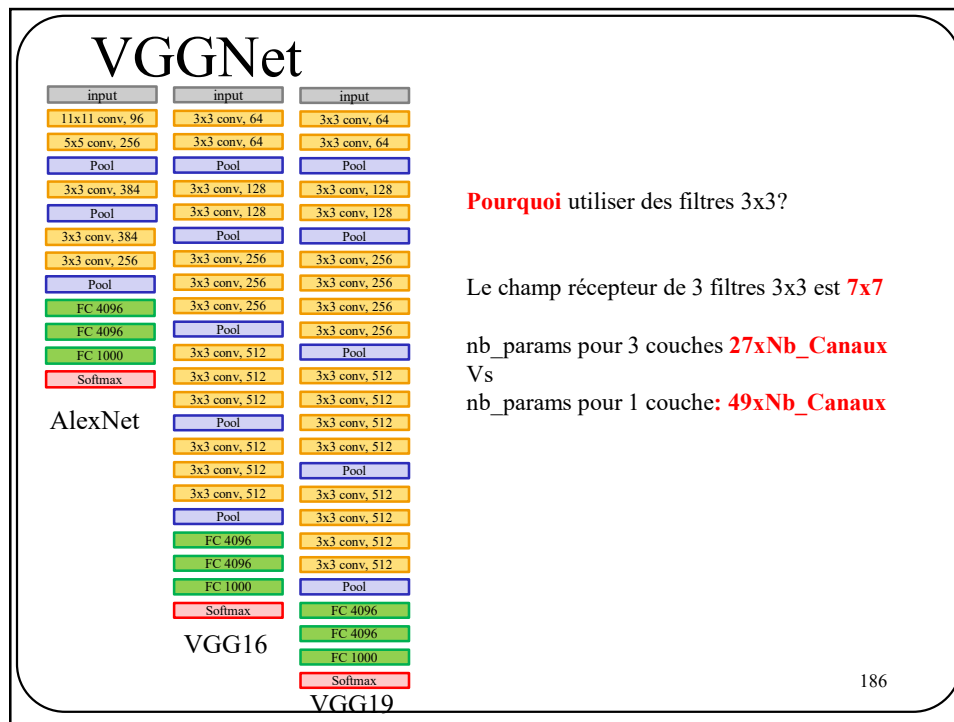
183




184




185



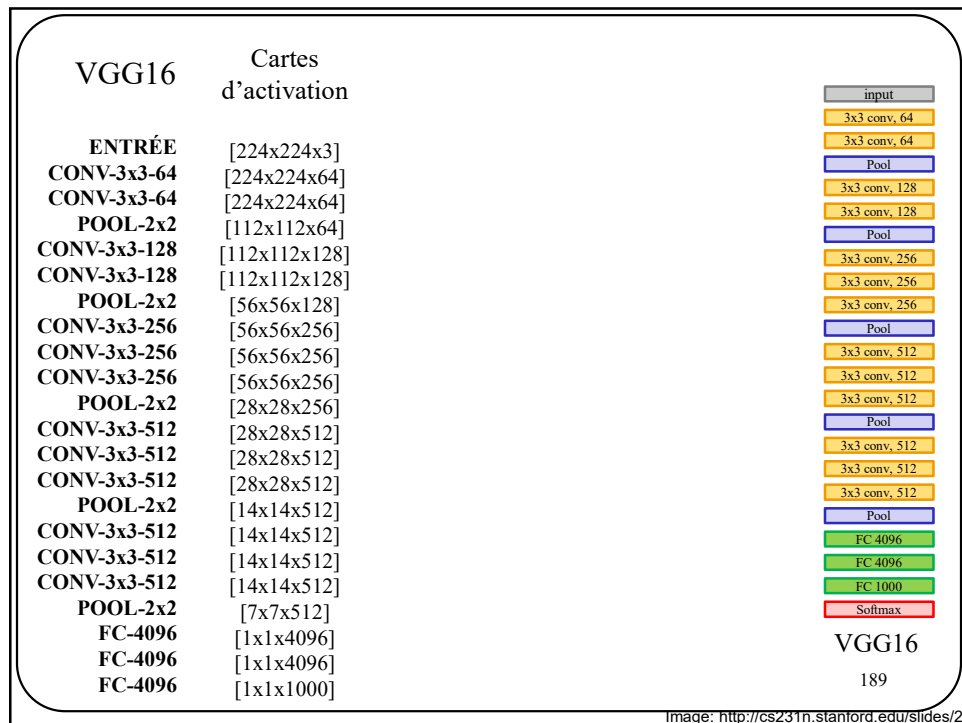
186



187



188



189

VGG16	Cartes d'activation	Nb Neurones	
ENTRÉE	[224x224x3]	150 K	input
CONV-3x3-64	[224x224x64]	3.2 M	3x3 conv, 64
CONV-3x3-64	[224x224x64]	3.2 M	3x3 conv, 64
POOL-2x2	[112x112x64]	800 k	Pool
CONV-3x3-128	[112x112x128]	1.6 M	3x3 conv, 128
CONV-3x3-128	[112x112x128]	1.6 M	3x3 conv, 128
POOL-2x2	[56x56x128]	400 K	Pool
CONV-3x3-256	[56x56x256]	800 K	3x3 conv, 256
CONV-3x3-256	[56x56x256]	800 K	3x3 conv, 256
CONV-3x3-256	[56x56x256]	800 K	3x3 conv, 256
POOL-2x2	[28x28x256]	200 K	Pool
CONV-3x3-512	[28x28x512]	400 K	3x3 conv, 512
CONV-3x3-512	[28x28x512]	400 K	3x3 conv, 512
CONV-3x3-512	[28x28x512]	400 K	3x3 conv, 512
POOL-2x2	[14x14x512]	100 K	Pool
CONV-3x3-512	[14x14x512]	100 K	FC 4096
CONV-3x3-512	[14x14x512]	100 K	FC 4096
CONV-3x3-512	[14x14x512]	100 K	FC 1000
POOL-2x2	[7x7x512]	25 K	Softmax
FC-4096	[1x1x4096]	4094	
FC-4096	[1x1x4096]	4096	
FC-4096	[1x1x1000]	1000	
			VGG16
			190

Image: <http://cs231n.stanford.edu/slides/2>

190

VGG16	Cartes d'activation	Nb Neurones	Nb Paramètres	
ENTRÉE	[224x224x3]	150 K	0	input
CONV-3x3-64	[224x224x64]	3.2 M	$(3*3*3)*64 = 1,728$	3x3 conv, 64
CONV-3x3-64	[224x224x64]	3.2 M	$(3*3*64)*64 = 36,864$	3x3 conv, 64
POOL-2x2	[112x112x64]	800 k	0	Pool
CONV-3x3-128	[112x112x128]	1.6 M	$(3*3*64)*128 = 73,728$	3x3 conv, 128
CONV-3x3-128	[112x112x128]	1.6 M	$(3*3*128)*128 = 147,456$	3x3 conv, 128
POOL-2x2	[56x56x128]	400 K	0	Pool
CONV-3x3-256	[56x56x256]	800 K	$(3*3*128)*256 = 294,912$	3x3 conv, 256
CONV-3x3-256	[56x56x256]	800 K	$(3*3*256)*256 = 589,824$	3x3 conv, 256
CONV-3x3-256	[56x56x256]	800 K	$(3*3*256)*256 = 589,824$	3x3 conv, 256
POOL-2x2	[28x28x256]	200 K	0	Pool
CONV-3x3-512	[28x28x512]	400 K	$(3*3*256)*512 = 1,179,648$	3x3 conv, 512
CONV-3x3-512	[28x28x512]	400 K	$(3*3*512)*512 = 2,359,296$	3x3 conv, 512
CONV-3x3-512	[28x28x512]	400 K	$(3*3*512)*512 = 2,359,296$	3x3 conv, 512
POOL-2x2	[14x14x512]	100 K	0	Pool
CONV-3x3-512	[14x14x512]	100 K	$(3*3*512)*512 = 2,359,296$	3x3 conv, 512
CONV-3x3-512	[14x14x512]	100 K	$(3*3*512)*512 = 2,359,296$	3x3 conv, 512
CONV-3x3-512	[14x14x512]	100 K	$(3*3*512)*512 = 2,359,296$	3x3 conv, 512
POOL-2x2	[7x7x512]	25 K	0	Pool
FC-4096	[1x1x4096]	4094	$7*7*512*4096 = 102,760,448$	FC 4096
FC-4096	[1x1x4096]	4096	$4096*4096 = 16,777,216$	FC 4096
FC-4096	[1x1x1000]	1000	$4096*1000 = 4,096,000$	FC 1000
				Softmax
				VGG16
				191


Image: <http://cs231n.stanford.edu/slides/2>

191

VGGNet

Nb neurones totaux : ~15 M
 Mémoire totale neurones (4 octets par neurones) : ~60 Mo
 Nb paramètres totaux : 138 M
 Mémoire total paramètres (4 octets par paramètres) : 552 Mo

~ 612 Mo pour la propagation avant d'une image



VGG16

192

Image: http://cs231n.stanford.edu/slides/2016_spring


192

VGGNet

Nb neurones totaux : ~15 M
 Mémoire totale neurones (4 octets par neurones) : ~60 Mo
 Nb paramètres totaux : ~138 M
 Mémoire total paramètres (4 octets par paramètres) : ~552 Mo

~612 Mo pour la propagation avant d'une image

>1.1 Go si on inclut la rétro-propagation



VGG16

193

Image: http://cs231n.stanford.edu/slides/2016_spring


193

Réseaux récurrents

(si le temps le permet)

194

Réseau de neurones de base (régression)



$$y(\vec{x}) = W^1 f_a(W^0 \vec{x})$$




$$\vec{h} = f_a(W^0 \vec{x})$$

$$y(\vec{x}) = W^1 \vec{h}$$

f_a : fonction d'activation


195

Réseau de neurones de base (classification)



196

Réseau de neurones de base (classification)




Ne permet que des tâches "1 pour 1"

- Classification (1 image = 1 étiquette)
- Régression (1 donnée = 1 vecteur)
- Localisation (1 boîte = 1 classification + 1 régression)

197


Illustration simplifiée




198

Différentes configurations pour différentes applications

1 entrée et 1 sortie

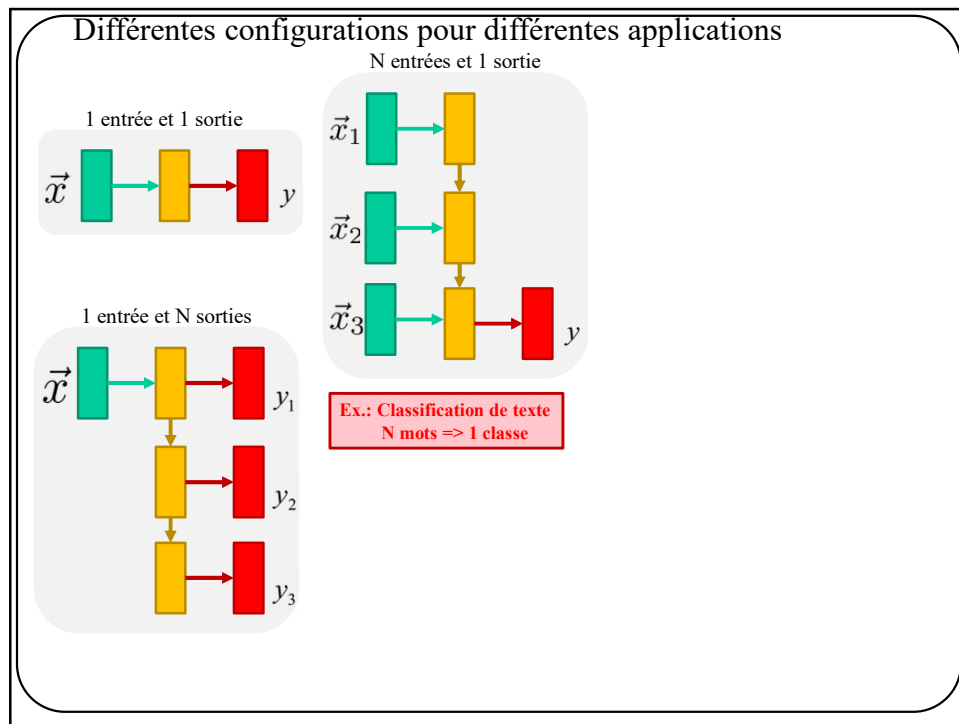


1 entrée et N sorties

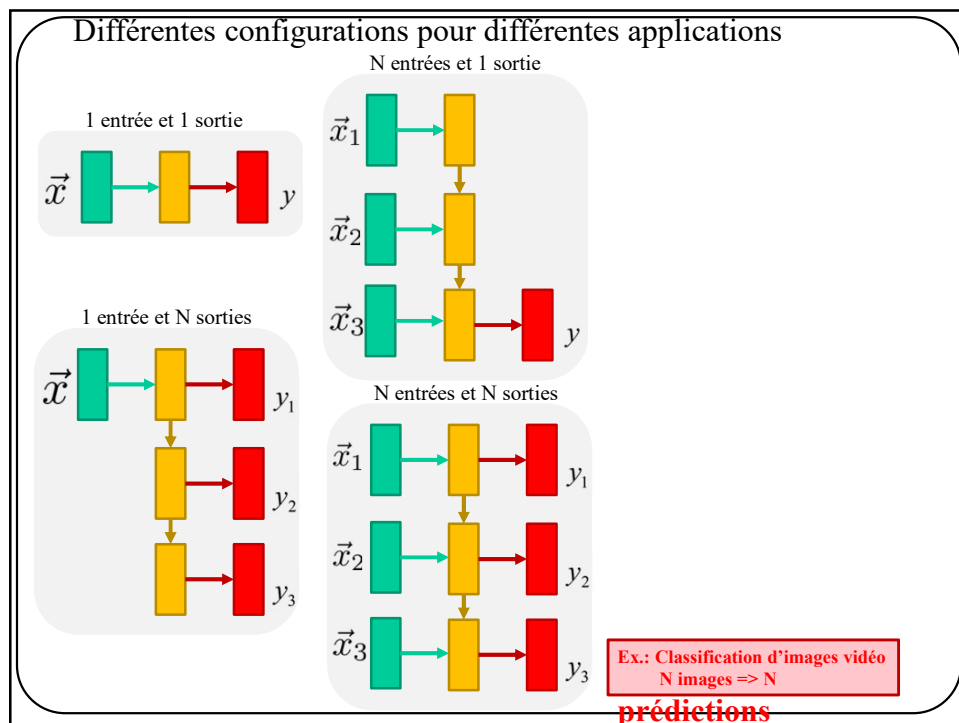


Ex.: description d'une image
1 image => N mots

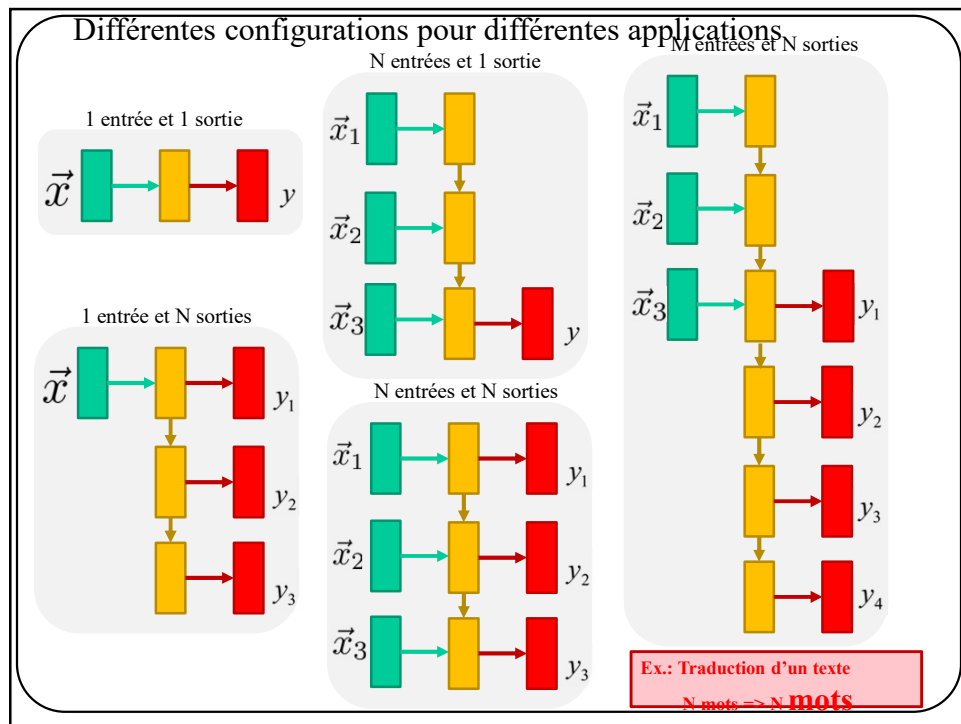
199




200



201




202




203

Réseau récurrent : la sortie des neurones est réinjectée dans leur entrée




204

Réseau récurrent : la sortie des neurones est réinjectée dans leur entrée




205

Réseau récurrent : la sortie des neurones est réinjectée dans leur entrée




206

Illustration simplifiée



207

Dans le cas général avec K sorties (régression)



$$y(\vec{x}) = W^{hy} f_a(W^{xh} \vec{x} + W^{hh} \vec{h})$$


↓

$$\vec{h} = f_a(W^{xh} \vec{x} + W^{hh} \vec{h})$$

$$\vec{y}(\vec{x}) = W^{hy} \vec{h}$$

208

Dans le cas général avec K sorties (classification)



$$y(\vec{x}) = W^{hy} f_a(W^{xh} \vec{x} + W^{hh} \vec{h})$$

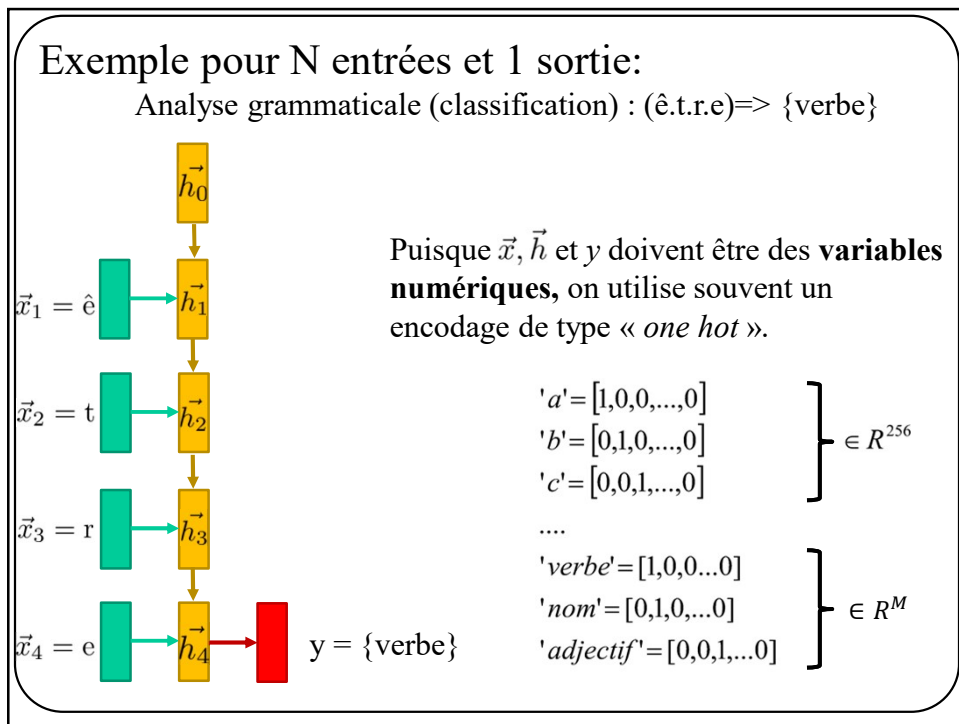
↓

$$\vec{h} = f_a(W^{xh} \vec{x} + W^{hh} \vec{h})$$

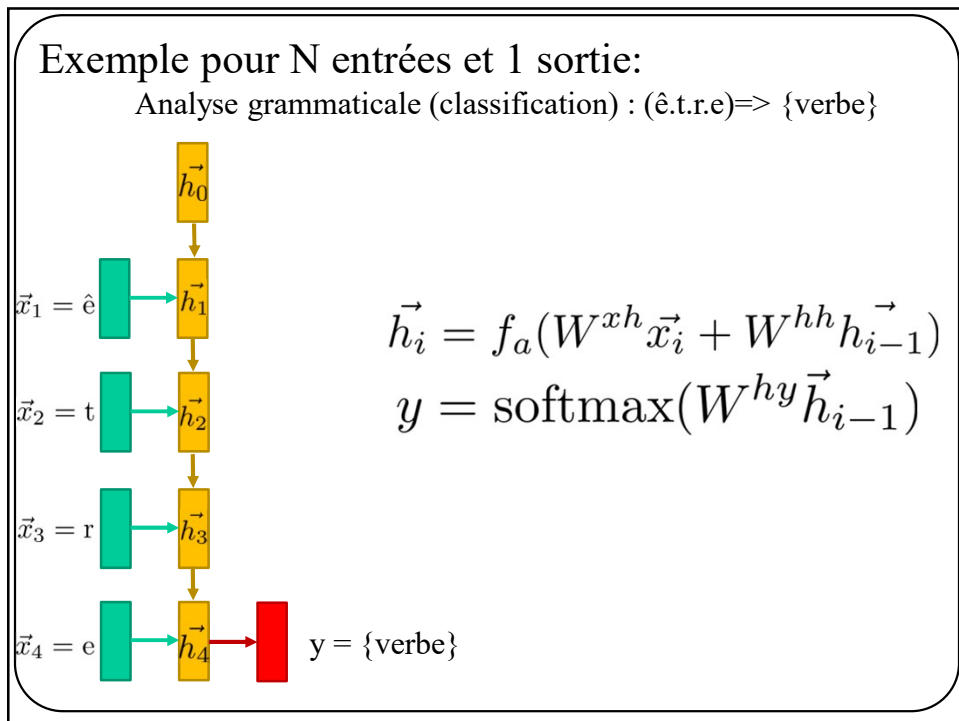
$$\hat{y} = W^{hy} \vec{h}$$

$$\vec{y}(\vec{x}) = \text{softmax}(\hat{y})$$

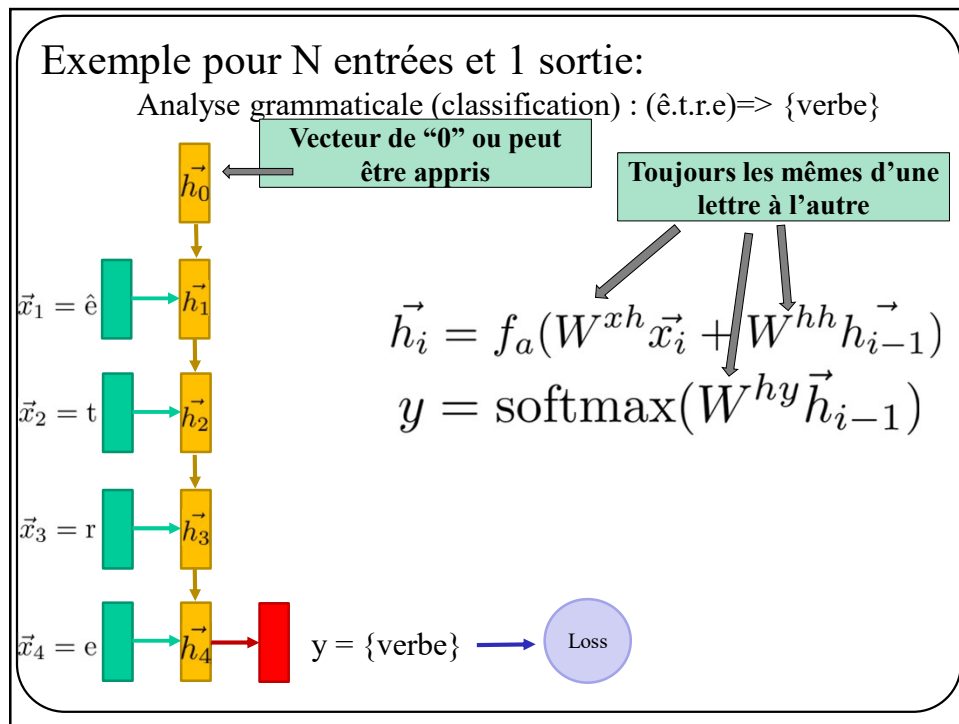
209



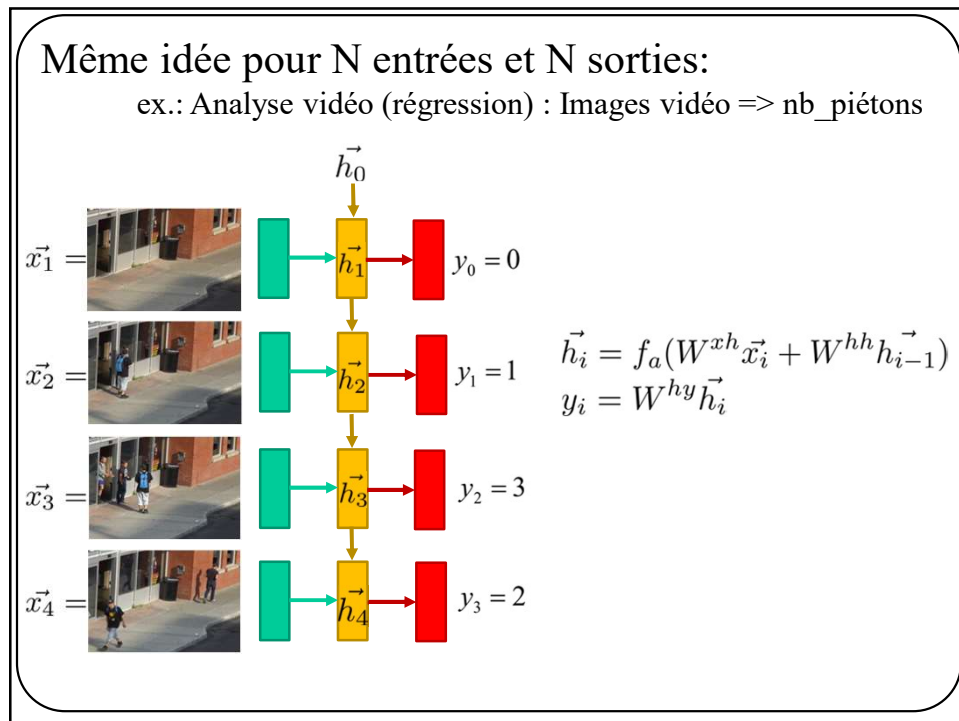
210



211



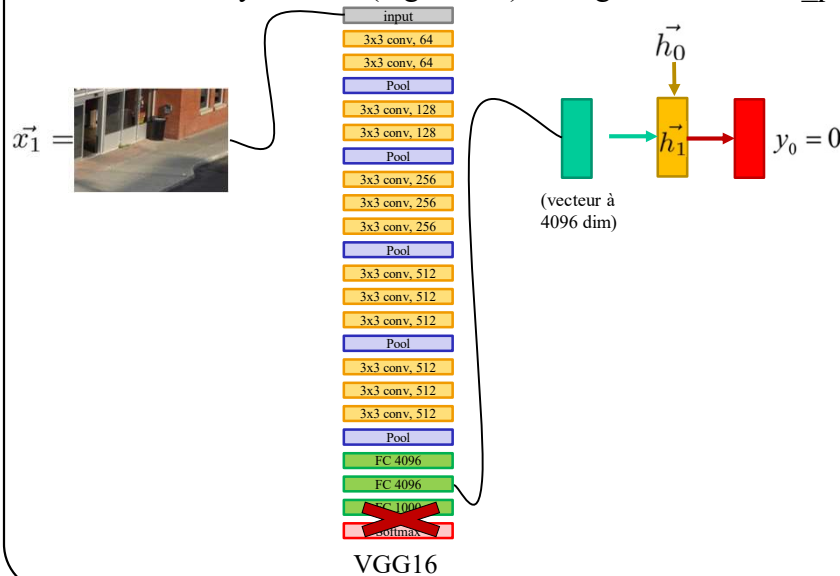
212



213

Même idée pour N entrées et N sorties:

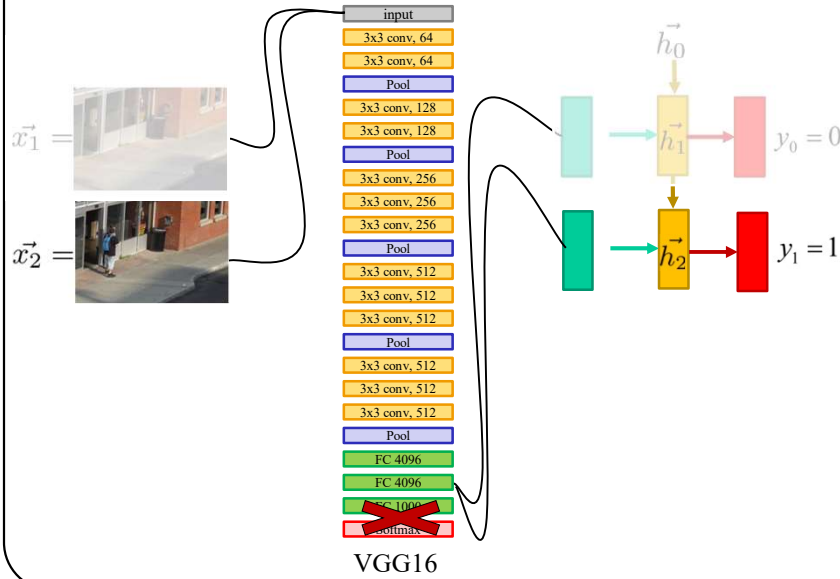
ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons



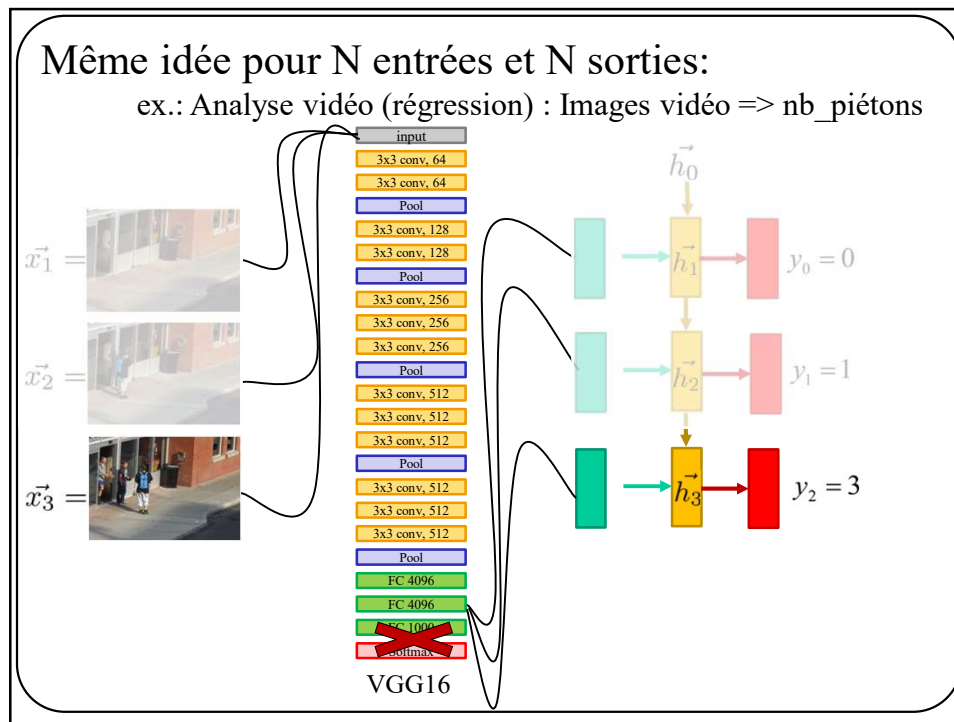
214

Même idée pour N entrées et N sorties:

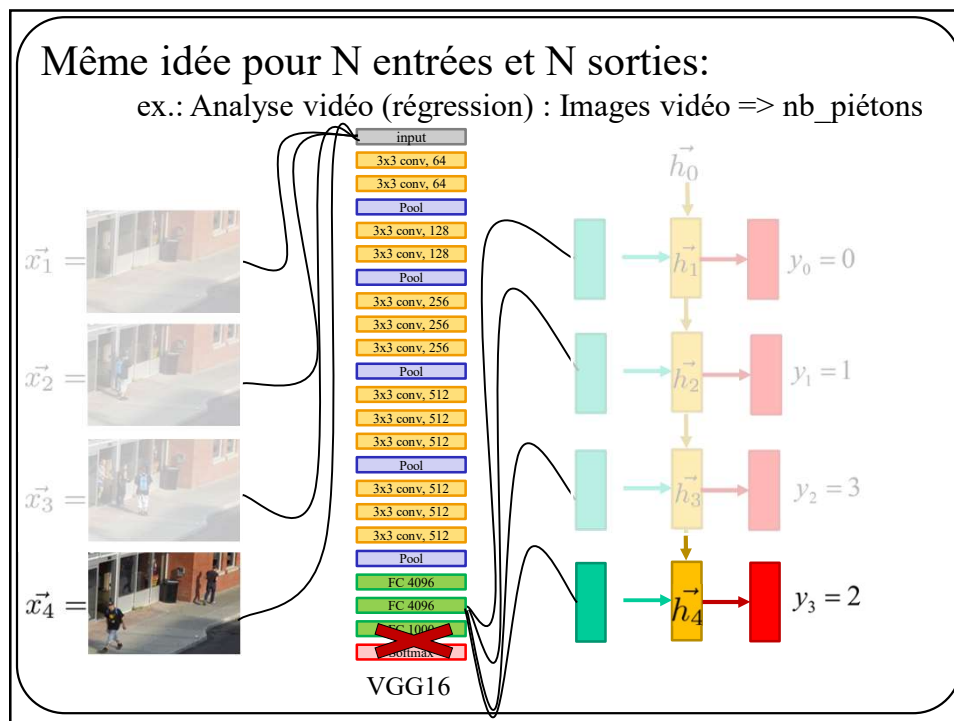
ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons



215



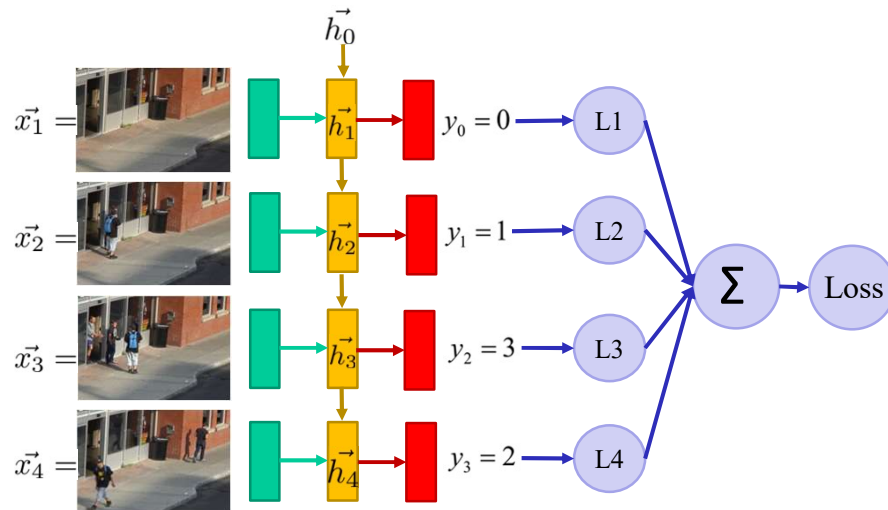
216



217

Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons



218

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet jouet : [a,e,m,s]

Représentation « one hot » jouet:

'a' = [1, 0, 0, 0]
 'e' = [0, 1, 0, 0]
 'm' = [0, 0, 1, 0]
 's' = [0, 0, 0, 1]

But : Entraîner un modèle à prédire les lettres du mot « **masse** ».

219

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « **masse** ».

$$\vec{x}_1 = \text{m} \quad \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix} \rightarrow$$

220

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « **masse** ».

$$\vec{x}_1 = \text{m} \quad \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix} \xrightarrow{W^{xh}} \begin{bmatrix} -0.3 \\ -0.1 \\ 0.9 \end{bmatrix}$$

$\downarrow W^{hh}$


$$\vec{h}_i = \tanh(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1})$$

221

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».



$$\vec{h}_i = \tanh(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1})$$


$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

222

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».



$$\vec{h}_i = \tanh(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1})$$


$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

223

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet :[a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».



$$\vec{h}_i = \tanh(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1})$$


$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

224

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet :[a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».



$$\vec{h}_i = \tanh(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1})$$


$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

225

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».

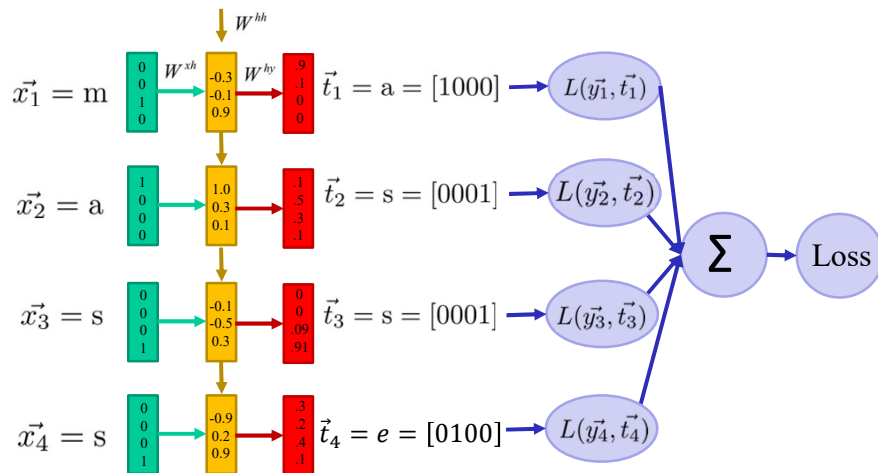


226

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».




227

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

Entraîner un modèle à prédire les lettres du mot « masse ».




228

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

En test : prédire les lettres les unes après les autres




Étape 1 : Calcul de la couche cachée

229

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[a,e,m,s]

En test : prédire les lettres les unes après les autres




Étape 2 : Calcul de la sortie (softmax)

230

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[a,e,m,s]

En test : prédire les lettres les unes après les autres




Étape 3 : Sélectionner le caractère le plus probable

231

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet : [a,e,m,s]

En test : prédire les lettres les unes après les autres




Étape 4 : Injecter le caractère prédit au début du réseau

232

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet : [a,e,m,s]

En test : prédire les lettres les unes après les autres




Et on recommence!

233

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

En test : prédire les lettres les unes après les autres




234

Autre exemple: prédiction de caractères (modèle de langue)

Alphabet : [a,e,m,s]

En test : prédire les lettres les unes après les autres



235

Autre exemple: prédiction de caractères (modèle de langue)

Code python: “mini-char-RNN” de A. Karpathy

<https://gist.github.com/karpathy/d4dee566867f8291f086>

Un RNN en 112 lignes !

```
Minimal character-level language model with a Vanilla Recurrent Neural Network, in Python/numpy

1 ---
2 Minimal character-level Vanilla RNN model. Written by Andrej Karpathy (@karpathy)
3 BSD License
4 ---
5 import numpy as np
6
7 # data I/O
8 data = open('input.txt', 'r').read() # should be simple plain text file
9 chars = list(set(data))
10 data_size, vocab_size = len(data), len(chars)
11 print 'data has %d characters, %d unique.' % (data_size, vocab_size)
12 char_to_ix = { ch:i for i,ch in enumerate(chars) }
13 ix_to_char = { i:ch for i,ch in enumerate(chars) }
14
15 # hyperparameters
16 hidden_size = 100 # size of hidden layer of neurons
17 seq_length = 25 # number of steps to unroll the RNN for
18 learning_rate = 1e-3
19
20 # model parameters
21 Wih = np.random.randn(hidden_size, vocab_size)*0.01 # input to hidden
22 Whh = np.random.randn(hidden_size, hidden_size)*0.01 # hidden to hidden
23 Woi = np.random.randn(vocab_size, hidden_size)*0.01 # hidden to output
24 bi = np.zeros(hidden_size, 1) # hidden bias
25 bo = np.zeros(vocab_size, 1) # output bias
26
27 def lossfun(inputs, targets, hprev):
28     """
29     inputs, targets are both lists of integers.
30     hprev is list/array of initial hidden state
31     returns the loss, gradients on model parameters, and last hidden state
32     """
33     xs, hs, ys, ps = [], [], [], []
34     h = hprev
35     loss = 0
36     # forward pass
37     for t in xrange(len(inputs)):
38         xs.append([inputs[t]]) # encode in 1-of-k representation
39         hs.append(h)
40         h = np.dot(Wih, xs) + np.dot(Whh, hs) + bi
```

$$\left. \begin{array}{l} 'a' = [1, 0, 0, \dots, 0] \\ 'b' = [0, 1, 0, \dots, 0] \\ 'c' = [0, 0, 1, \dots, 0] \\ \dots \end{array} \right\} \in \mathbb{R}^{256}$$

236

Autre exemple: prédiction de caractères (modèle de langue)

Code python: “mini-char-RNN” de A. Karpathy

<https://gist.github.com/karpathy/d4dee566867f8291f086>

THE SONNETS

by William Shakespeare

From fairest creatures we desire increase,
That thereby beauty's rose might never die,
But as the ripper should by time decrease,
His tender hee might bear his memory;
Dut thou, contracted to thine own bright eyes,
Feed'st thy light's flame with self-substantial fuel,
Making a famine where abundance lies,
Thyself thy foe, to thy sweet self too cruel:
Thou that art now the world's fresh ornament,
And only herald to the gaudy spring,
Within thine own bud biddest thy content,
And tender churl mak'st waste in niggarding:
Pity the world, or else this glutton be,
To eat the world's due, by the grave and thee.

When forty winters shall besiege thy brow,
And dig deep trenches in thy beauty's field,
Thy youth's proud livery so gazed on now,
Will be a tattered weed of small worth held:
Then being asked, where all thy beauty lies,
Where all the treasure of thy lusty days;
To say, within thine own deep sunken eyes,
Were an all-eating shame, and thriftless praise.
How much more praise deserves thy beauty's use,
If thou couldst answer, 'This fair child of mine
Shall sum my count, and make my old excuse,'
Proving his beauty by succession thine!
This were to be new made when thou art old,
And see thy blood warm when thou feel'st it cold.

237

Autre exemple: prédiction de caractères (modèle de langue)

tyntd-iafhatawiaoihrdemot lytdws e ,tfti, astai f ogoh eoase rrranbyne 'nhthnee e
plia tkllrgd t o idoe ns,smtt h ne etie h,hregtrs nigtike,aoaenns lng

↓ train more

"Tmont thithey" fomesscerliund
Keushey. Thom here
sheulke, anmerenith ol sivh I lalterthend Bleipile shuwv fil on aseterlome
coaniogennc Phe lism thond hon at. MeiDimorotion in ther thize."

↓ train more

Aftair fall unsuch that the hall for Prince Velzonski's that me of
her hearly, and behs to so arwage fiving were to it beloge, pavu say falling misfort
how, and Gogition is so overelical and offer.

↓ train more

"Why do what that day," replied Natasha, and wishing to himself the fact the
princess, Princess Mary was easier, fed in had oftened him.
Pierre aking his soul came to the packs and drove up his father-in-law women.

Crédit: A. Karpathy, CS231

238

Texte généré une fois le modèle entraîné

PANDARUS:

Alas, I think he shall be come approached and the day
When little strain would be attain'd into being never fed,
And who is but a chain and subjects of his death,
I should not sleep.

Second Senator:

They are away this miseries, produced upon my soul,
Breaking and strongly should be buried, when I perish
The earth and thoughts of many states.

DUKE VINCENTIO:

Well, your wit is in the care of side and that.

Second Lord:

They would be ruled after this chamber, and
my fair nues begun out of the fact, to be conveyed,
Whose noble souls I'll have the heart of the wars.

Clown:

Come, sir, I will make did behold your worship.

VIOLA:

I'll drink it.

VIOLA:

Why, Salisbury must find his flesh and thought
That which I am not apt, not a man and in fire,
To show the reining of the raven and the wars
To grace my hand reproach within, and not a fair are hand,
That Caesar and my goodly father's world;
When I was heaven of presence and our fleets,
We spare with hours, but cut thy council I am great,
Murdered and by thy master's ready there
My power to give thee but so much as hell:
Some service in the noble bondman here,
Would show him to her wine.

KING LEAR:

O, if you were a feeble sight, the courtesy of your law,
Your sight and several breath, will wear the gods
With his heads, and my hands are wonder'd at the deeds,
So drop upon your lordship's head, and your opinion
Shall be against your honour.

Crédit: A. Karpathy, CS231

239

Entraînement sur le code source de Linux en C++

```
static void do_command(struct seq_file *m, void *v)
{
    int column = 32 << (cmd[2] & 0x80);
    if (state)
        cmd = (int)(int_state ^ (in_8(&ch->ch_flags) & Cmd) ? 2 : 1);
    else
        seq = 1;
    for (i = 0; i < 16; i++) {
        if (k & (1 << i))
            pipe = (in_use & UNIXTHREAD_UNCCA) +
                ((count & 0x00000000ffffff) & 0x0000000f) << 8;
        if (count == 0)
            sub(pid, ppc_md.kexec_handle, 0x20000000);
        pipe_set_bytes(i, 0);
    }
    /* Free our user pages pointer to place camera if all dash */
    subsystem_info = &of_changes(PAGE_SIZE);
    rek_controls(offset, idx, &offset);
    /* Now we want to deliberately put it to device */
    control_check_polarity(&context, val, 0);
    for (i = 0; i < COUNTER; i++)
        seq_puts(m, "policy ");
}

#include <asm/in.h>
#include <asm/prom.h>
#include <asm/e820.h>
#include <asm/system_info.h>
#include <asm/setw.h>
#include <asm/ppcproto.h>

#define REQ_PG      vesa_slot_addr_pack
#define PPM_WOCHMP  AFER(0, load)
#define STACK_DDR(type)      (fnuc)

#define SWAP_ALLOCATE(x)      (0)
#define emulate_rsig() arch_get_unaligned_child()
#define access_rw(TEST) asm volatile("movd %0, %1" : : "r" (0)); \
    if (__type & DO_READ)

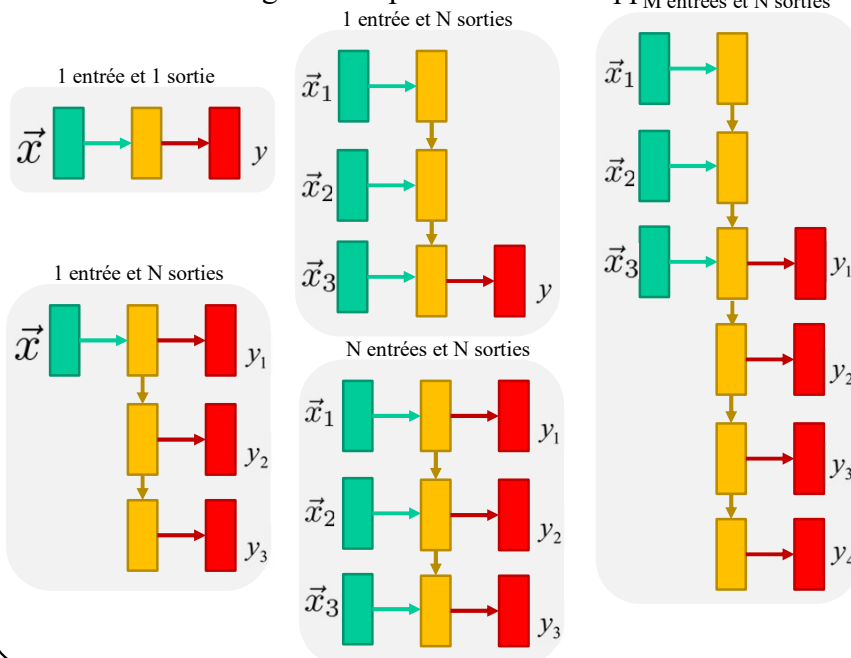
static void stat_PC_SEC __read_mostly offsetof(struct seq_argqueue, \
    pC[1]);

static void
os_prefix(unsigned long sys)
{
    #ifdef CONFIG_PSEUDOPT
        PUT_PARAM_RAID(2, sel) = get_state_state();
        set_pid_sum((unsigned long)state, current_state_str(),
            (unsigned long)-1->lr_full; low;
    }
}
```

Crédit: A. Karpathy, CS231

240


Différentes configurations pour différentes applications



241

Traduction Français-Anglais

N lettres => M lettres



242

Autre exemple: traduction

Traduire 'assez' -> 'enough'

Alphabet fr : [<BoS>,a,e,s,z,<EoS>]

Alphabet en : [<BoS>,e,g,h,n,o,u,<EoS>]

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Pas le même nombre d'entrées
que de sorties !

(BoS : Beginning of Sentence,
EoS:End of Sentence).

243

Autre exemple: traduction

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Traduire 'assez' -> 'enough'

Alphabet fr : [<BoS>,a,e,s,z,<EoS>]

Alphabet en : [<BoS>,e,g,h,n,o,u,<EoS>]



244


Autre exemple: traduction

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Traduire 'assez' -> 'enough'

Alphabet fr : [<BoS>,a,e,s,z,<EoS>]

Alphabet en : [<BoS>,e,g,h,n,o,u,<EoS>]



245


Autre exemple: traduction

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Traduire 'assez' -> 'enough'

Alphabet fr : [**<BoS>**,a,e,s,z,<EoS>]

Alphabet en : [**<BoS>**,e,g,h,n,o,u,<EoS>]



246


Autre exemple: traduction

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Traduire 'assez' -> 'enough'

Alphabet fr : [**<BoS>**,a,e,s,z,<EoS>]

Alphabet en : [**<BoS>**,e,g,h,n,o,u,<EoS>]



247


Autre exemple: traduction

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27.

Traduire 'assez' -> 'enough'

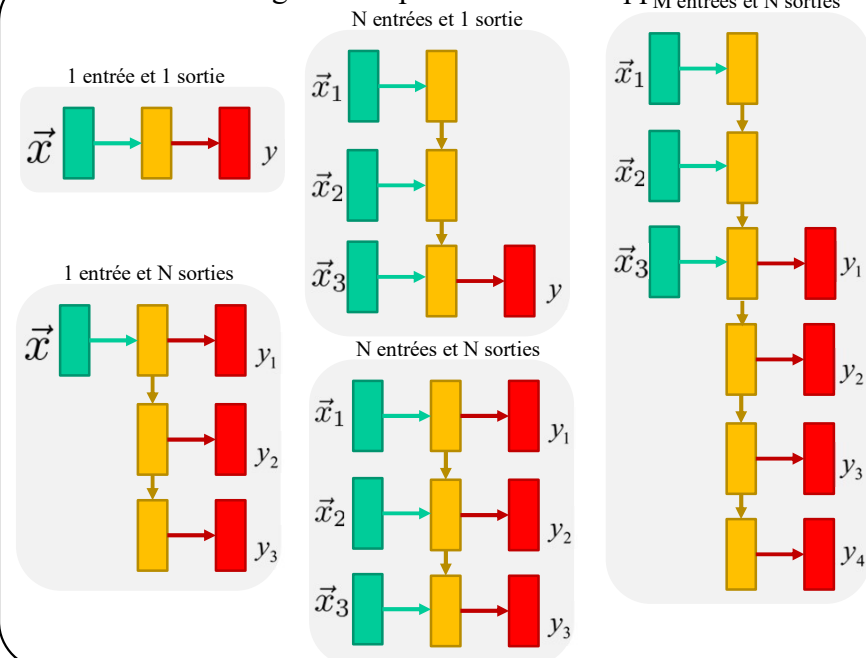
Alphabet fr: [**<BoS>**,a,e,s,z,**<EoS>**]

Alphabet en: [**<BoS>**,e,g,h,n,o,u,**<EoS>**]



248


Différentes configurations pour différentes applications



249


Différentes configurations pour différentes applications

Description du contenu d'une image (« captioning »)



250

Captioning




VGG16

Réseau VGG
pré-entraîné sur *ImageNet*

251

251



Captioning



VGG16

252

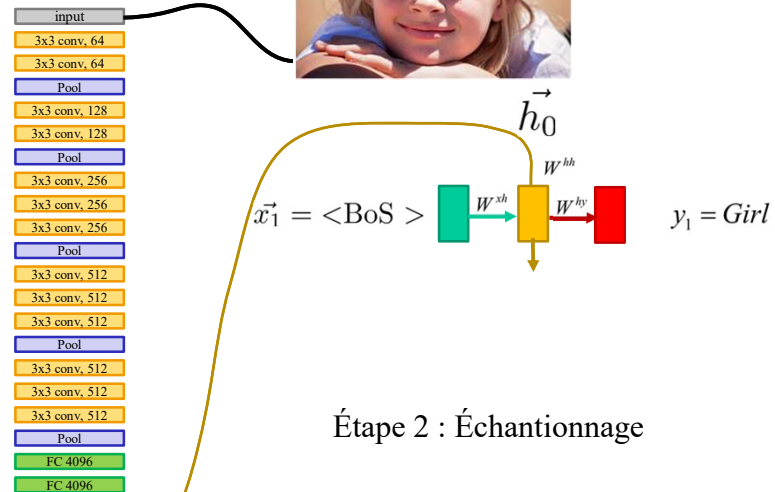
Captioning



Étape 1 : Init + Propagation avant

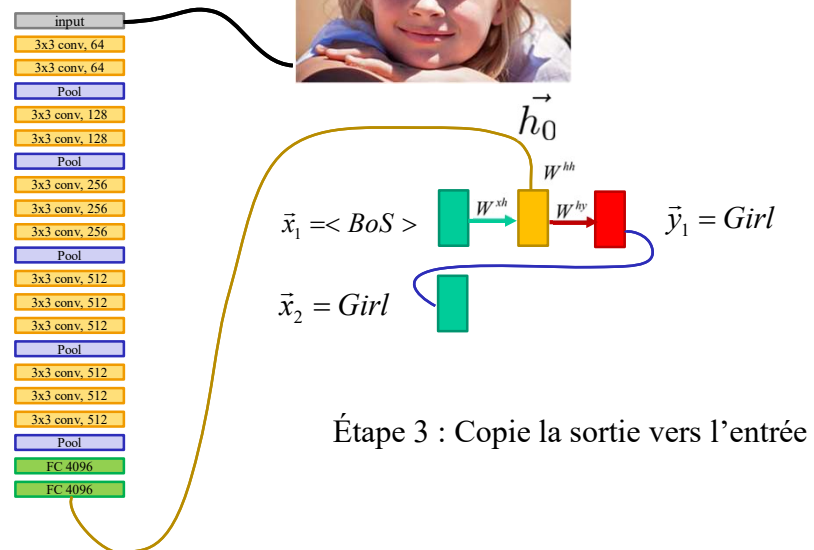
253

Captioning





254

Captioning



255

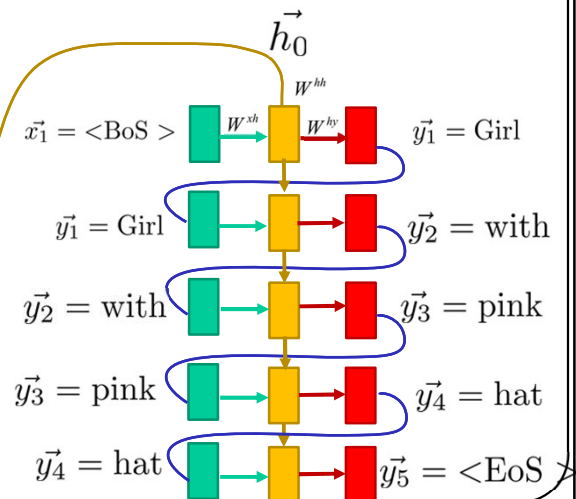

Captioning



Étape 4 : On recommence!

256

Captioning



257

Exemples de résultats

<https://github.com/karpathy/neuraltalk2>



an elephant standing in a grassy field with trees in the background



a man riding a wave on top of a surfboard



a street sign on a pole in front of a building



a group of people playing a game with nintendo wii controllers



a couple of zebra standing on top of a dirt field

258

258

Exemples d'erreurs

<https://github.com/karpathy/neuraltalk2>



a man is throwing a frisbee in a park



a man riding a skateboard down a street



a laptop computer sitting on top of a wooden desk



A woman is holding a cat in her hand



A woman standing on a beach holding a surfboard

259

259