

Méthodes d'apprentissage
IFT603-712

Théorie de la décision
Par
Pierre-Marc Jodoin

1

Régression linéaire

RAPPEL

- Le modèle de **régression linéaire** est le suivant :

$$y_{\vec{w}}(\vec{x}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_d x_d$$

$$\text{où } \vec{x} = (x_1, x_2, \dots, x_d)^T$$

- La prédiction correspond donc à
 - Une **droite** pour $d=1$
 - Un **plan** pour $d=2$
 - Un **hyperplan** pour $d>2$

2

2

Régression linéaire

RAPPEL

$$y_{\vec{w}}(\vec{x}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_d x_d$$

$$y_{\vec{w}}(\vec{x}) = \vec{w}^T \vec{x}$$

$$\text{où } \vec{x}' = (1, x_1, x_2, \dots, x_d)^T$$

3

3

Problème à résoudre

RAPPEL

$$\vec{w} = \arg \min_{\vec{w}} \sum_{n=1}^N (y_{\vec{w}}(\vec{x}_n) - t_n)^2$$

Il est très bien connu en technique d'apprentissage que cette solution est optimale lorsque le bruit est gaussien.


C'est même une question d'entrevue!

4

Formulation probabiliste

Loi conditionnelle (*maximum de vraisemblance*)

RAPPEL



5

Formulation probabiliste

RAPPEL

Pour entraîner le modèle $y_{\vec{w}}(\vec{x})$ nous passerons par une formulation probabiliste :

$$p(t | \vec{x}, \vec{w}, \Sigma) = N(t | y_{\vec{w}}(\vec{x}), \Sigma)$$

Hypothèse gaussienne

➤ Revient à supposer que les **cibles** sont des **versions bruitées** du vrai modèle

$$t_n = y_{\vec{w}}(\vec{x}_n) + \varepsilon$$

Bruit gaussien de moyenne 0 et de variance σ^2

6

Maximum de vraisemblance


RAPPEL

$$\bar{w} = \arg \min_{\bar{w}} \sum_{n=1}^N (y_{\bar{w}}(\bar{x}_n) - t_n)^2$$

$$\bar{w}_{MV} = (X^T X)^{-1} X^T T$$

Et bien sûr, on peut utiliser une **fonction de base** pour rendre le modèle non linéaire.

7




RAPPEL

Le meilleur modèle $y_{\bar{w}}(\bar{x}_n)$ selon correspond à la **moyenne** de la distribution **conditionnelle**

$$y_{\bar{w}}(\bar{x}_n) = E[t | \bar{x}] = \int t p(t | \bar{x}) dt$$

8



RAPPEL


On peut démontrer mathématiquement qu'une telle optimisation revient à un compromis entre deux concepts : **la variance et le biais**

9

9

Décomposition biais-variance (Bishop 3.2)

On a vu les concepts de « sur-apprentissage » et de « sous-apprentissage ».




$y(\vec{x})$: modèle trouvé par apprentissage
 $h(\vec{x})$: le meilleur modèle représentant les données

23

Décomposition biais-variance (Bishop 3.2)

On a vu les concepts de « sur-apprentissage » et de « sous-apprentissage ».




Le but d'un bon modèle est de trouver le **bon compromis biais-variance**

24

Décomposition biais-variance (Bishop 3.2)

On a vu les concepts de « sur-apprentissage » et de « sous-apprentissage ».




Variance élevée
Biais faible

Variance faible
Biais élevée


25

Variance élevée, Biais faible



26


Variance faible, Biais élevé



27

Variance

Peut être vu intuitivement comme la **écart moyen entre les « courbes grises »** $y(\bar{x}; D_i)$



Variance faible

Variance élevée


Dans le cas à 5 courbes:

$$\text{variance} = \frac{1}{5} \sum_{i=1}^5 \left(y(\bar{x}; D_i) - \underbrace{\frac{1}{5} \sum_{i=1}^5 y(\bar{x}; D_i)}_{\text{Courbe moyenne (bleue)}} \right)^2$$

28

Biais

Peut être vu intuitivement comme la **différence entre les « courbes verte et bleue »**



Biais élevé

biais faible


Dans le cas à 5 courbes:

$$\text{biais} = \frac{1}{5} \sum_{i=1}^5 \left(\underbrace{h(\bar{x})}_{\text{Courbe optimale (verte)}} - \underbrace{1/5 \sum_{i=1}^5 y(\bar{x}; D_i)}_{\text{Courbe moyenne (bleue)}} \right)^2$$

29

29

Compromis biais-variance



Biais élevé

Variance faible

Biais faible

Variance élevée


$$\text{variance} = \frac{1}{5} \sum_{i=1}^5 \left(y(\bar{x}; D_i) - 1/5 \sum_{i=1}^5 y(\bar{x}; D_i) \right)^2$$

$$\text{biais} = \frac{1}{5} \sum_{i=1}^5 \left(h(\bar{x}) - 1/5 \sum_{i=1}^5 y(\bar{x}; D_i) \right)^2$$

30

30

Analyse quand $N \rightarrow \infty$



Biais élevé

Variance faible

Biais faible

Variance élevée


$$\text{variance} = \frac{1}{N} \sum_{i=1}^N \left(y(\bar{x}; D_i) - 1/N \sum_{i=1}^N y(\bar{x}; D_i) \right)^2$$

$$\text{biais} = \frac{1}{N} \sum_{i=1}^N \left(h(\bar{x}) - 1/N \sum_{i=1}^N y(\bar{x}; D_i) \right)^2$$

31

31

Analyse quand $N \rightarrow \infty$



$$\text{variance} = E_D \left[\{y(\vec{x}; D) - E_D[y(\vec{x}; D)]\}^2 \right]$$

$$\text{biais} = E_D \left[\{h(\vec{x}) - E_D[y(\vec{x}; D)]\}^2 \right]$$

32

32

Analyse formelle

$$\begin{aligned} \{y(\vec{x}; D) - h(\vec{x})\}^2 &= \{y(\vec{x}; D) - E_D[y(\vec{x}; D)] + E_D[y(\vec{x}; D)] - h(\vec{x})\}^2 \\ &= \{y(\vec{x}; D) - E_D[y(\vec{x}; D)]\}^2 \\ &\quad + 2\{y(\vec{x}; D) - E_D[y(\vec{x}; D)]\}\{E_D[y(\vec{x}; D)] - h(\vec{x})\} \\ &\quad + \{E_D[y(\vec{x}; D)] - h(\vec{x})\}^2 \end{aligned}$$

On peut démontrer que

$$E[\{y(\vec{x}; D) - h(\vec{x})\}^2] = E_D[\{y(\vec{x}; D) - E_D[y(\vec{x}; D)]\}^2] + E_D[\{h(\vec{x}) - E_D[y(\vec{x}; D)]\}^2]$$

Variance

Biais

35

Conclusion

En IA, lorsqu'on cherche à minimiser l'erreur entre un modèle y et une solution optimale h ,

$$E[\{y(\vec{x}; D) - h(\vec{x})\}^2]$$


Cela revient à trouver un **compromis entre le biais et la variance**.

$$= E_D[\{y(\vec{x}; D) - E_D[y(\vec{x}; D)]\}^2] + E_D[\{h(\vec{x}) - E_D[y(\vec{x}; D)]\}^2]$$

Variance

Biais

36



37
