

Réseaux de neurones

IFT 780

Réseaux de neurones multicouches


Par

Pierre-Marc Jodoin

1

Séparation linéaire

(2D et 2 classes)



$$\begin{aligned}y_{\vec{w}}(\vec{x}) &= w_0 + w_1 x_1 + w_2 x_2 \\&= w_0 + \vec{w}^T \vec{x} \\&= \vec{w}'^T \vec{x}'\end{aligned}$$

$$y_{\vec{w}}(\vec{x}) = \vec{w}^T \vec{x}$$



Par simplicité

2 grands **avantages**. Une fois l'entraînement terminé,

1. Plus besoin de données d'entraînement
2. Classification est très rapide (**produit scalaire** entre 2 vecteurs)

2

Perceptron (2D et 2 classes)





Fonction de coût perceptron (loss)
et gradient

$$E_D(\vec{w}) = \frac{1}{N} \sum_{\vec{x}_n \in M} -t_n \vec{w}^T \vec{x}_n \quad \text{où } M \text{ est l'ensemble des données mal classées}$$

$$\nabla E_D(\vec{w}) = \frac{1}{N} \sum_{\vec{x}_n \in M} -t_n \vec{x}_n$$

3

Hinge Loss (2D et 2 classes)



Fonction de coût SVM (hinge loss)
et gradient

$$E_D(\vec{w}) = \frac{1}{N} \sum_{n=1}^N \max(0, 1 - t_n \vec{w}^T \vec{x}_n)$$

$$\nabla E_D(\vec{w}) = \frac{1}{N} \sum_{\vec{x}_n \in M} -t_n \vec{x}_n$$



4

2

Régression logistique

(2D, 2 classes)

Nouvelle fonction d'activation : **sigmoïde logistique**



Fonction de coût (*loss*) et gradient



$$E_D(\vec{W}) = -\frac{1}{N} \sum_{n=1}^N t_n \ln(y_{\vec{W}}(\vec{x}_n)) + (1 - t_n) \ln(1 - y_{\vec{W}}(\vec{x}_n))$$

$$\nabla E_D(\vec{W}) = \frac{1}{N} \sum_{n=1}^N (y_{\vec{W}}(\vec{x}_n) - t_n) \vec{x}_n$$

5

Perceptron Multiclasse

(2D et 3 classes)



$$y_{\vec{W}}(\vec{x}) = \begin{bmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \\ w_{2,0} & w_{2,1} & w_{2,2} \end{bmatrix} \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix}$$


6

3

Perceptron Multiclasse

Exemple

 $(1.1, -2.0)$



$$y_w(\vec{x}) = \begin{bmatrix} -2 & -3.6 & 0.5 \\ -4 & 2.4 & 4.1 \\ -6 & 4 & -4.9 \end{bmatrix} \begin{bmatrix} 1 \\ 1.1 \\ -2 \end{bmatrix} = \begin{bmatrix} -6.9 \\ -9.6 \\ 8.2 \end{bmatrix} \quad \begin{array}{ll} \text{Classe 0} & \\ \text{Classe 1} & \\ \text{Classe 2} & \end{array}$$

7

Perceptron Multiclasse

Fonction de coût (*Perceptron loss – One-VS-One*)

$$E_D(W) = \frac{1}{N} \sum_{\vec{x}_n \in M} (\vec{W}_j^T \vec{x}_n - \vec{W}_{t_n}^T \vec{x}_n)$$

↑ Somme sur l'ensemble des données mal classées
↑ Score de la bonne classe
↑ Score de la classe faussement prédictée par le modèle

8

Perceptron Multiclasse

Fonction de coût (*Perceptron loss – One-VS-One*)

$$E_D(W) = \frac{1}{N} \sum_{\vec{x}_n \in M} \underbrace{\left(\vec{W}_j^T \vec{x}_n - \vec{W}_{t_n}^T \vec{x}_n \right)}_{E_{\vec{x}_n}}$$

$$\nabla_{W_j} E_{\vec{x}_n} = \vec{x}_n$$

$$\nabla_{W_{t_n}} E_{\vec{x}_n} = -\vec{x}_n$$

$$\nabla_{W_i} E_{\vec{x}_n} = 0 \quad \forall i \neq j \text{ et } t_n$$

9

Perceptron Multiclasse one-vs-one

Descente de gradient stochastique (version naïve, batch_size = 1)

```
Initialiser W
k=0, i=0
DO k=k+1
    FOR n = 1 to N
        j = arg max WT  $\vec{x}_n$ 
        IF j ≠ ti THEN /* donnée mal classée*/
             $\vec{w}_j = \vec{w}_j - \eta \vec{x}_n$ 
             $\vec{w}_{t_i} = \vec{w}_{t_i} + \eta \vec{x}_n$ 
UNTIL toutes les données sont bien classées.
```

10

Perceptron Multiclasse one-vs-one

Exemple d'entraînement ($\eta=1$)

$$\vec{x}_n = (0.4, -1), t_n = 0$$

$$y_w(\vec{x}) = \begin{bmatrix} -2 & 3.6 & 0.5 \\ -4 & 2.4 & 4.1 \\ -6 & 4 & -4.9 \end{bmatrix} \begin{bmatrix} 1 \\ 0.4 \\ -1 \end{bmatrix} = \begin{bmatrix} -1.6 \\ -7.1 \\ 0.5 \end{bmatrix}$$

Classe 0
Classe 1
Classe 2

FAUX!

11

11

Perceptron Multiclasse

Exemple d'entraînement ($\eta=1$)

$$\vec{x}_n = (0.4, -1.0), t_n = 0$$

$$\vec{w}_0 \leftarrow \vec{w}_0 + \vec{x}_n \quad \begin{bmatrix} -2.0 \\ 3.6 \\ 0.5 \end{bmatrix} + \begin{bmatrix} 1 \\ 0.4 \\ -1 \end{bmatrix} = \begin{bmatrix} -1.0 \\ 4.0 \\ -0.5 \end{bmatrix}$$

$$\vec{w}_2 \leftarrow \vec{w}_2 - \vec{x}_n \quad \begin{bmatrix} -6.0 \\ 4.0 \\ -4.9 \end{bmatrix} - \begin{bmatrix} 1 \\ 0.4 \\ -1 \end{bmatrix} = \begin{bmatrix} -7.0 \\ 3.6 \\ -3.9 \end{bmatrix}$$

12

12

Hinge Multiclasse

Fonction de coût (**Hinge loss** ou **SVM loss – One vs one**)

$$E_D(W) = \frac{1}{N} \sum_{\vec{x}_n \in M} \max(0, 1 + \vec{W}_j^T \vec{x}_n - \vec{W}_{t_n}^T \vec{x}_n)$$

Score de la mauvaise classe prédite

Somme sur l'ensemble des
Données mal classées

Score de la bonne classe

13

Hinge Multiclasse

Fonction de coût (**Hinge loss** ou **SVM loss – One vs One**)

$$E_D(W) = \underbrace{\frac{1}{N} \sum_{\vec{x}_n \in M} \max(0, 1 + \vec{W}_j^T \vec{x}_n - \vec{W}_{t_n}^T \vec{x}_n)}_{E_{\vec{x}_n}}$$

$$\nabla_{W_{t_n}} E_{\vec{x}_n} = \begin{cases} -\vec{x}_n & \text{si } \vec{W}_{t_n}^T \vec{x}_n < \vec{W}_j^T \vec{x}_n + 1 \\ 0 & \text{sinon} \end{cases}$$

$$\nabla_{W_j} E_{\vec{x}_n} = \begin{cases} \vec{x}_n & \text{si } \vec{W}_{t_n}^T \vec{x}_n < \vec{W}_j^T \vec{x}_n + 1 \text{ et } j \neq t_n \\ 0 & \text{sinon} \end{cases}$$

14

Hinge Multiclasse one-vs-one

Descente de gradient stochastique (version naïve, batch_size = 1)

```


Initialiser  $\mathbf{W}$ 
k=0, i=0
DO k=k+1
    FOR n = 1 to N
        IF  $\vec{W}_{t_n}^T \vec{x}_n < \vec{W}_j^T \vec{x}_n + 1$  THEN
             $\vec{w}_{t_n} = \vec{w}_{t_n} - \eta \vec{x}_n$ 
             $\vec{w}_j = \vec{w}_j + \eta \vec{x}_n$ 
    UNTIL toutes les données sont bien classées.

```

Au TP1, implanter cette version « naïve »

15


Régression logistique multiclasse



Softmax


19

Régression logistique multiclasse



20

Régression logistique multiclasse



'airplane'	$\Rightarrow t = [1000000000]$
'automobile'	$\Rightarrow t = [0100000000]$
'bird'	$\Rightarrow t = [0010000000]$
'cat'	$\Rightarrow t = [0001000000]$
'deer'	$\Rightarrow t = [0000100000]$
'dog'	$\Rightarrow t = [0000010000]$
'frog'	$\Rightarrow t = [0000001000]$
'horse'	$\Rightarrow t = [0000000100]$
'ship'	$\Rightarrow t = [0000000010]$
'truck'	$\Rightarrow t = [0000000001]$

Étiquettes de classe : one-hot vector

21

Régression logistique multiclasse

Fonction de coût est une **entropie croisée** (*cross entropy loss*)

$$E_D(W) = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_{W_k}(\vec{x}_n)$$

$$\nabla E_D(W) = \frac{1}{N} \sum_{n=1}^N \vec{x}_n (y_W(\vec{x}_n) - \vec{t}_n)^T$$


22

Tous les détails du gradient de
l'entropie croisée :


jodoin.github.io/cours/ift603/softmax_grad.html

Au tp1: implanter une **version naïve** avec des boucles for
et une **version vectorisée SANS boucle for.**

23



24



25

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût
→ Taux d'apprentissage ou “learning rate”.

Descente de gradient stochastique

```
Initialiser w
k=0
FAIRE k=k+1
FOR n = 1 to N
    w = w -  $\eta^{[k]} \nabla E(\vec{x}_n)$ 
JUSQU'À ce que toutes les données
soient bien classées ou k==MAX_ITER
```

Optimisation par *Batch*

```
Initialiser w
k=0
FAIRE k=k+1
    w = w -  $\eta^{[k]} \sum_i \nabla E(\vec{x}_i)$ 
JUSQU'À ce que toutes les données
soient bien classées ou k==MAX_ITER
```

Parfois $\eta^{[k]} = cst / k$

26

Maintenant, rendons le réseau


profond
profond

Maintenant, rendons le réseau

27

12

2D, 2Classes, Régression logistique linéaire




28

28

2D, 2Classes, Réseau à 1 couche cachée


Maintenant, ajoutons arbitrairement 3 neurones



29


2D, 2Classes, Réseau à 1 couche cachée

Puisque les poids sont entre la couche d'entrée et la première couche
on va les identifier à l'aide de l'**indice [0]**



30

2D, 2Classes, Réseau à 1 couche cachée




NOTE: à la sortie de la première couche, on a 3 réels calculés ainsi

$$\sigma \left(\begin{bmatrix} w_{0,0}^{[0]} & w_{0,1}^{[0]} & w_{0,2}^{[0]} \\ w_{1,0}^{[0]} & w_{1,1}^{[0]} & w_{1,2}^{[0]} \\ w_{2,0}^{[0]} & w_{2,1}^{[0]} & w_{2,2}^{[0]} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ 1 \end{bmatrix} \right)$$

31

2D, 2Classes, Réseau à 1 couche cachée




NOTE: représentation plus simple de la sortie de la 1^{ère} couche (3 réels)

$$\sigma(W^{[0]}\vec{x})$$

32


2D, 2Classes, Réseau à 1 couche cachée

Si on veut effectuer une **classification 2 classes** via une **régression logistique** (donc une fonction coût par « entropie croisée ») on doit ajouter **un neurone de sortie**.




33

2D, 2Classes, Réseau à 1 couche cachée




34

2D, 2Classes, Réseau à 1 couche cachée




Ce réseau possède au total **13 paramètres**



35

2D, 2Classes, Réseau à 1 couche cachée



Plus on augmente le nombre de neurones dans la couche cachée,
plus on **augmente la capacité du système**.

Ce réseau a $5 \times 3 + 1 \times 6 = \textcolor{red}{21}$ paramètres

36

36


NOTE Importante

Le but de la première couche est de **projeter les données d'entrée** (ici $\vec{x} \in R^2$) vers un espace dimensionnel plus grand (ici $\sigma(W^{[0]}\vec{x}) \in R^5$) là où les **classes sont linéairement séparables**.

Car il ne faut pas oublier que la **couche de sortie** est une **régression logistique linéaire**.

Par conséquent, au lieu de fixer nous même la fonction de base, on laisse le **réseau l'apprendre**.

End-to-end training




37

37


Nombre de neurons VS Capacité

Aucun neurone caché




Classification linéaire
Underfitting
(pas assez de capacité)

12 neurones cachés



Classification non linéaire
BON RÉSULTAT
(bonne capacité)

60 neurones cachés




Classification non linéaire
Over fitting
(trop grande capacité)

<http://cs.stanford.edu/people/karpathy/convnetjs/demo/classify2d.html>

38

2D, 2Classes, Réseau à 1 couche cachée

Couche d'entrée Couche cachée Couche de sortie




39

39

kD, 2Classes, Réseau à 1 couche cachée

Couche d'entrée Couche cachée Couche de sortie



Ou peut facilement augmenter la dimensionnalité des données d'entrée.
Cela n'a pour effet que **d'augmenter le nombre de colonnes dans $W^{[0]}$**


Ce réseau a $5 \times (k+1) + 1 \times 6$ paramètres

40

40

kD, 2Classes, Réseau à 2 couches cachées

Couche d'entrée Couche cachée 1 Couche cachée 2 Couche de sortie



$$W^{[0]} \in R^{5 \times k+1}$$

$$W^{[1]} \in R^{3 \times 6}$$

$$\vec{w}^{[2]} \in R^4$$

En ajoutant une couche cachée, on ajoute une multiplication matricielle


Ce réseau a $5 \times (k+1) + 6 \times 3 + 1 \times 4$ paramètres

41

41

kD, 2 Classes, Réseau à 4 couches cachées

Couche d'entrée Couche cachée 1 Couche cachée 2 Couche cachée 3 Couche cachée 4 Couche de sortie



$$W^{[0]} \in R^{5 \times k+1}$$

$$W^{[1]} \in R^{3 \times 6}$$

$$W^{[2]} \in R^{4 \times 4}$$

$$W^{[3]} \in R^{5 \times 7}$$

$$\vec{w}^{[4]} \in R^8$$


Ce réseau a $5 \times (k+1) + 6 \times 3 + 4 \times 4 + 7 \times 5 + 1 \times 8$ paramètres

42

42

kD, 2 Classes, Réseau à 4 couches cachées

Couche d'entrée Couche cachée 1 Couche cachée 2 Couche cachée 3 Couche cachée 4 Couche de sortie



$$W^{[0]} \in R^{5 \times k+1}$$

$$W^{[1]} \in R^{3 \times 6}$$

$$W^{[2]} \in R^{4 \times 4}$$


$$W^{[3]} \in R^{5 \times 7}$$

$$\vec{w}^{[4]} \in R^8$$

NOTE : plus on augmente le nombre de couches, plus le réseau devient **profond** et plus on **augmente la capacité** du réseau.


43

Réseau de neurones multicouches = apprendre une fonction de base




44

Example



45




46



47




48



49

kD, 4 Classes, Réseau à 4 couches cachées

Couche d'entrée Couche cachée 1 Couche cachée 2 Couche cachée 3 Couche cachée 4 Couche de sortie




50

kD, 4 Classes, Réseau à 4 couches cachées


Couche d'entrée Couche cachée 1 Couche cachée 2 Couche cachée 3 Couche cachée 4 Couche de sortie

$$\begin{aligned} W^{[0]} &\in R^{5 \times k+1} \\ W^{[1]} &\in R^{3 \times 6} \\ W^{[2]} &\in R^{4 \times 4} \\ W^{[3]} &\in R^{5 \times 7} \\ W^{[4]} &\in R^{4 \times 8} \end{aligned}$$



51

kD, 4 Classes, Réseau à 4 couches cachées



52

Simulation

<http://cs.stanford.edu/people/karpathy/convnetjs/demo/classify2d.html>

53

Comment faire une prédiction?

Ex.: faire transiter un signal de **l'entrée à la sortie**
d'un réseau à **3 couches cachées**

```
import numpy as np

def sigmoid(x):
    return 1.0 / (1.0+np.exp(-x))

x = np.insert(x,0,1) # Ajouter biais
H1 = sigmoid(np.dot(W0,x))
H1 = np.insert(H1,0,1) # Ajouter biais } Couche 1

H2 = sigmoid(np.dot(W1,H1))
H2 = np.insert(H2,0,1) # Ajouter biais } Couche 2

H3 = sigmoid(np.dot(W2,H2))
H3 = np.insert(H3,0,1) # Ajouter biais } Couche 3

y_pred = np.dot(W3,H3) } Couche sortie
```

Forward pass

54

Comment optimiser les paramètres?

0- Partant de

$$W = \arg \min_W E_D(W) + \lambda R(W)$$

Trouver une fonction de régularisation. En général

$$R(W) = \|W\|_1 \text{ ou } \|W\|_2$$

55

55

26

Comment optimiser les paramètres?

1- Trouver une loss $E_D(W)$ comme par exemple

Hinge loss

Entropie croisée (*cross entropy*)



N'oubliez pas d'ajuster la sortie du réseau en fonction de la loss que vous aurez choisi.

cross entropy => Softmax

56

Comment optimiser les paramètres?

2- Calculer le gradient de la loss par rapport à chaque paramètre

$$\frac{\partial(E_D(W) + \lambda R(W))}{\partial w_{a,b}^{[c]}}$$

et lancer un algorithme de descente de gradient pour mettre à jour les paramètres.

$$w_{a,b}^{[c]} = w_{a,b}^{[c]} - \eta \frac{\partial(E_D(W) + \lambda R(W))}{\partial w_{a,b}^{[c]}}$$

57

57

Comment optimiser les paramètres?


$$\frac{\partial (E_D(W) + \lambda R(W))}{\partial w_{a,b}^{[c]}} \Rightarrow \text{calculé à l'aide d'une rétropropagation}$$

58

58

Disparition du gradient

(vanishing gradient)



Malheureusement, l'entraînement d'un **réseau profond** avec **rétro-propagation** et des fonctions d'activations **sigmoïdales** entraîne des problèmes de

disparition du gradient




59

59

On résoud le problème de la
disparition du gradient à l'aide
d'autres fonctions d'activations

60

Fonction d'activation



Sigmoïde

$$\sigma(x) = \frac{1}{1+e^{-x}}$$


- Ramène les valeurs entre 0 et 1
- Historiquement populaire

3 Problèmes :

- Un neurone saturé a pour effet de « tuer » les gradients

61

Fonction d'activation



Sigmoïde

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$


- Ramène les valeurs entre 0 et 1
- Historiquement populaire

3 Problèmes :

- Un neurone saturé a pour effet de « **tuer** » les **gradients**
- Sortie d'une sigmoïde n'est **pas centrée à zéro**.

62

Qu'arrive-t-il lorsque le vecteur d'entrée \vec{h} d'un neurone est toujours positif?




Le gradient par rapport à \vec{w} est ... **Positif? Négatif?**

Réponse : <https://rohanvarma.me/inputnormalization/>

63

Fonction d'activation



Sigmoïde

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$


- Ramène les valeurs entre 0 et 1
- Historiquement populaire

3 Problèmes :

- Un neurone saturé a pour effet de « **tuer** » les **gradients**
- Sortie d'une sigmoïde n'est **pas centrée à zéro**.
- `exp()` est **coûteux** lorsque le nombre de neurones est élevé.

64

Fonction d'activation




- Ramène les valeurs entre -1 et 1
- **Sortie centrée à zéro** 😊
- **Disparition du gradient** lorsque la fonction sature ☹

[LeCun et al., 1991]

65

Fonction d'activation

$$\text{ReLU}(x) = \max(0, x)$$




- Aucune **saturation** ☺
- Super **rapide** ☺
- **Convergence plus rapide** que sigmoïde/tanh (5 à 10x) ☺
- Sortie **non centrée à zéro** ☹
- **Un inconvénient :** qu'arrive-t-il au gradient lorsque $x < 0$? ☹

[Krizhevsky et al., 2012]

66

Fonction d'activation

$$\text{ELU}(x) = \begin{cases} x & \text{si } x > 0 \\ \alpha(e^x - 1) & \text{sinon} \end{cases}$$




- Tous les avantages de **ReLU**☺
- Sortie plus « **centrée à zéro** » ☺
- **Converge plus rapide** que sigmoïde/tanh (5 à 10x) ☺
- **Gradients meurent plus lentement** ☹
- $\exp()$ est **coûteux** ☹

[Clevert et al., 2015]

67

Fonction d'activation

$$\text{LReLU}(x) = \max(0.01x, x)$$




- Aucune **saturation** ☺
- Super **rapide** ☺
- **Converge plus rapide** que sigmoïde/tanh (5 à 10x) ☺
- **Gradients ne meurent pas** ☺
- 0.01 est un **hyperparamètre** ☺

[Mass et al., 2013]
[He et al., 2015]

68

Fonction d'activation

$$\text{PReLU}(x) = \max(\alpha x, x)$$



- Aucune **saturation** ☺
- Super **rapide** ☺
- **Converge plus rapide** que sigmoïde/tanh (5 à 10x) ☺
- **Gradients ne meurent pas** ☺
- α appris lors de la rétro-propagation ☺

[Mass et al., 2013]
[He et al., 2015]

69

Fonction d'activation

Plusieurs autres fonctions d'activation ont été proposée :

- GELU (Gaussian Error Linear Unit)
- SiLU (Sigmoid Linear Unit)
- Swish
- GLU (Gated Linear Unit)
- ReGLU (Rectified Gated Linear Unit)
- GEGLU (Gaussian Error Gated Linear Unit)
- SwiGLU (Swish-Gated Linear Unit)
- Etc.

À vous de les découvrir!

https://vitalab.github.io/blog/2024/08/20/new_activation_functions.html

70

En pratique

- Par défaut, le gens utilisent **ReLU**.
- Essayez **Leaky ReLU / PReLU / ELU / etc.**
- Essayez **tanh** mais n'attendez-vous pas à grand chose
- **Ne pas utiliser de sigmoïde** sauf à la sortie d'un réseau 2 classes ou pour des modèles d'attention.

71

34

Les bonnes pratiques

72

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût
→ Taux d'apprentissage ou "learning rate".

Descente de gradient stochastique

```
Initialiser w
k=0
FAIRE k=k+1
  FOR n = 1 to N
     $\mathbf{w} = \mathbf{w} - \eta^{[k]} \nabla E(\vec{x}_n)$ 
  JUSQU'À ce que toutes les données
  soient bien classées ou k== MAX_ITER
```

Optimisation par Batch

```
Initialiser w
k=0
FAIRE k=k+1
   $\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_i \nabla E(\vec{x}_i)$ 
  JUSQU'À ce que toutes les données
  soient bien classées ou k== MAX_ITER
```

$$\text{Parfois } \eta^{[k]} = cst / k$$

73

Optimisation



Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût
→ Taux d'apprentissage ou “learning rate”.

Optimisation par **mini-batch**

Initialiser \mathbf{w}

$k=0$

FAIRE $k=k+1$

FAIRE $n=0$ à N par sauts de **MBS** /**Mini-batch size**/

$$\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\vec{x}_i)$$

JUSQU'À ce que toutes les données soient bien classées ou
 $k==\text{MAX_ITER}$

}] Itération

74

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

→ Gradient de la fonction de coût
→ Taux d'apprentissage ou “learning rate”.

Optimisation par **mini-batch**

Initialiser \mathbf{w}

$k=0$

FAIRE $k=k+1$

FAIRE $n=0$ à N par sauts de **MBS** /**Mini-batch size**/

$$\mathbf{w} = \mathbf{w} - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\vec{x}_i)$$


JUSQU'À ce que toutes les données soient bien classées ou
 $k==\text{MAX_ITER}$

}] Epoch

75

Mini-batch = **vectorisation** de la propagation avant et de la rétro-propagation


76




Propagation avant pour un réseau à 2 couches cachées (7 étapes)

	\vec{x}	$\in IR^4$
Étape 2 \longrightarrow	$W_1 \vec{x}$	$\in IR^5$
	$h(W_1 \vec{x})$	$\in IR^5$
	$W_2 h(W_1 \vec{x})$	$\in IR^3$
	$h(W_2 h(W_1 \vec{x}))$	$\in IR^3$
Étape 6 \longrightarrow	$\vec{W}_3^T (h(W_2 h(W_1 \vec{x})))$	$\in IR$
	$\sigma(\vec{W}_3^T (h(W_2 h(W_1 \vec{x}))))$	$\in IR$

77



78



79

Solution

Il est plus efficace d'effectuer **UNE multiplication matricielle** que **PLUSIEURS matrice-vecteur** (exemple de la 2^e étape, batch de 3)

$$W_1 X = \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \\ w_{41} & w_{42} & w_{43} & w_{44} \\ w_{51} & w_{52} & w_{53} & w_{54} \end{pmatrix} \begin{bmatrix} a & d & h \\ b & e & i \\ c & f & j \\ d & g & k \end{bmatrix} = \begin{bmatrix} u_1 & v_1 & z_1 \\ u_2 & v_2 & z_2 \\ u_3 & v_3 & z_3 \\ u_4 & v_4 & z_4 \\ u_5 & v_5 & z_5 \end{bmatrix}$$

UNE multiplication matricielle

80

Solution

$$\bar{W}_3^T(h(W_2 h(W_1 \vec{x})))$$

Il est plus efficace d'effectuer UNE multiplication matricielle que **PLUSIEURS produits scalaires** (exemple de la 6^e étape, batch de 3)

$$\begin{aligned} (w_1 & \quad w_2 & \quad w_3) \begin{pmatrix} a \\ b \\ c \end{pmatrix} &= (w_1a + w_2b + w_3c) \\ (w_1 & \quad w_2 & \quad w_3) \begin{pmatrix} d \\ e \\ f \end{pmatrix} &= (w_1d + w_2e + w_3f) \\ (w_1 & \quad w_2 & \quad w_3) \begin{pmatrix} g \\ h \\ i \end{pmatrix} &= (w_1g + w_2h + w_3i) \end{aligned} \quad \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix} = Y$$

TROIS produits scalaires

81

Solution

Il est plus efficace d'effectuer **UNE multiplication matricielle** que **PLUSIEURS produits scalaires (exemple de la 6^e étape, batch de 3)**

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix} = Y$$

UNE multiplication matricielle

82

Vectorisation de la propagation avant

En résumé, lorsqu'on propage une « *batch* » de données

Au niveau Neuronal (batch = 1)	Multi. Vecteur-Vecteur	$\vec{W}^T \vec{x} = [w_1 \ w_2 \ w_3] \begin{pmatrix} a \\ b \\ c \end{pmatrix}$
Au niveau Neuronal (batch = 3)	Multi. Vecteur-Matrice	$\vec{W}^T X = [w_1 \ w_2 \ w_3] \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix}$
Au niveau de la couche (batch = 3)	Multi. Matrice-Matrice	$WX = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{bmatrix} \begin{pmatrix} a & d & h \\ b & e & i \\ c & f & j \end{pmatrix}$

83

Conclusion

100% du temps, on combine ensemble les données dans des **mini-batch** de 2 à 32 données.

84

$$X = \begin{bmatrix} | & | & | \\ \vec{x}_1 & \vec{x}_2 & \vec{x}_3 \\ | & | & | \end{bmatrix}$$
$$Y = \begin{bmatrix} \sigma(h(\vec{W}_2 h(W_1 \vec{x}_1))) \\ \sigma(h(\vec{W}_2 h(W_1 \vec{x}_2))) \\ \sigma(h(\vec{W}_2 h(W_1 \vec{x}_3))) \end{bmatrix}^T$$



Vectoriser la rétropropagation

85

Vectoriser la rétropropagation

Exemple simple pour **1 neurone et une batch de 3 données**

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

\vec{w}^T X Y

En supposant qu'on connaît le gradient pour les 3 éléments de Y provenant de la sortie du réseau, comment faire pour propager le gradient vers \vec{w}^T ?

86

Vectoriser la rétropropagation

Exemple simple pour **1 neurone et une batch de 3 données**

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

\vec{w}^T X Y

Rappelons que l'objectif est de faire une **descente de gradient**, i.e.

$$w_1 \leftarrow w_1 - \eta \frac{\partial E}{\partial w_1} \quad w_2 \leftarrow w_2 - \eta \frac{\partial E}{\partial w_2} \quad w_3 \leftarrow w_3 - \eta \frac{\partial E}{\partial w_3}$$

87

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

$$\vec{w}^T \quad X \quad Y$$

Concentrons-nous sur w_1

$$w_1 \leftarrow w_1 - \eta \frac{\partial E}{\partial w_1}$$

$$w_1 \leftarrow w_1 - \eta \frac{\partial E^T}{\partial Y} \frac{\partial Y}{\partial w_1} \quad (\text{par propriété de la dérivée en chaîne})$$

$$w_1 \leftarrow w_1 - \eta \left[\frac{\partial E_1}{\partial Y} \quad \frac{\partial E_2}{\partial Y} \quad \frac{\partial E_3}{\partial Y} \right] \begin{bmatrix} a \\ d \\ g \end{bmatrix}$$

(provient de la rétro-propagation)

$$w_1 \leftarrow w_1 - \eta \left(\frac{\partial E_1}{\partial Y} a + \frac{\partial E_2}{\partial Y} b + \frac{\partial E_3}{\partial Y} c \right)$$

88

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

$$\vec{w}^T \quad X \quad Y$$

Concentrons-nous sur w_1

$$w_1 \leftarrow w_1 - \eta \frac{\partial E}{\partial w_1}$$

$$w_1 \leftarrow w_1 - \eta \frac{\partial E^T}{\partial Y} \frac{\partial Y}{\partial w_1} \quad (\text{par propriété de la dérivée en chaîne})$$

$$w_1 \leftarrow w_1 - \eta \left[\frac{\partial E_1}{\partial Y} \quad \frac{\partial E_2}{\partial Y} \quad \frac{\partial E_3}{\partial Y} \right] \begin{bmatrix} a \\ d \\ g \end{bmatrix}$$

(Puisqu'on a une batch de 3 éléments, on a 3 prédictions et donc 3 gradients)

$$w_1 \leftarrow w_1 - \eta \left(\frac{\partial E_1}{\partial Y} a + \frac{\partial E_2}{\partial Y} b + \frac{\partial E_3}{\partial Y} c \right)$$

89

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

$$\vec{w}^T \quad X \quad Y$$

Donc en résumé ...

$$w_1 \leftarrow w_1 - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} a \\ d \\ g \end{bmatrix}$$

90

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

$$\vec{w}^T \quad X \quad Y$$

Et pour tous les poids

$$w_1 \leftarrow w_1 - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} a \\ d \\ g \end{bmatrix}$$

$$w_2 \leftarrow w_2 - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} b \\ e \\ h \end{bmatrix}$$

$$w_3 \leftarrow w_3 - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} c \\ f \\ i \end{bmatrix}$$

91

$$[w_1 \quad w_2 \quad w_3] \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1a + w_2b + w_3c \\ w_1d + w_2e + w_3f \\ w_1g + w_2h + w_3i \end{pmatrix}^T$$

$$\vec{w}^T \qquad X \qquad Y$$

Et pour tous les poids

$$\begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}^T \leftarrow \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}^T - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}$$

$$\vec{w}^T \leftarrow \vec{w}^T - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y} & \frac{\partial E_2}{\partial Y} & \frac{\partial E_3}{\partial Y} \end{bmatrix} \begin{bmatrix} \frac{\partial Y_1}{\partial w_1} & \frac{\partial Y_1}{\partial w_2} & \frac{\partial Y_1}{\partial w_3} \\ \frac{\partial Y_2}{\partial w_1} & \frac{\partial Y_2}{\partial w_2} & \frac{\partial Y_2}{\partial w_3} \\ \frac{\partial Y_3}{\partial w_1} & \frac{\partial Y_3}{\partial w_2} & \frac{\partial Y_3}{\partial w_3} \end{bmatrix}$$

$$\vec{w}^T \leftarrow \vec{w}^T - \eta \frac{\partial \vec{E}^T}{\partial Y} \frac{\partial Y}{\partial \vec{W}}$$

Matrice jacobienne

92

$$\begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \\ w_{41} & w_{42} & w_{43} & w_{44} \\ w_{51} & w_{52} & w_{53} & w_{54} \end{bmatrix} \begin{bmatrix} a & d & h \\ b & e & i \\ c & f & j \\ d & g & k \end{bmatrix} = \begin{bmatrix} u_1 v_1 z_1 \\ u_2 v_2 z_2 \\ u_3 v_3 z_3 \\ u_4 v_4 z_4 \\ u_5 v_5 z_5 \end{bmatrix}$$

$$W \qquad X \qquad Y$$

Même chose pour **1 couche 5x4 et une batch de 3 données**

$$W \leftarrow W^T - \eta \begin{bmatrix} \frac{\partial E_1}{\partial Y_1} & \frac{\partial E_2}{\partial Y_1} & \frac{\partial E_3}{\partial Y_1} \\ \frac{\partial E_1}{\partial Y_2} & \frac{\partial E_2}{\partial Y_2} & \frac{\partial E_3}{\partial Y_2} \\ \frac{\partial E_1}{\partial Y_3} & \frac{\partial E_2}{\partial Y_3} & \frac{\partial E_3}{\partial Y_3} \\ \frac{\partial E_1}{\partial Y_4} & \frac{\partial E_2}{\partial Y_4} & \frac{\partial E_3}{\partial Y_4} \\ \frac{\partial E_1}{\partial Y_5} & \frac{\partial E_2}{\partial Y_5} & \frac{\partial E_3}{\partial Y_5} \end{bmatrix} \begin{bmatrix} a & b & c & d \\ d & e & f & g \\ h & i & j & k \end{bmatrix}$$

$$W^T \leftarrow W^T - \eta \frac{\partial E^T}{\partial Y} \frac{\partial Y}{\partial W}$$

93

Vectorisation de la rétro-propagation

En résumé, lorsqu'on rétro-propage le gradient d'une batch

Au niveau
neuronal

Multi.
Vecteur-Matrice

$$W_i \leftarrow W_i - \eta \frac{\partial \vec{E}^T}{\partial Y} \frac{\partial Y}{\partial W_i}$$
$$W_i \leftarrow W_i - \eta \frac{\partial \vec{E}^T}{\partial Y} X_i$$

Au niveau
de la couche

Multi.
Matrice-Matrice

$$W^T \leftarrow W^T - \eta \frac{\partial E^T}{\partial Y} \frac{\partial Y}{\partial W}$$
$$W^T \leftarrow W^T - \eta \frac{\partial E^T}{\partial Y} X$$


94

Vectorisation de l'entropie croisée

95

46


Rappel : entropie croisée, 1 donnée



$$\begin{aligned} L_{\vec{x}}(W) &= - \sum_{k=1}^K t_{kn} \ln y_{W_k}(\vec{x}) \\ &= -\vec{t}^T \ln y_W(\vec{x}) \end{aligned}$$

$$\nabla_W L_{\vec{x}}(W) = (y_W(\vec{x}_n) - \vec{t}) \vec{x}^T$$


96



Propagation avant d'une donnée pour un réseau à **1 couche** (3 étapes)

\vec{x} $W \vec{x}$ $Y = SM(W\vec{x})$ $L = -\vec{t}^T \ln Y$	$\in \mathbb{R}^4$ $\in \mathbb{R}^3$ $\in \mathbb{R}^3$ $\in \mathbb{R}$
--	--

97




Exemple de perte:

$$Y = \begin{bmatrix} 0.1 \\ 0.6 \\ 0.3 \end{bmatrix} \text{ et } \vec{t} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\begin{aligned} L &= -[0 \ 0 \ 1] \ln \begin{bmatrix} 0.1 \\ 0.6 \\ 0.3 \end{bmatrix} \\ &= -[0 \ 0 \ 1] \begin{bmatrix} -2.3 \\ -0.5 \\ -1.2 \end{bmatrix} \\ &= 1.2 \end{aligned}$$


98




Exemple de gradient

$$\begin{aligned} \nabla_W L &= (Y - \vec{t}) \vec{x}^T \\ &= \left(\begin{bmatrix} 0.1 \\ 0.6 \\ 0.3 \end{bmatrix} - \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right) [1, 2, 3, 4] \\ &= \begin{bmatrix} 0.1 \\ 0.6 \\ -0.7 \end{bmatrix} [1, 2, 3, 4] \\ &= \begin{bmatrix} .1 & .2 & .3 & .4 \\ .6 & 1.2 & 1.8 & 2.4 \\ .3 & .6 & .9 & 1.2 \end{bmatrix} \in \mathbb{R}^{3 \times 4} \end{aligned}$$


99



100



101



Exemple de gradient


$$\begin{aligned}
 \nabla_W L &= (Y - T) X \\
 &= \left(\begin{bmatrix} 0.1 & 0.7 \\ 0.6 & 0.25 \\ 0.3 & 0.05 \end{bmatrix} - \begin{bmatrix} 0 & 1 \\ 0 & 0 \\ 1 & 0 \end{bmatrix} \right) \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{bmatrix} \\
 &= \begin{bmatrix} 0.1 & -0.3 \\ 0.6 & 0.25 \\ -0.7 & 0.05 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{bmatrix} \\
 &= \begin{bmatrix} -1.4 & -1.6 & -1.8 & -2 \\ 1.8 & 2.7 & 3.6 & 4.4 \\ -.5 & -1.1 & -1.7 & -2.4 \end{bmatrix}
 \end{aligned}$$

102

Pour plus de détails:

<https://medium.com/datathings/vectorized-implementation-of-back-propagation-1011884df84>
<https://peterroelants.github.io/posts/neural-network-implementation-part04/>

103



104

Comment initialiser un réseau de
neurones?

$W = ?$

105

Initialisation

Première idée: faibles valeurs aléatoires
(Gaussienne $\mu = 0, \sigma = 0.01$)

```
W_i=0.01*np.random.randn(H_i,H_im1)
```


Fonctionne bien pour de petits réseaux mais
pas pour des réseaux profonds.



E.g. réseau à 10 couches avec 500 neurones par couche et des **tanh** comme fonctions d'activation.

106

Rappel tanh...




107

Histogrammes des valeurs de sortie des 10 couches.

```
input layer had mean 0.000927 and std 0.999388
hidden layer 1 had mean -0.000117 and std 0.213081
hidden layer 2 had mean -0.000001 and std 0.047551
hidden layer 3 had mean -0.000002 and std 0.010630
hidden layer 4 had mean 0.000001 and std 0.002378
hidden layer 5 had mean 0.000002 and std 0.000532
hidden layer 6 had mean -0.000000 and std 0.000119
hidden layer 7 had mean 0.000000 and std 0.000026
hidden layer 8 had mean -0.000000 and std 0.000006
hidden layer 9 had mean 0.000000 and std 0.000001
hidden layer 10 had mean -0.000000 and std 0.000000
```

L'activation des couches devient zéro!




Crédit <http://cs231n.stanford.edu/>

108

Histogrammes des valeurs de sortie des 10 couches.


```
input layer had mean 0.000927 and std 0.999388
hidden layer 1 had mean -0.000117 and std 0.213081
hidden layer 2 had mean -0.000001 and std 0.047551
hidden layer 3 had mean -0.000002 and std 0.010630
hidden layer 4 had mean 0.000001 and std 0.002378
hidden layer 5 had mean 0.000002 and std 0.000532
hidden layer 6 had mean -0.000000 and std 0.000119
hidden layer 7 had mean 0.000000 and std 0.000026
hidden layer 8 had mean -0.000000 and std 0.000006
hidden layer 9 had mean 0.000000 and std 0.000001
hidden layer 10 had mean -0.000000 and std 0.000000
```

Vous voyez ce qui arrive à la *forward pass* et la *rétropropagation*?




Crédit <http://cs231n.stanford.edu/>


109




110



111



112




113

```
W_i=np.random.randn(H_i,H_im1)/np.sqrt(H_im1)
```

input layer had mean 0.000501 and std 0.999444
hidden layer 1 had mean 0.398623 and std 0.582273
hidden layer 2 had mean 0.272352 and std 0.483795
hidden layer 3 had mean 0.186976 and std 0.279912
hidden layer 4 had mean 0.136442 and std 0.198685
hidden layer 5 had mean 0.099568 and std 0.149299
hidden layer 6 had mean 0.072234 and std 0.193280
hidden layer 7 had mean 0.049775 and std 0.072748
hidden layer 8 had mean 0.035138 and std 0.051572
hidden layer 9 had mean 0.025404 and std 0.038583
hidden layer 10 had mean 0.018468 and std 0.026876

Par contre en utilisant ReLU
on a encore un problème




Crédit <http://cs231n.stanford.edu/>

114

```
W_i=np.random.randn(H_i,H_im1)/np.sqrt(H_im1/2)
```

input layer had mean 0.000501 and std 0.999444
hidden layer 1 had mean 0.562488 and std 0.825232
hidden layer 2 had mean 0.553614 and std 0.827835
hidden layer 3 had mean 0.545867 and std 0.813855
hidden layer 4 had mean 0.565396 and std 0.826902
hidden layer 5 had mean 0.547678 and std 0.834092
hidden layer 6 had mean 0.587103 and std 0.860035
hidden layer 7 had mean 0.596867 and std 0.870616
hidden layer 8 had mean 0.623214 and std 0.889348
hidden layer 9 had mean 0.567498 and std 0.845357
hidden layer 10 had mean 0.552531 and std 0.84452

He et al., 2015
(note additional /2)




Crédit <http://cs231n.stanford.edu/>

115

Prétraitement des données

Centrer et normaliser les données d'entrée



116

Les « sanity checks » ou vérifications diligentes

117

Sanity checks

1. Toujours s'assurer qu'une initialization aléatoire donne une **perte (loss) maximale**

Exemple : pour le cas **10 classes**, une **régularisation à 0** et une **entropie croisée**.

$$E_D(W) = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_{W,k}(\bar{x}_n)$$

Si l'initialisation est aléatoire, alors la probabilité sera en moyenne égale pour chaque classe

$$\begin{aligned} E_D(W) &= -\frac{1}{N} \sum_{n=1}^N \ln \frac{1}{10} \\ &= \ln(10) \\ &= 2.30 \end{aligned}$$

118

Sanity checks

1. Toujours s'assurer qu'une initialization aléatoire donne une **perte (loss) maximale**

Exemple : pour le cas **10 classes**, une **régularisation à 0** et une **entropie croisée**.

```
def init_two_layer_model(input_size, hidden_size, output_size):
    # initialize a model
    model = {}
    model['W1'] = 0.0001 * np.random.randn(input_size, hidden_size)
    model['b1'] = np.zeros(hidden_size)
    model['W2'] = 0.0001 * np.random.randn(hidden_size, output_size)
    model['b2'] = np.zeros(output_size)
    return model
```

```
model = init_two_layer_model(32*32*3, 50, 10) # input size, hidden size, number of classes
loss, grad = two_layer_net(X_train, model, y_train, 0.0) # disable regularization
```

2.30261216167

loss ~2.3.
"correct" for
10 classes

returns the loss and the
gradient for all parameters

Crédit <http://cs231n.stanford.edu>

119

Sanity checks

2. Et lorsqu'on **augmente la régularisation**, la perte augmente aussi

```
def init_two_layer_model(input_size, hidden_size, output_size):
    # initialize a model
    model = {}
    model['W1'] = 0.0001 * np.random.randn(input_size, hidden_size)
    model['b1'] = np.zeros(hidden_size)
    model['W2'] = 0.0001 * np.random.randn(hidden_size, output_size)
    model['b2'] = np.zeros(output_size)
    return model
```

```
model = init_two_layer_model(32*32*3, 50, 10) # input size, hidden size, number of classes
loss, grad = two_layer_net(X_train, model, y_train[1e3]) crank up regularization
print loss
```

3.06859716482

loss went up, good. (sanity check)

Crédit <http://cs231n.stanford.edu/>

120

Sanity checks

3. Toujours s'assurer qu'on peut « **over-fitter** » sur un petit nombre de données.

Lets try to train now...

Tip: Make sure that you can overfit very small portion of the training data

Very small loss, train accuracy 1.00, nice!

```
model = init_two_layer_model(32*32*3, 50, 10) # input size, hidden size, number of classes
trainer = (classifierTrainer())
X_tiny = X_train[:20] # take 20 examples
y_tiny = y_train[:20]
best_model, stats = trainer.train(X_tiny, y_tiny, X_tiny, y_tiny,
                                  model=two_layer_net,
                                  num_epochs=200, reg=0.0,
                                  update='sgd', learning_rate_decay=1,
                                  sample_batches = False,
                                  learning_rate=1e-3, verbose=True)


Finished epoch 1 / 200: cost 2.405693, train: 0.400000, val 0.400000, lr 1.000000e-03
Finished epoch 2 / 200: cost 2.382364, train: 0.450000, val 0.450000, lr 1.000000e-03
Finished epoch 3 / 200: cost 2.301049, train: 0.600000, val 0.600000, lr 1.000000e-03
Finished epoch 4 / 200: cost 2.301196, train: 0.650000, val 0.650000, lr 1.000000e-03
Finished epoch 5 / 200: cost 2.300444, train: 0.650000, val 0.650000, lr 1.000000e-03
Finished epoch 6 / 200: cost 2.282664, train: 0.550000, val 0.550000, lr 1.000000e-03
Finished epoch 7 / 200: cost 2.293664, train: 0.600000, val 0.600000, lr 1.000000e-03
Finished epoch 8 / 200: cost 2.285996, train: 0.550000, val 0.550000, lr 1.000000e-03
Finished epoch 9 / 200: cost 2.268994, train: 0.550000, val 0.550000, lr 1.000000e-03
Finished epoch 10 / 200: cost 2.234787, train: 0.500000, val 0.500000, lr 1.000000e-03
Finished epoch 11 / 200: cost 2.234787, train: 0.500000, val 0.500000, lr 1.000000e-03
Finished epoch 12 / 200: cost 2.076862, train: 0.500000, val 0.500000, lr 1.000000e-03
Finished epoch 13 / 200: cost 1.974499, train: 0.400000, val 0.400000, lr 1.000000e-03
Finished epoch 14 / 200: cost 1.858886, train: 0.400000, val 0.400000, lr 1.000000e-03
Finished epoch 15 / 200: cost 1.774398, train: 0.450000, val 0.450000, lr 1.000000e-03
Finished epoch 16 / 200: cost 1.717438, train: 0.450000, val 0.450000, lr 1.000000e-03
Finished epoch 17 / 200: cost 1.642358, train: 0.500000, val 0.500000, lr 1.000000e-03
Finished epoch 18 / 200: cost 1.535239, train: 0.600000, val 0.590000, lr 1.000000e-03
Finished epoch 19 / 200: cost 1.421527, train: 0.600000, val 0.590000, lr 1.000000e-03
...
Finished epoch 195 / 200: cost 0.082650, train: 1.000000, val 1.000000, lr 1.000000e-03
Finished epoch 196 / 200: cost 0.002674, train: 1.000000, val 1.000000, lr 1.000000e-03
Finished epoch 197 / 200: cost 0.002655, train: 1.000000, val 1.000000, lr 1.000000e-03
Finished epoch 198 / 200: cost 0.002655, train: 1.000000, val 1.000000, lr 1.000000e-03
Finished epoch 199 / 200: cost 0.092017, train: 1.000000, val 1.000000, lr 1.000000e-03
Finished epoch 200 / 200: cost 0.002597, train: 1.000000, val 1.000000, lr 1.000000e-03
finished optimization. best validation accuracy: 1.000000
```

Crédit <http://cs231n.stanford.edu/>

121

Sanity checks

4. Toujours visualiser les courbes d'apprentissage et de validation




Source: <https://www.learnopencv.com/wp-content/uploads/2017/11/cnn-keras-curves-without-aug.jpg>

122

Sanity checks

4. Toujours visualiser les courbes d'apprentissage et de validation



Credit <http://cs231n.stanford.edu>

123

Sanity checks

5. Toujours vérifier la validité d'un gradient

Comme on l'a vu, calculer un gradient est sujet à erreur. Il faut donc toujours s'assurer que nos gradients sont bons au fur et à mesure qu'on écrit notre code. En voici la meilleure façon

Rappel

Approximation numérique de la dérivée

$$\frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

124

Sanity checks

5. Toujours vérifier la validité d'un gradient

On peut facilement calculer un gradient à l'aide d'une approximation numérique.

Rappel

Approximation numérique du gradient


$$\nabla E(W) \approx \frac{E(W+H) - E(W)}{H}$$

En calculant

$$\frac{\partial E(W)}{\partial w_i} \approx \frac{E(w_i + h) - E(w_i)}{h} \quad \forall i$$

125

Vérification du gradient (exemple)



W

$$\begin{array}{ll}
 W_{00} = 0.34 & W_{00} = 0.34 +0.0001 \\
 W_{01} = -1.11 & W_{01} = -1.11 \\
 W_{02} = 0.78 & W_{02} = 0.78 \\
 \dots & \dots \\
 W_{20} = -3.1 & W_{20} = -3.1 \\
 W_{21} = -1.5, & W_{21} = -1.5, \\
 W_{22} = 0.33 & W_{22} = 0.33
 \end{array}$$

W+h


gradient W

$$-2.5 = (1.25322 - 1.25347) / 0.0001$$

$$E(W)=1.25347 \quad E(W+h)=1.25322$$

126

Vérification du gradient (exemple)



W

$$\begin{array}{ll}
 W_{00} = 0.34 & W_{00} = 0.34 \\
 W_{01} = -1.11 & W_{01} = -1.11 +0.0001 \\
 W_{02} = 0.78 & W_{02} = 0.78 \\
 \dots & \dots \\
 W_{20} = -3.1 & W_{20} = -3.1 \\
 W_{21} = -1.5, & W_{21} = -1.5, \\
 W_{22} = 0.33 & W_{22} = 0.33
 \end{array}$$

W+h


gradient W

$$\begin{array}{ll}
 -2.5 & \\
 0.6 = (1.25353 - 1.25347) / 0.0001 &
 \end{array}$$

$$E(W)=1.25347 \quad E(W+h)=1.25353$$

127

Vérification du gradient (exemple)



W

$W_{00} = 0.34$	$W_{00} = 0.34$	-2.5
$W_{01} = -1.11$	$W_{01} = -1.11$	0.6
$W_{02} = 0.78$	$W_{02} = 0.78$ +0.0001	0.0=(1.25347-1.25347)/0.0001
...	...	
$W_{20} = -3.1$	$W_{20} = -3.1$	
$W_{21} = -1.5,$	$W_{21} = -1.5,$	
$W_{22} = 0.33$	$W_{22} = 0.33$	


W+h

gradient W

$$\mathbf{E(W)=1.25347 \quad E(W+h)=1.25347}$$

128

Vérification du gradient (exemple)



W

$W_{00} = 0.34$	$W_{00} = 0.34$	-2.5
$W_{01} = -1.11$	$W_{01} = -1.11$	0.6
$W_{02} = 0.78$	$W_{02} = 0.78$	0.0
...
$W_{20} = -3.1$	$W_{20} = -3.1$	1.1
$W_{21} = -1.5,$	$W_{21} = -1.5,$	1.3
$W_{22} = 0.33$	$W_{22} = 0.33$	-2.1


W+h

gradient W

$$\mathbf{E(W)=1.25347}$$

129

Vérification du gradient (exemple)



gradient W (numérique) gradient W (retro-propagation)

-2.5		-2.5
0.6		0.6
0.0	=	0.0
...		...
1.1		1.1
1.3		1.3
-2.1		-2.1



130



Autre bonne pratique

Dropout

131

Dropout

Forcer à zéro certains neurones de façon aléatoire à chaque itération



Srivastava et al. "Dropout: a simple way to prevent neural networks from overfitting", JMLR 2014

132

Dropout

Idée : s'assurer que chaque neurone apprend pas lui-même
en brisant au hasard des chemins.

133

Dropout

```
p = 0.5 # probability of keeping a unit active. higher = less dropout

def train_step(X):
    """ X contains the data """

    # forward pass for example 3-layer neural network
    H1 = np.maximum(0, np.dot(W1, X) + b1)
    U1 = np.random.rand(*H1.shape) < p # first dropout mask
    H1 *= U1 # drop!
    H2 = np.maximum(0, np.dot(W2, H1) + b2)
    U2 = np.random.rand(*H2.shape) < p # second dropout mask
    H2 *= U2 # drop!
    out = np.dot(W3, H2) + b3

    # backward pass: compute gradients... (not shown)
    # perform parameter update... (not shown)
```

Crédit <http://cs231n.stanford.edu/>

134

Dropout

Le problème avec **Dropout** est en **prédiction (« test time »)**

car *dropout ajoute du bruit* à la prédiction


$$pred = y_W(\vec{x}, Z)$$

↑
masque aléatoire

135

dropout **ajoute du bruit** à la prédiction.

Exemple simple : $\vec{x} = \begin{pmatrix} 2.2 \\ 1.3 \end{pmatrix}, t=1$




Si on lance le modèle 10 fois, on aura 10 réponses différentes

```
[ 0.09378555  0.76511644  0.141098 ]
[ 0.13982909  0.62885327  0.23131764]
[ 0.23658253  0.61960162  0.14381585]
[ 0.23779425  0.51357115  0.24863461]
[ 0.16005442  0.68060227  0.1593433 ]
[ 0.16303195  0.50583392  0.33113413]
[ 0.24183069  0.51319834  0.24497097]
[ 0.14521815  0.52006858  0.33471327]
[ 0.09952161  0.66276146  0.23771692]
[ 0.16172851  0.6044877   0.23378379]
```

136

dropout **ajoute du bruit** à la prédiction.

Exemple simple : $\vec{x} = \begin{pmatrix} 2.2 \\ 1.3 \end{pmatrix}, t=1$



Solution, exécuter le modèle un grand nombre de fois et **prendre la moyenne**.

```
[ 0.09378555  0.76511644  0.141098 ]
[ 0.13982909  0.62885327  0.23131764]
[ 0.23658253  0.61960162  0.14381585]
[ 0.23779425  0.51357115  0.24863461]
[ 0.16005442  0.68060227  0.1593433 ]
[ 0.16303195  0.50583392  0.33113413]
[ 0.24183069  0.51319834  0.24497097]
[ 0.14521815  0.52006858  0.33471327]
[ 0.09952161  0.66276146  0.23771692]
[ 0.16172851  0.6044877   0.23378379]
(...
[ 0.15933813,  0.65957005,  0.18109183]
```

137

Exécuter le modèle un grand nombre de fois et **prendre la moyenne** revient à calculer **l'espérance mathématique**


$$pred = E_z [y_w(\vec{x}, \vec{z})] = \sum_i P(\vec{z}) y_w(\vec{x}, \vec{z})$$

Bonne nouvelle, on peut faire plus simple en approximant l'espérance mathématique!

138

Regardons pour un neurone

Avec une probabilité de *dropout* de 50%, en prédiction w_1 et w_2 seront **nuls 1 fois sur 2**



$$\begin{aligned} E[a] &= \frac{1}{4}(w_1x_1 + w_2x_2) + \frac{1}{4}(w_1x_1 + 0x_2) \\ &\quad + \frac{1}{4}(0x_1 + w_2x_2) + \frac{1}{4}(0x_1 + 0x_2) \\ &= \frac{1}{2}(w_1x_1 + w_2x_2) \end{aligned}$$

En prédiction, on a qu'à multiplier par la prob. de dropout.

139

```

""" Vanilla Dropout: Not recommended implementation (see notes below) """

p = 0.5 # probability of keeping a unit active. higher = less dropout

def train_step(X):
    """ X contains the data """

    # forward pass for example 3-layer neural network
    H1 = np.maximum(0, np.dot(W1, X) + b1)
    U1 = np.random.rand(*H1.shape) < p # first dropout mask
    H1 *= U1 # drop!
    H2 = np.maximum(0, np.dot(W2, H1) + b2)
    U2 = np.random.rand(*H2.shape) < p # second dropout mask
    H2 *= U2 # drop!
    out = np.dot(W3, H2) + b3

    # backward pass: compute gradients... (not shown)
    # perform parameter update... (not shown)

def predict(X):
    # ensembled forward pass
    H1 = np.maximum(0, np.dot(W1, X) + b1) * p # NOTE: scale the activations
    H2 = np.maximum(0, np.dot(W2, H1) + b2) * p # NOTE: scale the activations
    out = np.dot(W3, H2) + b3

```

En prédition, tous les neurones sont actifs

→ tout ce qu'il faut faire est de **multiplier la sortie de chaque couche par la probabilité de dropot**

Crédit <http://cs231n.stanford.edu/>

140

NOTE

Au tp2, vous implanterez un **dropout inverse**. À vous de le découvrir!

141

Descente de gradient **version améliorée**

142


Descente de gradient

$$W^{[t+1]} = W^{[t]} - \eta \nabla E_{W^{[t]}}(D)$$

143

Descente de gradient : **problème**


Progrès quasi nul lorsque la pente est très faible



144

Descente de gradient : **problème**

Les points de selles sont fréquents en haute dimension



145

Descente de gradient : **problème**


Qu'arrive-t-il si la fonction de coût (loss) a une pente prononcée dans une direction et moins prononcée dans une autre direction?

146


Descente de gradient : **problème**

Qu'arrive-t-il si la fonction de coût (loss) a une pente prononcée dans une direction et moins prononcée dans une autre direction?

Progrès très lent le long de la pente la plus faible et oscillation le long de l'autre direction.



147



148

Descente de gradient + Momentum

Descente de gradient
 $E_D(W)$ stochastique

$$w_{t+1} = w_t - \eta \nabla E_{\bar{x}_n}(w_t)$$


Descente de gradient
stochastique + **Momentum**

$$\begin{aligned} v_{t+1} &= \alpha v_t + (1-\alpha) \nabla E_{\bar{x}_n}(W_t) \\ w_{t+1} &= w_t - \eta v_{t+1} \end{aligned}$$


Provient de l'équation de la vitesse

ρ exprime la « **friction** », en général $\in [0.5, 1]$

149



150



151

AdaGrad (décroissance automatique de η)

Descente de gradient
stochastique

AdaGrad

$$\begin{aligned} dE_t &= \nabla E_{\bar{x}_n}(\mathbf{w}_t) \\ \mathbf{w}_{t+1} &= \mathbf{w}_t - \eta \nabla E_{\bar{x}_n}(\mathbf{w}_t) \quad m_{t+1} = m_t + |dE_t| \\ \mathbf{w}_{t+1} &= \mathbf{w}_t - \frac{\eta}{m_{t+1} + \epsilon} dE_t \end{aligned}$$

152

AdaGrad (décroissance automatique de η)

Descente de gradient
stochastique

AdaGrad


$$\begin{aligned} dE_t &= \nabla E_{\bar{x}_n}(\mathbf{w}_t) \\ \mathbf{w}_{t+1} &= \mathbf{w}_t - \eta \nabla E_{\bar{x}_n}(\mathbf{w}_t) \quad m_{t+1} = m_t + |dE_t| \\ \mathbf{w}_{t+1} &= \mathbf{w}_t - \frac{\eta}{m_{t+1} + \epsilon} dE_t \end{aligned}$$

η décroît sans cesse au fur
et à mesure de l'optimisation

153

AdaGrad (décroissance automatique de η)

Qu'arrive-t-il à long terme?



154

RMSProp (AdaGrad amélioré)

AdaGrad

$$dE_t = \nabla E_{\bar{x}_n}(\mathbf{w}_t)$$

$$m_{t+1} = m_t + |dE_t|$$

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{m_{t+1} + \epsilon} dE_t$$

RMSProp


$$dE_t = \nabla E_{\bar{x}_n}(\mathbf{w}_t)$$

$$m_{t+1} = \gamma m_t + (1-\gamma) |dE_t|^2$$


$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{m_{t+1} + \epsilon} dE_t$$

η décroît lorsque le gradient est élevé
 η augmente lorsque le gradient est faible

155



156



157

Adam (Combo entre Momentum et RMSProp)

Momentum

$$v_{t+1} = \rho v_t + \nabla E_{\bar{x}_n}(w_t)$$

$$w_{t+1} = w_t - \eta v_{t+1}$$

Adam

$$dE_t = \nabla E_{\bar{x}_n}(w_t)$$

$$v_{t+1} = \alpha v_t + (1-\alpha) dE_t$$

$$m_{t+1} = \gamma m_t + (1-\gamma) |dE_t|$$

$$w_{t+1} = w_t - \frac{\eta}{m_{t+1} + \epsilon} v_{t+1}$$

Momentum

158

Adam (Combo entre Momentum et RMSProp)

RMSProp

$$dE_t = \nabla E_{\bar{x}_n}(w_t)$$

$$m_{t+1} = \gamma m_t + (1-\gamma) |dE_t|$$

$$w_{t+1} = w_t - \frac{\eta}{m_{t+1} + \epsilon} dE_t$$

Adam

$$dE_t = \nabla E_{\bar{x}_n}(w_t)$$

$$v_{t+1} = \alpha v_t + (1-\alpha) dE_t$$

$$m_{t+1} = \gamma m_t + (1-\gamma) |dE_t|$$

$$w_{t+1} = w_t - \frac{\eta}{m_{t+1} + \epsilon} v_{t+1}$$

RMSprop

159

Adam (Version complète)

$$v_{t=0} = 0$$

$$m_{t=0} = 0$$

for t=1 à num_iterations
for n=0 à N

$$dE_t = \nabla E_{\bar{x}_n} (\mathbf{w}_t)$$

$$v_{t+1} = \alpha v_t + (1-\alpha) dE_t$$

$$m_{t+1} = \gamma m_t + (1-\gamma) |dE_t|$$



$$v_{t+1} = \frac{v_{t+1}}{1 - \beta_1^t}, m_{t+1} = \frac{m_{t+1}}{1 - \beta_2^t}$$

$$\beta_1 = 0.9, \beta_2 = 0.99$$

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \frac{\eta}{m_{t+1} + \epsilon} v_{t+1}$$

160

Illustrations




À voir sur :

www.denizyuret.com/2015/03/alec-radfords-animations-for.html

161

Autre excellent survol

<http://ruder.io/optimizing-gradient-descent/>



162