Réseaux de neurones

IFT 780

Segmentation et localisation

Par
Pierre-Marc Jodoin, Antoine Théberge

Classification

?

?

Segmentation sémantique

Segmentation par instances

Localisation

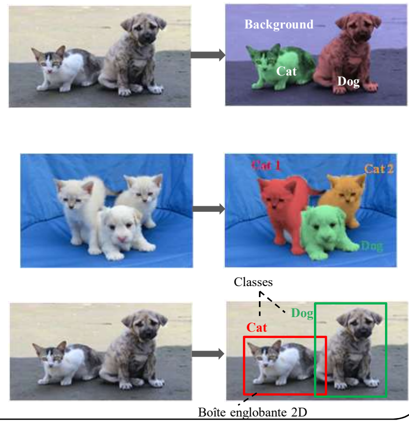

Segmentation sémantique

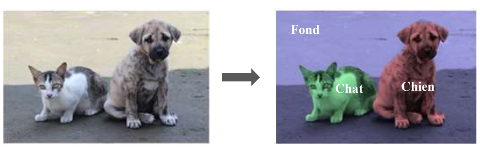

Image **Segmentation**

But: Assigner la bonne étiquette de classe à **chaque pixel de l'image d'entrée**

Peut être vu comme un problème de classification dense et structurée

Possiblement des millions de pixels

Prédictions structure spatiale

Segmentation sémantique

Pourquoi ?

M. Cordts, M. Omran, S. Ramos, T. Rehfeld, M. Enzweiler, R. Benenson, U. Franke, S. Roth, and B. Schiele, "The Cityscapes Dataset for Semantic Urban Scene Understanding," in Proc. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016. [Bibtex]

Segmentation sémantique

Pourquoi ?

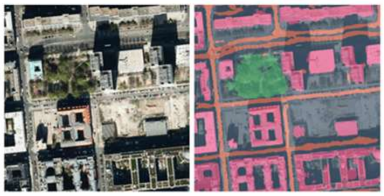

Fig. 7: Left: Original satellite image. Right: Semantic segmentation of roads, buildings and vegetation.

Ng, V., & Hofmann, D. (2018, July). Scalable feature extraction with aerial and satellite imagery. In Proceedings of the 17th Python in Science Conference (SCIPY 2018), Austin, TX, USA (pp. 9-15).

Segmentation sémantique

Pourquoi ?

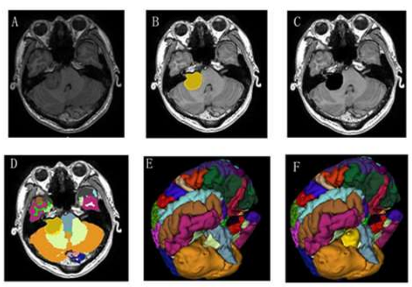

Hou, X., Yang, D., Li, D., Liu, M., Zhou, Y., & Shi, M. (2020). A new simple brain segmentation method for extracerebral intracranial tumors. *PloS one*, *15*(4), e0230754.

Segmentation sémantique

Comment mesurer la performance de la segmentation ?

Pour la classification:
- "Top 1%"
- "Top 5%"
- …

Pour la segmentation ?

Cible – Vérité terrain

Prédiction

Segmentation sémantique

Comment mesurer la performance de la segmentation ?

Matrice de confusion:

		Vérité terrain	
		Positif	Négatif
Prédiction	Positif	*True positive (TP)*	*False Positive (FP)*
	Négatif	*False negative (FN)*	*True negative (TN)*

Segmentation sémantique

Comment mesurer la performance de la segmentation ?

Justesse ("Pixel accuracy") $\frac{TP+TN}{TP+TN+FP+FN}$

Intersection over Union (IOU)/ Jaccard Index $\frac{TP}{TP+FP+FN}$

Dice $\frac{2TP}{2TP+FP+FN}$

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »

Rappel classification d'images 32x32

Image: **32x32x3**
Stride : **1**

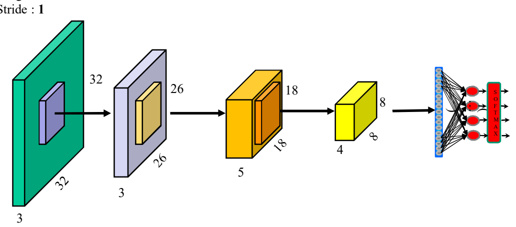

3x(26x26)=2,028 neurones
3x7x7x3 = 441 paramètres

5x(18x18)=1,620 neurones
5x9x9x3 = 1,215 paramètres

4x(8x8)=256 neurones
4x11x11x5 = 2,420 paramètres

Segmentation sémantique

Jusqu’à présent, on a vu comment classifier des images.
Idée: segmentation = classifier des sous-parties (*patches*) d’image

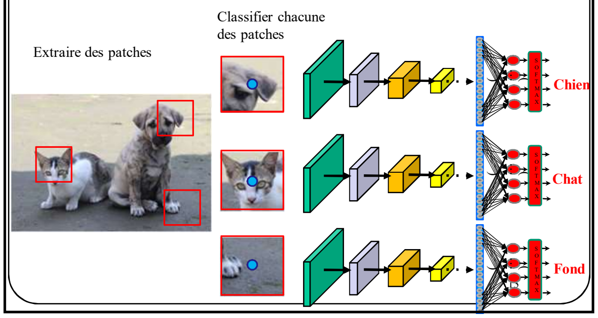

Segmentation sémantique

Jusqu’à présent, on a vu comment classifier des images.
Idée: segmentation = classifier des sous-parties (*patches*) d’image

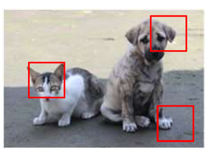

Segmentation sémantique

Jusqu’à présent, on a vu comment classifier des images.
Idée: segmentation = classifier des sous-parties (*patches*) d’image

Exemple d’un réseau à convolution pour des patches RGB 31x31
(Image tirée de l’article)

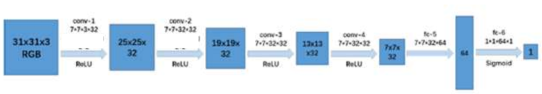

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Plusieurs inconvénients

1. **Très long** tant en entraînement qu'en test
   1. Entraînement

      Si 10,000 images 640x480 (300 000 pixels/image)

      = 3 milliards de patches!

      1 epoch = 3 milliards de propagations avant

      et de rétro-propagations

2. Prédiction basée sur une **information locale (une patch)**

16

Segmentation sémantique

Amélioration 1: remplacer la couche pleinement connectée par une couche convolutive

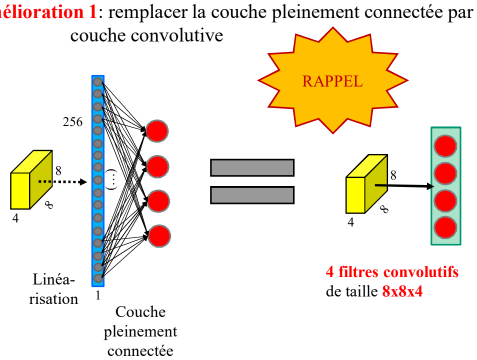

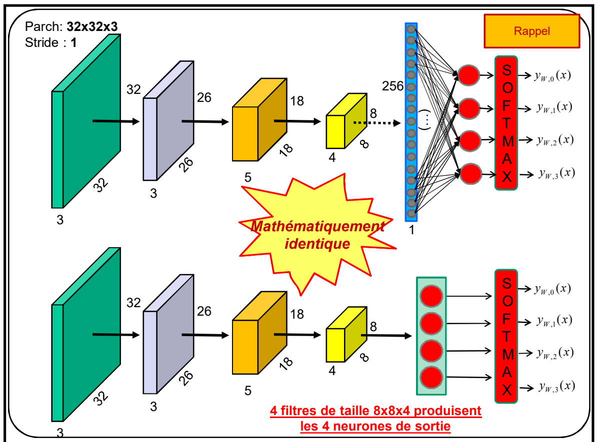

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »

Avec le réseau que voici, avec des conv « valid » et sans *pooling*, pour une image en **entrée** de **320x240**, on aura en **sortie 289x209 pixels**, chacun ayant un vecteur de **4 prédictions**.

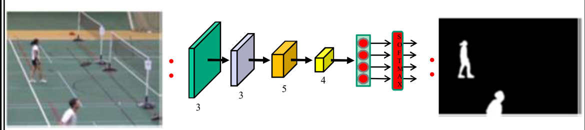

Immense avantage : fini les patches, on peut traiter une image avec 1 propagation avant et 1 rétropropagation

19

Segmentation sémantique

Taille des cartes d'activation pour une image en entrée 320x240

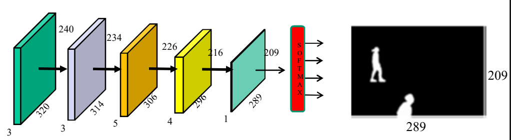

Immense avantage : fini les patches, on peut traiter une image avec 1 propagation avant et 1 rétropropagation

20

Segmentation sémantique

Si on remplace les convolutions « valid » par des **convolutions « same »** (avec du *padding*) nous aurons en sortie une image de la même taille que l'image d'entrée

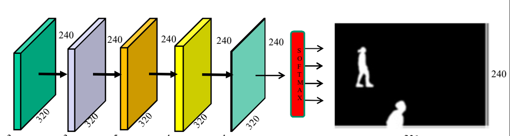

Immense avantage : fini les patches, on peut traiter une image avec 1 propagation avant et 1 rétropropagation

21

Segmentation sémantique

Un réseau comme celui de la page précédente n'est jamais utilisé en pratique. Voici un exemple:

Image Vérité terrain Résultat

Pourquoi la prédiction est-elle bruitée ? Pourquoi autant de trous dans la prédiction ?

Réponse : le "receptive field" est trop petit !

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Segmentation sémantique

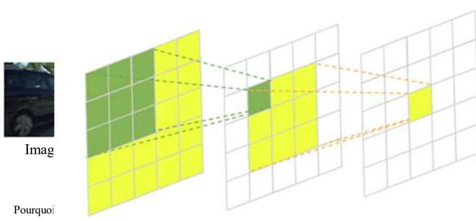

Réponse : le "receptive field" est trop petit !

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Note: taille du receptive field

$$r_0 = \sum_{l=1}^{L} \left((k_l - 1) \prod_{i=1}^{l-1} s_i \right) + 1$$

r = *receptive field*
k = *kernel*
s = *stride*
l = *layers* du réseau

https://distill.pub/2019/computing-receptive-fields

Note: taille du receptive field

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
couche 4 : 4 filtres de taille 8x8
convolution « *valid* »

Image: **32x32x3**
Stride : **1**

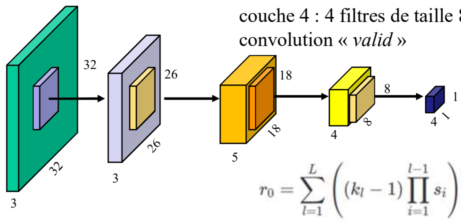

$$r_0 = \sum_{l=1}^{L} \left((k_l - 1) \prod_{i=1}^{l-1} s_i \right) + 1$$

https://distill.pub/2019/computing-receptive-fields

6 + 8 + 10 + 7 + 1 = 32

Note: taille du *receptive field*

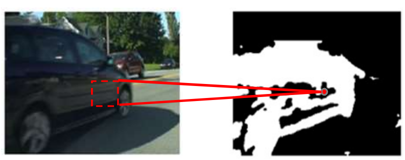

Chaque prédiction en sortie se fait sur la base d'une portion de taille 32x32 de l'image d'entrée. En ce sens, le réseau n'a **qu'une vision locale et partielle de l'image.**

https://distill.pub/2019/computing-receptive-fields

6 + 8 + 10 + 7 + 1 = 32

Segmentation sémantique

Amélioration 2: pour avoir plus de contexte dans la prédiction, entraîner un CNN avec des **images multirésolution**. En test, **combiner les prédictions** (ensemble de modèles)

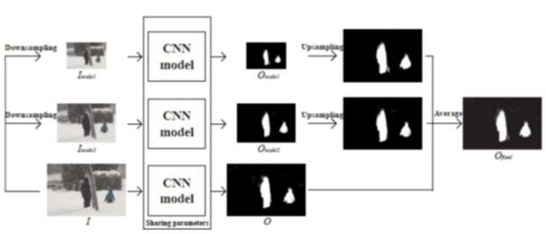

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Segmentation sémantique

Amélioration 3: Pour raffiner les résultats, entraîner 2 modèles en cascade. Un premier qui segmente l'image d'entrée et le second qui segmente l'image d'entrée et la carte de segmentation du premier. Cela permet d'améliorer la cohésion spatiale.

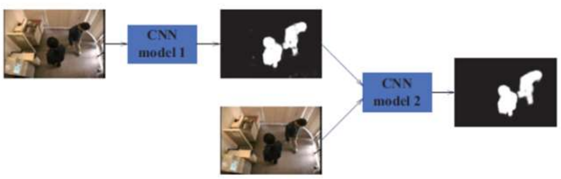

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Segmentation sémantique

Image	Vérité terrain	CNN patches 31x31	CNN patches 31x31 multirésolution	CNN patches 31x31 multirésolution cascade

Wang Y, Luo Z., Jodoin P-M (2017) **Interactive Deep Learning Method for Segmenting Moving Objects** Pattern Recognition Letters, 96, p.66-75

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240)

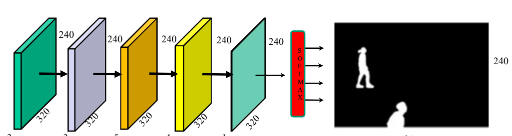

Solutions:

$$r_0 = \sum_{l=1}^{L} \left((k_l - 1) \prod_{i=1}^{l-1} s_i \right) + 1$$

1- **ajouter beaucoup de couches**
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque bloc convolutionnel**
4- faire un mélange de tout ça!

30

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240)

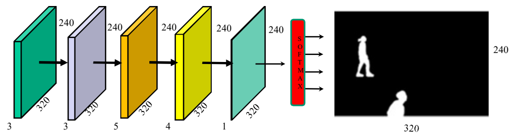

Solutions:

Avec des filtres 3x3 minimum de 120 couches!

1- **ajouter beaucoup de couches**
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque bloc convolutionnel**
4- faire un mélange de tout ça!

31

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240)

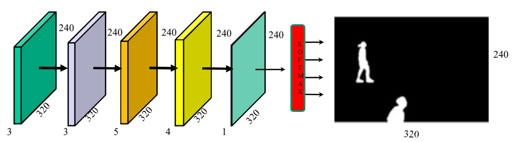

Solutions:

1- ~~**ajouter beaucoup de couches**~~
2- utiliser des **convolutions dilatées** (
3- mettre des couches de **pooling apr**
4- faire un mélange de tout ça!

Explosion de la mémoire
Et des temps de calculs
Et problème de disparition de gradients

32

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240)

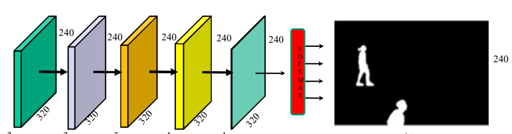

Solutions:

~~1- ajouter beaucoup de couches~~
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque**
4- faire un mélange de tout ça!

33

Segmentation sémantique

Rappel

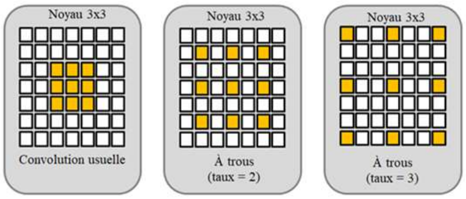

Champ récepteur=3x3 **Champ récepteur=5x5** **Champ récepteur=7x7**

34

Segmentation sémantique

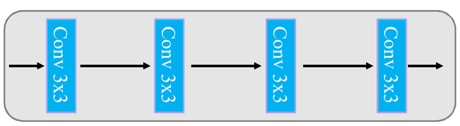

Champ récepteur (taux = 1)	3x3	5x5	7x7	9x9
Champ récepteur (taux = 2)	5x5	9x9	13x13	17x17
Champ récepteur (taux = 3)	7x7	13x13	19x19	21x21

$$r_0 = \sum_{l=1}^{L}\left((k_l - 1)\prod_{i=1}^{l-1} s_i\right) + 1$$

k = taux*(k-1) + 1

35

Segmentation sémantique

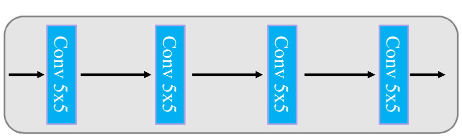

Champ récepteur (taux = 1)	5x5	9x9	13x13	17x17
Champ récepteur (taux = 2)	9x9	17x17	25x25	33x33
Champ récepteur (taux = 3)	15x15	29x29	43x43	57x57

$$r_0 = \sum_{l=1}^{L}\left((k_l - 1)\prod_{i=1}^{l-1} s_i\right) + 1$$

k = taux*(k-1) + 1

36

FullNet

Le « **FullNet** » [Qu et al. 2019] implémente ce type de réseau mais avec des blocs convolutifs **denses** comme ceux du **denseNet**.

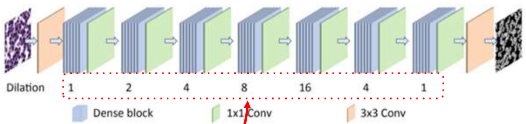

Taux de dilatation par bloc

H. Qu, Z.Yan, G.M. Riedlinger, S.De and D.N. Metaxas
"Improving Nuclei/Gland Instance Segmentation in Histopathology Images by Full Resolution Neural Network and Spatial Constrained Loss", in proc of MICCAI 2019

37

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240).

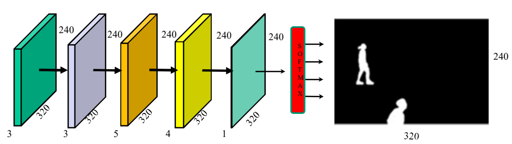

Solutions:

~~1- ajouter beaucoup de couches~~
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque bloc convolutionnel**
4- faire un mélange de tout ça!

38

Image: Long et al. "Fully convolutional networks for semantic segmentation." ICCV, 2015.

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240).

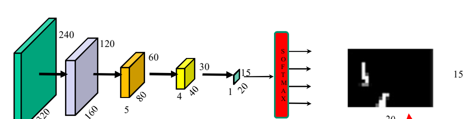

Solutions:

~~1- ajouter beaucoup de couches~~
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque bloc convolutionnel**
4- faire un mélange de tout ça!

Résolution trop faible en sortie

39

Image: Long et al. "Fully convolutional networks for semantic segmentation." ICCV, 2015.

Segmentation sémantique

Solution : augmenter la resolution en sortie à l'aide d'un **décodeur**.

Réseau encodeur-décodeur (ici "SegNet")

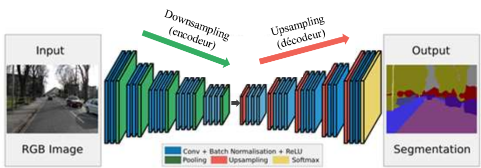

Problème: la résolution spatiale est <u>perdue</u> avec les couches de sous-échantillonnage **(Conv + Pooling)**

Solution: Augmenter la resolution à l'aide d'un décodeur et de couches de sur-échantillonage **(??? + Conv)**

Adapté de:
Badrinarayanan et al. "Segnet: A deep convolutional encoder-decoder architecture for image segmentation." PAMI, 2017.

40

Pour **augmenter la taille** des cartes d'activation il faut une opération de "***upsampling***"

Deux types d'approches

- Méthodes sans paramètres => *<u>unpooling</u>*
- Méthode avec paramètres => <u>convolution transposée</u>

Unpooling (dégroupage ?)

Noyau 1x1
Stride ½ (genre)

« planche de clous » →

7	8
2	1

2x2xC

7	0	8	0
0	0	0	0
2	0	1	0
0	0	0	0

4x4xC

« plus proche voisin » →

7	8
2	1

2x2xC

7	7	8	8
7	7	8	8
2	2	1	1
2	2	1	1

4x4xC

Unpooling

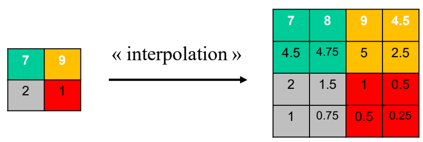

Convolution transposée

L'idée ici est moins intuitive que pour du unpooling.

Commençons par un exemple 1D…

44

Convolution de base

(exemple 1d)

Convolution "*valid*" stride =1 Convolution "*valid*" stride =3

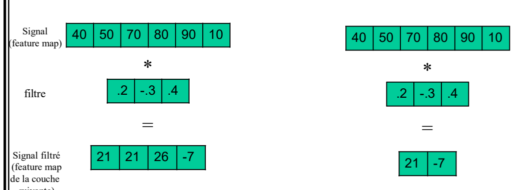

45

Opération matrice-vecteur
(exemple 1d)

Convolution "*valid*" stride =1

$$\begin{bmatrix} .2 & -.3 & .4 & 0 & 0 & 0 \\ 0 & .2 & -.3 & .4 & 0 & 0 \\ 0 & 0 & .2 & -.3 & .4 & 0 \\ 0 & 0 & 0 & .2 & -.3 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \\ 70 \\ 80 \\ 90 \\ 10 \end{bmatrix} = \begin{bmatrix} 21 \\ 21 \\ 26 \\ -7 \end{bmatrix}$$

Convolution "*valid*" stride =3

$$\begin{bmatrix} .2 & -.3 & .4 & 0 & 0 & 0 \\ 0 & 0 & 0 & .2 & -.3 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \\ 70 \\ 80 \\ 90 \\ 10 \end{bmatrix} = \begin{bmatrix} 21 \\ -7 \end{bmatrix}$$

46

Opération matrice-vecteur
(exemple 1d)

Convolution "*valid*" stride =1

$$\begin{bmatrix} .2 & -.3 & .4 & 0 & 0 & 0 \\ 0 & .2 & -.3 & .4 & 0 & 0 \\ 0 & 0 & .2 & -.3 & .4 & 0 \\ 0 & 0 & 0 & .2 & -.3 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \\ 70 \\ 80 \\ 90 \\ 10 \end{bmatrix} = \begin{bmatrix} 21 \\ 21 \\ 26 \\ -7 \end{bmatrix}$$

4x6 6x1 = 4x1

Convolution "*valid*" stride =3

$$\begin{bmatrix} .2 & -.3 & .4 & 0 & 0 & 0 \\ 0 & 0 & 0 & .2 & -.3 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \\ 70 \\ 80 \\ 90 \\ 10 \end{bmatrix} = \begin{bmatrix} 21 \\ -7 \end{bmatrix}$$

2x6 6x1 = 2x1

47

Convolution transposée

Le but est d'avoir un filtre dont la taille des opérations **est inversée**

Convolution "*valid*" stride =1

$$\begin{bmatrix} .2 & 0 & 0 & 0 \\ -.3 & .2 & 0 & 0 \\ .4 & -.3 & .2 & 0 \\ 0 & .4 & -.3 & .2 \\ 0 & 0 & .4 & -.3 \\ 0 & 0 & 0 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \\ 70 \\ 80 \end{bmatrix} = \begin{bmatrix} 8 \\ -2 \\ 15 \\ 15 \\ 4 \\ 32 \end{bmatrix}$$

Convolution "*valid*" stride =3

$$\begin{bmatrix} .2 & 0 \\ -.3 & 0 \\ .4 & 0 \\ 0 & .2 \\ 0 & -.3 \\ 0 & .4 \end{bmatrix} \begin{bmatrix} 40 \\ 50 \end{bmatrix} = \begin{bmatrix} 8 \\ -12 \\ -16 \\ 10 \\ -15 \\ 20 \end{bmatrix}$$

48

Convolution transposée

Le but est d'avoir un filtre dont la taille des opérations **est inversée**

Convolution "*valid*" stride =1

Convolution "*valid*" stride =3

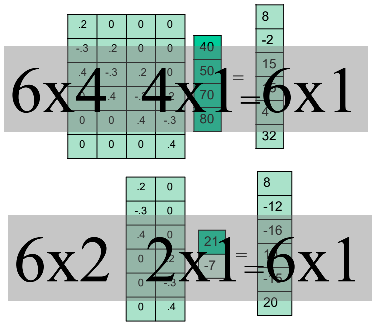

Convolution transposée

Le but est d'avoir un filtre dont la taille des opérations **est inversée**

Convolution "*valid*" stride =1

Convolution "*valid*" stride =3

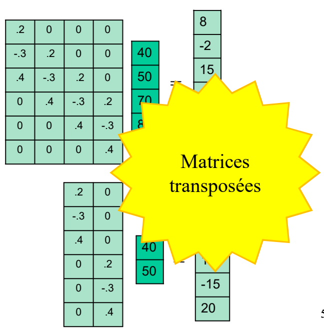

Convolution transposée

Exemple avec 2x2 stride 1

Stride dans l'espace de "sortie", pas l'espace "d'entrée"

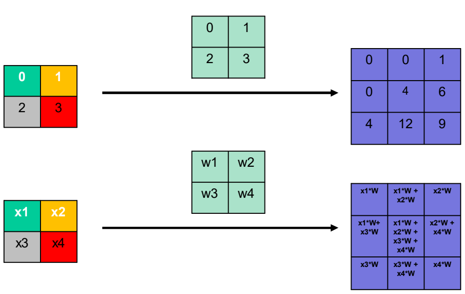

Convolution transposée

Exemple chiffré avec 2x2 stride 1

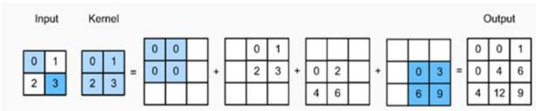

Autres noms:
- Déconvolution
- *Upconvolution*
- *Fractionally-strided convolution*

Ressemble beaucoup à la rétropropagation d'une couche convolutive !

https://towardsdatascience.com/transposed-convolution-demystified-84ca81b4baba

52

Convolution transposée

Exemple chiffré avec 2x2 stride 1

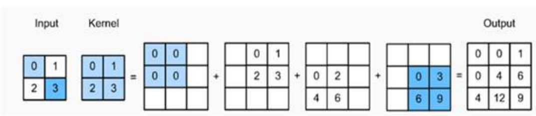

Problème ?

https://towardsdatascience.com/transposed-convolution-demystified-84ca81b4baba

53

Convolution transposée

Exemple chiffré avec 2x2 stride 1

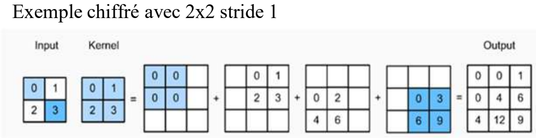

Problème ?
Crée des artefacts
de "damier" au chevauchement
(*checkerboard)*

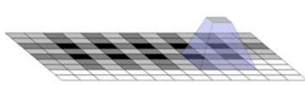

https://distill.pub/2016/deconv-checkerboard/

54

Convolution transposée

Solution ? (partielle)
Augmenter le *stride*
pour éviter le chevauchement

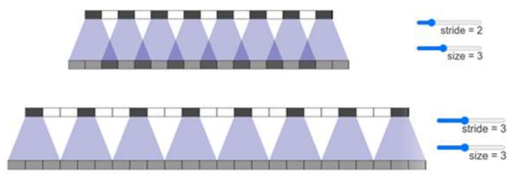

https://distill.pub/2016/deconv-checkerboard/

55

Convolution transposée

Solution ? (partielle)
Augmenter le *stride*
pour éviter le chevauchement

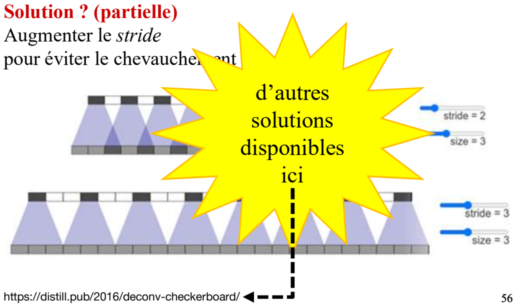

https://distill.pub/2016/deconv-checkerboard/

56

Note: super-résolution

Comment entraîner un réseau à convolutions à faire de la super-résolution ?

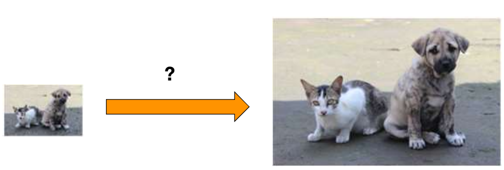

59

Note: super-résolution

S'entraîner avec des images à haute-résolution qui ont été réduites !

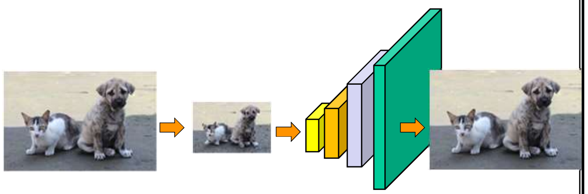

Sub-pixel ou interpolation + convolution

Shi, W., Caballero, J., Huszár, F., Totz, J., Aitken, A. P., Bishop, R., ... & Wang, Z. (2016). Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1874-1883).

60

Segmentation: Encodeur-décodeur

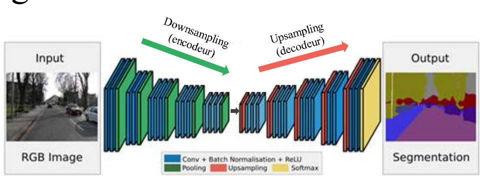

Généralement:

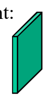

: max pooling (réduction /2)

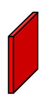

: Interpolation et/ou Convolution transposée (augmentation *2)

Adapté de:
Badrinarayanan et al. "Segnet: A deep convolutional encoder-decoder architecture for image segmentation." PAMI, 2017.

61

Segmentation: Encodeur-décodeur

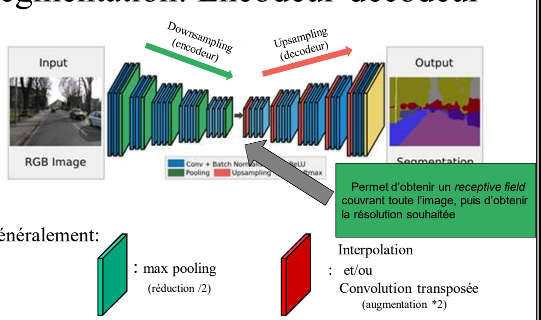

Permet d'obtenir un *receptive field* couvrant toute l'image, puis d'obtenir la résolution souhaitée

Généralement:

: max pooling (réduction /2)

: Interpolation et/ou Convolution transposée (augmentation *2)

Adapté de:
Badrinarayanan et al. "Segnet: A deep convolutional encoder-decoder architecture for image segmentation." PAMI, 2017.

62

Encodeur-décodeur

Encodeur: projette l'image d'entrée vers un espace de plus faible dimension
Décodeur: projette l'image de faible dimension vers l'espace souhaité

Architecture *généralement* symétrique

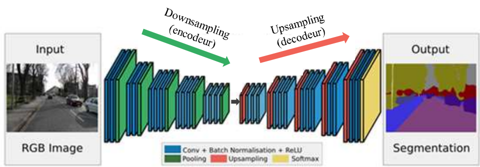

tiré de:
Badrinarayanan et al. "Segnet: A deep convolutional encoder-decoder architecture for image segmentation." PAMI, 2017.

63

Encodeur-décodeur

Encodeur: projette l'image d'entrée vers un espace de plus faible dimension
Décodeur: projette l'image de faible dimension vers l'espace souhaité

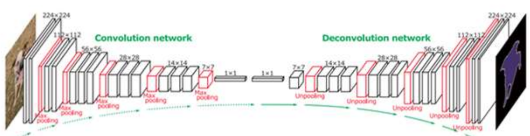

Figure 2. Overall architecture of the proposed network. On top of the convolution network based on VGG 16-layer net, we put a multi-layer deconvolution network to generate the accurate segmentation map of an input proposal. Given a feature representation obtained from the convolution network, dense pixel-wise class prediction map is constructed through multiple series of unpooling, deconvolution and rectification operations.

tiré de:
Noh, H., Hong, S., & Han, B. (2015). Learning deconvolution network for semantic segmentation. In *Proceedings of the IEEE international conference on computer vision* (pp. 1520-1528).

64

Max pooling - Max unpooling

7	0	0	0
0	0	8	0
0	0	1	0
0	2	0	0

→

7	8
2	1

1	2
3	4

→

1	0	0	0
0	0	2	0
0	0	4	0
0	3	0	0

Noh, H., Hong, S., & Han, B. (2015). Learning deconvolution network for semantic segmentation. In *Proceedings of the IEEE international conference on computer vision* (pp. 1520-1528).

Encodeur-décodeur

Un inconvénient des structures encodeur-décodeur

Perte d'information

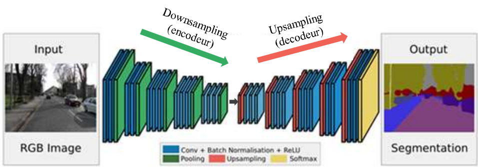

Adapté de:
Badrinarayanan et al. "Segnet: A deep convolutional encoder-decoder architecture for image segmentation." PAMI, 2017.

66

Solution : les ***skip connections***

U-Net [Ronneberger et al., 2015]

Skip connection

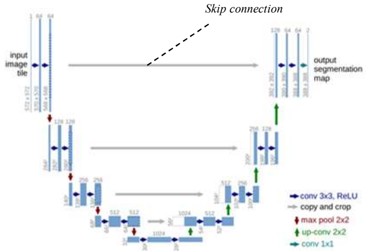

CNN le plus populaire en imagerie médicale

Image: Ronneberger et al. "U-net: Convolutional networks for biomedical image segmentation." MICCAI, 2015.

Solution : les ***skip connections***

U-Net [Ronneberger et al., 2015]

Skip connection

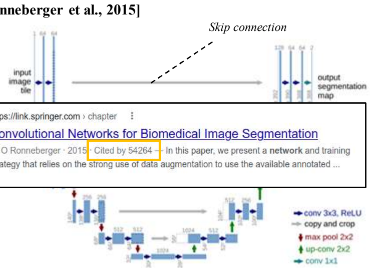

https://link.springer.com › chapter
Convolutional Networks for Biomedical Image Segmentation
by O Ronneberger · 2015 · Cited by 54264 — In this paper, we present a network and training strategy that relies on the strong use of data augmentation to use the available annotated ...

CNN le plus populaire en imagerie médicale

Image: Ronneberger et al. "U-net: Convolutional networks for biomedical image segmentation." MICCAI, 2015.

Solution : les ***skip connections***

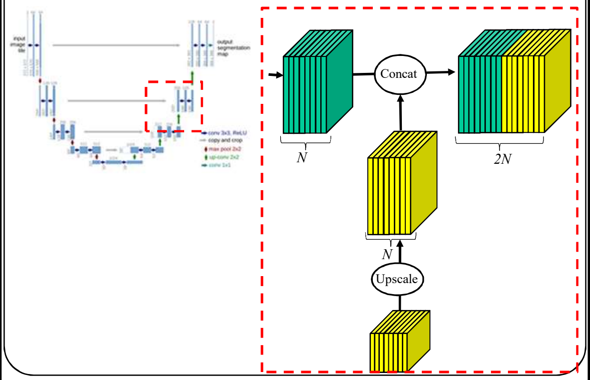

3D-UNet/V-Net

Identiques au Unet mais avec des **convolutions 3D**

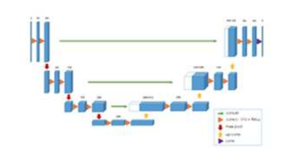

Fig. 2: The 3D u-net architecture. Blue boxes represent feature maps. The number of channels is denoted above each feature map.

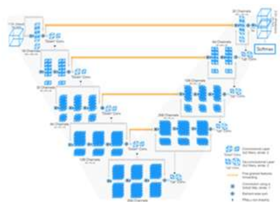

Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016, October). 3D U-Net: learning dense volumetric segmentation from sparse annotation. In *International conference on medical image computing and computer-assisted intervention* (pp. 424-432). Springer, Cham.

Milletari, F., Navab, N., & Ahmadi, S. A. (2016, October). V-net: Fully convolutional neural networks for volumetric medical image segmentation. In 2016 fourth international conference on 3D vision (3DV) (pp. 565-571). IEEE.

70

3D-UNet/V-Net

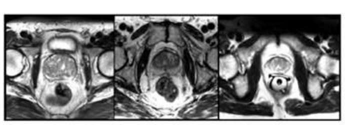

Fig. 1. Slices from MRI volumes depicting prostate. This data is part of the PROMISE2012 challenge dataset [7].

Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016, October). 3D U-Net: learning dense volumetric segmentation from sparse annotation. In *International conference on medical image computing and computer-assisted intervention* (pp. 424-432). Springer, Cham.

Milletari, F., Navab, N., & Ahmadi, S. A. (2016, October). V-net: Fully convolutional neural networks for volumetric medical image segmentation. In 2016 fourth international conference on 3D vision (3DV) (pp. 565-571). IEEE.

71

Imagerie médicale

Exemples d'images 3D en imagerie médicale

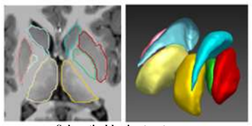

Subcortical brain structures
[Dolz et al, 2018]

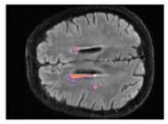

White matter hyperintensities
[Dolz et al, 2019]

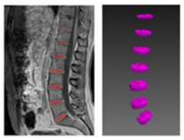

Intervertebral disks
[Dolz et al, 2019]

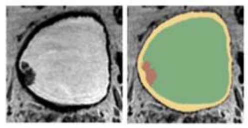

Prostate wall and tumor
[Dolz et al, 2018]

72

W-Net

Deux UNets bouts-à-bouts, mais sert à faire de la **segmentation non supervisée**

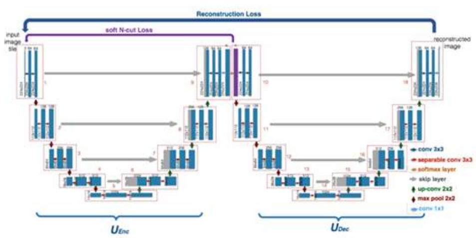

Xia, X., & Kulis, B. (2017). W-net: A deep model for fully unsupervised image segmentation. arXiv preprint arXiv:1711.08506.

73

W-Net

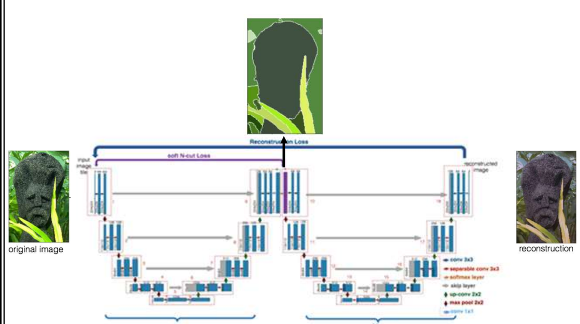

74

W-Net

Deux UNets bouts-à-bouts, mais sert à faire de la **segmentation non supervisée**

Xia, X., & Kulis, B. (2017). W-net: A deep model for fully unsupervised image segmentation. arXiv preprint arXiv:1711.08506.

75

Segmentation sémantique

Problème : ce modèle a un champ récepteur (***receptive field***) relativement petit (ici 32x32). Au lieu, on aimerait que les pixels de sortie aient un champ récepteur de la taille de l'image d'entrée (ici 320x240).

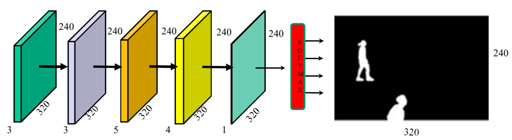

Solutions:

~~1- ajouter beaucoup de couches~~
2- utiliser des **convolutions dilatées** (convolutions *à trous*)
3- mettre des couches de **pooling après chaque bloc convolutionnel**
4- faire un mélange de tout ça

77

Image: Long et al. "Fully convolutional networks for semantic segmentation." ICCV, 2015.

E-Net
(E pour *Efficient*)

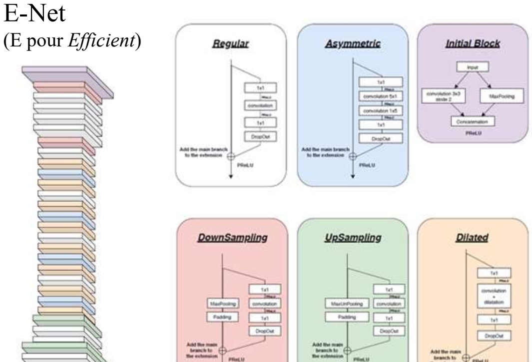

Paszke, A. Chaurasia, S. Kim, and E. Culurciello. Enet: A deep neural network architecture for real-time semantic segmentation, *arXiv: 1606.02147, 2016.*

E-Net : le “combo” ultime
(E pour *Efficient*)

Table 1: ENet architecture. Output sizes are given for an example input of 512×512.

Name	Type	Output size
initial		$16 \times 256 \times 256$
bottleneck1.0	downsampling	$64 \times 128 \times 128$
4× bottleneck1.x		$64 \times 128 \times 128$
bottleneck2.0	downsampling	$128 \times 64 \times 64$
bottleneck2.1		$128 \times 64 \times 64$
bottleneck2.2	dilated 2	$128 \times 64 \times 64$
bottleneck2.3	asymmetric 5	$128 \times 64 \times 64$
bottleneck2.4	dilated 4	$128 \times 64 \times 64$
bottleneck2.5		$128 \times 64 \times 64$
bottleneck2.6	dilated 8	$128 \times 64 \times 64$
bottleneck2.7	asymmetric 5	$128 \times 64 \times 64$
bottleneck2.8	dilated 16	$128 \times 64 \times 64$
Repeat section 2, without bottleneck2.0		
bottleneck4.0	upsampling	$64 \times 128 \times 128$
bottleneck4.1		$64 \times 128 \times 128$
bottleneck4.2		$64 \times 128 \times 128$
bottleneck5.0	upsampling	$16 \times 256 \times 256$
bottleneck5.1		$16 \times 256 \times 256$
fullconv		$C \times 512 \times 512$

Paszke, A. Chaurasia, S. Kim, and E. Culurciello. Enet: A deep neural network architecture for real-time semantic segmentation, *arXiv: 1606.02147, 2016.*

E-Net
(E pour *Efficient*)

Table 2: Performance comparison.

Model	NVIDIA TX1						NVIDIA Titan X					
	480×320		640×360		1280×720		640×360		1280×720		1920×1080	
	ms	fps	ms	fps	ms	fps	ms	fps	ms	fps	ms	fps
SegNet	757	1.3	1251	0.8	-	-	69	14.6	289	3.5	637	1.6
ENet	47	21.1	69	14.6	262	3.8	7	135.4	21	46.8	46	21.6

Table 3: Hardware requirements. FLOPs are estimated for an input of $3 \times 640 \times 360$.

	GFLOPs	Parameters	Model size (fp16)
SegNet	286.03	29.46M	56.2 MB
ENet	3.83	0.37M	0.7 MB

Très efficace!!! 300 fois moins de calculs pour des résultats similaires à SegNet

Paszke, A. Chaurasia, S. Kim, and E. Culurciello. Enet: A deep neural network architecture for real-time semantic segmentation, *arXiv: 1606.02147, 2016.*

DeepLab V1,V2,V3, PSPNet, MSCADC, etc.

Plusieurs méthodes utilisent à la fois des **convolutions dilatées** et du « **upsampling** ».

Configuration typique:

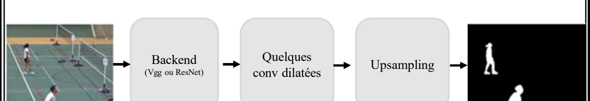

H.Zhao, J.Shi, X. Qi, X. Wang, J. Jia, Pyramid Scene Parsing Network, CVPR 2017

L. Chen, G. Papandreou, I.Kokkinos, K.Murphy, A.L. Yuille
Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs, ICLR 2015

F. Yu, V. Koltun, Multi-Scale Context Aggregation by Dilated Convolution, ICLR 2016

L. Chen, G. Papandreou, I.Kokkinos, K.Murphy, A.L. Yuille
DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs, PAMI 2016

DeepLab V1,V2,V3, PSPNet, MSCADC, etc.

Une méthode très populaire : **DeepLab**

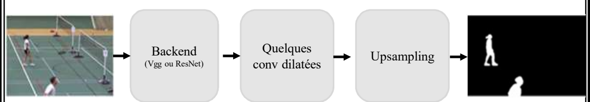

H.Zhao, J.Shi, X. Qi, X. Wang, J. Jia, Pyramid Scene Parsing Network, CVPR 2017

L. Chen, G. Papandreou, I.Kokkinos, K.Murphy, A.L. Yuille
Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs, ICLR 2015

F. Yu, V. Koltun, Multi-Scale Context Aggregation by Dilated Convolution, ICLR 2016

L. Chen, G. Papandreou, I.Kokkinos, K.Murphy, A.L. Yuille
DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs, PAMI 2016

DeepLab V1/V2

(certains détails peuvent varier)

Ex.: Vgg backend

- ConvAxA + relu
- ConvAxA dilatée de d + relu
- Conditional Random Field (CRF)
- MaxPool stride 2
- MaxPool stride 1
- Upsampling, taux A

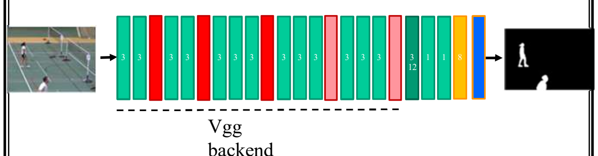

On peut aussi mettre un backend ResNet

L. Chen, G. Papandreou, I.Kokkinos, K.Murphy, A.L. Yuille
Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs, ICLR 2015

MSCADC

(certains détails peuvent varier)

- ConvAxA + relu
- ConvAxA dilatée de d + relu
- MaxPool stride 2
- MaxPool stride 1
- Upsampling, taux A

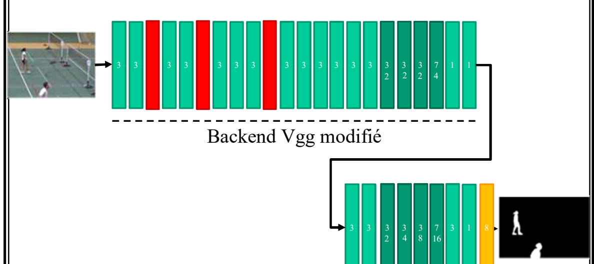

F. Yu, V. Koltun, Multi-Scale Context Aggregation by Dilated Convolution, ICLR 2016

DeepLabv3

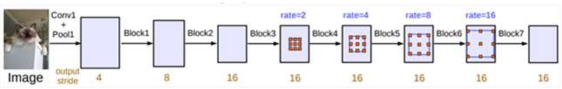

(b) Going deeper with atrous convolution. Atrous convolution with $rate > 1$ is applied after block3 when $output\_stride = 16$.
Figure 3. Cascaded modules without and with atrous convolution.

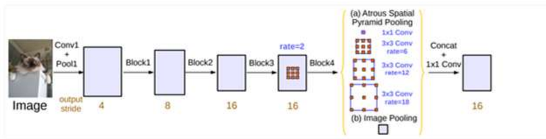

Figure 5. Parallel modules with atrous convolution (ASPP), augmented with image-level features.

Chen, L. C., Papandreou, G., Schroff, F., & Adam, H. (2017). Rethinking atrous convolution for semantic image segmentation. *arXiv preprint arXiv:1706.05587*.

RefineNet

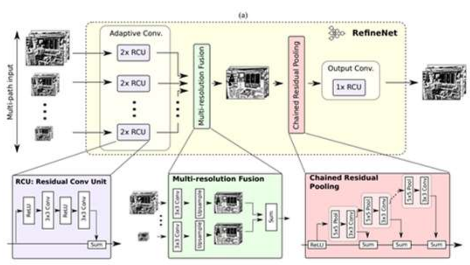

Figure 3. The individual components of our multi-path refinement network architecture RefineNet. Components in RefineNet employ residual connections with identity mappings. In this way, gradients can be directly propagated within RefineNet via local residual connections, and also directly propagate to the input paths via long-range residual connections, and thus we achieve effective end-to-end training of the whole system.

Lin, G., Milan, A., Shen, C., & Reid, I. (2017). Refinenet: Multi-path refinement networks for high-resolution semantic segmentation. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1925-1934).

En pratique:

U-Net [Ronneberger et al., 2015]

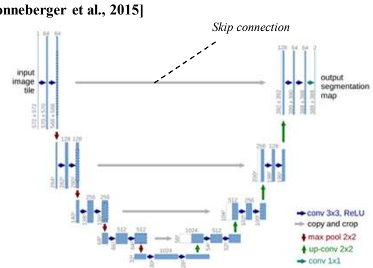

CNN le plus populaire en imagerie médicale

Image: Ronneberger et al. "U-net: Convolutional networks for biomedical image segmentation." MICCAI, 2015.

En pratique:

U-Net [Ronneberger et al., 2015]

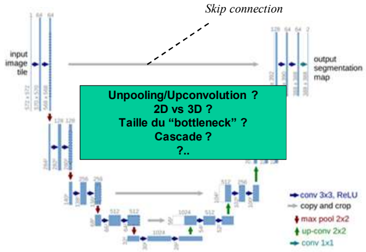

CNN le plus populaire en imagerie médicale

Image: Ronneberger et al. "U-net: Convolutional networks for biomedical image segmentation." MICCAI, 2015.

En pratique : nnU-Net

L'imagerie médicale est un domaine vaste et varié

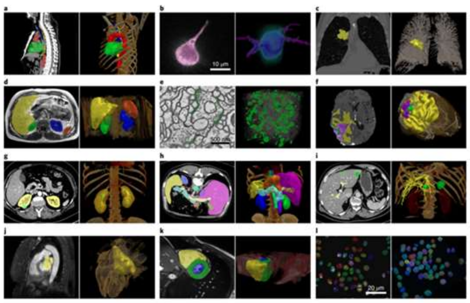

Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2), 203-211.

En pratique : nnU-Net

L'imagerie médicale est un domaine vaste et varié

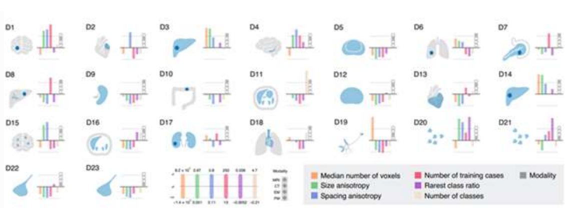

Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2), 203-211.

En pratique : nnU-Net *(no-new-net)*

L'imagerie médicale est un domaine vaste et varié

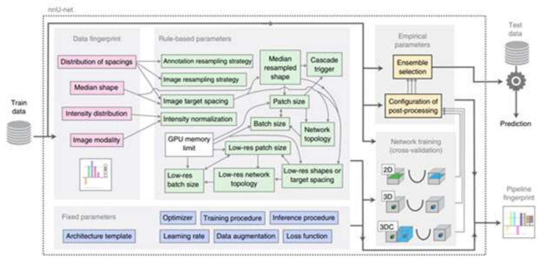

Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2), 203-211.

En pratique : nnU-Net *(no-new-net)*

L'imagerie médicale est un domaine vaste et varié

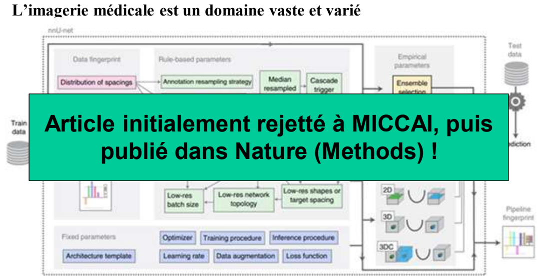

Article initialement rejetté à MICCAI, puis publié dans Nature (Methods) !

Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2), 203-211.

En pratique : nnU-Net *(no-new-net)*

nnU-Net est de loin le meilleur!

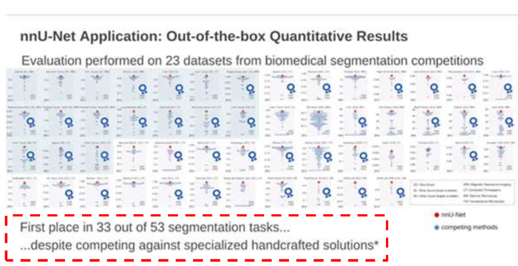

Beyond the Patterns 29 - Fabian Isensee - nnU-Net: self-configuring deep learning image segmentation
https://www.youtube.com/watch?v=C6tpnJRpt90

Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2), 203-211.

DÉTECTION D'OBJETS

94

Segmentation sémantique

Segmentation par instances

Localisation / Détection

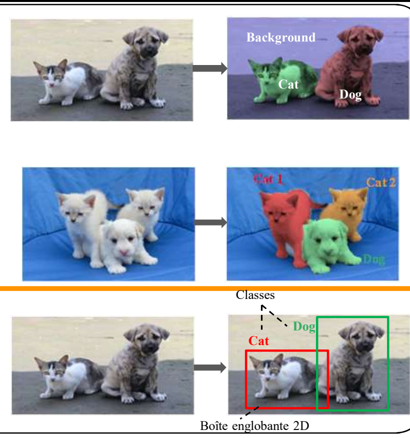

Détection d'objets

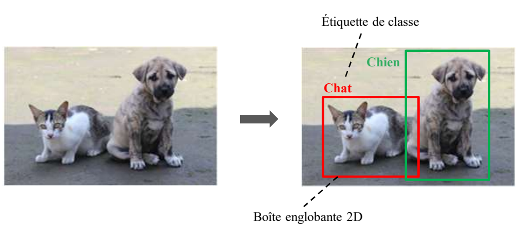

BUT: localiser et reconnaître des <u>objets</u> (ou personnes, animaux).

96

Détection d'un seul objet

97

Détection d'un seul objet

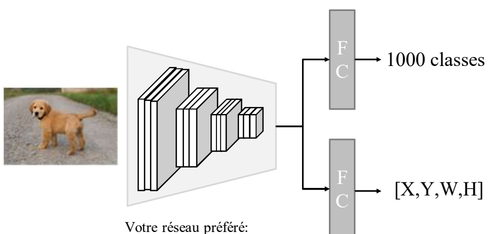

Votre réseau préféré:
VggNet, ResNet, ResNeXt, InceptionNet, etc
(souvent préentraîné sur imageNet)

98

Détection d'un seul objet

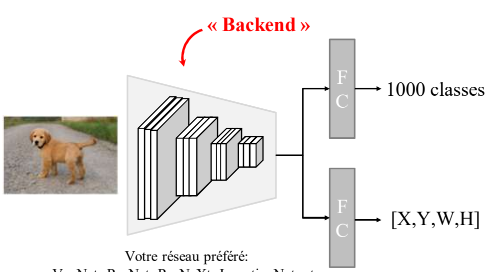

Votre réseau préféré:
VggNet, ResNet, ResNeXt, InceptionNet, etc
(souvent préentraîné sur imageNet)

99

Détection d'un seul objet

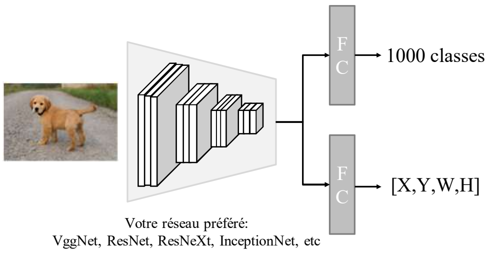

Votre réseau préféré:
VggNet, ResNet, ResNeXt, InceptionNet, etc
(souvent préentraîné sur imageNet)

Deux têtes de sortie :
1- Classification
2- Régression

100

Détection d'un seul objet

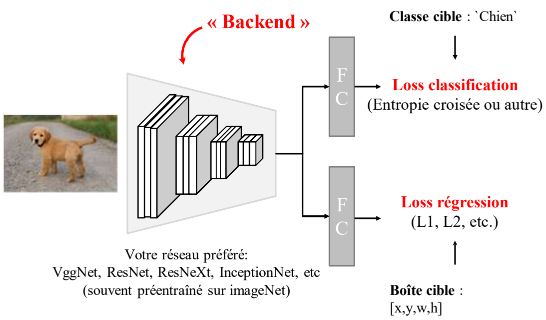

Votre réseau préféré:
VggNet, ResNet, ResNeXt, InceptionNet, etc
(souvent préentraîné sur imageNet)

101

Détection d'un seul objet

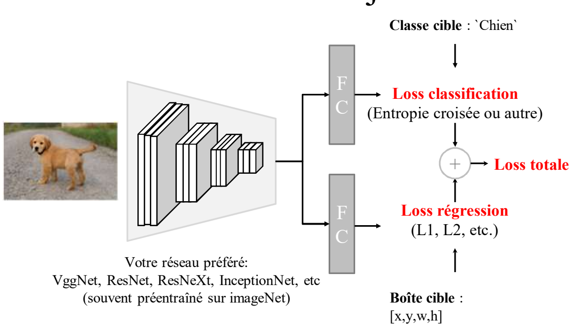

Votre réseau préféré:
VggNet, ResNet, ResNeXt, InceptionNet, etc
(souvent préentraîné sur imageNet)

102

Détection d'un seul objet

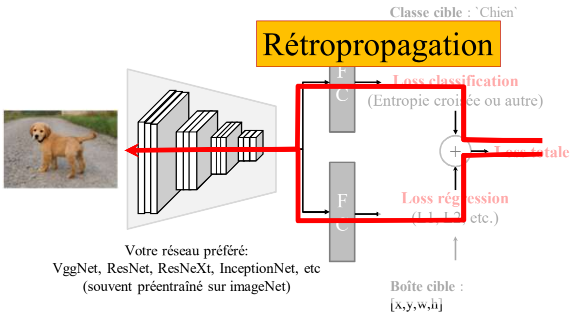

103

Application similaire : estimation de pose

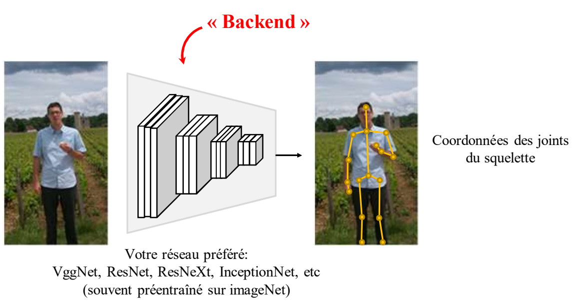

Toshev and Szegedy, "DeepPose: Human Pose Estimation via Deep Neural Networks", CVPR 2014

Application similaire : estimation de pose

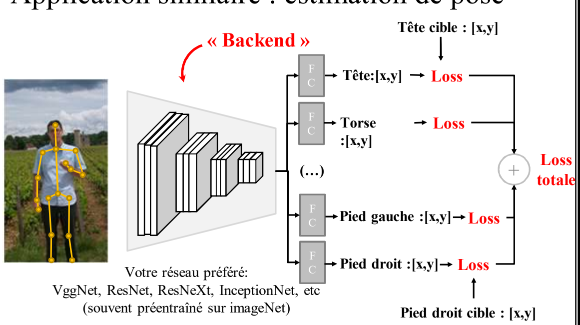

Toshev and Szegedy, "DeepPose: Human Pose Estimation via Deep Neural Networks", CVPR 2014

Localisation de plusieurs objets

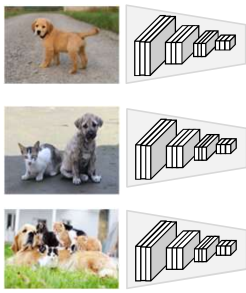

P('Chien') = p
[x,y,w,h]

P('Chien') = p
[x,y,w,h]
P('Chat') = p
[x,y,w,h]

P('Chien') = p
[x,y,w,h]
P('Chat') = p
[x,y,w,h]
P('Chat') = p
[x,y,w,h]
…

Localisation de plusieurs objets

Problème: chaque image commande une sortie différente

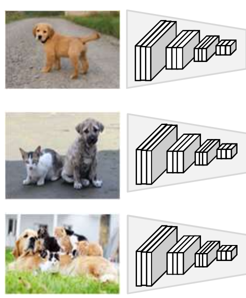

'Chien'
[x,y,w,h]

'Chien'
[x,y,w,h]
'Chat' [x,y,w,h]

'Chien'
[x,y,w,h]
'Chat' [x,y,w,h]
'Chat' [x,y,w,h]
…

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

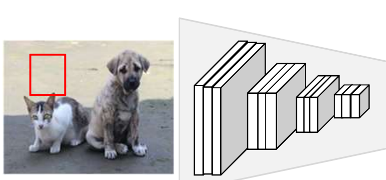

P('Fond') = 1

Votre réseau préféré:
VggNet, ResNet, ResNeXt, etc
(souvent préentraîné sur imageNet)

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

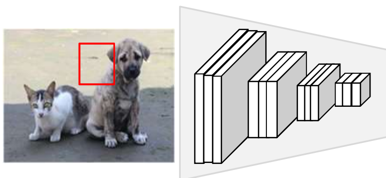

P('Fond') = 0.7

Votre réseau préféré:
VggNet, ResNet, ResNeXt, etc
(souvent préentraîné sur imageNet)

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

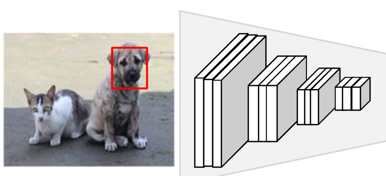

P('Chien') = 0.9

Votre réseau préféré:
VggNet, ResNet, ResNeXt, etc
(souvent préentraîné sur imageNet)

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

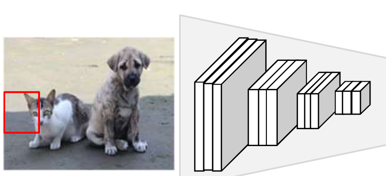

P('Fond') = 0.5

Votre réseau préféré:
VggNet, ResNet, ResNeXt, etc
(souvent préentraîné sur imageNet)

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

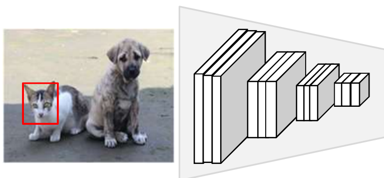

P('Chat') = 0.9

Votre réseau préféré:
VggNet, ResNet, ResNeXt, etc
(souvent préentraîné sur imageNet)

Localisation de plusieurs objets

Solution 1 : appliquer un CNN à une fenêtre coulissante

3 classes :'Chien', 'Chat', 'Fond'

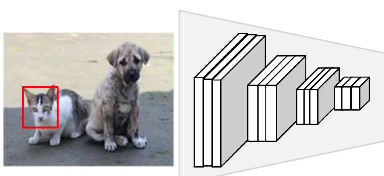

P('Chat') = 0.9

L'inconvénient de cette méthode est qu'elle requière de traiter un très grand nombre de fenêtres coulissantes de plusieurs dimensions.

Localisation de plusieurs objets

Solution 2 : Présélectionner un nombre restreint de fenêtres.

Il est relativement facile et rapide de trouver ~1000 fenêtres susceptibles de contenir un objet d'intérêt

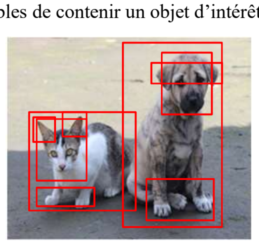

On appelle ce type de méthodes « *Region proposal method* »

Alexe et al, "Measuring the objectness of image windows", TPAMI 2012
Uijlings et al, "Selective Search for Object Recognition", IJCV 2013
Cheng et al, "BING: Binarized normed gradients for objectness estimation at 300fps", CVPR 2014
Zitnick and Dollar, "Edge boxes: Locating object proposals from edges", ECCV 2014

R-CNN [Girshick et al, 2014]

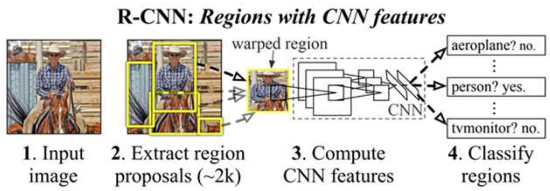

1. Extraire des regions (de 1000 à 2000) à l'aide d'une « *region proposal method* »

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

115

R-CNN [Girshick et al, 2014]

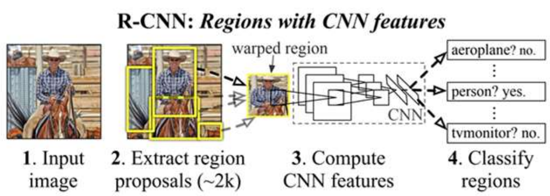

1. Extraire des regions (1000 à 2000) à l'aide d'une « *region proposal method* »

2. Crop + réajuster la taille de chaque région afin qu'elles soient toutes identiques

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

116

R-CNN [Girshick et al, 2014]

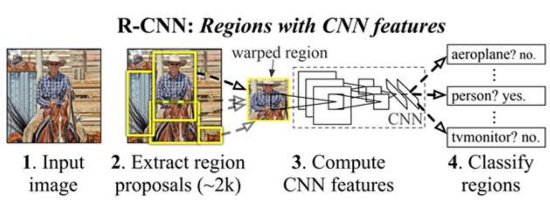

1. Extraire des regions (1000 à 2000) à l'aide d'une « *region proposal method* »

2. Crop + réajuster la taille de chaque région afin qu'elles soient toutes identiques

3. Extraire des caractéristiques profondes (sortie de AlexNet ou VggNet avant le Softmax)

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

117

R-CNN [Girshick et al, 2014]

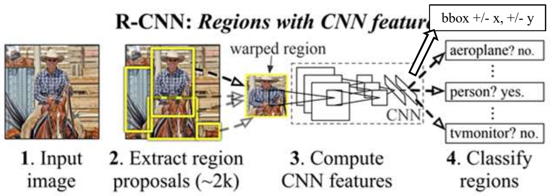

1. Extraire des regions (1000 à 2000) à l'aide d'une « *region proposal method* »

2. Crop + réajuster la taille de chaque région afin qu'elles soient toutes identiques

3. Extraire des caractéristiques profondes (sortie de AlexNet ou VggNet avant le Softmax)

4. Classification & localization (localisation pour ajuster la position des régions)

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

118

R-CNN [Girshick et al, 2014]

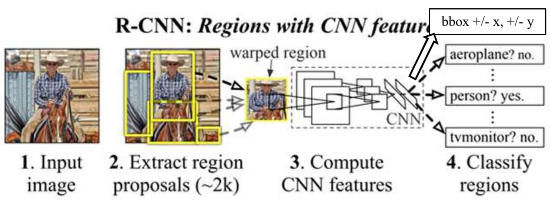

1. Extraire des regions (1000 à 2000) à l'aide d'une « *region proposal method* »

2. Crop + réajuster la taille de chaque région afin qu'elles soient toutes identiques

3. Extraire des caractéristiques profondes (sortie de AlexNet ou VggNet avant le Softmax)

4. Classification & localization (localisation pour ajuster la position des régions)

5. Éliminer les fenêtres qui se chevauchent en ne gardant que les plus "probables"

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

119

R-CNN [Girshick et al, 2014]

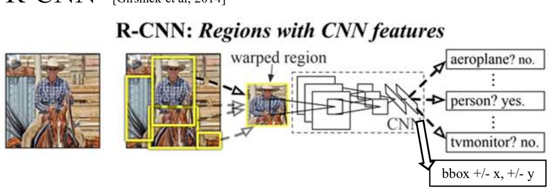

Composantes:
- *Region-proposal* par *Selective Search*
- "Backend" (AlexNet ou VGG16) pré-entraîné sur ImageNet puis *finetuned* sur Pascal VOC
- SVM *par classe* pour la classification
- Régresseur pour bouger les régions

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

120

(Parenthèse)

Pour mieux comprendre

121

Region proposal methods

Présélectionner un nombre restreint de fenêtres.

Image tirée de l'article

Alexe et al, "Measuring the objectness of image windows", TPAMI 2012
Uijlings et al, "Selective Search for Object Recognition", IJCV 2013
Cheng et al, "BING: Binarized normed gradients for objectness estimation at 300fps", CVPR 2014
Zitnick and Dollar, "Edge boxes: Locating object proposals from edges", ECCV 2014

Region proposal methods

Présélectionner un nombre restreint de fenêtres.

À partir d'une segmentation initiale

1. Sélectionner les régions les plus similaires
2. Regrouper ces régions
3. Répéter jusqu'à ce qu'une seule région ne reste

À chaque étape, on calcule les boîtes autour des régions
On garde les *n* dernières boîtes

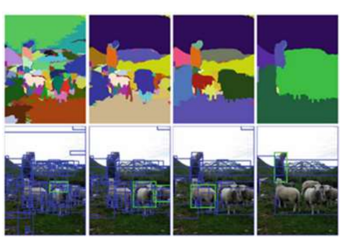

Alexe et al, "Measuring the objectness of image windows", TPAMI 2012
Uijlings et al, "Selective Search for Object Recognition", IJCV 2013
Cheng et al, "BING: Binarized normed gradients for objectness estimation at 300fps", CVPR 2014
Zitnick and Dollar, "Edge boxes: Locating object proposals from edges", ECCV 2014

Intersection over Union

Aussi appelé "Jaccard Index"

Comment comparer les régions ?

$$\frac{|\text{Intersection}|}{|\text{Union}|}$$

0.5 est "correct"
0.7 est bon
0.9 est excellent

Intersection over Union

Aussi appelé "Jaccard Index"

Comment comparer les régions ?

$$\frac{|\text{Intersection}|}{|\text{Union}|}$$

0.5 est "correct"
0.7 est bon
0.9 est excellent

Intersection over Union

Aussi appelé "Jaccard Index"

Comment comparer les régions ?

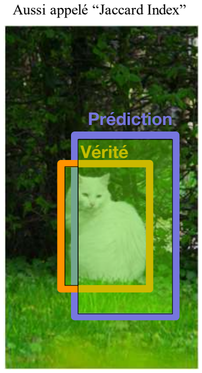

$$\frac{|\text{Intersection}|}{|\text{Union}|}$$

0.5 est "correct"
0.7 est bon
0.9 est excellent

"Non-Max Suppression"

Comment éviter les duplicatas (2 boîtes sur un même objet) ?

1. Sélectionner la boîte avec le plus haut score
2. Éliminer les boîtes avec un IoU > ε (p.e. 0.7) ayant un score moins élevé
3. Répéter jusqu'à ce qu'aucune boîte ne puisse être éliminée

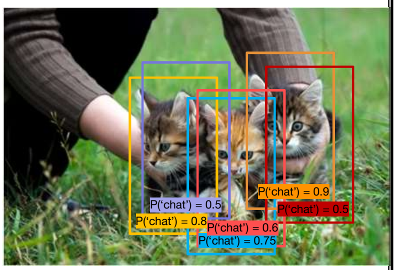

"Non-Max Suppression"

Comment éviter les duplicatas (2 boîtes sur un même objet) ?

1. Sélectionner la boîte avec le plus haut score
2. Éliminer les boîtes avec un IoU > ε (p.e. 0.7) ayant un score moins élevé
3. Répéter jusqu'à ce qu'aucune boîte ne puisse être éliminée

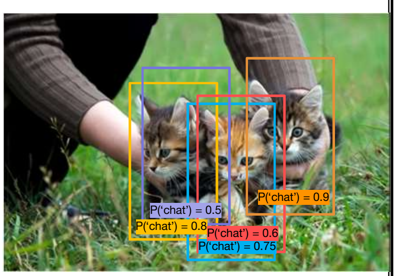

"Non-Max Suppression"

Comment éviter les duplicatas (2 boîtes sur un même objet) ?

1. Sélectionner la boîte avec le plus haut score
2. Éliminer les boîtes avec un IoU > ε (p.e. 0.7) ayant un score moins élevé
3. Répéter jusqu'à ce qu'aucune boîte ne puisse être éliminée

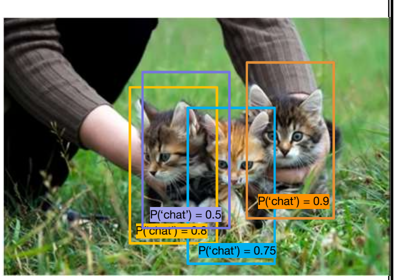

“Non-Max Suppression”

Comment éviter les duplicatas (2 boîtes sur un même objet) ?

1. Sélectionner la boîte avec le plus haut score
2. Éliminer les boîtes avec un IoU > ε (p.e. 0.7) ayant un score moins élevé
3. Répéter jusqu'à ce qu'aucune boîte ne puisse être éliminée

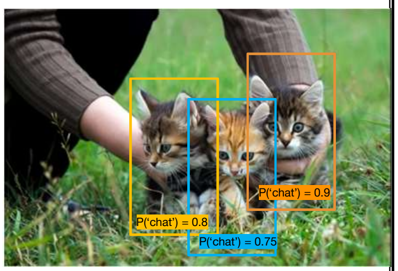

“mean Average Precision”

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction ET de la localisation

Classification:
- “Top 1%”
- “Top 5%”
- Top ..%

Segmentation:
- (Sørensen–)Dice/F1
- IoU/Jaccard Index
- Précision

Localisation ?

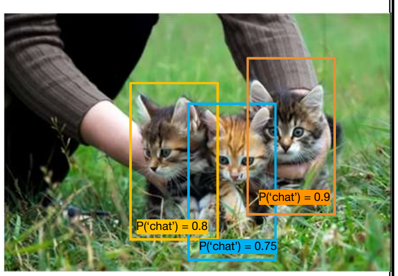

“mean Average Precision”

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

Matrice de confusion:

		Vérité Positif	**Vérité** Négatif
Prédiction	Positif	*True positive (TP)*	*False Positive (FP)*
Prédiction	Négatif	*False negative (FN)*	*True negative (TN)*

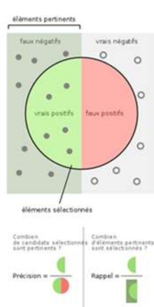

Précision: Les éléments trouvés sont-ils les bons ?
Rappel (sensibilité): Les bons éléments sont-ils trouvés ?

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante
         2. Sinon, l'indiquer comme faux positif
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

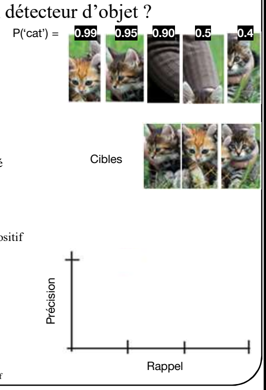

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. **Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante**
         2. Sinon, l'indiquer comme faux positif
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

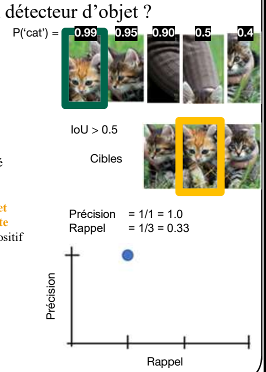

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. **Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante**
         2. Sinon, l'indiquer comme faux positif
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

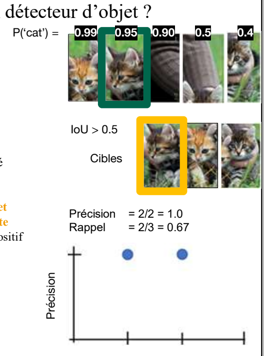

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante
         2. **Sinon, l'indiquer comme faux positif**
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

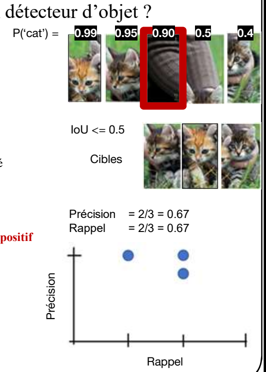

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante
         2. **Sinon, l'indiquer comme faux positif**
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

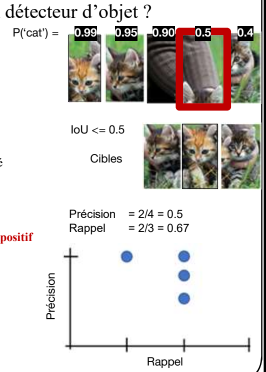

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par probabilité
      ii. Prendre la détection la plus probable
         1. **Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante**
         2. Sinon, l'indiquer comme faux positif
      iii. Tracer le point
   b. Calculer l'aire sous la courbe

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes

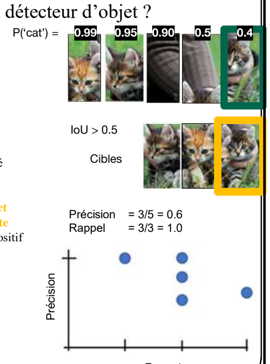

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Doit évaluer la qualité de la prédiction *ET* de la localisation

1. Faire la détection sur toutes les images de test
2. Pour chaque image et chaque classe
   a. Pour chaque détection
      i. Ordonner les détections par
      ii. Prendre la détection la plus probable
         1. Si elle correspond à une cible, l'indiquer comme vrai positif et éliminer la cible correspondante
         2. Sinon, l'indiquer comme faux positif
      iii. Tracer le point
   b. Calculer l'aire sous la courbe
   => *average precision*

3. Faire la moyenne pour chaque image
4. Faire la moyenne pour toutes les classes => **mAP**

P('cat') =

IoU > 0.5

Cibles

Précision = 3/5 = 0.6
Rappel = 3/3 = 1.0

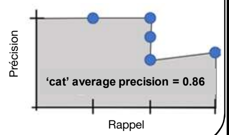

Adapté de https://web.eecs.umich.edu/~justincj/slides/eecs498/498_FA2019_lecture15.pdf

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Exemples:

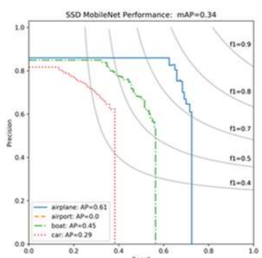

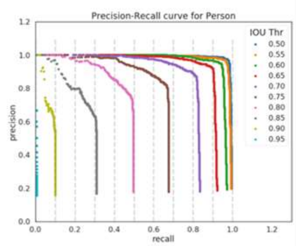

Van Etten, A. (2019, January). Satellite imagery multiscale rapid detection with windowed networks. In *2019 IEEE Winter Conference on Applications of Computer Vision (WACV)* (pp. 735-743). IEEE.

https://medium.com/@timothycarlen/understanding-the-map-evaluation-metric-for-object-detection-a07fe6962cf3

"mean Average Precision"

Comment mesurer la performance d'un détecteur d'objet ?

Autre exemple

method	train set	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	persn	plant	sheep	sofa	train	tv	mAP
SPPnet BB [11]†	07 \ diff	73.9	72.3	62.5	51.5	44.4	74.4	73.0	74.4	42.3	73.6	57.7	70.3	74.6	74.3	54.2	34.0	56.4	56.4	67.9	73.5	63.1
R-CNN BB [10]	07	73.4	77.0	63.4	45.4	**44.6**	75.1	78.1	79.8	40.5	73.7	62.2	79.4	78.1	73.1	64.2	**35.6**	66.8	67.2	70.4	**71.1**	66.0
FRCN [ours]	07	74.5	78.3	69.2	53.2	36.6	77.3	78.2	82.0	40.7	72.7	67.9	79.6	79.2	73.0	69.0	30.1	65.4	70.2	75.8	65.8	66.9
FRCN [ours]	07 \ diff	74.6	**79.0**	68.6	57.0	39.3	79.5	**78.6**	81.9	**48.0**	74.0	67.4	80.5	80.7	74.1	69.6	31.8	67.1	68.4	75.3	65.5	68.1
FRCN [ours]	07+12	**77.0**	78.1	**69.3**	**59.4**	38.3	**81.6**	**78.6**	**86.7**	42.8	**78.8**	**68.9**	**84.7**	**82.0**	**76.6**	**69.9**	31.8	**70.1**	**74.8**	**80.4**	70.4	**70.0**

Table 1. **VOC 2007 test** detection average precision (%). All methods use VGG16. Training set key: **07**: VOC07 trainval, **07 \ diff**: **07** without "difficult" examples, **07+12**: union of **07** and VOC12 trainval. †SPPnet results were prepared by the authors of [11].

Girshick, R. (2015). Fast r-cnn. In *Proceedings of the IEEE international conference on computer vision* (pp. 1440-1448).

Jeux de données populaires

Action Classification (10 classes + “other”)

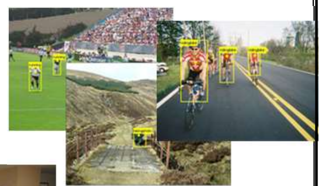

Pascal VOC (2005-2012)

Classification/Detection (20 classes)

http://host.robots.ox.ac.uk/pascal/VOC/voc2012/index.html

Jeux de données populaires

ImageNet (2013+)

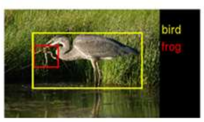

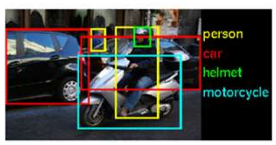

Comparative scale

		PASCAL VOC 2012	ILSVRC 2013
Number of object classes		20	**200**
Training	Num images	5717	395909
	Num objects	13609	345854
Validation	Num images	5823	20121
	Num objects	13841	55502
Testing	Num images	10991	40152
	Num objects	---	---

https://image-net.org/challenges/LSVRC/2013/

Jeux de données populaires

MS-COCO (2014+) 100 classes

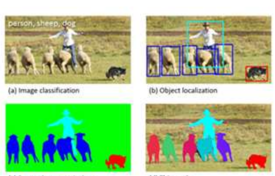

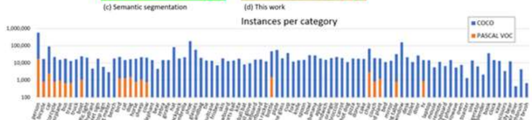

Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014, September). Microsoft coco: Common objects in context. In European conference on computer vision (pp. 740-755). Springer, Cham.

Jeux de données populaires

MS-COCO (2014+) 100 classes

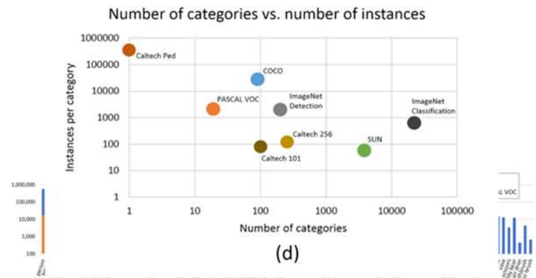

Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., ... & Zitnick, C. L. (2014, September). Microsoft coco: Common objects in context. In European conference on computer vision (pp. 740-755). Springer, Cham.

De retour au programme principal

147

R-CNN [Girshick et al, 2014]

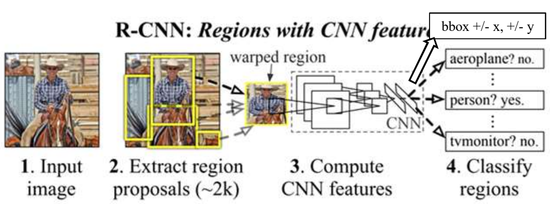

VOC 2010 test	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv	mAP
DPM v5 [20]†	49.2	53.8	13.1	15.3	35.5	53.4	49.7	27.0	17.2	28.8	14.7	17.8	46.4	51.2	47.7	10.8	34.2	20.7	43.8	38.3	33.4
UVA [39]	56.2	42.4	15.3	12.6	21.8	49.3	36.8	46.1	12.9	32.1	30.0	36.5	43.5	52.9	32.9	15.3	41.1	31.8	47.0	44.8	35.1
Regionlets [41]	65.0	48.9	25.9	24.6	24.5	56.1	54.5	51.2	17.0	28.9	30.2	35.8	40.2	55.7	43.5	14.3	43.9	32.6	54.0	45.9	39.7
SegDPM [18]†	61.4	53.4	25.6	25.2	35.5	51.7	50.6	50.8	19.3	33.8	26.8	40.4	48.3	54.4	47.1	14.8	38.7	35.0	52.8	43.1	40.4
R-CNN	67.1	64.1	46.7	32.0	30.5	56.4	57.2	65.9	27.0	47.3	40.9	66.6	57.8	65.9	53.6	26.7	56.5	38.1	52.8	50.2	50.2
R-CNN BB	**71.8**	**65.8**	**53.0**	**36.8**	**35.9**	**59.7**	**60.0**	**69.9**	**27.9**	**50.6**	**41.4**	**70.0**	**62.0**	**69.0**	**58.1**	**29.5**	**59.4**	**39.3**	**61.2**	**52.4**	**53.7**

Table 1: Detection average precision (%) on VOC 2010 test. R-CNN is most directly comparable to UVA and Regionlets since all methods use selective search region proposals. Bounding-box regression (BB) is described in Section C. At publication time, SegDPM was the top-performer on the PASCAL VOC leaderboard. †DPM and SegDPM use context rescoring not used by the other methods.

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

148

R-CNN [Girshick et al, 2014]

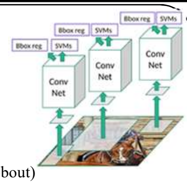

Problème du R-CNN

3 entraînements séparés (pas d'entraînement bout-en-bout)
- *Finetuning* du CNN (entropie croisée)
  - pré-entraîné sur ImageNet
  - ré-entraîné sur Pascal VOC
- Entraînement du SVM (Hinge loss)
- Entraînement de la régression (loss L2)

Entraînement lent et complexe
- 84h

Détection lente
- 47secondes / image avec VGG16

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

149

R-CNN [Girshick et al, 2014]

Problème du R-CNN

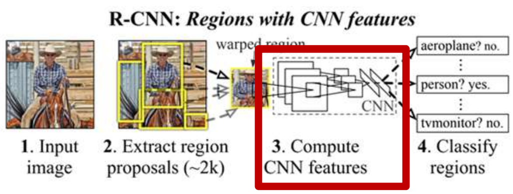

2000 *propagations avant* par image !

Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014

150

Fast R-CNN [Girshick, 2015]

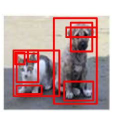

640x480x3

1. Localiser des régions

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

« Backend »

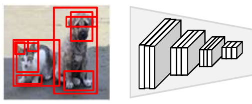

640x480x3

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

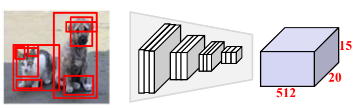

640x480x3

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels. Cartes d'activation **20x15x512**

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

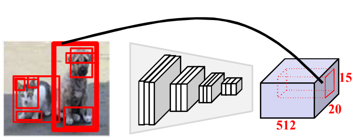

640x480x3

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels. Cartes d'activation **20x15x512**

3. À tour de rôle, projeter chaque région vers les cartes d'activation.

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

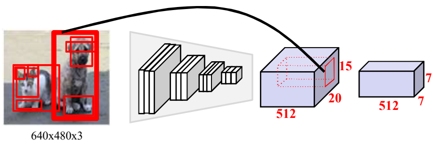

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels. Cartes d'activation **20x15x512**

3. À tour de rôle, projeter chaque région vers les cartes d'activation.

4. Crop + resize **7x7x512** (« ROI pooling »)

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

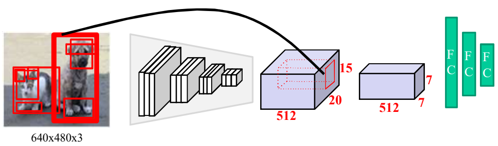

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels. Cartes d'activation **20x15x512**

3. À tour de rôle, projeter chaque région vers les cartes d'activation.

4. Crop + resize **7x7x512** (« ROI pooling »)

5. Couches pleinemen connectées

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick, 2015]

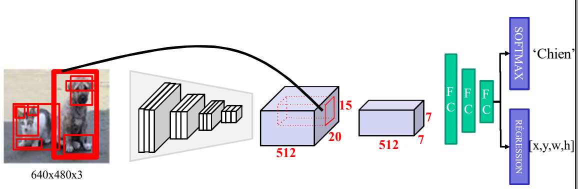

1. Localiser des régions

2. Propagation avant de l'image dans 5 blocs convolutionnels. Cartes d'activation **20x15x512**

3. À tour de rôle, projeter chaque région vers les cartes d'activation.

4. Crop + resize **7x7x512** (« ROI pooling »)

5. Couches pleinemen connectées

6. Classification + régression

Girshick, "Fast R-CNN", ICCV 2015.

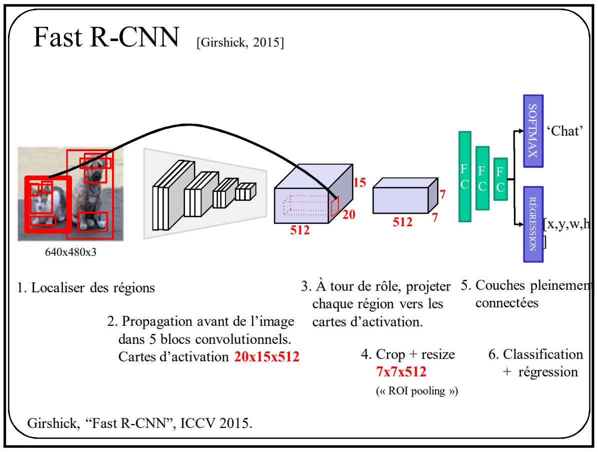
Fast R-CNN [Girshick, 2015]
‘Chat’
SOFTMAX
RÉGRESSION
[x,y,w,h
F C
F C
F C
15
20
512
7
7
512
640x480x3
1. Localiser des régions
2. Propagation avant de l’image dans 5 blocs convolutionnels. Cartes d’activation 20x15x512
3. À tour de rôle, projeter chaque région vers les cartes d’activation.
4. Crop + resize 7x7x512
(« ROI pooling »)
5. Couches pleinemen connectées
6. Classification + régression
Girshick, “Fast R-CNN”, ICCV 2015.

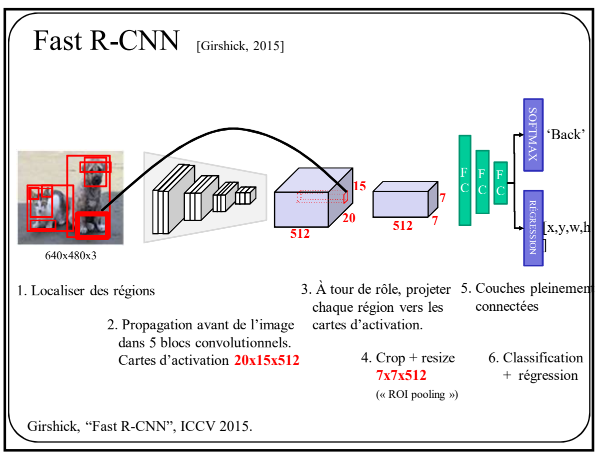
Fast R-CNN [Girshick, 2015]
‘Back’
SOFTMAX
RÉGRESSION
[x,y,w,h
F C
F C
F C
15
20
512
7
7
512
640x480x3
1. Localiser des régions
2. Propagation avant de l’image dans 5 blocs convolutionnels. Cartes d’activation 20x15x512
3. À tour de rôle, projeter chaque région vers les cartes d’activation.
4. Crop + resize 7x7x512
(« ROI pooling »)
5. Couches pleinemen connectées
6. Classification + régression
Girshick, “Fast R-CNN”, ICCV 2015.

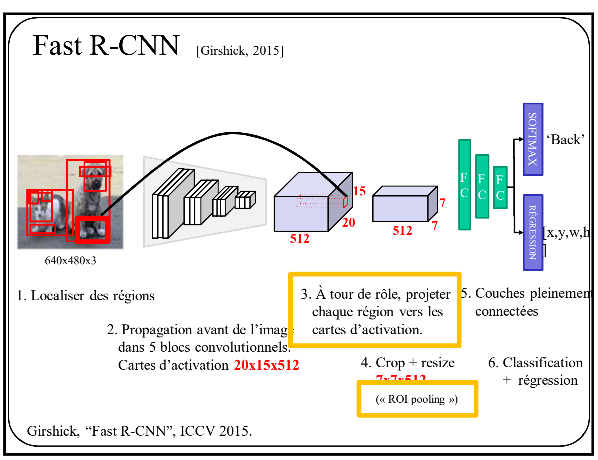
Fast R-CNN [Girshick, 2015]
‘Back’
SOFTMAX
RÉGRESSION
[x,y,w,h
F C
F C
F C
15
20
512
7
7
512
640x480x3
1. Localiser des régions
2. Propagation avant de l’imag dans 5 blocs convolutionnels. Cartes d’activation 20x15x512
3. À tour de rôle, projeter chaque région vers les cartes d’activation.
4. Crop + resize
(« ROI pooling »)
5. Couches pleinemen connectées
6. Classification + régression
Girshick, “Fast R-CNN”, ICCV 2015.

ROI pooling

Comment transformer une région de taille arbitraire en taille fixe pour un CNN ?

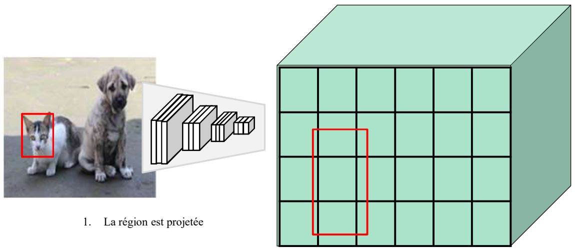

1. La région est projetée

Girshick, “Fast R-CNN”, ICCV 2015.

ROI pooling

Comment transformer une région de taille arbitraire en taille fixe pour un CNN ?

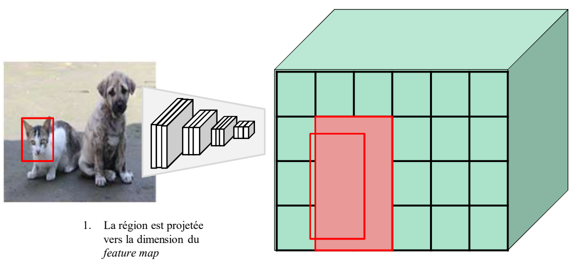

1. La région est projetée vers la dimension du *feature map*

2. La région est ajustée à la grille (*snap*)

Girshick, “Fast R-CNN”, ICCV 2015.

ROI pooling

Comment transformer une région de taille arbitraire en taille fixe pour un CNN ?

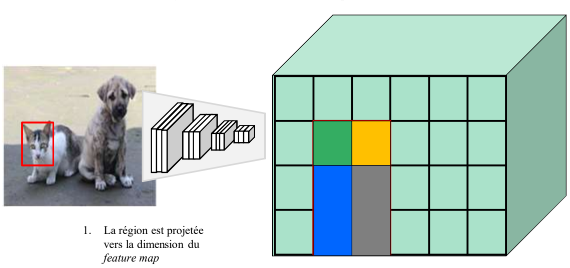

1. La région est projetée vers la dimension du *feature map*

2. La région est ajustée à la grille (*snap*)
3. La grille est subdivisée en nxn régions cibles (p.e. 7x7)

Girshick, “Fast R-CNN”, ICCV 2015.

ROI pooling

Comment transformer une région de taille arbitraire en taille fixe pour un CNN ?

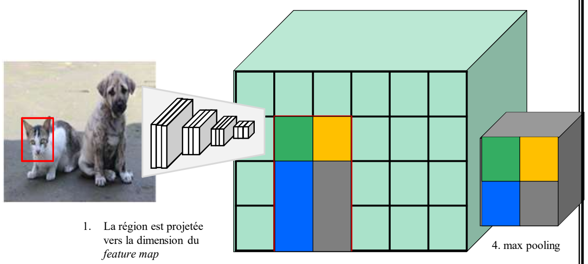

Girshick, “Fast R-CNN”, ICCV 2015.

Fast R-CNN [Girshick, 2015]

Autre illustration (de Girshick):

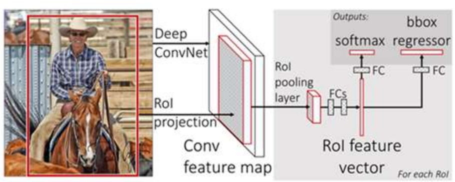

Avantages:
- 1 propagation avant par image au lieu de 1 par région
- Entraînement bout-en-bout

Inconvénients:
- La “*region proposal method*” indépendante du réseau

Girshick, “Fast R-CNN”, ICCV 2015.

Fast R-CNN [Girshick et al, 2015]

Tiré de l’article

method	train set	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	persn	plant	sheep	sofa	train	tv	mAP
BabyLearning	Prop.	78.0	74.2	61.3	45.7	42.7	68.2	66.8	80.2	40.6	70.0	49.8	79.0	74.5	77.9	64.0	35.3	67.9	55.7	68.7	62.6	63.2
NUS_NIN_c2000	Unk.	80.2	73.8	61.9	43.7	**43.0**	70.3	67.6	80.7	41.9	69.7	51.7	78.2	75.2	76.9	65.1	**38.6**	**68.3**	58.0	68.7	63.3	63.8
R-CNN BB [10]	12	79.6	72.7	61.9	41.2	41.9	65.9	66.4	84.6	38.5	67.2	46.7	82.0	74.8	76.0	65.2	35.6	65.4	54.2	67.4	60.3	62.4
FRCN [ours]	12	80.3	74.7	66.9	46.9	37.7	73.9	68.6	87.7	41.7	71.1	51.1	86.0	77.8	79.8	69.8	32.1	65.5	63.8	76.4	61.7	65.7
FRCN [ours]	07++12	**82.3**	**78.4**	**70.8**	**52.3**	38.7	**77.8**	**71.6**	**89.3**	**44.2**	**73.0**	**55.0**	**87.5**	**80.5**	**80.8**	**72.0**	35.1	**68.3**	**65.7**	**80.4**	**64.2**	**68.4**

Table 3. **VOC 2012 test** detection average precision (%). BabyLearning and NUS_NIN_c2000 use networks based on [17]. All other methods use VGG16. Training set key: see Table 2, **Unk.**: unknown.

Girshick, “Fast R-CNN”, ICCV 2015.

Fast R-CNN [Girshick et al, 2015]

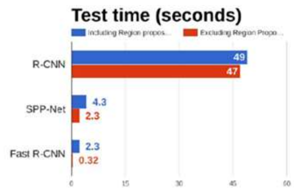

Girshick, "Fast R-CNN", ICCV 2015.

Fast R-CNN [Girshick et al, 2015]

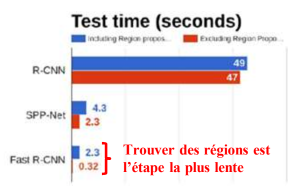

CNN: exécutés sur GPU => rapide !
Region proposal: exécuté sur CPU => lent :(

Girshick, "Fast R-CNN", ICCV 2015.

Faster R-CNN [Ren et al, 2015]

Idée:

- Trouver les régions à même les cartes d'activation avec un *Region Proposal Network (RPN)*
- Chaque boîte possible est une sortie du RPN

4 loss utilisées simultanément:

1. RPN : Classification **objet vs pas_un_objet**
2. RPN : régression [x,y,w,h]
3. Classification de l'objet dans la région (chien,chat…)
4. Régression des coordonnées finales de la region.

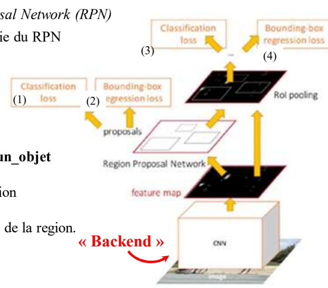

Ren et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." NIPS. 2015.

170

Faster R-CNN [Ren et al, 2015]

- Utilisation de **"anchors"**
- Boîtes de forme prédéterminée
- En pratique: k = 9

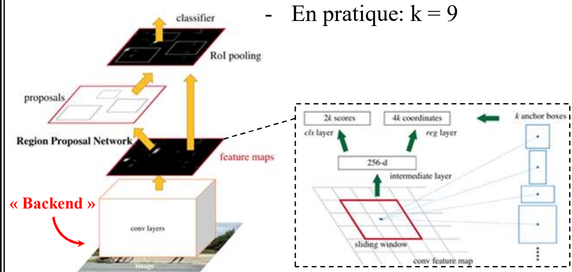

Ren et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." NIPS. 2015.

171

Faster R-CNN [Ren et al, 2015]

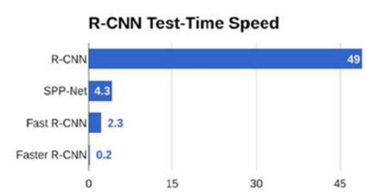

Table 5: **Timing** (ms) on a K40 GPU, except SS proposal is evaluated in a CPU. "Region-wise" includes NMS, pooling, fully-connected, and softmax layers. See our released code for the profiling of running time.

model	system	conv	proposal	region-wise	total	rate
VGG	SS + Fast R-CNN	146	1510	174	1830	0.5 fps
VGG	RPN + Fast R-CNN	141	**10**	47	**198**	**5 fps**
ZF	RPN + Fast R-CNN	31	**3**	25	**59**	**17 fps**

Ren et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." NIPS. 2015.

172

Faster R-CNN [Ren et al, 2015]

Table 7: Results on PASCAL VOC 2012 test set with Fast R-CNN detectors and VGG-16. For RPN, the train-time proposals for Fast R-CNN are 2000.

method	# box	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
SS	2000	12	65.7	80.3	74.7	66.9	46.9	37.7	73.9	68.6	87.7	41.7	71.1	51.1	86.0	77.8	79.8	69.8	32.1	65.5	63.8	76.4	61.7
SS	2000	07++12	68.4	82.3	78.4	70.8	52.3	38.7	77.8	71.6	89.3	44.2	73.0	55.0	**87.5**	80.5	80.8	72.0	35.1	68.3	**65.7**	80.4	64.2
RPN	300	12	67.0	82.3	76.4	71.0	48.4	45.2	72.1	72.3	87.3	42.2	73.7	50.0	86.8	78.7	78.4	77.4	34.5	70.1	57.1	77.1	58.9
RPN	300	07++12	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
RPN	300	COCO+07++12	**75.9**	**87.4**	**83.6**	**76.8**	**62.9**	**59.6**	**81.9**	**82.0**	**91.3**	**54.9**	**82.6**	**59.0**	**89.0**	**85.5**	**84.7**	**84.1**	**52.2**	**78.9**	65.5	**85.4**	**70.2**

Avantages:

- 1 propagation avant par image au lieu de 1 par région
- Entraînement bout-en-bout
- *Region proposal method* apprise !
- Inférence très rapide

Inconvénients:

- Architecture complexe avec plusieurs *moving parts*
- Entraînement pas vraiment bout en bout (anchors)
- Détection en plusieurs étapes

Ren et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." NIPS. 2015.

173

Faster R-CNN [Ren et al, 2015]

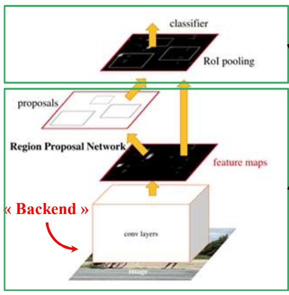

Deux étapes:
- Proposer les régions
- Classifier les régions

Idéalement, tout serait en une étape

Ren et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." NIPS. 2015.

174

Faster R-CNN

Autre illustration de *Faster R-CNN*

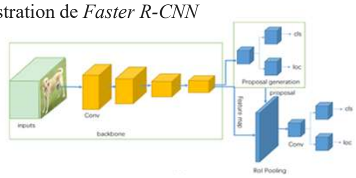

Jiao, L., Zhang, F., Liu, F., Yang, S., Li, L., Feng, Z., & Qu, R. (2019). A survey of deep learning-based object detection. *IEEE access*, *7*, 128837-128868.

175

Un 2e type d'approche sans RPN

Autre illustration de *Faster R-CNN*

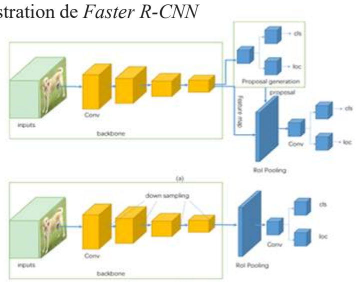

Jiao, L., Zhang, F., Liu, F., Yang, S., Li, L., Feng, Z., & Qu, R. (2019). A survey of deep learning-based object detection. *IEEE access*, *7*, 128837-128868.

176

YOLO [Redmon2017, Redmon2018]

Fini les « *region proposal methods* ». On convertit une image en une grille de **49 (7x7) prédictions**.

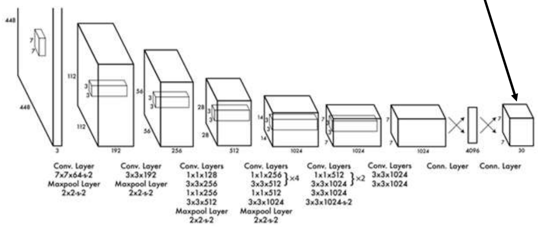

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018

177

YOLO [Redmon2017, Redmon2018]

Pour chaque élément de la grille 7x7, **on prédit 2 boîtes englobantes.**
15 prédictions par boîte : **[x,y,w,h,confiance]** et **10 classes**.
Avec 2 boîtes par élément, ça fait une **prédiction de 30 éléments**
(d'où le bloc 7x7x30 de la page précédente)

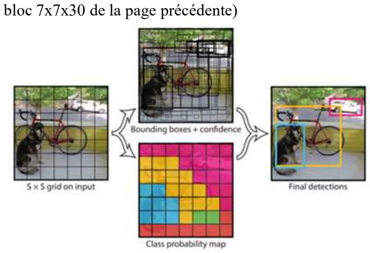

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018

178

YOLO [Redmon2017, Redmon2018]

Ainsi, YOLO prédit TOUJOURS **49x2=98 objets possibles** chacune avec un **indice de confiance**.

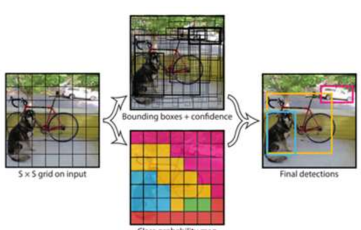

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018

179

YOLO [Redmon2017, Redmon2018]

VOC 2012 test	mAP	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
MR_CNN_MORE_DATA [11]	**73.9**	**85.5**	**82.9**	**76.6**	**57.8**	**62.7**	**79.4**	77.2	86.6	**55.0**	**79.1**	**62.2**	87.0	**83.4**	**84.7**	78.9	45.3	73.4	65.8	80.3	74.0
HyperNet_VGG	71.4	84.2	78.5	73.6	55.6	53.7	78.7	**79.8**	87.7	49.6	74.9	52.1	86.0	81.7	83.3	**81.8**	**48.6**	**73.5**	59.4	79.9	65.7
HyperNet_SP	71.3	84.1	78.3	73.3	55.5	53.6	78.6	79.6	87.5	49.5	74.9	52.1	85.6	81.6	83.2	81.6	48.4	73.2	59.3	79.7	65.6
Fast R-CNN + YOLO	70.7	83.4	78.5	73.5	55.8	43.4	79.1	73.1	**89.4**	49.4	75.5	57.0	**87.5**	80.9	81.0	74.7	41.8	71.5	68.5	**82.1**	67.2
MR_CNN_S_CNN [11]	70.7	85.0	79.6	71.5	55.3	57.7	76.0	73.9	84.6	50.5	74.3	61.7	85.5	79.9	81.7	76.4	41.0	69.0	61.2	77.7	72.1
Faster R-CNN [28]	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
DEEP_ENS_COCO	70.1	84.0	79.4	71.6	51.9	51.1	74.1	72.1	88.6	48.3	73.4	57.8	86.1	80.0	80.7	70.4	46.6	69.6	**68.8**	75.9	71.4
NoC [29]	68.8	82.8	79.0	71.6	52.3	53.7	74.1	69.0	84.9	46.9	74.3	53.1	85.0	81.3	79.5	72.2	38.9	72.4	59.5	76.7	68.1
Fast R-CNN [14]	68.4	82.3	78.4	70.8	52.3	38.7	77.8	71.6	89.3	44.2	73.0	55.0	**87.5**	80.5	80.8	72.0	35.1	68.3	65.7	80.4	64.2
UMICH_FGS_STRUCT	66.4	82.9	76.1	64.1	44.6	49.4	70.3	71.2	84.6	42.7	68.6	55.8	82.7	77.1	79.9	68.7	41.4	69.0	60.0	72.0	66.2
NUS_NIN_C2000 [7]	63.8	80.2	73.8	61.9	43.7	43.0	70.3	67.6	80.7	41.9	69.7	51.7	78.2	75.2	76.9	65.1	38.6	68.3	58.0	68.7	63.3
BabyLearning [7]	63.2	78.0	74.2	61.3	45.7	42.7	68.2	66.8	80.2	40.6	70.0	49.8	79.0	74.5	77.9	64.0	35.3	67.9	55.7	68.7	62.6
NUS_NIN	62.4	77.9	73.1	62.6	39.5	43.3	69.1	66.4	78.9	39.1	68.1	50.0	77.2	71.3	76.1	64.7	38.4	66.9	56.2	66.9	62.7
R-CNN VGG BB [13]	62.4	79.6	72.7	61.9	41.2	41.9	65.9	66.4	84.6	38.5	67.2	46.7	82.0	74.8	76.0	65.2	35.6	65.4	54.2	67.4	60.3
R-CNN VGG [13]	59.2	76.8	70.9	56.6	37.5	36.9	62.9	63.6	81.1	35.7	64.3	43.9	80.4	71.6	74.0	60.0	30.8	63.4	52.0	63.5	58.7
YOLO	57.9	77.0	67.2	57.7	38.3	22.7	68.3	55.9	81.4	36.2	60.8	48.5	77.2	72.3	71.3	63.5	28.9	52.2	54.8	73.9	50.8
Feature Edit [33]	56.3	74.6	69.1	54.4	39.1	33.1	65.2	62.7	69.7	30.8	56.0	44.6	70.0	64.4	71.1	60.2	33.3	61.3	46.4	61.7	57.8
R-CNN BB [13]	53.3	71.8	65.8	52.0	34.1	32.6	59.6	60.0	69.8	27.6	52.0	41.7	69.6	61.3	68.3	57.8	29.6	57.8	40.9	59.3	54.1
SDS [16]	50.7	69.7	58.4	48.5	28.3	28.8	61.3	57.5	70.8	24.1	50.7	35.9	64.9	59.1	65.8	57.1	26.0	58.8	38.6	58.9	50.7
R-CNN [13]	49.6	68.1	63.8	46.1	29.4	27.9	56.6	57.0	65.9	26.5	48.7	39.5	66.2	57.3	65.4	53.2	26.2	54.5	38.1	50.6	51.6

Table 3: PASCAL VOC 2012 Leaderboard. YOLO compared with the full `comp4` (outside data allowed) public leaderboard as of November 6th, 2015. Mean average precision and per-class average precision are shown for a variety of detection methods. YOLO is the only real-time detector. Fast R-CNN + YOLO is the forth highest scoring method, with a 2.3% boost over Fast R-CNN.

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018

YOLO [Redmon2017, Redmon2018]

Ensemble de Fast R-CNN + YOLO

Moins bon que les autres, mais plus simple et rapide

Table 3: PASCAL VOC 2012 Leaderboard. YOLO compared with the full `comp4` (outside data allowed) public leaderboard as of November 6th, 2015. Mean average precision and per-class average precision are shown for a variety of detection methods. YOLO is the only real-time detector. Fast R-CNN + YOLO is the forth highest scoring method, with a 2.3% boost over Fast R-CNN.

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017

YOLOv2-3

v2:
- Batch norm
- Images de plus haute résolution
- *Anchors*
- et autres

v3:
- Réseau plus profond
- Détection à plusieurs résolutions
- Plus de boîtes par élément de grille

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018
Redmon, J., & Farhadi, A. (2018). Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.

YOLOv2-v3

Yolo v2 et James Bond

https://www.youtube.com/watch?v=VOC3huqHrss

https://pjreddie.com
(Site web du premier auteur)

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018
J. Redmon, & Farhadi, A. (2018). Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.

183

YOLOv2-v3

À ce jour, nous sommes rendu à YOLOv7!

C3huqHrss

om

J. Redmon, S Divvala, R Girshick, A Farhad "You Only Look Once: Unified, Real-Time Object Detection", CVPR 2017
J. Redmon, A. Farhadi "YOLO9000: Better, Faster, Stronger", CVPR 2018
J. Redmon, & Farhadi, A. (2018). Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.

184

SSD (single shot detector) [Liu et al. 2016]

Tout comme YOLO:

- **Pas de « *region proposal method* »** pour SSD
- Prédiction d'un **nombre fixe** de boîtes englobantes.
  - 98 pour YOLO
  - **8732 pour SSD300**
  - **24564 pour SSD512 (!)**
- Prédit 25 éléments : **[x,y,w,h,confiance,c_1,…, c_{20}]**
- Élimine les boîtes avec une confiance faible

W Liu, D Anguelov, D Erhan, C Szegedy, S Reed, C-Y Fu, AC. Berg "SSD: Single Shot MultiBox Detector", ECCV 2016

SSD300 (single shot detector) [Liu et al. 2016]

Utilise les **10 premières couches de VGG16** comme ***backend***

VGG16

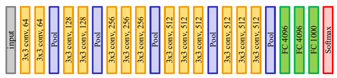

186

SSD300 (single shot detector) [Liu et al. 2016]

Utilise les **10 premières couches de VGG16** comme ***backend***

VGG16

SSD300 (single shot detector) [Liu et al. 2016]

Utilise les **10 premières couches de VGG16** comme ***backend***

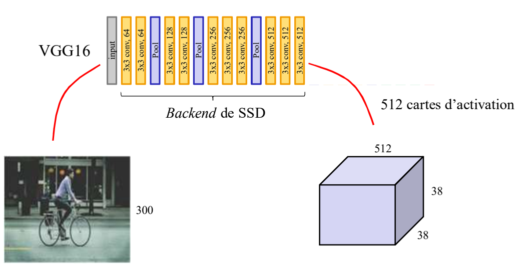

SSD300 (single shot detector) [Liu et al. 2016]

Utilise les **10 premières couches de VGG16** comme ***backend***

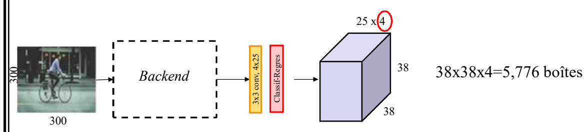

4 prédictions par pixel
1 prédiction= 25 éléments **[x,y,w,h,confiance,c_1,…, c_{20}]**

SSD300 (single shot detector) [Liu et al. 2016]

Prédiction de **5,776 boîtes**

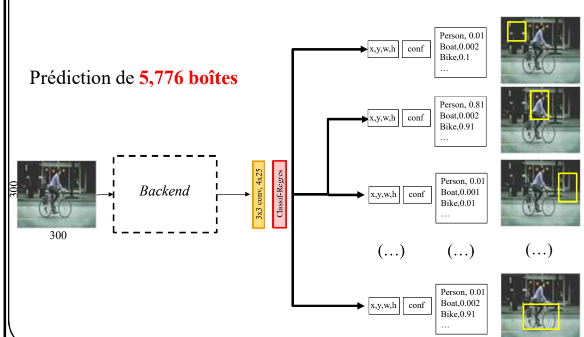

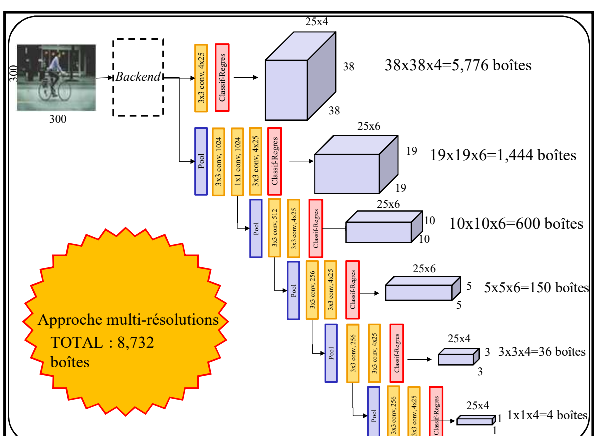

SSD (single shot detector) [Liu et al. 2016]

Autre illustration tirée de l'article (plus compacte)

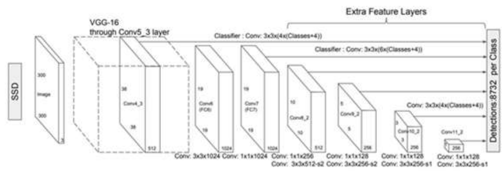

W Liu, D Anguelov, D Erhan, C Szegedy, S Reed, C-Y Fu, AC. Berg "SSD: Single Shot MultiBox Detector", ECCV 2016

SSD (single shot detector) [Liu et al. 2016]

Method	mAP	FPS
Faster R-CNN (VGG16)	73.2	7
Fast YOLO	52.7	155
YOLO (VGG16)	66.4	21
SSD300	74.3	46
SSD512	76.8	19
SSD300	74.3	59
SSD512	76.8	22

mAP : mean average precision

W Liu, D Anguelov, D Erhan, C Szegedy, S Reed, C-Y Fu, AC. Berg "SSD: Single Shot MultiBox Detector", ECCV 2016

SSD (single shot detector) [Liu et al. 2016]

https://medium.com/@jonathan_hui/ssd-object-detection-single-shot-multibox-detector-for-real-time-processing-9bd8deac0e06

Excellent document sur SSD

Segmentation par instance

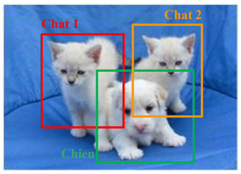

Localisation

Segmentation
par instance

195

Mask R-CNN [He et al., 2017]

Idée de base:

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN [He et al., 2017]

Idée de base:

1. Localisation

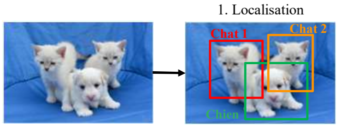

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN [He et al., 2017]

Idée de base:

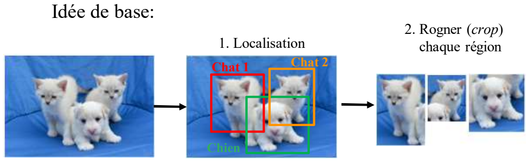

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN [He et al., 2017]

Idée de base:

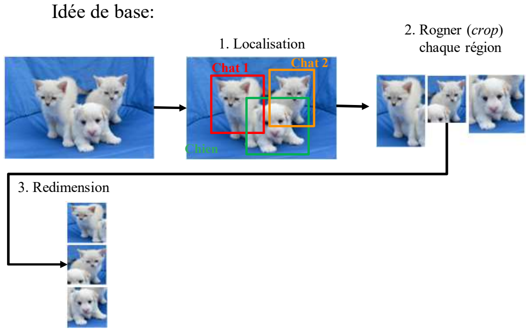

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN [He et al., 2017]

Idée de base:

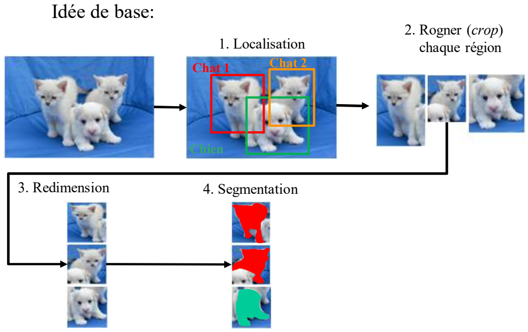

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN [He et al., 2017]

Idée de base:

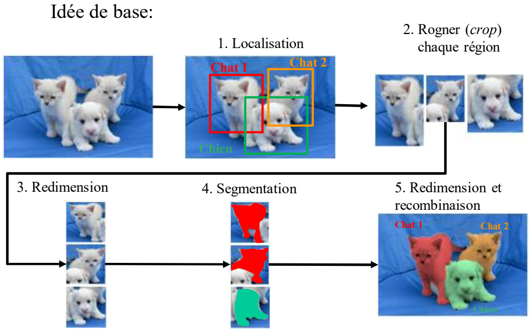

Images: He et al. "Mask R-CNN." ICCV, 2017

Mask R-CNN

=

CNN localization + CNN segmentation

202

Mask R-CNN

=

Faster R-CNN (avec backend ResNet) + CNN segmentation

(Config de l'article d'origine. D'autres versions de Mask R-CNN utilisent d'autres backends.)

203

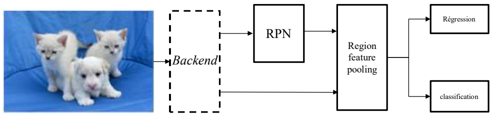

Faster R-CNN

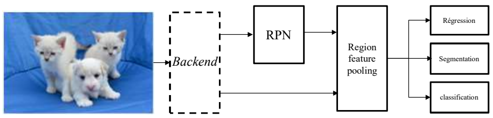

Mask R-CNN

Mask R-CNN **[He et al., 2017]**

Illustration issue de l'article

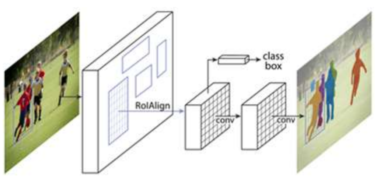

Images: He et al. "Mask R-CNN." ICCV, 2017

205

Mask R-CNN **[He et al., 2017]**

Illustration issue de l'article

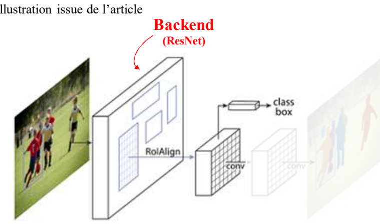

Faster R-CNN

Images: He et al. "Mask R-CNN." ICCV, 2017

206

Mask R-CNN [He et al., 2017]

Illustration issue de l'article

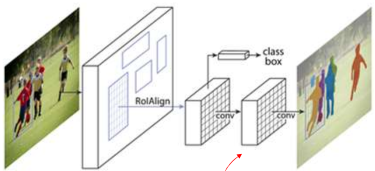

Séquence de convolutions
Pour la segmentation

Images: He et al. "Mask R-CNN." ICCV, 2017

207

Mask R-CNN [He et al., 2017]

Figure 5. More results of **Mask R-CNN** on COCO test images, using ResNet-101-FPN and running at 5 fps, with 35.7 mask AP (Table 1).

Images: He et al. "Mask R-CNN." ICCV, 2017

209

Mask R-CNN [He et al., 2017]

https://www.analyticsvidhya.com/blog/2019/07/computer-vision-implementing-mask-r-cnn-image-segmentation/

Excellent document sur **Mask R-CNN**

En résumé

Bons survols:

- Jiao, L., Zhang, F., Liu, F., Yang, S., Li, L., Feng, Z., & Qu, R. (2019). A survey of deep learning-based object detection. IEEE access, 7, 128837-128868.
- Huang, J., Rathod, V., Sun, C., Zhu, M., Korattikara, A., Fathi, A., ... & Murphy, K. (2017). Speed/accuracy trade-offs for modern convolutional object detectors. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 7310-7311).

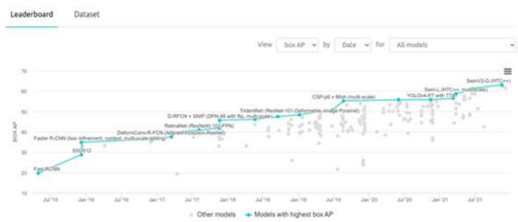

https://paperswithcode.com/sota/object-detection-on-coco

211

En résumé

La détection d'objets et segmentation d'instances est complexe avec beaucoup d'astruces pour entraîner et prédire.

Deux grandes familles de méthodes:

Two-stage detectors (e.g. fasterRCNN)
- Plus complexes
- Plus lents
- Plus performants

Single Stage detectors (e.g. yolo,SSD)
- Plus simples
- Plus rapides
- Moins performants

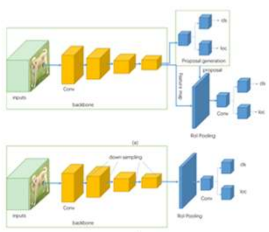

Bibliothèque de détection d'objets/segmentation en Pytorch
https://github.com/facebookresearch/detectron2

Jiao, L., Zhang, F., Liu, F., Yang, S., Li, L., Feng, Z., & Qu, R. (2019). A survey of deep learning-based object detection. *IEEE access*, *7*, 128837-128868.

212