Réseaux de neurones

# IFT 780

Réseaux récurrents

Par

Pierre-Marc Jodoin, Antoine Théberge

1

## Réseau de neurones de base (régression)

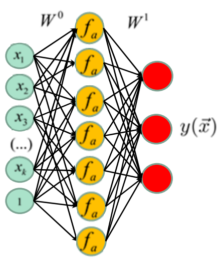


$$y(\vec{x}) = W^1 f_a(W^0\vec{x})$$

$$\vec{h} = f_a(W^0\vec{x})$$
$$y(\vec{x}) = W^1\vec{h}$$

$f_a$ : fonction d'activation

2

## Réseau de neurones de base (classification)

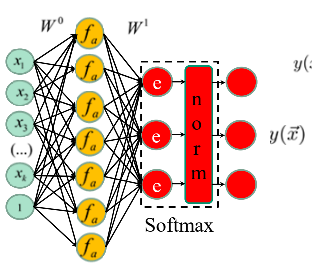


$$y(\vec{x}) = \text{softmax}(W^1 f_a(W^0\vec{x}))$$

$$\vec{h} = f_a(W^0\vec{x})$$
$$\hat{y} = W^1\vec{h}$$
$$y(\vec{x}) = \text{softmax}(\hat{y})$$

3

## Réseau de neurones de base (classification)

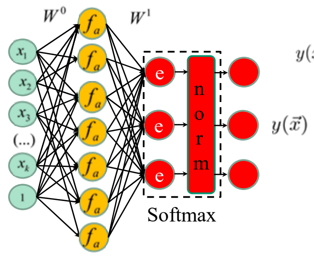


$$y(\vec{x}) = \text{softmax}(W^1 f_a(W^0\vec{x}))$$

$$\vec{h} = f_a(W^0\vec{x})$$
$$\hat{y} = W^1\vec{h}$$
$$y(\vec{x}) = \text{softmax}(\hat{y})$$

Ne permet que des tâches “1 pour 1”
- Classification (1 image = 1 étiquette)
- Régression (1 donnée = 1 vecteur)
- Localisation (1 boîte = 1 classification + 1 régression)

4

## Illustration simplifiée

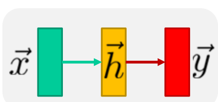


**RN de base**

5

## Différentes configurations pour différentes applications

1 entrée et 1 sortie

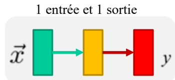


1 entrée et N sorties

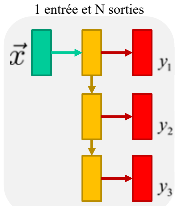


**Ex.: description d’une image**
**1 image => N mots**

6

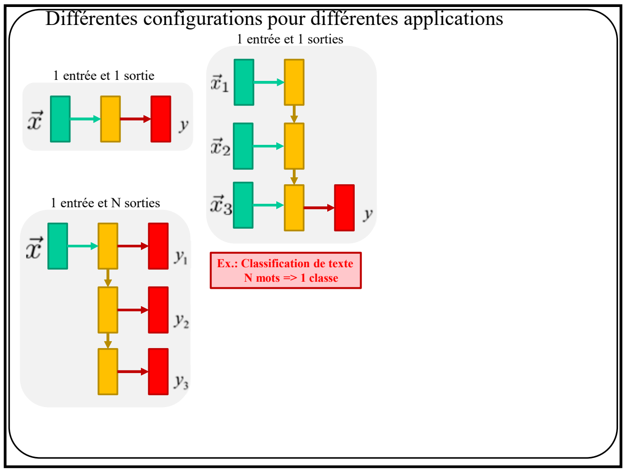
Différentes configurations pour différentes applications
1 entrée et 1 sorties
1 entrée et 1 sortie
1 entrée et N sorties
Ex.: Classification de texte
N mots => 1 classe

7

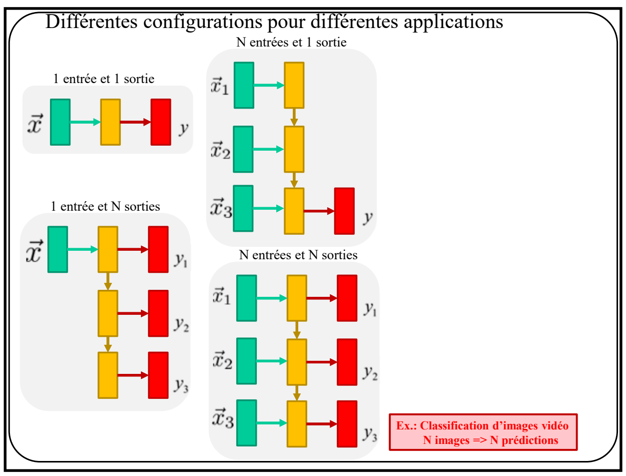
Différentes configurations pour différentes applications
N entrées et 1 sortie
1 entrée et 1 sortie
1 entrée et N sorties
N entrées et N sorties
Ex.: Classification d'images vidéo
N images => N prédictions

8

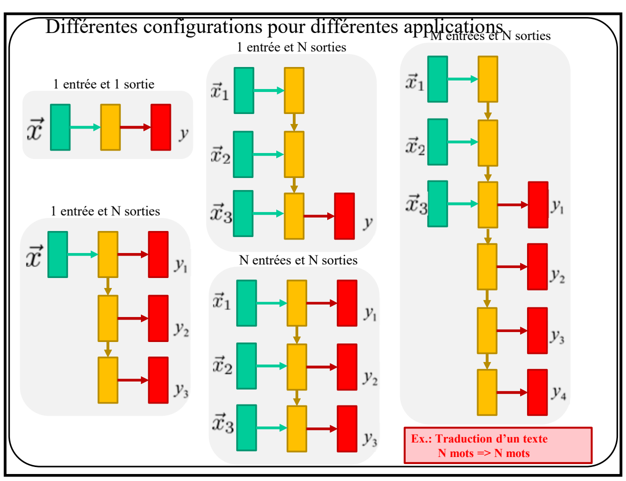
Différentes configurations pour différentes applications
M entrées et N sorties
1 entrée et N sorties
1 entrée et 1 sortie
1 entrée et N sorties
N entrées et N sorties
Ex.: Traduction d'un texte
N mots => N mots

9

**Réseau récurrent** : la sortie des neurones est réinjectée dans leur entrée

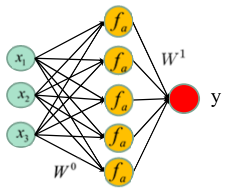


10

**Réseau récurrent** : la sortie des neurones est réinjectée dans leur entrée

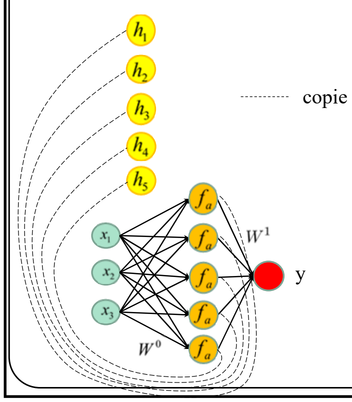


11

**Réseau récurrent** : la sortie des neurones est réinjectée dans leur entrée

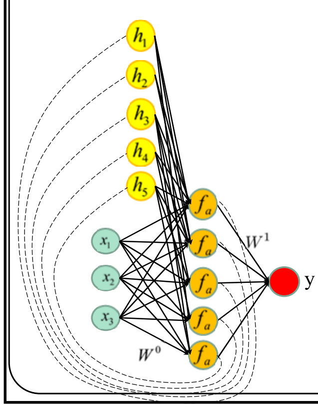


Ici, au lieu d'avoir 3 entrées, chaque neurone caché a **3+5=8 entrées.**

12

**Réseau récurrent** : la sortie des neurones est réinjectée dans leur entrée

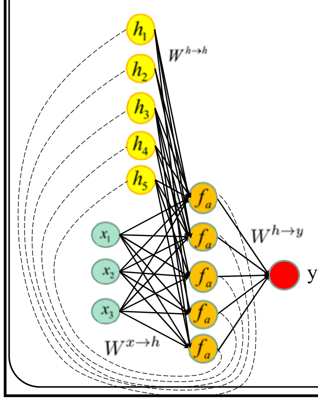


$$y(\vec{x}) = W^{h\to y} f_a(W^{x\to h}\vec{x} + W^{h\to h}\vec{h})$$

$$\downarrow$$

$$\vec{h} = f_a(W^{x\to h}\vec{x} + W^{h\to h}\vec{h})$$

$$y(\vec{x}) = W^{h\to y}\vec{h}$$

13

Illustration simplifiée

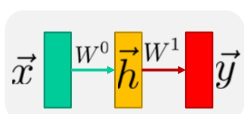


RN de base

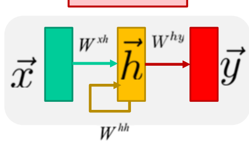


RN récurrent

14

Dans le cas général avec K sorties (régression)

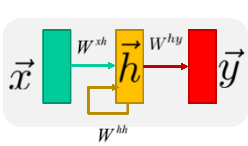


$$y(\vec{x}) = W^{hy} f_a(W^{xh}\vec{x} + W^{hh}\vec{h})$$

$$\downarrow$$

$$\vec{h} = f_a(W^{xh}\vec{x} + W^{hh}\vec{h})$$

$$\vec{y}(\vec{x}) = W^{hy}\vec{h}$$

15

## Dans le cas général avec K sorties (classification)

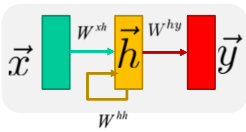


$$y(\vec{x}) = W^{hy} f_a(W^{xh}\vec{x} + W^{hh}\vec{h})$$

$$\downarrow$$

$$\vec{h} = f_a(W^{xh}\vec{x} + W^{hh}\vec{h})$$
$$\hat{y} = W^{hy}\vec{h}$$
$$\vec{y}(\vec{x}) = \text{softmax}(\hat{y})$$

16

## Exemple pour N entrées et 1 sortie:

Analyse grammaticale (classification) : (ê.t.r.e)=> {verbe}

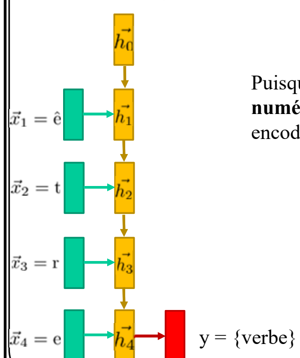


Puisque $\vec{x}, \vec{h}$ et $y$ doivent être des **variables numériques** on utilise souvent un encodage de type « *one hot* ».

$$\left.\begin{array}{l} 'a' = [1,0,0,\ldots,0] \\ 'b' = [0,1,0,\ldots,0] \\ 'c' = [0,0,1,\ldots,0] \end{array}\right\} \in R^{256}$$

....

$$\left.\begin{array}{l} '\textit{verbe}' = [1,0,0\ldots0] \\ '\textit{nom}' = [0,1,0,\ldots0] \\ '\textit{adjectif}' = [0,0,1,\ldots0] \end{array}\right\} \in R^{M}$$

17

## Exemple pour N entrées et 1 sortie:

Analyse grammaticale (classification) : (ê.t.r.e)=> {verbe}

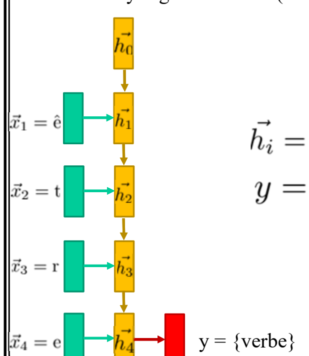


$$\vec{h_i} = f_a(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$y = \text{softmax}(W^{hy}\vec{h}_{i-1})$$

18

## Exemple pour N entrées et 1 sortie:

Analyse grammaticale (classification) : (ê.t.r.e)=> {verbe}

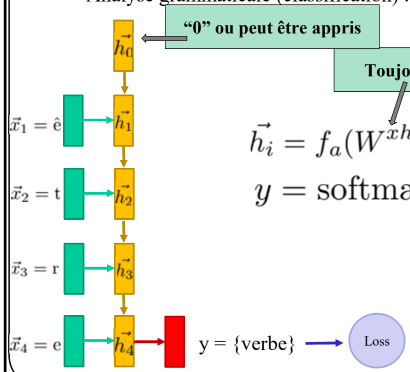


$$\vec{h_i} = f_a(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$y = \mathrm{softmax}(W^{hy}\vec{h}_{i-1})$$

19

## Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

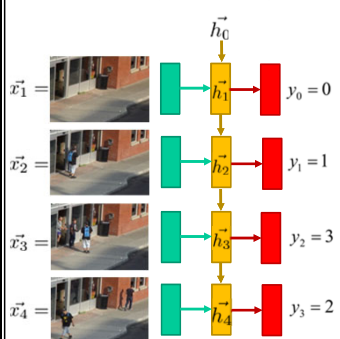


$$\vec{h_i} = f_a(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$y_i = W^{hy}\vec{h_i}$$

20

## Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

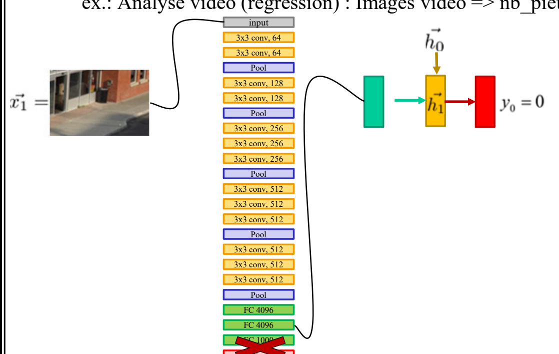


VGG16

21

Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

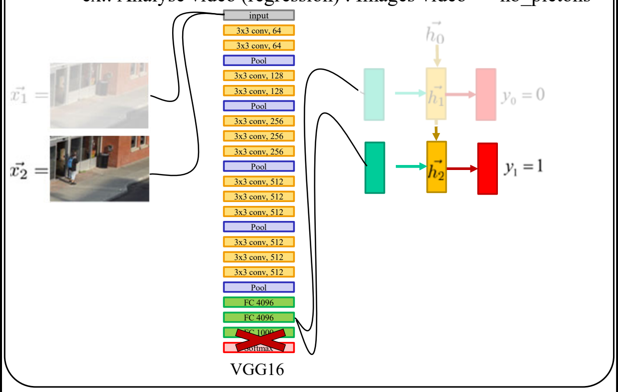


22

Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

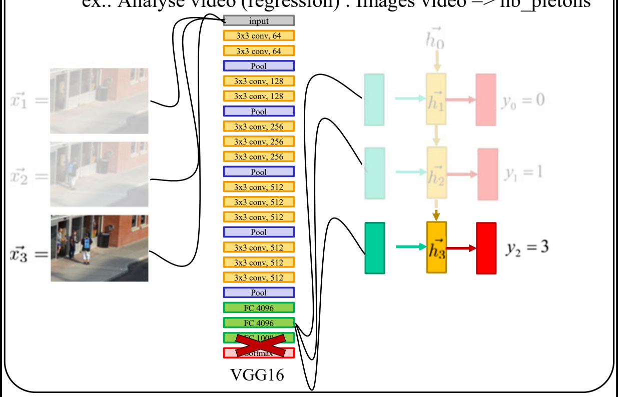


23

Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

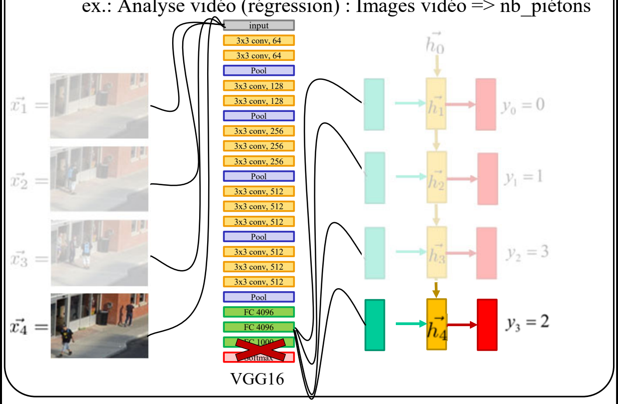


24

Même idée pour N entrées et N sorties:

ex.: Analyse vidéo (régression) : Images vidéo => nb_piétons

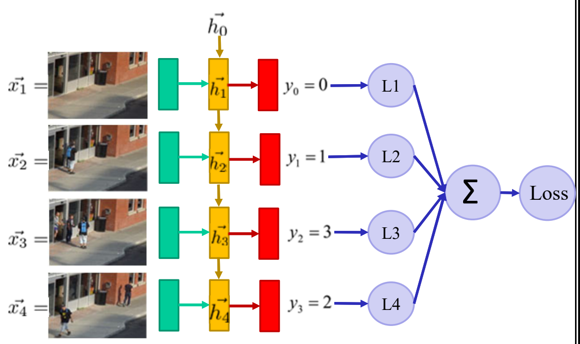


25

Autre exemple: **prédiction de caractères** (modèle de langue)

**Alphabet jouet** :[**a,e,m,s**]

**Représentation « one hot » jouet:**

'a' = [1, 0, 0, 0]
'e' = [0, 1, 0, 0]
'm' = [0, 0, 1, 0]
's' = [0, 0, 0, 1]

**But :** Entraîner un modèle à prédire les lettres du mot « **masse** ».

26

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

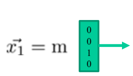


27

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

$\vec{x_1} = \text{m}$

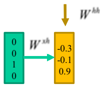


$$\vec{h_i} = \tanh(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$

28

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

$\vec{x_1} = \text{m}$

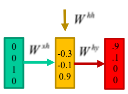


$$\vec{h_i} = \tanh(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

29

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

$\vec{x_1} = \text{m}$

$\vec{x_2} = \text{a}$

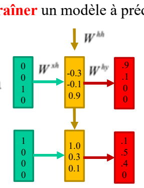


$$\vec{h_i} = \tanh(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$\vec{y}(\vec{x}_i) = \text{softmax}(W^{hy}\vec{h}_i)$$

30

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

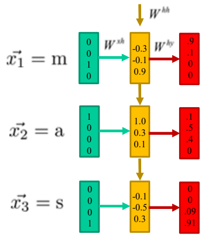


$$\vec{h_i} = \tanh(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$\vec{y}(\vec{x_i}) = \mathrm{softmax}(W^{hy}\vec{h_i})$$

31

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

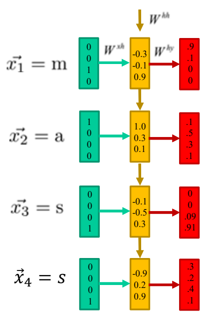


$$\vec{h_i} = \tanh(W^{xh}\vec{x_i} + W^{hh}\vec{h_{i-1}})$$
$$\vec{y}(\vec{x_i}) = \mathrm{softmax}(W^{hy}\vec{h_i})$$

32

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

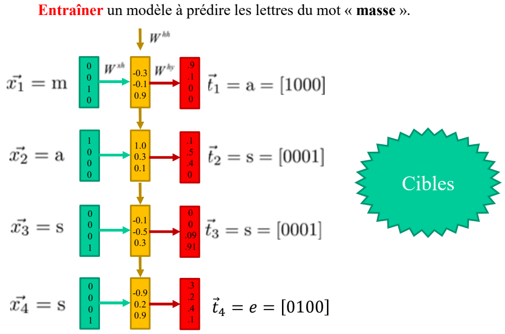


33

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

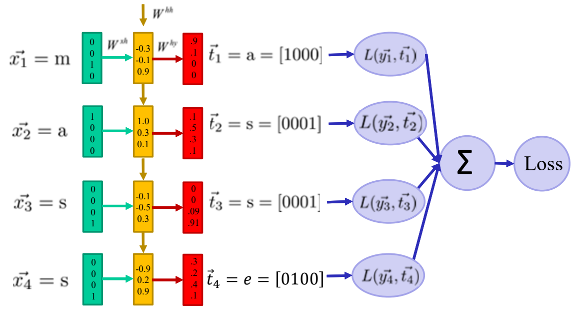


34

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**Entraîner** un modèle à prédire les lettres du mot « **masse** ».

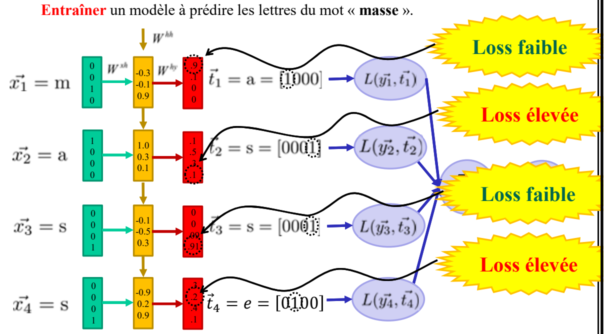


35

## Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]
**En test** : prédire les lettres les unes après les autres

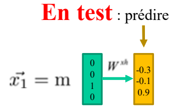


**Étape 1** : Calcul de la couche cachée

36

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

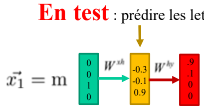


**Étape 2** : Calcul de la sortie (softmax)

37

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

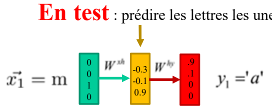


**Étape 3** : Sélectionner le caractère le plus probable

38

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

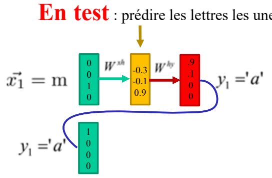


**Étape 4 :** Injecter le caractère prédit au début du réseau

39

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

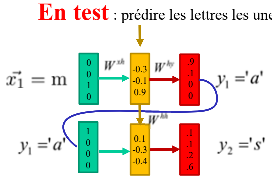


Et on recommence!

40

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

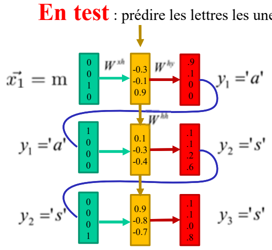


41

Autre exemple: **prédiction de caractères** (modèle de langue)

Alphabet :[**a,e,m,s**]

**En test** : prédire les lettres les unes après les autres

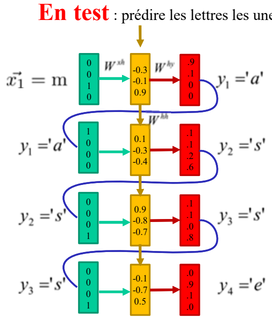


42

## Autre exemple: **prédiction de caractères** (modèle de langue)

Code python: **“mini-char-RNN” de A. Karpathy**
https://gist.github.com/karpathy/d4dee566867f8291f086
Un RNN en 112 lignes !

$$\left.\begin{array}{l}'a'=[1,0,0,...,0]\\ 'b'=[0,1,0,...,0]\\ 'c'=[0,0,1,...,0]\end{array}\right\}\in R^{256}$$

...

43

## Autre exemple: **prédiction de caractères** (modèle de langue)

Code python: **“mini-char-RNN” de A. Karpathy**
https://gist.github.com/karpathy/d4dee566867f8291f086

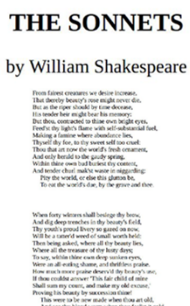
**THE SONNETS**

by William Shakespeare

44

## Autre exemple: **prédiction de caractères** (modèle de langue)

```
tyntd-iafhatawiaoihrdemot  lytdws  e ,tfti, astai f ogoh eoase rrranbyne 'nhthnee e
plia tklrgd t o idoe ns,smtt   h ne etie h,hregtrs nigtike,aoaenns lng
```

train more

```
"Tmont thithey" fomesscerliund
Keushey. Thom here
sheulke, anmerenith ol sivh I lalterthend Bleipile shuwy fil on aseterlome
coaniogennc Phe lism thond hon at. MeiDimorotion in ther thize."
```

train more

```
Aftair fall unsuch that the hall for Prince Velzonski's that me of
her hearly, and behs to so arwage fiving were to it beloge, pavu say falling misfort
how, and Gogition is so overelical and ofter.
```

train more

```
"Why do what that day," replied Natasha, and wishing to himself the fact the
princess, Princess Mary was easier, fed in had oftened him.
Pierre aking his soul came to the packs and drove up his father-in-law women.
```

Crédit: A. Karpathy, CS231

45

## Texte généré une fois le modèle entraîné

```
PANDARUS:
Alas, I think he shall be come approached and the day
When little srain would be attain'd into being never fed,
And who is but a chain and subjects of his death,
I should not sleep.

Second Senator:
They are away this miseries, produced upon my soul,
Breaking and strongly should be buried, when I perish
The earth and thoughts of many states.

DUKE VINCENTIO:
Well, your wit is in the care of side and that.

Second Lord:
They would be ruled after this chamber, and
my fair nues begun out of the fact, to be conveyed,
Whose noble souls I'll have the heart of the wars.

Clown:
Come, sir, I will make did behold your worship.

VIOLA:
I'll drink it.
```

```
VIOLA:
Why, Salisbury must find his flesh and thought
That which I am not aps, not a man and in fire,
To show the reining of the raven and the wars
To grace my hand reproach within, and not a fair are hand,
That Caesar and my goodly father's world;
When I was heaven of presence and our fleets,
We spare with hours, but cut thy council I am great,
Murdered and by thy master's ready there
My power to give thee but so much as hell:
Some service in the noble bondman here,
Would show him to her wine.

KING LEAR:
O, if you were a feeble sight, the courtesy of your law,
Your sight and several breath, will wear the gods
With his heads, and my hands are wonder'd at the deeds,
So drop upon your lordship's head, and your opinion
Shall be against your honour.
```

Crédit: A. Karpathy, CS231

46

## Entraînement sur le code source de Linux en C++

```c
static void do_command(struct seq_file *m, void *v)
{
  int column = 32 << (cmd[2] & 0x80);
  if (state)
    cmd = (int)(int_state ^ (in_8(&ch->ch_flags) & Cmd) ? 2 : 1);
  else
    seq = 1;
  for (i = 0; i < 16; i++) {
    if (k & (1 << 1))
      pipe = (in_use & UMXTHREAD_UNCCA) +
        ((count & 0x00000000fffffff8) & 0x000000f) << 8;
    if (count == 0)
      sub(pid, ppc_md.kexec_handle, 0x20000000);
    pipe_set_bytes(i, 0);
  }
  /* Free our user pages pointer to place camera if all dash */
  subsystem_info = &of_changes[PAGE_SIZE];
  rek_controls(offset, idx, &soffset);
  /* Now we want to deliberately put it to device */
  control_check_polarity(&context, val, 0);
  for (i = 0; i < COUNTER; i++)
    seq_puts(s, "policy ");
}
```

```c
#include <asm/io.h>
#include <asm/prom.h>
#include <asm/e820.h>
#include <asm/system_info.h>
#include <asm/setew.h>
#include <asm/pgproto.h>

#define REG_PG    vesa_slot_addr_pack
#define PFM_NOCOMP  AFSR(0, load)
#define STACK_DDR(type)     (func)

#define SWAP_ALLOCATE(nr)     (e)
#define emulate_sigs()  arch_get_unaligned_child()
#define access_rw(TST)  asm volatile("movd %%esp, %0, %3" : : "r" (0));   \
  if (__type & DO_READ)

static void stat_PC_SEC __read_mostly offsetof(struct seq_argsqueue, \
          pC>[1]);

static void
os_prefix(unsigned long sys)
{
#ifdef CONFIG_PREEMPT
  PUT_PARAM_RAID(2, sel) = get_state_state();
  set_pid_sum((unsigned long)state, current_state_str(),
           (unsigned long)-1->lr_full; low;
}
```

Crédit: A. Karpathy, CS231

47

## Différentes configurations pour différentes applications

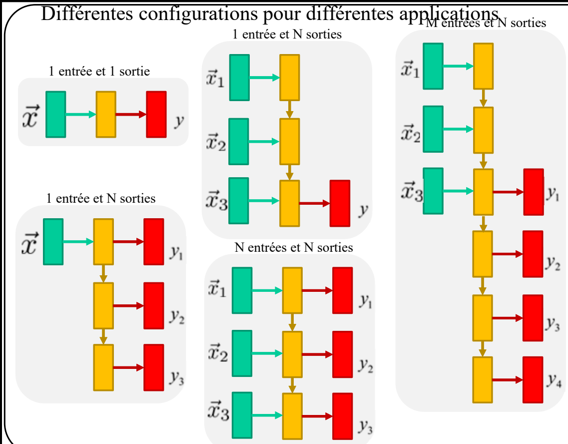


48

**Traduction Français-Anglais**

**N lettres => M lettres**

M entrées et N sorties

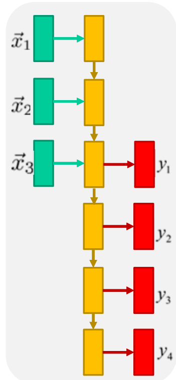


49

Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

Pas le même nombre d'entrées que de sorties !
(BoS : Begining of Sentence, EoS:End of Sentence).

50

Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

$\vec{x}_1 = \text{<BoS>}$

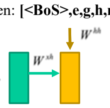


51

## Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

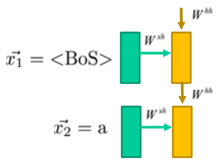


52

## Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

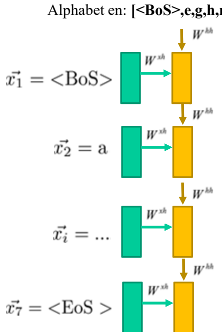


53

## Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

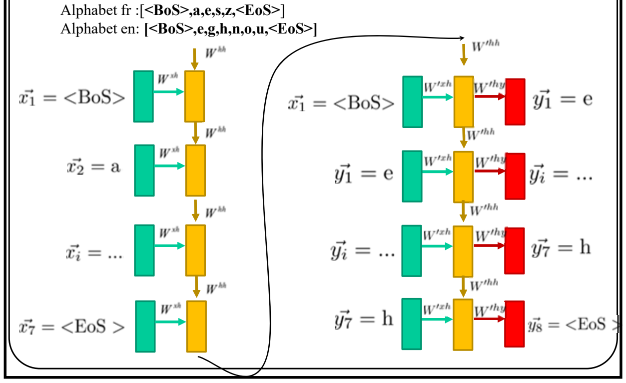


54

## Autre exemple: **traduction**

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

Traduire 'assez' -> 'enough'
Alphabet fr :[**<BoS>,a,e,s,z,<EoS>**]
Alphabet en: **[<BoS>,e,g,h,n,o,u,<EoS>]**

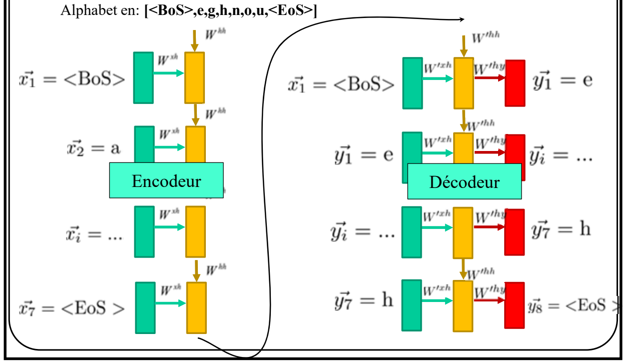


55

## Différentes configurations pour différentes applications

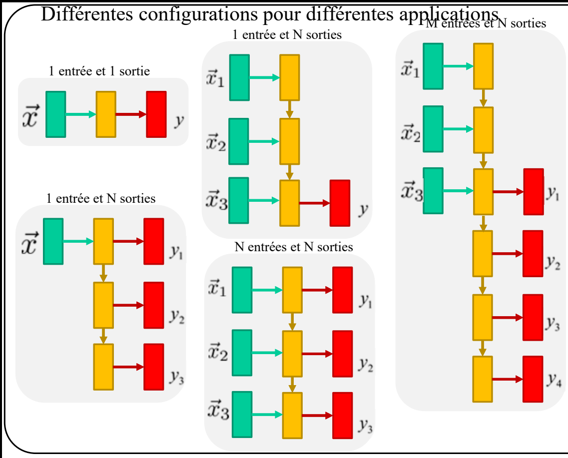


56

## Différentes configurations pour différentes applications

**Description du contenu d'une image (« captioning »)**

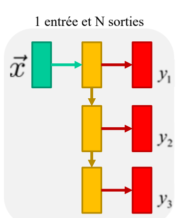


57

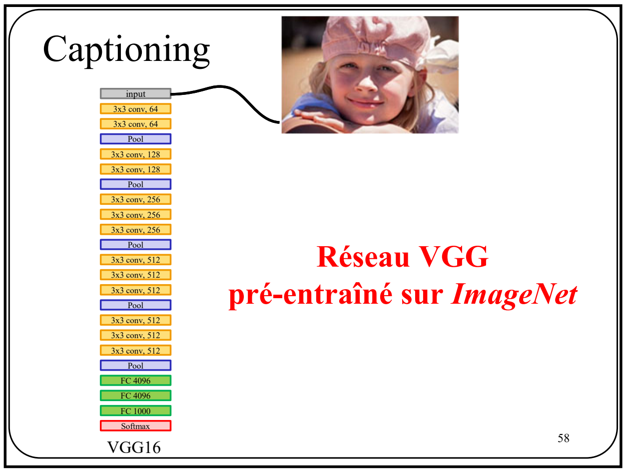
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
FC 1000
Softmax
VGG16
Réseau VGG
pré-entraîné sur *ImageNet*
58

58

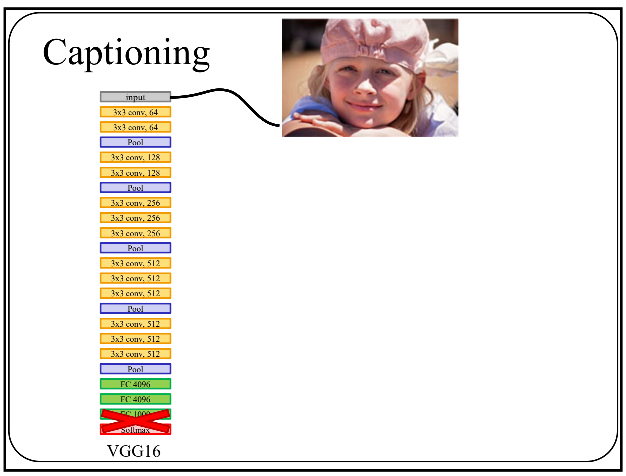
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
VGG16

59

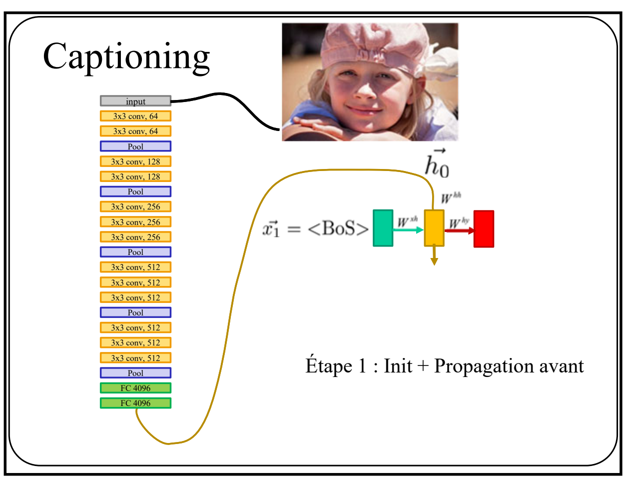
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
$\vec{h}_0$
$\vec{x}_1$ = <BoS>
$W^{xh}$
$W^{hh}$
$W^{hy}$
Étape 1 : Init + Propagation avant

60

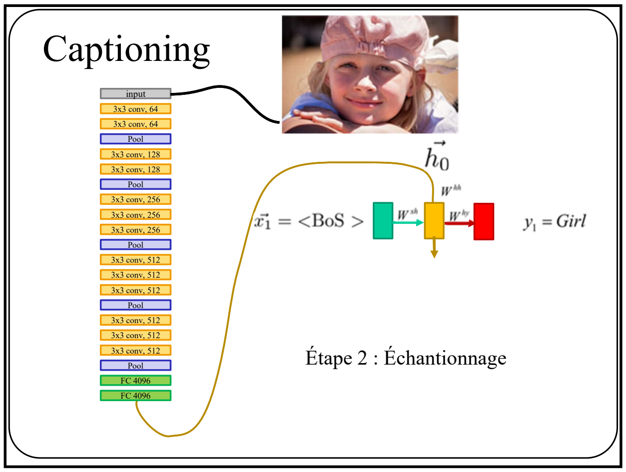
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
$\vec{h}_0$
$W^{hh}$
$\vec{x}_1$ = <BoS >
$W^{xh}$
$W^{hy}$
$y_1 = Girl$
Étape 2 : Échantionnage

61

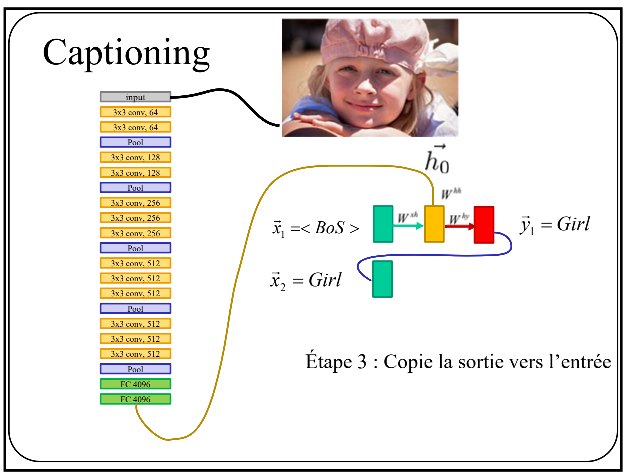
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
$\vec{h}_0$
$W^{hh}$
$\vec{x}_1$ =< BoS >
$W^{xh}$
$W^{hy}$
$\vec{y}_1 = Girl$
$\vec{x}_2 = Girl$
Étape 3 : Copie la sortie vers l'entrée

62

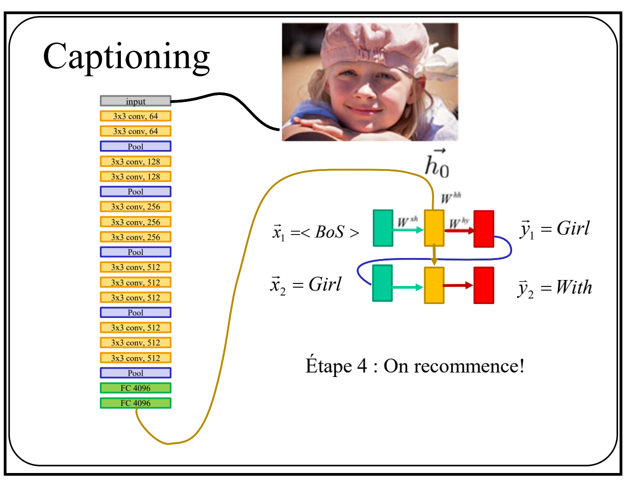
Captioning
input
3x3 conv, 64
3x3 conv, 64
Pool
3x3 conv, 128
3x3 conv, 128
Pool
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
Pool
FC 4096
FC 4096
$\vec{h}_0$
$W^{hh}$
$\vec{x}_1$ =< BoS >
$W^{xh}$
$W^{hy}$
$\vec{y}_1 = Girl$
$\vec{x}_2 = Girl$
$\vec{y}_2 = With$
Étape 4 : On recommence!

63

## Captioning

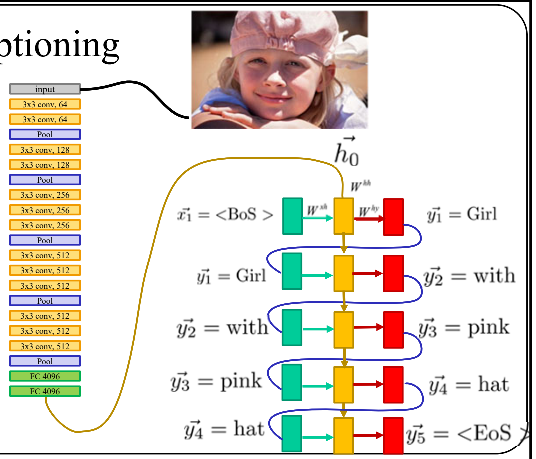


64

## Exemples de résultats

kwwsv=22jlwkxe1frp2ndusdwk|2qhxudowdon5

an elephant standing in a grassy field with trees in the background

a man riding a wave on top of a surfboard


a street sign on a pole in front of a building

a group of people playing a game with nintendo wii controllers

a couple of zebra standing on top of a dirt field

65

65

## Exemples d'erreurs

kwwsv=22jlwkxe1frp2ndusdwk|2qhxudowdon5

a man is throwing a frisbee in a park

a man riding a skateboard down a street

a laptop computer sitting on top of a wooden desk

*A woman is holding a cat in her hand*

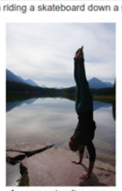

*A woman standing on a beach holding a surfboard*

66

66

## *NeuralTalk and Walk* kwwsv=22ylp hr1frp 24797<5334



67

67

## Analyse de texte

Souvent les modèles de langue utilisent l'encodage « one hot »

Pour des **caractères**…

$$\left.\begin{array}{l} 'a' = [1,0,0,\ldots,0] \\ 'b' = [0,1,0,\ldots,0] \\ 'c' = [0,0,1,\ldots,0] \end{array}\right\} \in R^{256}$$

$\ldots$

68

68

## Analyse de texte

Souvent les modèles de langue utilisent l'encodage « one hot »

Pour des **mots**…

$\ldots$

$$\left.\begin{array}{l} '\mathit{grand}' = [\ldots,1,0,0,\ldots,0] \\ '\mathit{grandement}' = [\ldots,0,1,0,\ldots,0] \\ '\mathit{grandeur}' = [\ldots,0,0,1,\ldots,0] \end{array}\right\} \in R^{10,000}$$

$\ldots$

69

69

## Prédiction sur des lettres vs. mots

$$\left.\begin{array}{l}'a'=[1,0,0,...,0]\\ 'b'=[0,1,0,...,0]\\ 'c'=[0,0,1,...,0]\end{array}\right\}\in R^{256}$$

Prédiction sur des lettres

...

...

$$\left.\begin{array}{l}'grand'=[...,1,0,0,...,0]\\ 'grandement'=[...,0,1,0,...,0]\\ 'grandeur'=[...,0,0,1,...,0]\end{array}\right\}\in R^{10,000}$$

Prédiction sur des mots

...

70

## Prédiction sur des lettres vs. mots

$'a'=[1,0,0,...,0]$

$'b'=[0,1,0$ ... lettres

$'c'=[0,0,1$

...

...

$'grand'=$

$'grandem$ ... mots

$'grandeur'=[...,0,0,1,...,0]$

...

En analyse des langues, un vecteur numérique associé à une séquence de caractères se nomme « JETON » (« token »)

71

## Limites des Jetons « one-hot »

Bien que simple, cet encodage a plusieurs **inconvénients**

1- Peu efficace en mémoire lorsque non compressés

ex.: 10,000 bits pour encoder le mot « **je** » dans une langue à 10,000 mots!

2- Pas de distance sémantique entre les Jetons:

Ex.

**distance[one-hot('bon'), one-hot('bien')]= distance[one-hot('bon'), one-hot('trottoir')]**

Or, on souhaiterait un **code** tel que

**distance[code('bon'), code('bien')]** << **distance[code('bon'), code('trottoir')]**

**distance[code('Jean'), code('Chantal')]** << **distance[code('bon'), code('trottoir')]**

**distance[code('Inde'), code('Liban')]** << **distance[code('bon'), code('trottoir')]**

74

Une solution est d'utiliser l'encodage **Word2Vec** de [Mikolov et al. '13]

Exemple jouet: on veut représenter ces 8 mots par des jetons à 4 éléments

Jeton *« one-hot »*

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| 'the' | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 'quick' | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| 'brown' | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| 'fox' | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 |
| 'jumps' | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 |
| 'over' | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 |
| 'lazy' | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 |
| 'dog' | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 |

Dictionnaire de Jetons

| | | | |
|---|---|---|---|
| 2 | 3 | 4 | 5 |
| -1 | -3 | -2 | 2 |
| 11 | 6 | 4 | -3 |
| -4 | 8 | -4 | 4 |
| 24 | -6 | 42 | 17 |
| 91 | 13 | 14 | -5 |
| 0 | 36 | 4 | 56 |
| -1 | 0 | 1 | 35 |

1 ligne = code pour 1 mot

75

Word2Vec s'appuie sur 2 idées fondamentales

**Idée 1**: **Dictionnaire = matrice d'encodage**

**Comment sélectionner le jeton d'un mot**? En multipliant son vecteur One-hot par la matrice d'encodage (le dictionnaire!)

Ex: sélectionner le jeton de « brown »

Dictionnaire Jeton (matrice d'encodage)

$$\begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 2 & 3 & 4 & 5 \\ -1 & -3 & -2 & 2 \\ 11 & 6 & 4 & -3 \\ -4 & 8 & -4 & 4 \\ 24 & -6 & 42 & 17 \\ 91 & 13 & 14 & -5 \\ 0 & 36 & 4 & 56 \\ -1 & 0 & 1 & 35 \end{pmatrix} = \begin{pmatrix} 11 & 6 & 4 & -3 \end{pmatrix}$$

76

Word2Vec s'appuie sur 2 idées fondamentales


**Idée 1**: **Dictionnaire jeton = matrice d'encodage**

**Première couche d'un réseau de neurones**
**=**
**matrice d'encodage**

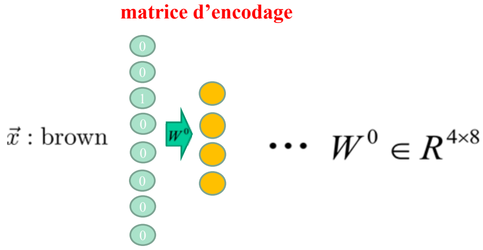


77

**Word2Vec** s'appuie sur 2 idées fondamentales


Idée 1: **Dictionnaire = matrice d'encodage**

**Première couche d'un réseau de neurones**
**=**
**matrice d'encodage**

$$jeton_{\vec{x}} = W^0\ \vec{x}$$

78

**Word2Vec** s'appuie sur 2 idées fondamentales


Idée 1: **Dictionnaire = matrice d'encodage**

On pourra donc utiliser un réseau de neurones pour calculer le contenu du dictionnaire

79

**Word2Vec** s'appuie sur 2 idées fondamentales

Idée 2: **2 mots proches dans un texte = 2 mots proches sémantiquement**

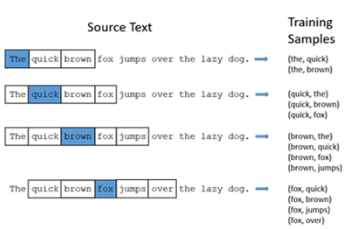


Basé sur un corpus de texte, on va créer des **millions de paires de mots**

80

## Word2Vec [Mikolov et al. '13]

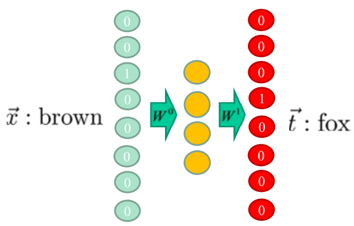


Entraîner un réseau de neurones
à reproduire le 2e mot partant du 1er

81

## Word2Vec [Mikolov et al. '13]

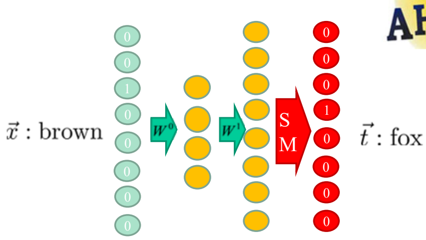


Puisque la sortie est de type « *one-hot* »
on utilise un softmax

82

## Word2Vec [Mikolov et al. '13]

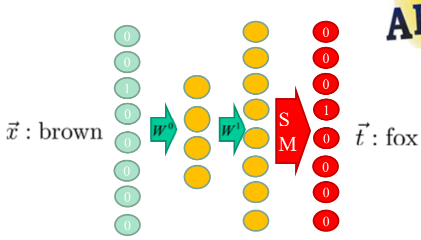


$$y(\vec{x}) = \mathrm{softmax}(W^1 f_a(W^0 \mathrm{x}))$$

83

## Word2Vec [Mikolov et al. '13]


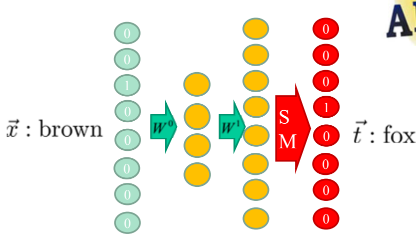


Lorsqu'entraîné, utiliser $W^0$ comme dictionnaire

84

## Word2Vec [Mikolov et al. '13]

Cet algorithme vient avec **d'autres détails**

- Réduire l'occurrence des mots fréquents et sémantiquement faibles (*the, of, for, this, or, and,…*)
- Combiner des mots qui forment une entité (ex: *nations unies*)
- Divers trucs pour simplifier/accélérer l'entraînement

85

**Distance sémantique entre deux mots = distance entre leur jeton**

| Word | First similar word | Second similar word | Third similar word |
|---|---|---|---|
| colosseum | rome (0.994) | roma (0.994) | coliseum (0.994) |
| colosseo | anfiteatro (0.995) | travel (0.994) | italia (0.994) |
| scala | aux (0.993) | camelias (0.992) | milano (0.992) |
| pompei | retweeted (0.988) | nuovi (0.979) | settembre (0.978) |
| roma | rome (0.995) | metro (0.994) | colosseum (0.994) |
| italia | anfiteatro (0.995) | rome (0.995) | colosseo (0.994) |
| italy | travel (0.998) | davanti (0.997) | photography (0.997) |

| Word | Similar Words | Similarity | Word | Similar Words | Similarity |
|---|---|---|---|---|---|
| Linux | windows | 0.85 | Twitter | facebook | 0.90 |
| | redhat | 0.83 | | instagram | 0.86 |
| | unix | 0.83 | | netflix | 0.84 |
| | mac os | 0.82 | | snapchat | 0.82 |
| | citrix | 0.81 | | google | 0.81 |
| | serveurs | 0.80 | | tweets | 0.80 |
| | microsoft | 0.79 | | youtube | 0.80 |
| | ibm | 0.79 | | linkedin | 0.77 |
| | windows server | 0.79 | | maddyness | 0.77 |
| | env windows | 0.79 | | tweet | 0.77 |

Ahmia, Oussama & Béchet, Nicolas & Marteau, Pierre-Francois. *Two Multilingual Corpora Extracted from the Tenders Electronic Daily for Machine Learning and Machine Translation Applications.*in LREC 2018

86

86

# Word2Vec

http://mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/

Très bon tutoriel!

T.Mikolov et al. (2013). "Efficient Estimation of Word Representations in Vector Space", in ICLR 2013

87

# Comment entraîner un RNN?

88

# Histoire de gradients

RN de classification avec entropie croisée

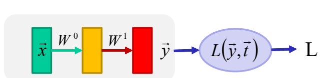


$$\vec{y}(\vec{x}) = S_M\left(W^1 \tanh\left(W^0\vec{x}\right)\right)$$

$$L = L_{EC}\left(\vec{y},\vec{t}\right)$$

89

## Histoire de gradients

Simple RN de classification avec entropie croisée

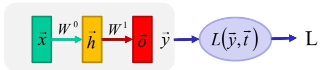


$$\vec{h} = \tanh\left(W^0\vec{x}\right)$$
$$\vec{o} = W^1\vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

Propagation
avant

90

## Histoire de gradients

Simple RN de classification avec entropie croisée

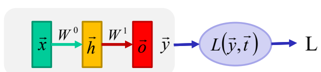


$$\vec{h} = \tanh\left(W^0\vec{x}\right)$$
$$\vec{o} = W^1\vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

Pour entraîner le réseau
il faut calculer

$$\nabla_{W^o} L \quad \text{et} \quad \nabla_{W^1} L$$

91

## Histoire de gradients

Simple RN de classification avec entropie croisée

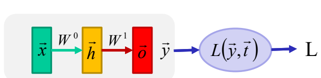


$$\vec{h} = \tanh\left(W^0\vec{x}\right)$$
$$\vec{o} = W^1\vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

Dérivée en chaîne

$$\nabla_{W^1} L = \nabla_{\vec{y}} L \nabla_{\vec{o}} \vec{y} \nabla_{W^1} \vec{o}$$
$$\nabla_{W^o} L = \nabla_{\vec{y}} L \nabla_{\vec{o}} \vec{y} \nabla_{\vec{h}} \vec{o} \nabla_{W^0} \vec{h}$$

92

## Histoire de gradients

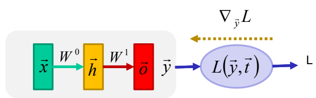


$$\vec{h} = \tanh\left(W^0 \vec{x}\right)$$
$$\vec{o} = W^1 \vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

$$\nabla_{\vec{y}} L = -\frac{\vec{t}}{\vec{y}}$$

Rétro-propagation

93

## Histoire de gradients

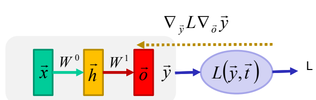


$$\vec{h} = \tanh\left(W^0 \vec{x}\right)$$
$$\vec{o} = W^1 \vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

$$\nabla_{\vec{o}} \vec{y} = I\vec{y}^T - \vec{y}^T \vec{y}$$
$$\nabla_{\vec{y}} L = -\frac{\vec{t}}{\vec{y}}$$

Rétro-propagation

94

## Histoire de gradients

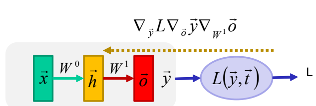


$$\vec{h} = \tanh\left(W^0 \vec{x}\right)$$
$$\vec{o} = W^1 \vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

$$\nabla_{W^1} \vec{o} = \vec{h}$$
$$\nabla_{\vec{o}} \vec{y} = I\vec{y}^T - \vec{y}^T \vec{y}$$
$$\nabla_{\vec{y}} L = -\frac{\vec{t}}{\vec{y}}$$

Rétro-propagation

95

## Histoire de gradients

$\nabla_{\vec{y}} L \nabla_{\vec{o}} \vec{y} \nabla_{\vec{h}} \vec{o}$

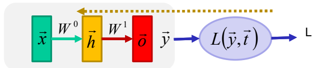


$$\vec{h} = \tanh\left(W^0 \vec{x}\right)$$
$$\vec{o} = W^1 \vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

Rétro-propagation

$$\nabla_{\vec{h}} \vec{o} = W^1$$
$$\nabla_{W^1} \vec{o} = \vec{h}$$
$$\nabla_{\vec{o}} \vec{y} = \mathrm{I}\vec{y}^T - \vec{y}^T \vec{y}$$
$$\nabla_{\vec{y}} L = -\frac{\vec{t}}{\vec{y}}$$

96

## Histoire de gradients

$\nabla_{\vec{y}} L \nabla_{\vec{o}} \vec{y} \nabla_{\vec{h}} \vec{o} \nabla_{W^0} \vec{h}$

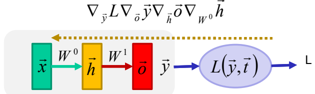


$$\vec{h} = \tanh\left(W^0 \vec{x}\right)$$
$$\vec{o} = W^1 \vec{h}$$
$$\vec{y} = S_M\left(\vec{o}\right)$$
$$L = L_{CE}\left(\vec{y},\vec{t}\right)$$

Rétro-propagation

$$\nabla_{W^o} \vec{h} = 1 - \tanh^2\left(W^1 \vec{x}\right)\vec{x}$$
$$\nabla_{\vec{h}} \vec{o} = W^1$$
$$\nabla_{W^1} \vec{o} = \vec{h}$$
$$\nabla_{\vec{o}} \vec{y} = \mathrm{I}\vec{y}^T - \vec{y}^T \vec{y}$$
$$\nabla_{\vec{y}} L = -\frac{\vec{t}}{\vec{y}}$$

97

## Ex.: 3 données, 3 rétro-propagations

$\nabla_{W^1} L_1$

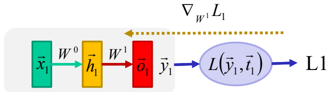


$\nabla_{W^1} L_2$

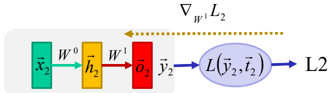


$\nabla_{W^1} L_3$

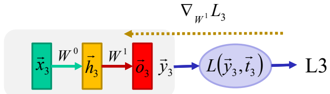


98

## Ex.: 3 données, 3 rétro-propagations

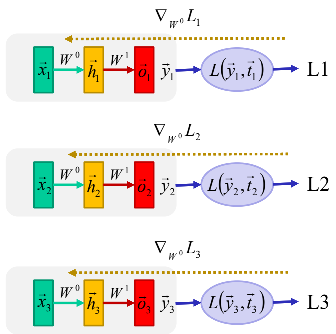


99

## 3 rétro-propagations

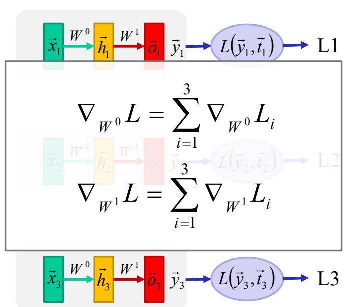


$$\nabla_{W^0} L = \sum_{i=1}^{3} \nabla_{W^0} L_i$$

$$\nabla_{W^1} L = \sum_{i=1}^{3} \nabla_{W^1} L_i$$

100

## Réseau récurrent: gradient pour $W^{hy}$

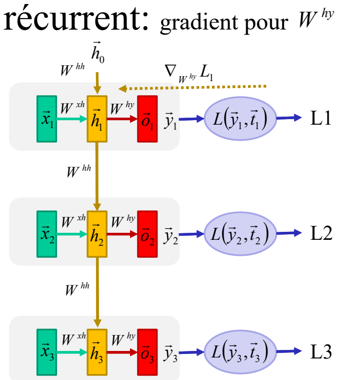


101

## Réseau récurrent: gradient pour $W^{hy}$

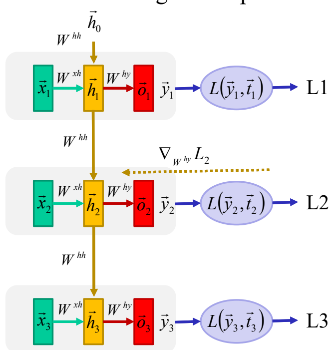


102

## Réseau récurrent: gradient pour $W^{hy}$

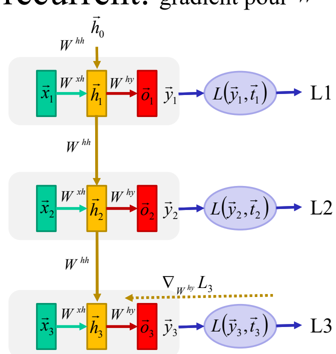


103

## Réseau récurrent: gradient pour $W^{hy}$

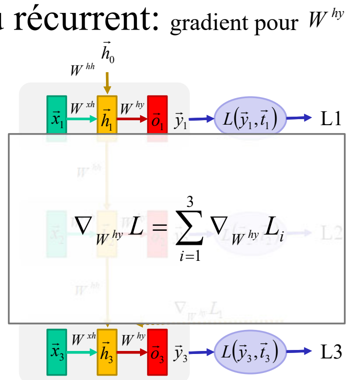


$$\nabla_{W^{hy}} L = \sum_{i=1}^{3} \nabla_{W^{hy}} L_i$$

104

## Réseau récurrent: gradient pour $W^{hh}$

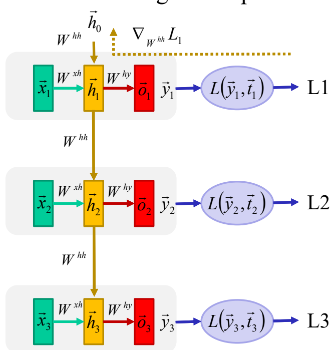


105

## Réseau récurrent: gradient pour $W^{hh}$

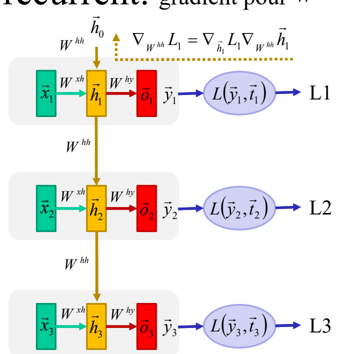


106

## Réseau récurrent: gradient pour $W^{hh}$

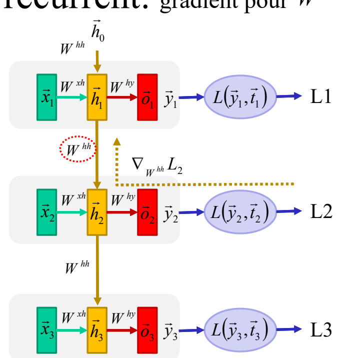


107

## Réseau récurrent: gradient pour $W^{hh}$

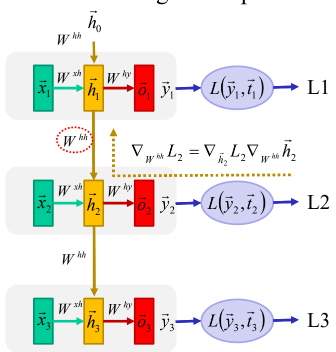


108

## Réseau récurrent: gradient pour $W^{hh}$

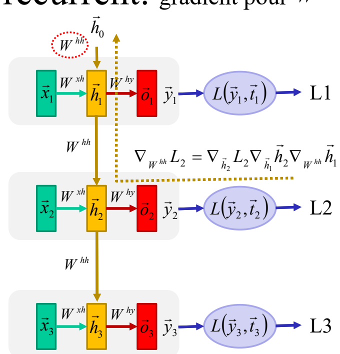


109

## Réseau récurrent: gradient pour $W^{hh}$

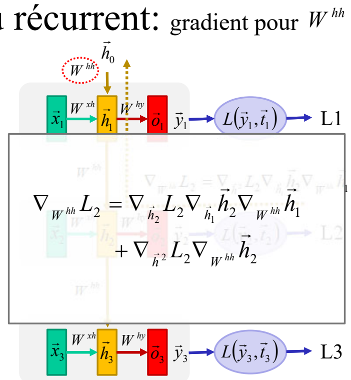


$$\nabla_{W^{hh}} L_2 = \nabla_{\vec{h}_2} L_2 \nabla_{\vec{h}_1} \vec{h}_2 \nabla_{W^{hh}} \vec{h}_1 + \nabla_{\vec{h}^2} L_2 \nabla_{W^{hh}} \vec{h}_2$$

110

## Réseau récurrent: gradient pour $W^{hh}$

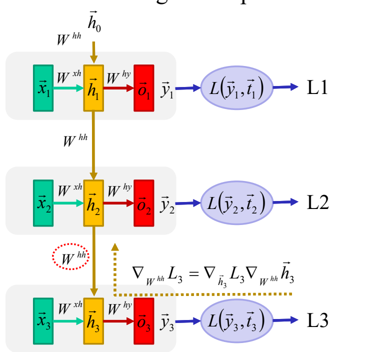


111

## Réseau récurrent: gradient pour $W^{hh}$

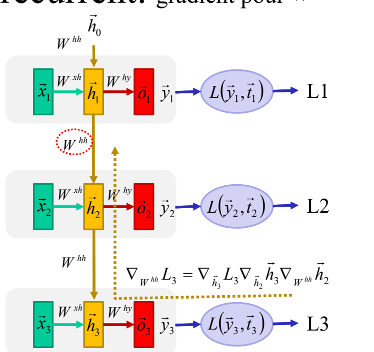


112

## Réseau récurrent: gradient pour $W^{hh}$

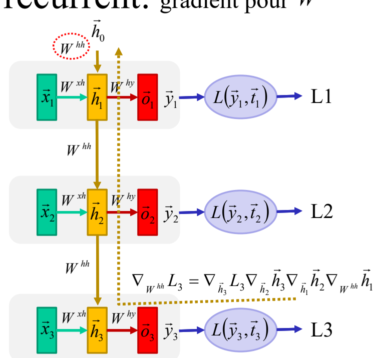


113

## Réseau récurrent: gradient pour $W^{hh}$

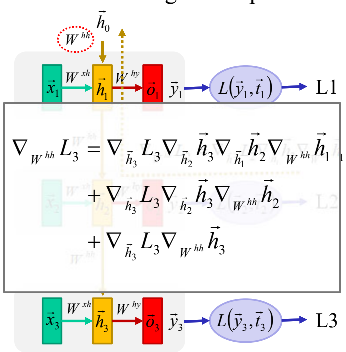


$$\nabla_{W^{hh}} L_3 = \nabla_{\vec{h}_3} L_3 \nabla_{\vec{h}_2} \vec{h}_3 \nabla_{\vec{h}_1} \vec{h}_2 \nabla_{W^{hh}} \vec{h}_1 + \nabla_{\vec{h}_3} L_3 \nabla_{\vec{h}_2} \vec{h}_3 \nabla_{W^{hh}} \vec{h}_2 + \nabla_{\vec{h}_3} L_3 \nabla_{W^{hh}} \vec{h}_3$$

114

## Réseau récurrent: gradient pour $W^{hh}$

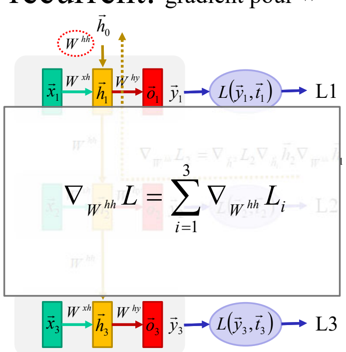


$$\nabla_{W^{hh}} L = \sum_{i=1}^{3} \nabla_{W^{hh}} L_i$$

116

## Réseau récurrent: gradient pour $W^{xh}$

$$\nabla_{W^{xh}} L_1 = \nabla_{\vec{h}_1} L_1 \nabla_{W^{xh}} \vec{h}_1$$

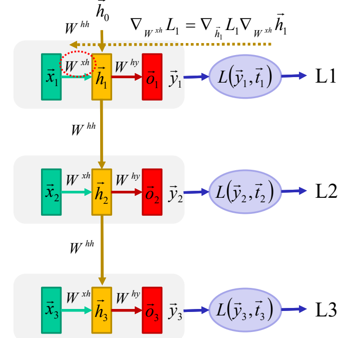


118

## Réseau récurrent: gradient pour $W^{xh}$

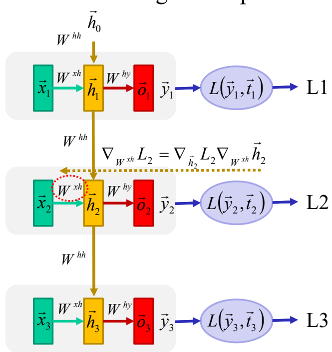


119

## Réseau récurrent: gradient pour $W^{xh}$

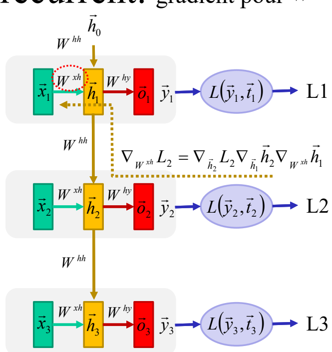


120

## Réseau récurrent: gradient pour $W^{xh}$

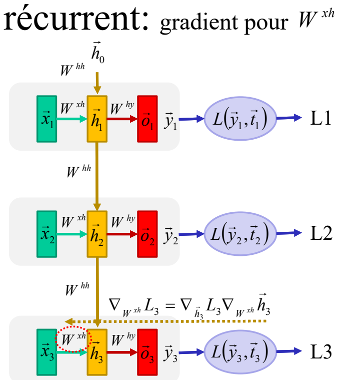


121

## Réseau récurrent: gradient pour $W^{xh}$

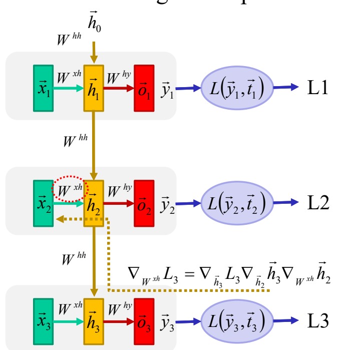


$$\nabla_{W^{xh}} L_3 = \nabla_{\vec{h}_3} L_3 \nabla_{\vec{h}_2} \vec{h}_3 \nabla_{W^{xh}} \vec{h}_2$$

122

## Réseau récurrent: gradient pour $W^{xh}$

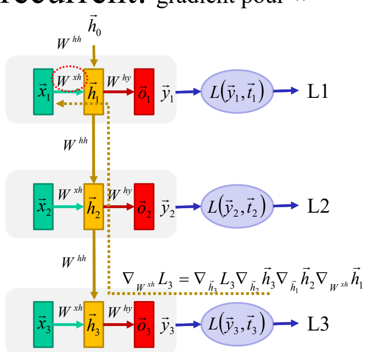


$$\nabla_{W^{xh}} L_3 = \nabla_{\vec{h}_3} L_3 \nabla_{\vec{h}_2} \vec{h}_3 \nabla_{\vec{h}_1} \vec{h}_2 \nabla_{W^{xh}} \vec{h}_1$$

123

## Réseau récurrent: gradient pour $W^{xh}$

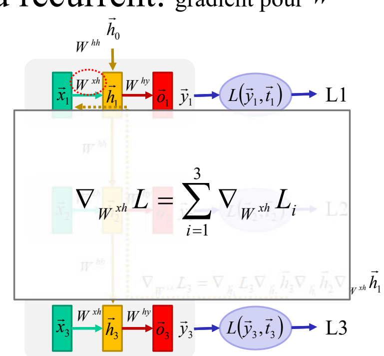


$$\nabla_{W^{xh}} L = \sum_{i=1}^{3} \nabla_{W^{xh}} L_i$$

124

## Réseau récurrent: calcul du gradient

Moins difficile qu'il n'y paraît.

```
# backward pass: compute gradients going backwards
dWxh, dWhh, dWhy = np.zeros_like(Wxh), np.zeros_like(Whh), np.zeros_like(Why)
dbh, dby = np.zeros_like(bh), np.zeros_like(by)
dhnext = np.zeros_like(hs[0])
for t in reversed(xrange(len(inputs))):
  dy = np.copy(ps[t])
  dy[targets[t]] -= 1 # backprop into y. see http://cs231n.github.io/neural-networks-case-study/#grad if confused here
  dWhy += np.dot(dy, hs[t].T)
  dby += dy
  dh = np.dot(Why.T, dy) + dhnext # backprop into h
  dhraw = (1 - hs[t] * hs[t]) * dh # backprop through tanh nonlinearity
  dbh += dhraw
  dWxh += np.dot(dhraw, xs[t].T)
  dWhh += np.dot(dhraw, hs[t-1].T)
  dhnext = np.dot(Whh.T, dhraw)
for dparam in [dWxh, dWhh, dWhy, dbh, dby]:
  np.clip(dparam, -5, 5, out=dparam) # clip to mitigate exploding gradients
return loss, dWxh, dWhh, dWhy, dbh, dby, hs[len(inputs)-1]
```

Voir https://d2l.ai/chapter_recurrent-neural-networks/bptt.html pour plus d'informations

125

Les réseaux récurrents ont un inconvénient majeur:

difficile à établir des **relations à longue distance**

126

126

## Exemples: analyse grammaticale

Entraîner un réseau à détecter des erreurs grammaticales

« La »
« présidente »
« fut »
« réélu »

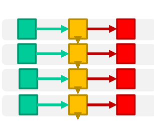

OK
OK
OK
ERREUR (réélue)

Exemple d'une relation à **courte distance**
(1 mot sépare « présidente » de « réélu »)

127

127

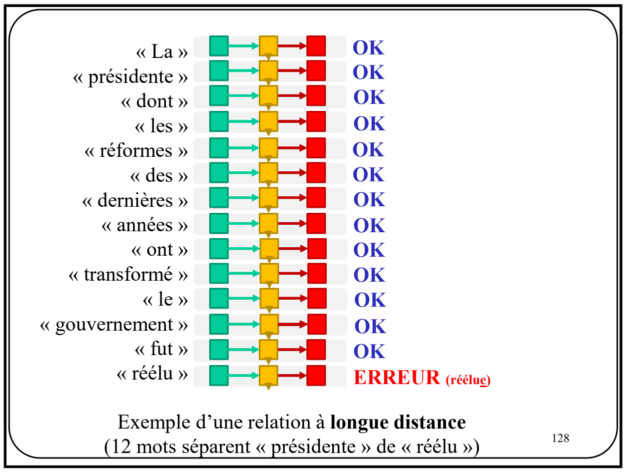
« La » OK
« présidente » OK
« dont » OK
« les » OK
« réformes » OK
« des » OK
« dernières » OK
« années » OK
« ont » OK
« transformé » OK
« le » OK
« gouvernement » OK
« fut » OK
« réélu » ERREUR (réélue)
Exemple d'une relation à **longue distance**
(12 mots séparent « présidente » de « réélu »)
128

128

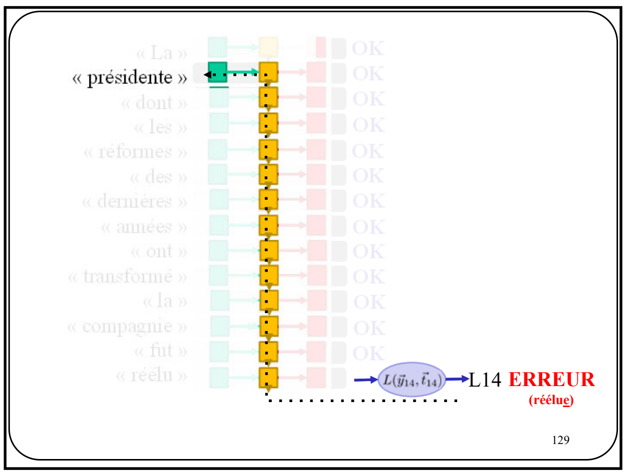
« La »
« présidente »
« dont »
« les »
« réformes »
« des »
« dernières »
« années »
« ont »
« transformé »
« la »
« compagnie »
« fut »
« réélu »
OK
$L(\vec{y}_{14}, \vec{t}_{14})$
L14 ERREUR
(réélue)
129

129

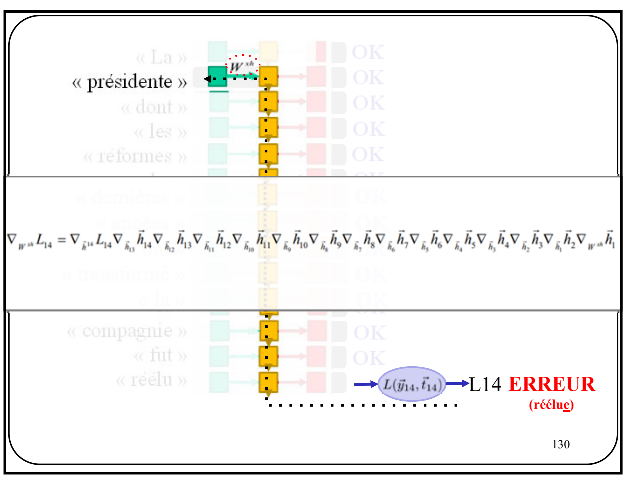
« présidente »
$W^{xh}$
$\nabla_{W^{xh}} L_{14} = \nabla_{\vec{h}^{14}} L_{14} \nabla_{\vec{h}_{13}} \vec{h}_{14} \nabla_{\vec{h}_{12}} \vec{h}_{13} \nabla_{\vec{h}_{11}} \vec{h}_{12} \nabla_{\vec{h}_{10}} \vec{h}_{11} \nabla_{\vec{h}_{9}} \vec{h}_{10} \nabla_{\vec{h}_{8}} \vec{h}_{9} \nabla_{\vec{h}_{7}} \vec{h}_{8} \nabla_{\vec{h}_{6}} \vec{h}_{7} \nabla_{\vec{h}_{5}} \vec{h}_{6} \nabla_{\vec{h}_{4}} \vec{h}_{5} \nabla_{\vec{h}_{3}} \vec{h}_{4} \nabla_{\vec{h}_{2}} \vec{h}_{3} \nabla_{\vec{h}_{1}} \vec{h}_{2} \nabla_{W^{xh}} \vec{h}_{1}$
$L(\vec{y}_{14}, \vec{t}_{14})$
L14 ERREUR
(réélue)
130

130

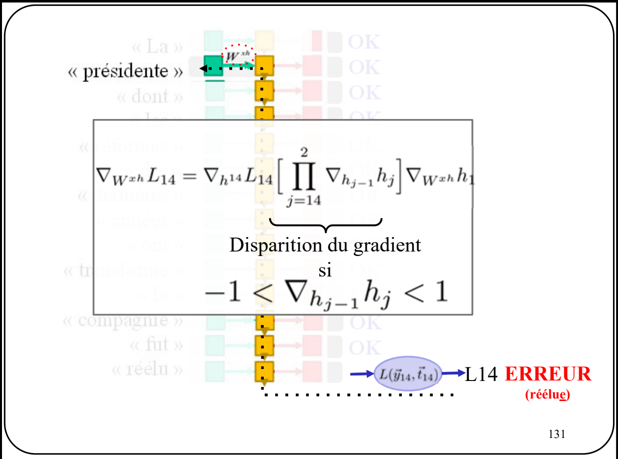


131

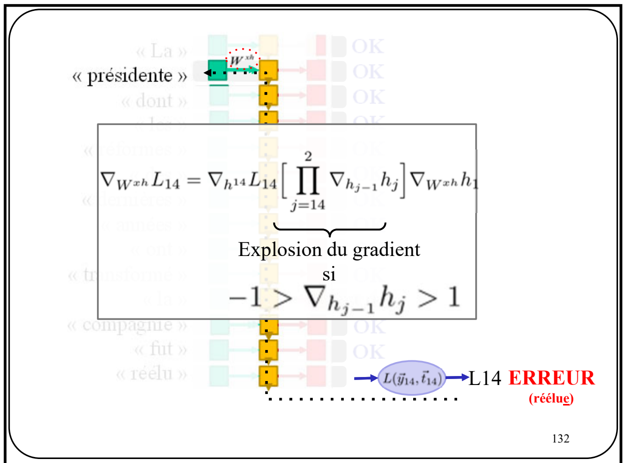


132

Problème connexe

**Gestion de la mémoire**

133

133

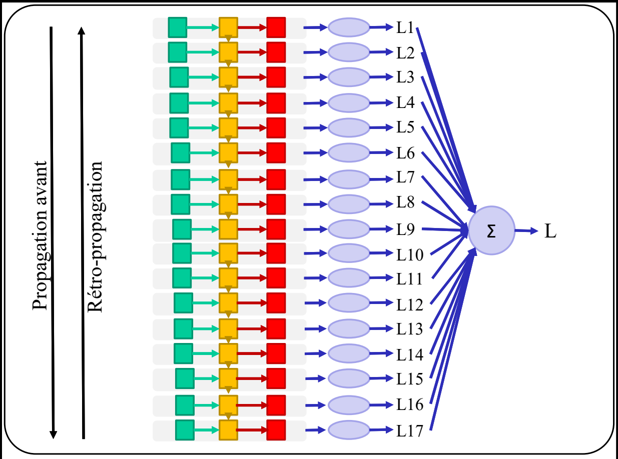


134

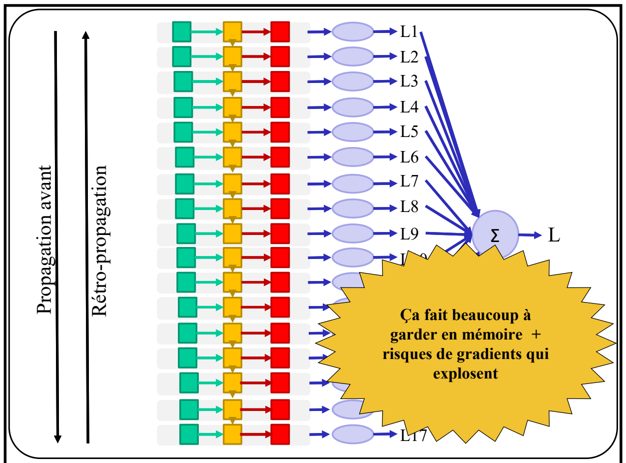


135

Solution pour la gestion de la mémoire

**Fenêtres coulissantes**

136

136

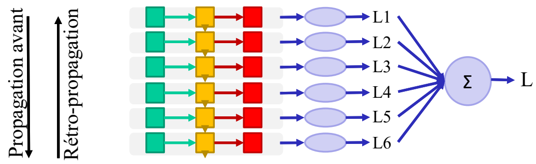


Lorsque les séquences sont trop longues
On entraîne le réseau par fenêtres coulissantes

137

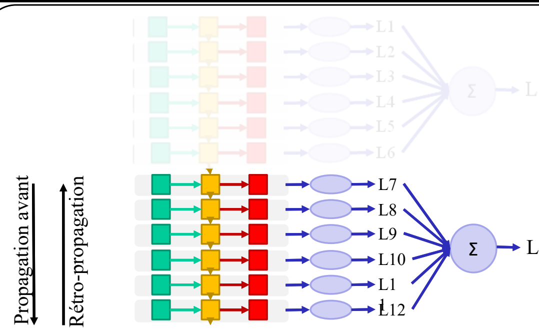


on propage le contenu de la couche cachée
d’une section à l’autre.

138

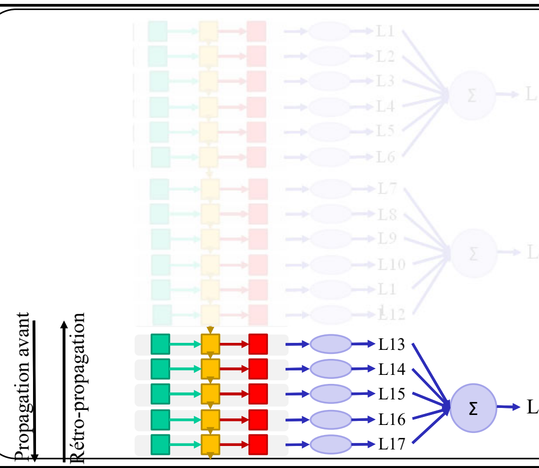


139

## Solution à la disparition du gradient:

**Gated Recurrent Unit : GRU**
**Long-Short Term Memory : LSTM**

140

140

## Illustration + formulation d'un RNN

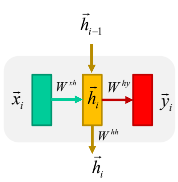

$$\vec{h}_i = f_a\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

141

141

## Autre illustration du même RNN

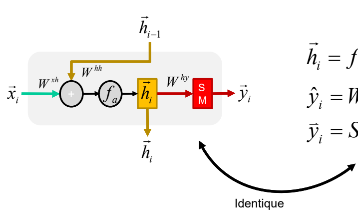


$$\vec{h}_i = f_a\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

142

142

## Autre illustration du même RNN

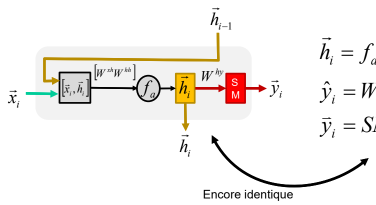


$$\vec{h}_i = f_a\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

143

143

## GRU (Gated Recurrent Unit)

Modif 1

$$f_a = \tanh$$

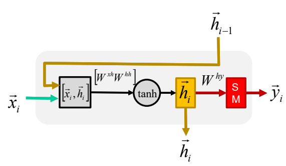

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

144

144

## GRU (Gated Recurrent Unit)

Modif 2

***Update gate***

$$\sigma = \text{sigmoid}$$

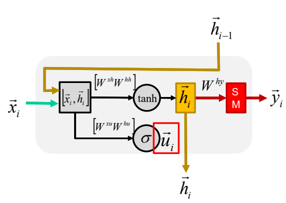

$$\boxed{\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)}$$
$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

145

145

# GRU (Gated Recurrent Unit)

Modif 2

***Update gate***

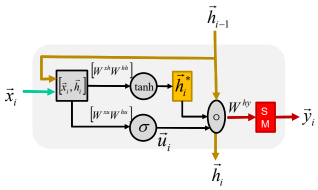


$$\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)$$
$$\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)$$
$$\vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + \left(1-\vec{u}_i\right)\circ \vec{h}_{i-1}$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

146

146

# GRU (Gated Recurrent Unit)

Modif 2

***« element-wise product »***
*ou*
***« Hadamard product »***

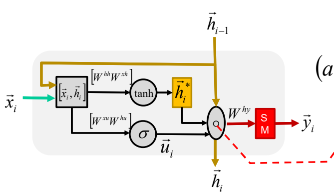


$$(a,b,c)\circ(x,y,z)=(ax,by,cz)$$

147

147

# GRU (Gated Recurrent Unit)

Modif 3

***Reset gate***

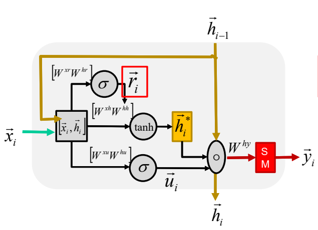


$$\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)$$
$$\boxed{\vec{r}_i = \sigma\left(W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}\right)}$$
$$\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\vec{r}_i \circ \vec{h}_{i-1}\right)\right)$$
$$\vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + \left(1-\vec{u}_i\right)\circ \vec{h}_{i-1}$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\vec{y}_i = SMAX\left(\hat{y}_i\right)$$

148

148

## Comprendre les *gates*

$$\textbf{SI} \quad \begin{aligned} u_i &= 1 \\ r_i &= 1 \end{aligned} \quad \}\{$$

$$\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)$$
$$\vec{r}_i = \sigma\left(W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}\right)$$
$$\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\vec{r}_i \circ \vec{h}_{i-1}\right)\right)$$
$$\vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + (1-\vec{u}_i)\circ \vec{h}_{i-1}$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\bar{y}_i = SMAX(\hat{y}_i)$$

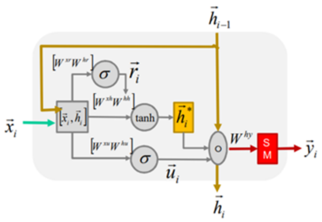





## Comprendre les *gates*

$$\textbf{SI} \quad \begin{aligned} u_i &= 1 \\ r_i &= 1 \end{aligned} \quad \}\{$$

$$\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)$$
$$\vec{r}_i = \sigma\left(W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}\right)$$
$$\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\vec{r}_i \circ \vec{h}_{i-1}\right)\right)$$
$$\vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + \cancel{(1-\vec{u}_i)\circ \vec{h}_{i-1}}$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\bar{y}_i = SMAX(\hat{y}_i)$$

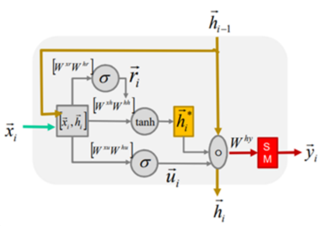





## Comprendre les *gates*

$$\textbf{SI} \quad \begin{aligned} u_i &= 1 \\ r_i &= 1 \end{aligned} \quad \}\{$$

$$\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)$$
$$\vec{r}_i = \cancel{\sigma\left(W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}\right)}\ 1$$
$$\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\cancel{\vec{r}_i}\ 1 \circ \vec{h}_{i-1}\right)\right)$$
$$\vec{h}_i = \cancel{\vec{u}_i}\ 1 \circ \vec{h}_i^* + \cancel{(1-\vec{u}_i)\circ \vec{h}_{i-1}}$$
$$\hat{y}_i = W^{hy}\vec{h}_i$$
$$\bar{y}_i = SMAX(\hat{y}_i)$$

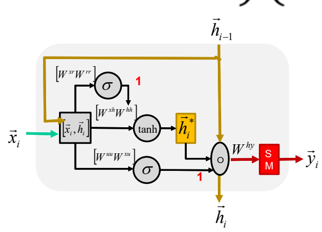

## Comprendre les *gates*

$$\textbf{\textit{SI}}\quad \begin{matrix}\vec{u}_i = 1\\ \vec{r}_i = 1\end{matrix}\ \Bigg\}\Bigg\{\ \begin{aligned}&\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)\\ &\vec{h}_i = \vec{h}_i^*\\ &\hat{y}_i = W^{hy}\vec{h}_i\\ &\vec{y}_i = SMAX(\hat{y}_i)\end{aligned}$$

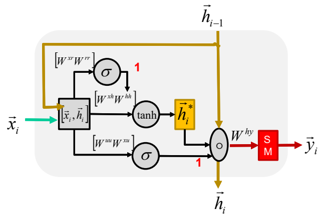




152

## Comprendre les *gates*

$$\textbf{\textit{SI}}\quad \begin{matrix}\vec{u}_i = 1\\ \vec{r}_i = 1\end{matrix}\ \Bigg\}\Bigg\{\ \begin{aligned}&\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right)\\ &\vec{h}_i = \vec{h}_i^*\\ &\hat{y}_i = W^{hy}\vec{h}_i\\ &\vec{y}_i = SMAX(\hat{y}_i)\end{aligned}$$

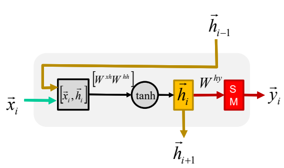


RNN de base!



153

$$\textbf{\textit{SI}}\quad \begin{matrix}\vec{u}_i \neq 1\\ \vec{r}_i = 0\end{matrix}\ \Bigg\}\Bigg\{\ \begin{aligned}&\vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)\\ &\vec{r}_i = \sigma\left(W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}\right)\\ &\vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\cancel{(\vec{r}_i \circ \vec{h}_{i-1})}\right)\\ &\vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + (1-\vec{u}_i)\circ \vec{h}_{i-1}\\ &\hat{y}_i = W^{hy}\vec{h}_i\\ &\vec{y}_i = SMAX(\hat{y}_i)\end{aligned}$$

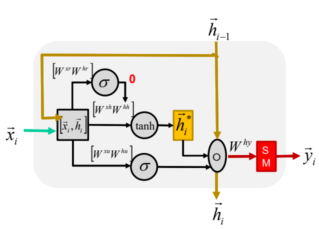




154

**SI** $\vec{u}_i \neq 1$, $\vec{r}_i = 0$

$$\begin{cases} \vec{u}_i = \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right) \\ \vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i\right) \\ \vec{h}_i = \vec{u}_i \circ \vec{h}_i^* + (1-\vec{u}_i)\circ \vec{h}_{i-1} \\ \hat{y}_i = W^{hy}\vec{h}_i \\ \vec{y}_i = SMAX(\hat{y}_i) \end{cases}$$

$\vec{h}_i^*$ ne dépend que de $\vec{x}_i$ et non de $\vec{h}_{i-1}$

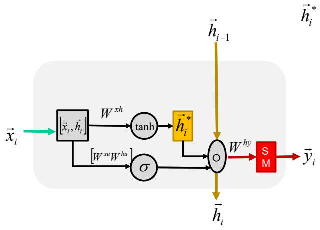


155

155

**SI** $\vec{u}_i = 0$, $\vec{r}_i = 0$

$$\begin{cases} \vec{u}_i = \sigma\left(\cancel{W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}}\right) \\ \vec{r}_i = \sigma\left(\cancel{W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}}\right) \\ \vec{h}_i^* = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\cancel{\vec{r}_i \circ \vec{h}_{i-1}}\right)\right) \\ \vec{h}_i = \cancel{\vec{u}_i \circ \vec{h}_i^*} + (1-\cancel{\vec{u}_i}^{\,1})\circ \vec{h}_{i-1} \\ \hat{y}_i = W^{hy}\vec{h}_i \\ \vec{y}_i = SMAX(\hat{y}_i) \end{cases}$$

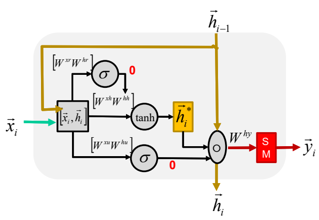


156

156

**SI** $\vec{u}_i = 0$, $\vec{r}_i = 0$

$$\begin{cases} \vec{h}_i = \vec{h}_{i-1} \\ \hat{y}_i = W^{cy}\vec{h}_i \\ \vec{y}_i = SMAX(\hat{y}_i) \end{cases}$$

$\vec{h}_{i-1}$ est recopié

$\vec{x}_i$ est ignoré

*Aucune disparition de gradient*

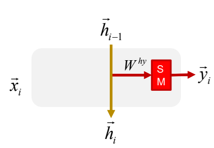


157

157

**SI** $\vec{u}_i = 1$, $\vec{r}_i = 0$

$$\left\{\begin{aligned}
\vec{u}_i &= \sigma\left(W^{xu}\vec{x}_i + W^{hu}\vec{h}_{i-1}\right)\\
\vec{r}_i &= \sigma\left(\cancel{W^{xr}\vec{x}_i + W^{hr}\vec{h}_{i-1}}\right)\\
\vec{h}_i^* &= \tanh\left(W^{xh}\vec{x}_i + W^{hh}\left(\cancel{\vec{r}_i \circ \vec{h}_{i-1}}\right)\right)\\
\vec{h}_i &= \cancel{\vec{u}_i}^{\,1} \circ \vec{h}_i^* + \left(\cancel{1-\vec{u}_i}\right) \circ \vec{h}_{i-1}\\
\hat{y}_i &= W^{hy}\vec{h}_i\\
\vec{y}_i &= SMAX(\hat{y}_i)
\end{aligned}\right.$$

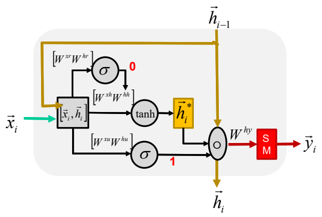


158

158

**SI** $\vec{u}_i = 1$, $\vec{r}_i = 0$

$$\left\{\begin{aligned}
\vec{h}_i &= \tanh\left(W^{xh}\vec{x}_i\right)\\
\hat{y}_i &= W^{hy}\vec{h}_i\\
\vec{y}_i &= SMAX(\hat{y}_i)
\end{aligned}\right.$$

$\vec{h}_{i-1}$ **est ignoté**

$\vec{x}_i$ **est le seul utilisé**

***Gradient temporel <u>bloqué</u>***

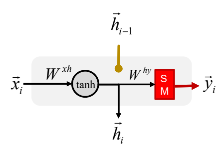


159

159

## Gated Recurrent Unit (GRU)

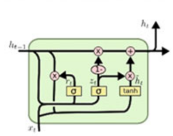

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$
$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$
$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$
$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

Le web regorge d'illustrations de GRU!

Figure: Cristopher Olah, "Understanding LSTM Networks" (2015) / Slide: Alberto Montes

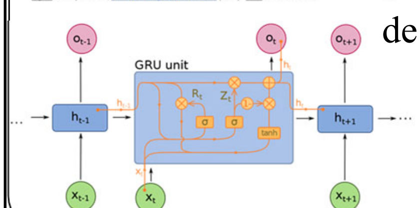


160

## LSTM (Long Short Term Memory)

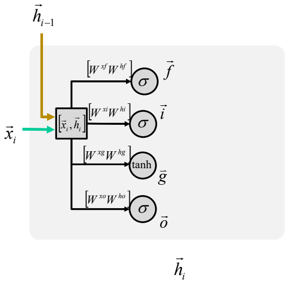


$\vec{f}$ : forget gate
$\vec{i}$ : input gate
$\vec{g}$ : gate gate
$\vec{o}$ : output gate

Hochreiter and Schmidhuber, "Long Short Term Memory", Neural Computation,1997

161

## LSTM (Long Short Term Memory)

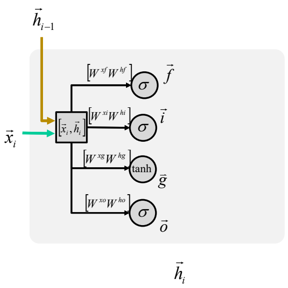


$\vec{f}$ : forget gate
$\vec{i}$ : input gate
$\vec{g}$ : gate gate

**Modèle récurrent le plus utilisé. À bien comprendre !**

Hochreiter and Schmidhuber, "Long Short Term Memory", Neural Computation,1997

162

## LSTM (Long Short Term Memory)

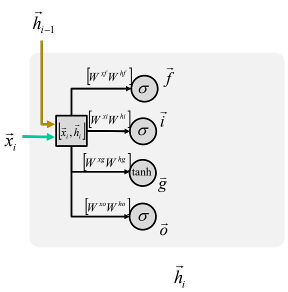


$$\vec{f} = \sigma\left(W^{xf}\vec{x}_i + W^{hf}\vec{h}_{i-1}\right)$$
$$\vec{i} = \sigma\left(W^{xi}\vec{x}_i + W^{hi}\vec{h}_{i-1}\right)$$
$$\vec{g} = \tanh\left(W^{xg}\vec{x}_i + W^{hg}\vec{h}_{i-1}\right)$$
$$\vec{o} = \sigma\left(W^{xo}\vec{x}_i + W^{ho}\vec{h}_{i-1}\right)$$

163

163

## LSTM (Long Short Term Memory)

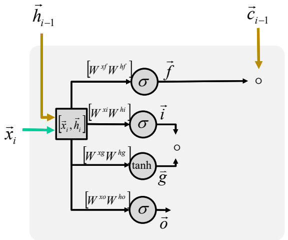


$\vec{f} \circ \vec{c}_i$

$\vec{i} \circ \vec{g}$

164

164

## LSTM (Long Short Term Memory)

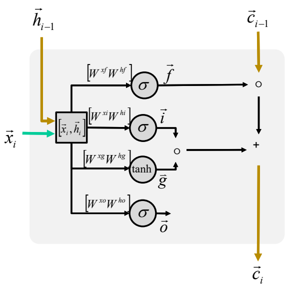


$\vec{c}_i = \vec{f} \circ \vec{c}_i + \vec{i} \circ \vec{g}$

165

165

## LSTM (Long Short Term Memory)

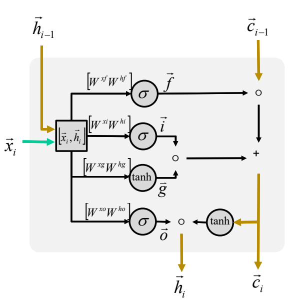


$\vec{c}_i = \vec{f} \circ \vec{c}_i + \vec{i} \circ \vec{g}$

$\vec{h}_i = \vec{o} \circ \tanh(\vec{c}_i)$

166

166

# LSTM (Long Short Term Memory)

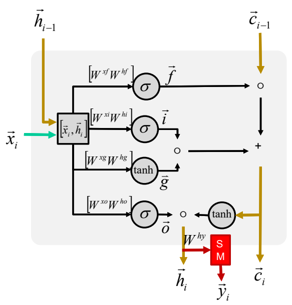

$$\vec{c}_i = \vec{f} \circ \vec{c}_i + \vec{i} \circ \vec{g}$$
$$\vec{h}_i = \vec{o} \circ \tanh(\vec{c}_i)$$
$$\vec{y}_i = SMAX\left(W^{hy}\vec{h}_i\right)$$

167

167

# LSTM (Long Short Term Memory)

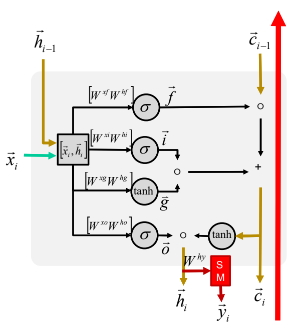

Gradient simplifié

168

168

# LSTM (Long Short Term Memory)

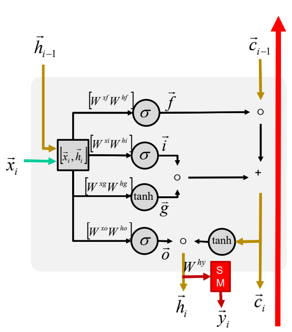

Gradient simplifié

Ça vous rappelle quelque chose ?
Le Resnet !

169

169

# LSTM (Long Short Term Memory)

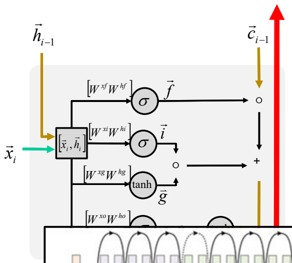

Gradient simplifié

Ça vous rappelle quelque chose ?
Le Resnet !

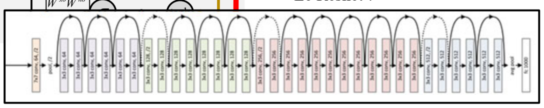

ResNET

170

# LSTM et GRU

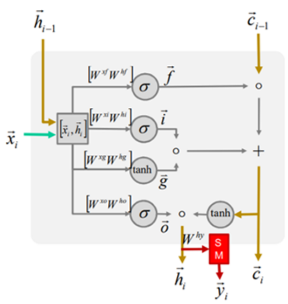

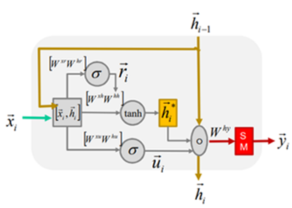

171

171

# LSTM et GRU

- Servent à protéger le gradient
- Conçus empiriquement
- GRU légèrement plus simple
- Les “gates” ne servent qu’à bloquer ou permettre à l’information (données ou temporelle) de passer

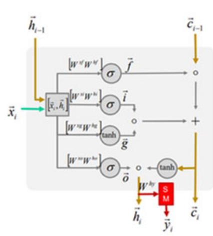

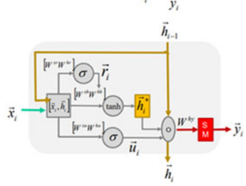

172

172

## RNN multi-couches

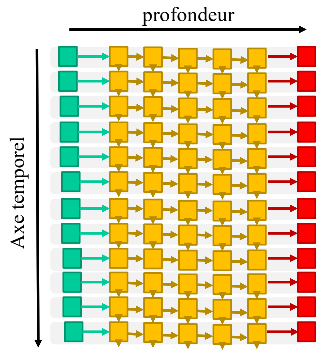


173

## Modèles d’attention

174

## Seq2Seq:

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, *27*.

‘**nous mangeons du pain**’ -> ‘**we are eating bread**’

Réseau récurrent traducteur typique.

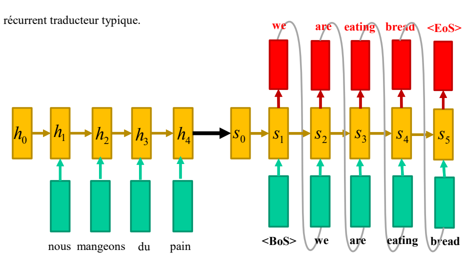


175

## Seq2Seq:

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

**'nous mangeons du pain' -> 'we are eating bread'**

**Problème avec cette formulation ?**

Réseau récurrent traducteur typique.

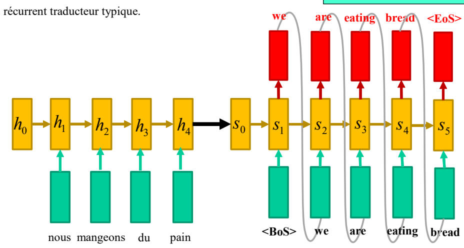


176

## Seq2Seq:

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

**'nous mangeons du pain' -> 'we are eating bread'**

**Problème avec cette formulation ?**

Réseau récurrent traducteur typique.

**La séquence d'entrée est résumée dans un seul vecteur S0**

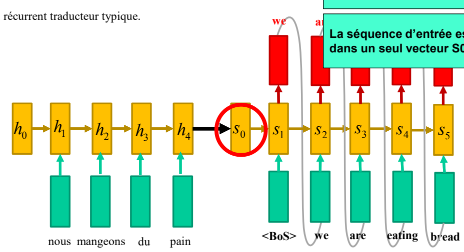


177

## Seq2Seq:

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in neural information processing systems, 27.*

**'nous mangeons du pain' -> 'we are eating bread'**

**Problème avec cette formulation ?**

Réseau récurrent traducteur typique.

**La séquence d'entrée est résumée dans un seul vecteur S0**

**Il faut trouver une façon d'ajouter plus de contexte**

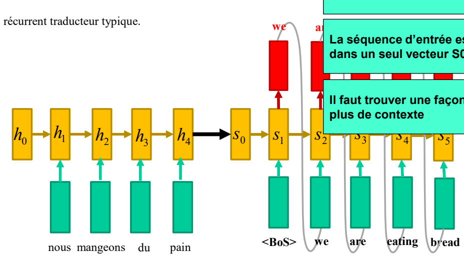


178

## Seq2Seq avec attention
(version simplifiée)

Bahdanau, D., Cho, K., & Bengio, Y. (2014). Neural machine translation by jointly learning to align and translate. arXiv preprint arXiv:1409.0473.

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

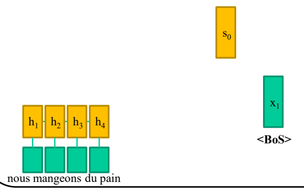


$s_0$ = init value

179

## Seq2Seq avec attention
(version simplifiée)

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

$$e_{1i} = \vec{w}^{sa^T}\vec{s}_0 + \vec{w}^{ha^T}\vec{h}_i \quad \in R$$

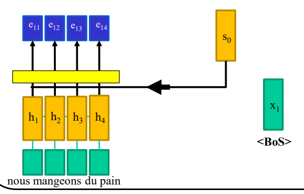


180

## Seq2Seq avec attention
(version simplifiée)

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

$$e_{1i} = \vec{w}^{sa^T}\vec{s}_0 + \vec{w}^{ha^T}\vec{h}_i \quad \in R$$

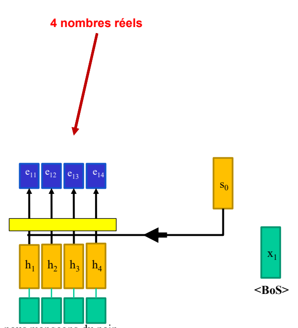


181

## Seq2Seq avec attention
(version simplifiée)

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

$$e_{1i} = \vec{w}^{sa\,T}\vec{s}_0 + \vec{w}^{ha\,T}\vec{h}_i \quad \in R$$

$$a_{1i} = \frac{\exp(e_{1i})}{\sum_{t=1}^{4}\exp(e_{1t})} \quad \in R$$

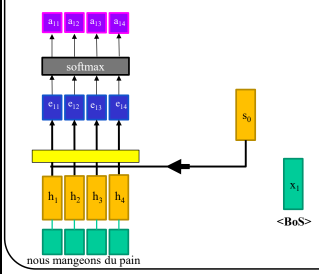


182

## Seq2Seq avec attention
(version simplifiée)

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

$$e_{1i} = \vec{w}^{sa\,T}\vec{s}_0 + \vec{w}^{ha\,T}\vec{h}_i \quad \in R$$

$$a_{1i} = \frac{\exp(e_{1i})}{\sum_{t=1}^{4}\exp(e_{1t})} \quad \in R$$

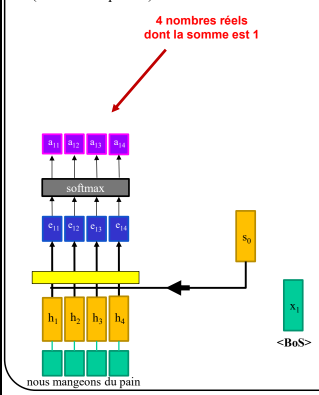


183

## Seq2Seq avec attention
(version simplifiée)

$$\vec{h}_i = \tanh\left(W^{xh}\vec{x}_i + W^{hh}\vec{h}_{i-1}\right) \quad \in R^D$$

$$e_{1i} = \vec{w}^{sa\,T}\vec{s}_0 + \vec{w}^{ha\,T}\vec{h}_i \quad \in R$$

$$a_{1i} = \frac{\exp(e_{1i})}{\sum_{t=1}^{4}\exp(e_{1t})} \quad \in R$$

$$\vec{c}_1 = \sum_{t=1}^{4} a_{1t}\vec{h}_t \quad \in R^V$$

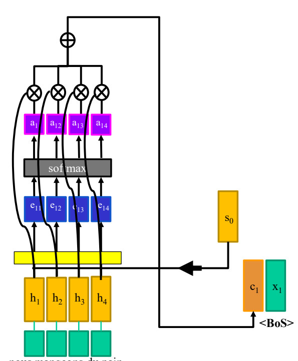


184

## Seq2Seq avec attention
(version simplifiée)

$\vec{a}_1$ : vecteur d'attention

$\vec{c}_1$ : vecteur de context

$$\vec{c}_1 = \sum_{t=1}^{4} a_{1t}\vec{h}_t$$

Le vecteur de contexte est la somme pondérée par le vecteur d'attention des représentations hi

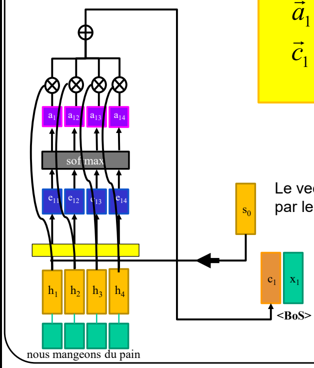


185

## Seq2Seq avec attention
(version simplifiée)

$$e_{1i} = \vec{w}^{sa^T}\vec{s}_0 + \vec{w}^{ha^T}\vec{h}_i$$

$$a_{1i} = \frac{\exp(e_{1i})}{\sum_{t=1}^{4}\exp(e_{1t})}$$

$$\vec{c}_1 = \sum_{t=1}^{4} a_{1t}\vec{h}_t$$

$$s_1 = \tanh\left(W^{ss}\vec{s}_0 + W^{cs}\vec{c}_1 + W^{xs}\vec{x}_1\right)$$

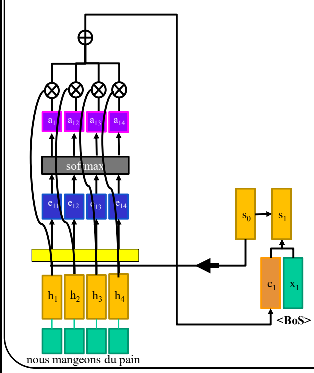


186

## Seq2Seq avec attention
(version simplifiée)

$$e_{1i} = \vec{w}^{sa^T}\vec{s}_0 + \vec{w}^{ha^T}\vec{h}_i$$

$$a_{1i} = \frac{\exp(e_{1i})}{\sum_{t=1}^{4}\exp(e_{1t})}$$

$$\vec{c}_1 = \sum_{t=1}^{4} a_{1t}\vec{h}_t$$

$$s_1 = \tanh\left(W^{ss}\vec{s}_0 + W^{cs}\vec{c}_1 + W^{xs}\vec{x}_1\right)$$

$$y_1 = \mathrm{softmax}\left(W^{sy}\vec{s}_1\right)$$

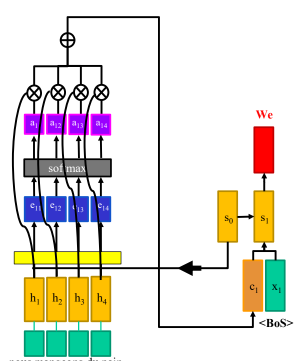


187

## Seq2Seq avec attention
(version simplifiée)

$$e_{2i} = \vec{w}^{sa^T}\vec{s}_1 + \vec{w}^{ha^T}\vec{h}_i$$

$$a_{2i} = \frac{\exp(e_{2i})}{\sum_{t=1}^{4}\exp(e_{2t})}$$

$$\vec{c}_2 = \sum_{t=1}^{4} a_{2t}\vec{h}_t$$

$$s_2 = \tanh\left(W^{ss}\vec{s}_1 + W^{cs}\vec{c}_2 + W^{xs}\vec{x}_2\right)$$

$$y_2 = \text{softmax}\left(W^{sy}\vec{s}_2\right)$$

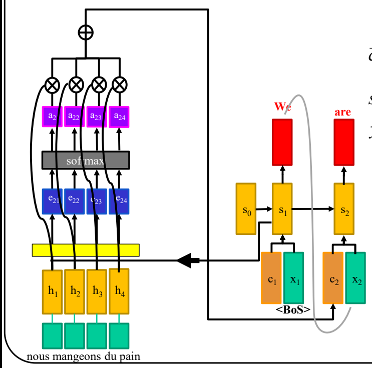


188

## Seq2Seq avec attention
(version simplifiée)

$$e_{3i} = \vec{w}^{sa^T}\vec{s}_2 + \vec{w}^{ha^T}\vec{h}_i$$

$$a_{3i} = \frac{\exp(e_{3i})}{\sum_{t=1}^{4}\exp(e_{3t})}$$

$$\vec{c}_3 = \sum_{t=1}^{4} a_{3t}\vec{h}_t$$

$$s_3 = \tanh\left(W^{ss}\vec{s}_2 + W^{cs}\vec{c}_3 + W^{xs}\vec{x}_3\right)$$

$$y_3 = \text{softmax}\left(W^{sy}\vec{s}_3\right)$$

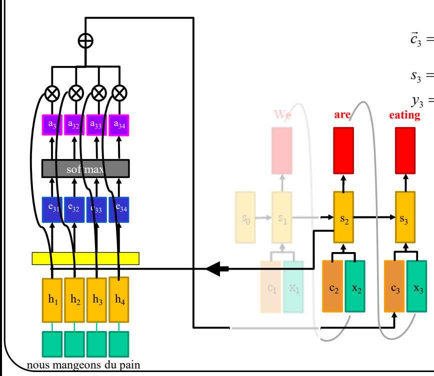


189

## Seq2Seq avec attention
(version simplifiée)

$$e_{4i} = \vec{w}^{sa^T}\vec{s}_3 + \vec{w}^{ha^T}\vec{h}_i$$

$$a_{4i} = \frac{\exp(e_{4i})}{\sum_{t=1}^{4}\exp(e_{4t})}$$

$$\vec{c}_4 = \sum_{t=1}^{4} a_{4t}\vec{h}_t$$

$$s_4 = \tanh\left(W^{ss}\vec{s}_3 + W^{cs}\vec{c}_4 + W^{xs}\vec{x}_4\right)$$

$$y_4 = \text{softmax}\left(W^{sy}\vec{s}_4\right)$$

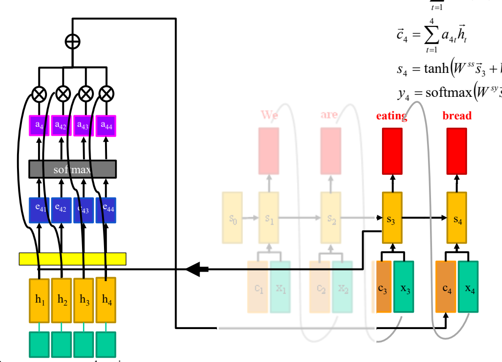


190

## Un vecteur d'attention pour chaque mot

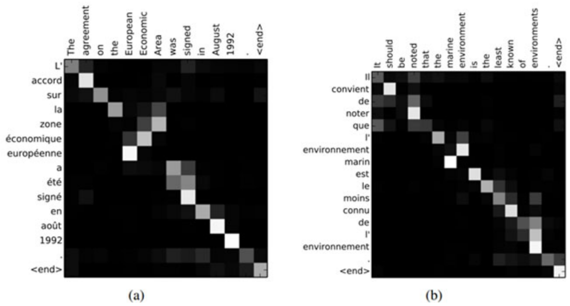


(a) (b)

Bahdanau, D., Cho, K., & Bengio, Y. (2014). Neural machine translation by jointly learning to align and translate. arXiv preprint arXiv:1409.0473.

191

## Seq2Seq avec attention

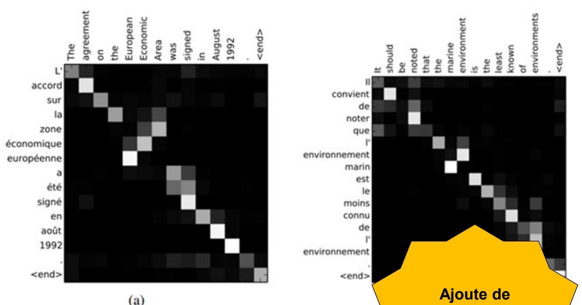


(a)

**Ajoute de l'interprétabilité au modèle !**

Bahdanau, D., Cho, K., & Bengio, Y. (2014). Neural machine translation by jointly learning arXiv:1409.0473.

192

# L'auto-attention
*(self attention)*

204

204

## Revenons à la base : **multiplication matricielle**

Considérons les 4 matrices suivantes

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \end{pmatrix} \in R^{3x4}$$

$$W^q = \begin{pmatrix} W^q{}_{11} & W^q{}_{12} & W^q{}_{13} \\ W^q{}_{21} & W^q{}_{22} & W^q{}_{23} \\ W^q{}_{31} & W^q{}_{32} & W^q{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^k = \begin{pmatrix} W^k{}_{11} & W^k{}_{12} & W^k{}_{13} \\ W^k{}_{21} & W^k{}_{22} & W^k{}_{23} \\ W^k{}_{31} & W^k{}_{32} & W^k{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^V = \begin{pmatrix} W^V{}_{11} & W^V{}_{12} & W^V{}_{13} \\ W^V{}_{21} & W^V{}_{22} & W^V{}_{23} \end{pmatrix} \in R^{2x3}$$

205

205

## Revenons à la base : **multiplication matricielle**

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \end{pmatrix} \in R^{3x4}$$

$$W^q = \begin{pmatrix} W^q{}_{11} & W^q{}_{12} & W^q{}_{13} \\ W^q{}_{21} & W^q{}_{22} & W^q{}_{23} \\ W^q{}_{31} & W^q{}_{32} & W^q{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^k = \begin{pmatrix} W^k{}_{11} & W^k{}_{12} & W^k{}_{13} \\ W^k{}_{21} & W^k{}_{22} & W^k{}_{23} \\ W^k{}_{31} & W^k{}_{32} & W^k{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^V = \begin{pmatrix} W^V{}_{11} & W^V{}_{12} & W^V{}_{13} \\ W^V{}_{21} & W^V{}_{22} & W^V{}_{23} \end{pmatrix} \in R^{2x3}$$

Leur multiplication donne:

$$W^q X = Q = \begin{pmatrix} Q_{11} & Q_{12} & Q_{13} & Q_{14} \\ Q_{21} & Q_{22} & Q_{23} & Q_{24} \\ Q_{31} & Q_{32} & Q_{33} & Q_{34} \end{pmatrix} \in R^{3x4}$$

$$W^K X = K = \begin{pmatrix} K^x{}_{11} & K^x{}_{12} & K^x{}_{13} & K^x{}_{14} \\ K^x{}_{21} & K^x{}_{22} & K^x{}_{23} & K^x{}_{24} \\ K^x{}_{31} & K^x{}_{32} & K^x{}_{33} & K^x{}_{34} \end{pmatrix} \in R^{3x4}$$

$$W^V X = V = \begin{pmatrix} V^x_{11} & V^x_{12} & V^x_{13} & V^x_{14} \\ V^x_{21} & V^x_{22} & V^x_{23} & V^x_{24} \end{pmatrix} \in R^{2x4}$$

206

206

## Auto attention

X est une matrice de données pour laquelle chaque colonne *i* correspond au jeton d'une mot $\vec{x}_i$

$$X = \begin{pmatrix} \boxed{\begin{matrix} x_{11} \\ x_{21} \\ x_{31} \end{matrix}} & \boxed{\begin{matrix} x_{12} \\ x_{22} \\ x_{32} \end{matrix}} & \boxed{\begin{matrix} x_{13} \\ x_{23} \\ x_{33} \end{matrix}} & \boxed{\begin{matrix} x_{14} \\ x_{24} \\ x_{34} \end{matrix}} \end{pmatrix} \in R^{3x4}$$

Nous mangeons du pain

Dans cet exemple, 4 mots en entrée donc 4 colonnes dans X
Les jetons peuvent être obtenus par **Word2Vec**

207

207

# Auto attention

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \end{pmatrix} \in R^{3x4}$$

Nous mangeons du pain

$$W^q = \begin{pmatrix} W^q{}_{11} & W^q{}_{12} & W^q{}_{13} \\ W^q{}_{21} & W^q{}_{22} & W^q{}_{23} \\ W^q{}_{31} & W^q{}_{32} & W^q{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^k = \begin{pmatrix} W^k{}_{11} & W^k{}_{12} & W^k{}_{13} \\ W^k{}_{21} & W^k{}_{22} & W^k{}_{23} \\ W^k{}_{31} & W^k{}_{32} & W^k{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^V = \begin{pmatrix} W^V{}_{11} & W^V{}_{12} & W^V{}_{13} \\ W^V{}_{21} & W^V{}_{22} & W^V{}_{23} \end{pmatrix} \in R^{2x3}$$

**W** : Matrices de paramètres appris par **rétropropagation**

208

208

# Auto attention

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \end{pmatrix} \in R^{3x4}$$

Nous mangeons du pain

$$W^q = \begin{pmatrix} W^q{}_{11} & W^q{}_{12} & W^q{}_{13} \\ W^q{}_{21} & W^q{}_{22} & W^q{}_{23} \\ W^q{}_{31} & W^q{}_{32} & W^q{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^k = \begin{pmatrix} W^k{}_{11} & W^k{}_{12} & W^k{}_{13} \\ W^k{}_{21} & W^k{}_{22} & W^k{}_{23} \\ W^k{}_{31} & W^k{}_{32} & W^k{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^V = \begin{pmatrix} W^V{}_{11} & W^V{}_{12} & W^V{}_{13} \\ W^V{}_{21} & W^V{}_{22} & W^V{}_{23} \end{pmatrix} \in R^{2x3}$$

Matrices de paramètres appris par rétropropagation

**Pour ces 3 matrices, le nombre de colonnes (3) doit être égale au nombre de lignes dans X (3)**

209

209

# Auto attention

$$X = \begin{pmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \end{pmatrix} \in R^{3x4}$$

Nous mangeons du pain

$$W^q = \begin{pmatrix} W^q{}_{11} & W^q{}_{12} & W^q{}_{13} \\ W^q{}_{21} & W^q{}_{22} & W^q{}_{23} \\ W^q{}_{31} & W^q{}_{32} & W^q{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^k = \begin{pmatrix} W^k{}_{11} & W^k{}_{12} & W^k{}_{13} \\ W^k{}_{21} & W^k{}_{22} & W^k{}_{23} \\ W^k{}_{31} & W^k{}_{32} & W^k{}_{33} \end{pmatrix} \in R^{3x3}$$

$$W^V = \begin{pmatrix} W^V{}_{11} & W^V{}_{12} & W^V{}_{13} \\ W^V{}_{21} & W^V{}_{22} & W^V{}_{23} \end{pmatrix} \in R^{2x3}$$

Matrices de paramètres appris par rétropropagation

**Pour ces 3 matrices, le nombre de ligne (3,3,2) est arbitraire**

210

210

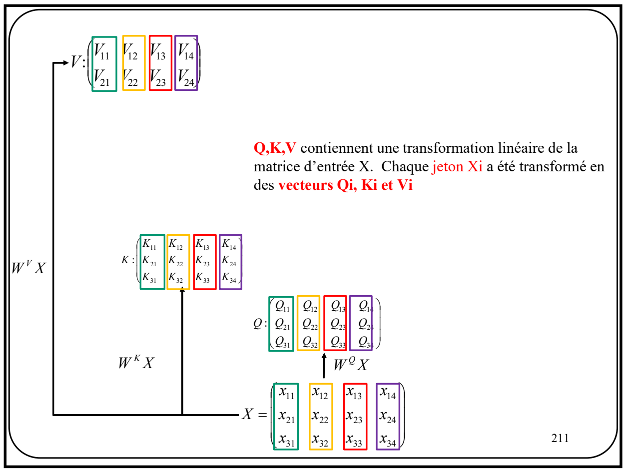
Q,K,V contiennent une transformation linéaire de la matrice d'entrée X. Chaque jeton Xi a été transformé en des vecteurs Qi, Ki et Vi
V :
K :
Q :
X =
$W^V X$
$W^K X$
$W^Q X$
211

211

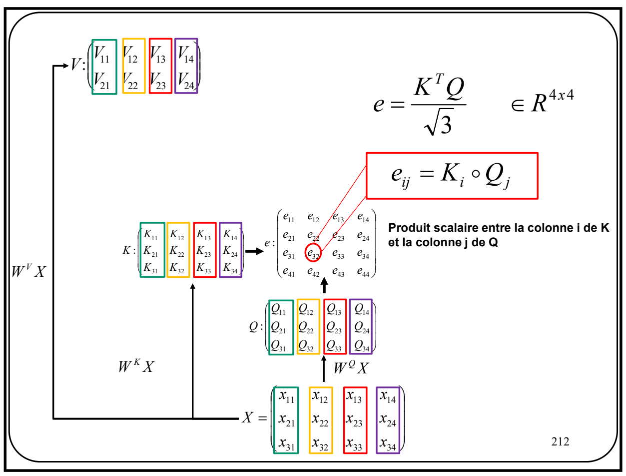
$e = \frac{K^T Q}{\sqrt{3}} \quad \in R^{4x4}$
$e_{ij} = K_i \circ Q_j$
Produit scalaire entre la colonne i de K et la colonne j de Q
V :
K :
Q :
e :
X =
$W^V X$
$W^K X$
$W^Q X$
212

212

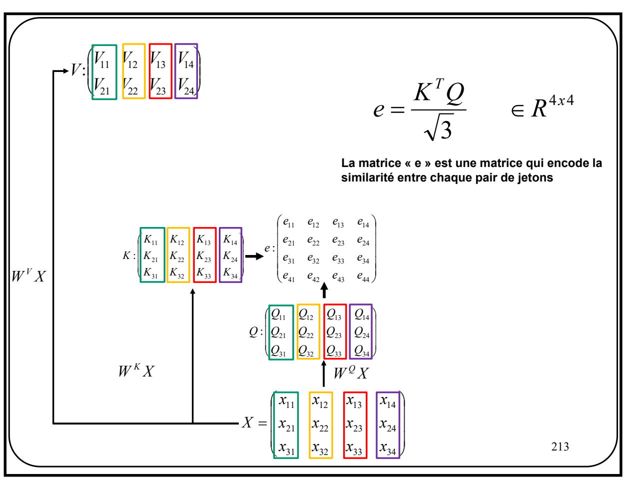
$e = \frac{K^T Q}{\sqrt{3}} \quad \in R^{4x4}$
La matrice « e » est une matrice qui encode la similarité entre chaque pair de jetons
V :
K :
Q :
e :
X =
$W^V X$
$W^K X$
$W^Q X$
213

213

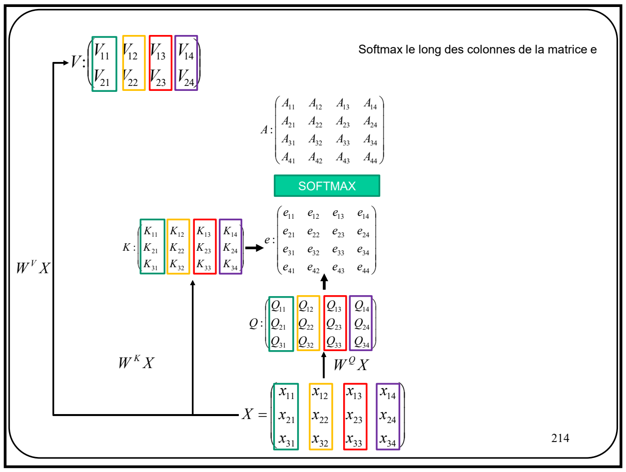
Softmax le long des colonnes de la matrice e
SOFTMAX
214

214

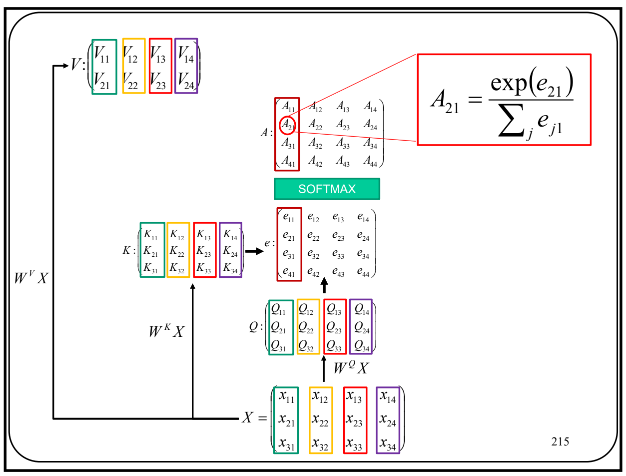
$A_{21} = \frac{\exp(e_{21})}{\sum_j e_{j1}}$
SOFTMAX
215

215

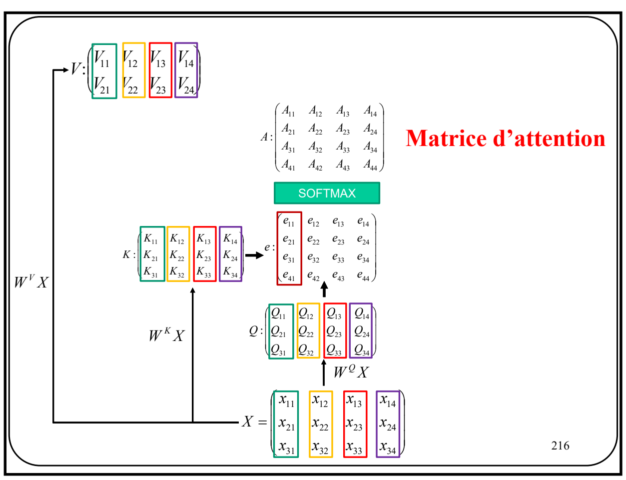
Matrice d'attention
SOFTMAX
216

216

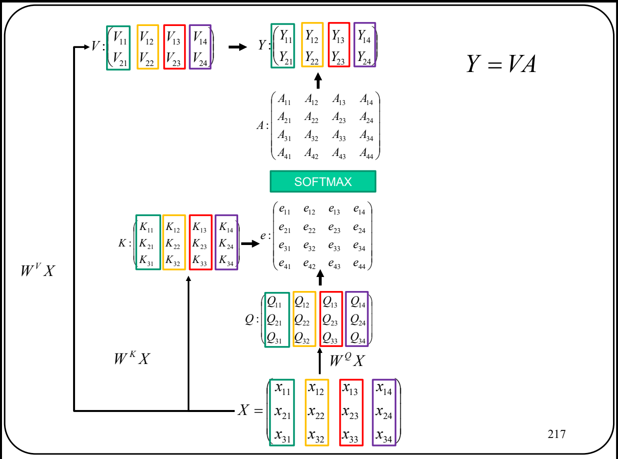


217

## Couche d'auto-attention *(Self-attention layer)*

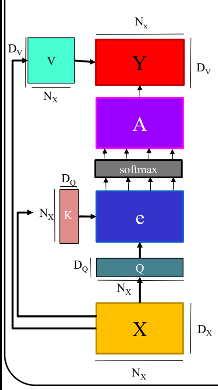


**X** données
**Q**uery: que chercher dans nos données
**K**ey: la "clé" des données
**V**alue: la "valeur" des données
**E**ntries: le "contenu" des données
**A**ttention: la pertinence des entrées

$$Q = W^Q X$$
$$K = W^K X$$
$$V = W^V X$$
$$e = \frac{K^T Q}{\sqrt{D_Q}}$$
$$A_{ji} = \frac{\exp(e_{ji})}{\sum_j e_{ji}}$$
$$Y = VA$$

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

218

## Autre façon d'illustrer la couche d'auto-attention

$$Attention(Q,K,V) = V \cdot \mathrm{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

X

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

219

## Autre façon d'illustrer la couche d'auto-attention

$$Attention(Q,K,V) = V \cdot \text{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

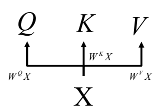


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

220

## Autre façon d'illustrer la couche d'auto-attention

$$Attention(Q,K,V) = V \cdot \text{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

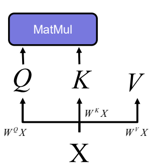


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

221

## Autre façon d'illustrer la couche d'auto-attention

$$Attention(Q,K,V) = V \cdot \text{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

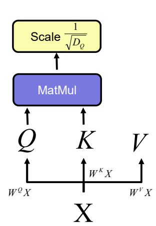


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

222

## Autre façon d'illustrer la couche d'auto-attention

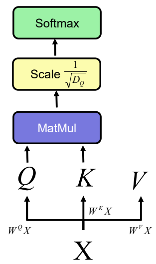


$$Attention(Q,K,V) = V \cdot \text{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

223

## Autre façon d'illustrer la couche d'auto-attention

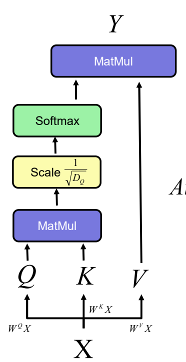


$$Attention(Q,K,V) = V \cdot \text{softmax}\left(\frac{K^T Q}{\sqrt{D_Q}}\right)$$

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

224

## Couche d'auto-attention *(Self-attention layer)*

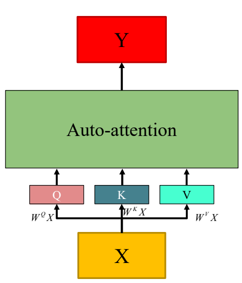


**Autre représentation schématique**

225

## Couche d'auto-attention *(Self-attention layer)*

**Autre représentation schématique**

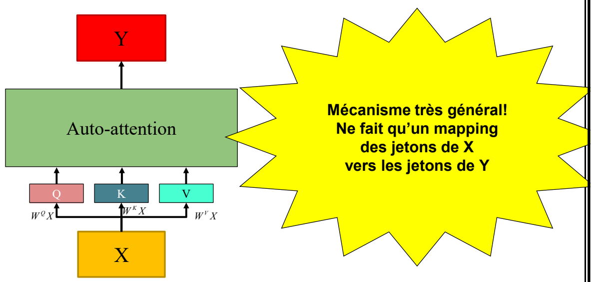


226

## Auto-attention multi-têtes *(Multi-head Self-attention)*

Illustration à 2 têtes

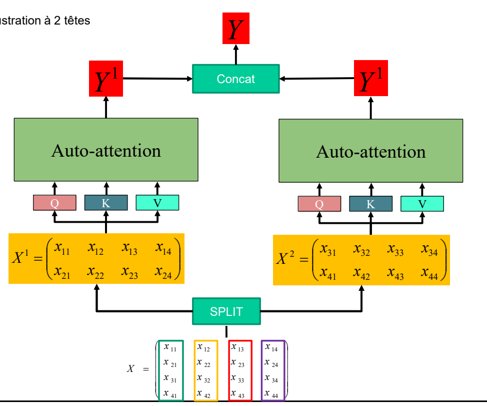


227

227

## Auto-attention multi-tête *(Multi-head Self-attention)*

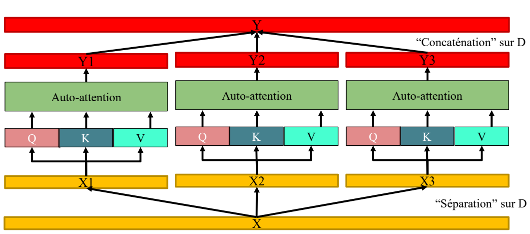


**Très bon résumé de l'auto-attention multi-tête :**

**https://towardsdatascience.com/transformers-explained-visually-part-3-multi-head-attention-deep-dive-1c1ff1024853**

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

228

L’apothéose des réseaux de neurones

# *Transformer*

*(Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

229

# *Transformer*

*Implique* ***aucune notion de récurrence***

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

230

*Transformer (Attention is all you need)*

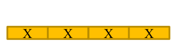


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

231

## *Transformer (Attention is all you need)*

- Auto-attention multi-têtes sur les dimensions de X

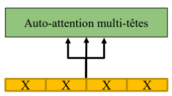


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

232

## *Transformer (Attention is all you need)*

- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle

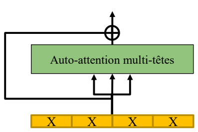


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

233

## *Transformer (Attention is all you need)*

- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"

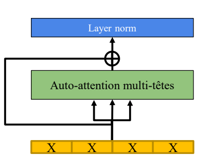


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

234

## *Transformer (Attention is all you need)*

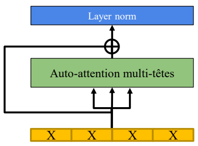


$$y = \frac{x - \mathrm{E}[x]}{\sqrt{\mathrm{Var}[x] + \epsilon}} * \gamma + \beta$$

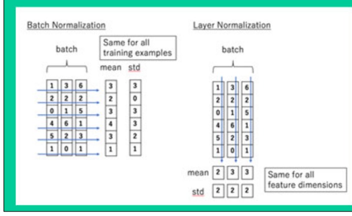


Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

235

## *Transformer (Attention is all you need)*

$$mlp(x) = \max(0, xW^1)W^2$$

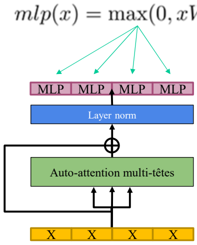


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

236

## *Transformer (Attention is all you need)*

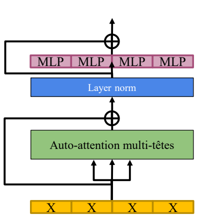


- Intra-attention multi-tête sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

237

## *Transformer (Attention is all you need)*

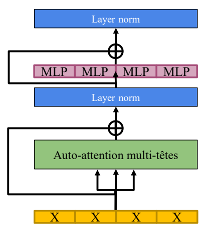


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle
- 2e "Layer-norm"

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

238

## *Transformer (Attention is all you need)*

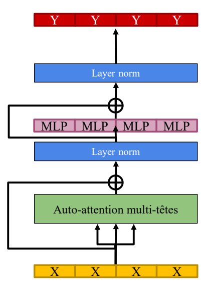


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle
- 2e "Layer-norm"

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

239

## *Transformer (Attention is all you need)*

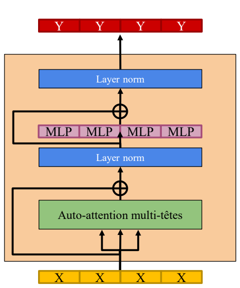


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle
- 2e "Layer-norm"

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

240

## Transformer (Attention is all you need)

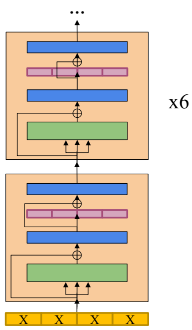


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle
- 2e "Layer-norm"

Le bloc est répété 6 fois pour l'encodeur

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

241

## Transformer (Attention is all you need)

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

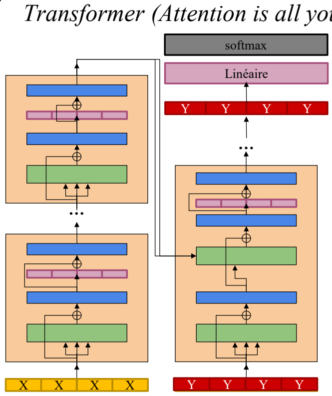


- Auto-attention multi-têtes sur les dimensions de X
- "+ " = connexion résiduelle
- "Layer-norm"
- MLP pour chaque jeton
- 2e "+ " = connexion résiduelle
- 2e "Layer-norm"

Le bloc est répété 6 fois pour l'encodeur

La sortie de l'encodeur sert de K,V pour tous les décodeurs

Le décodeur est répété 6 fois

242

## Transformer (Attention is all you need)

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

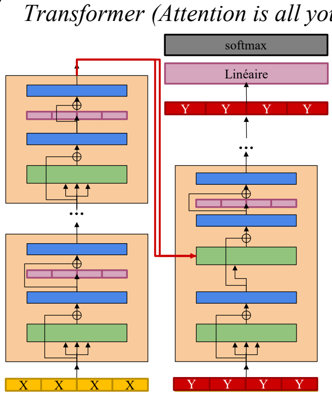


- Intra-attention multi-tête sur les dimensions de X
- "+ " = connection résiduelle
- "Layer-norm"
- MLP par entrée

Le bloc est répété 6 fois pour l'encodeur

La sortie de l'encodeur sert de K,V pour tous les décodeurs

Le décodeur est répété 6 fois

243

## *Transformer (Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

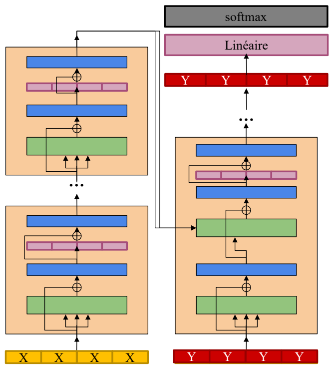


- Intra-attention multi-tête sur les dimensions de X
- “+ “ = connection résiduelle
- “Layer-norm”
- MLP par entrée

Le bloc est répété 6 fois pour l’encodeur

La sortie de l’encodeur sert de K,V pour tous les décodeurs

Pour la modélisation de langage:
- X: texte en français
- Y input: <BoS> + phrase en anglais
- Y output: phrase en anglais

244

## *Transformer (Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

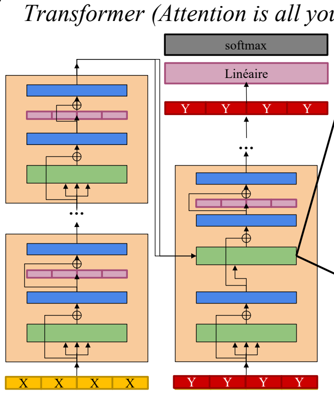


- Intra-attention multi-tête sur les

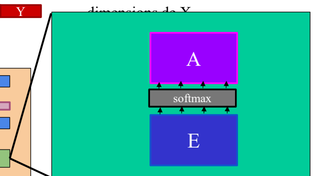


Pour la modélisation de langage:
- X: texte en français
- Y input: <BoS> + phrase en anglais
- Y output: phrase en anglais

245

## *Transformer (Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30.*

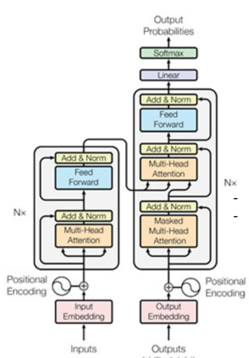


Supers bons tutoriels:
- https://jalammar.github.io/illustrated-transformer/
- https://data-science-blog.com/blog/2021/04/07/multi-head-attention-mechanism/

249

## *Transformer (Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30*.

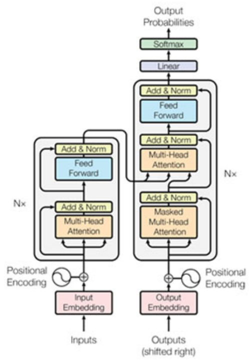


Très gourmand en mémoire:
- Matrices de poids $W^Q, W^K, W^V$
- Couches pleinement connectées
- "Répétition" de paramètres par les multi-têtes

Très demandant en opérations
- Complexité quadratique

250

## *Transformer (Attention is all you need)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems, 30*.

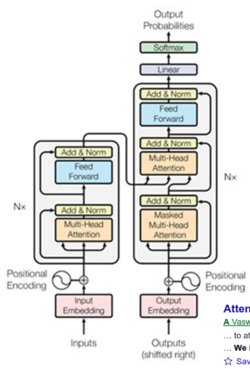


Très gourmand en mémoire:
- Matrices de poids $W^Q, W^K, W^V$
- Couches pleinement connectées
- "Répétition" de paramètres par les multi-têtes

Aussi très populaires !

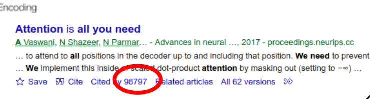


251

## Différentes version de transformers

Srxudsshe=Uhvqhw083=56P gh sdudp äwhv

| Model | Layers | Width | Heads | Params | Data | Training |
|---|---|---|---|---|---|---|
| Transformer-Base | 12 | 512 | 8 | 65M | | 8x P100 (12 hours) |
| Transformer-Large | 12 | 1024 | 16 | 213M | | 8x P100 (3.5 days) |

fuhglw=Mxvwlq Mrkqvrq

252

## Transformers

| Model | Layers | Width | Heads | Params | Data | Training |
|---|---|---|---|---|---|---|
| Transformer-Base | 12 | 512 | 8 | 65M | | 8x P100 (12 hours) |
| Transformer-Large | 12 | 1024 | 16 | 213M | | 8x P100 (3.5 days) |
| BERT-Base | 12 | 768 | 12 | 110M | 13 GB | |
| BERT-Large | 24 | 1024 | 16 | 340M | 13 GB | |

fuàglw=Mxvwlq Mrkqvrq

253

## Transformers

| Model | Layers | Width | Heads | Params | Data | Training |
|---|---|---|---|---|---|---|
| Transformer-Base | 12 | 512 | 8 | 65M | | 8x P100 (12 hours) |
| Transformer-Large | 12 | 1024 | 16 | 213M | | 8x P100 (3.5 days) |
| BERT-Base | 12 | 768 | 12 | 110M | 13 GB | |
| BERT-Large | 24 | 1024 | 16 | 340M | 13 GB | |
| XLNet-Large | 24 | 1024 | 16 | ~340M | 126 GB | 512x TPU-v3 (2.5 days) |
| RoBERTa | 24 | 1024 | 16 | 355M | 160 GB | 1024x V100 GPU (1 day) |

fuàglw=Mxvwlq Mrkqvrq

254

## Transformers

| Model | Layers | Width | Heads | Params | Data | Training |
|---|---|---|---|---|---|---|
| Transformer-Base | 12 | 512 | 8 | 65M | | 8x P100 (12 hours) |
| Transformer-Large | 12 | 1024 | 16 | 213M | | 8x P100 (3.5 days) |
| BERT-Base | 12 | 768 | 12 | 110M | 13 GB | |
| BERT-Large | 24 | 1024 | 16 | 340M | 13 GB | |
| XLNet-Large | 24 | 1024 | 16 | ~340M | 126 GB | 512x TPU-v3 (2.5 days) |
| RoBERTa | 24 | 1024 | 16 | 355M | 160 GB | 1024x V100 GPU (1 day) |
| GPT-2 | 12 | 768 | ? | 117M | 40 GB | |
| GPT-2 | 24 | 1024 | ? | 345M | 40 GB | |
| GPT-2 | 36 | 1280 | ? | 762M | 40 GB | |
| GPT-2 | 48 | 1600 | ? | 1.5B | 40 GB | |

fuàglw=Mxvwlq Mrkqvrq

255

## *Transformers*

| Model | Layers | Width | Heads | Params | Data | Training |
|---|---|---|---|---|---|---|
| Transformer-Base | 12 | 512 | 8 | 65M | | 8x P100 (12 hours) |
| Transformer-Large | 12 | 1024 | 16 | 213M | | 8x P100 (3.5 days) |
| BERT-Base | 12 | 768 | 12 | 110M | 13 GB | |
| BERT-Large | 24 | 1024 | 16 | 340M | 13 GB | |
| XLNet-Large | 24 | 1024 | 16 | ~340M | 126 GB | 512x TPU-v3 (2.5 days) |
| RoBERTa | 24 | 1024 | 16 | 355M | 160 GB | 1024x V100 GPU (1 day) |
| GPT-2 | 12 | 768 | ? | 117M | 40 GB | |
| GPT-2 | 24 | 1024 | ? | 345M | 40 GB | |
| GPT-2 | 36 | 1280 | ? | 762M | 40 GB | |
| GPT-2 | 48 | 1600 | ? | 1.5B | 40 GB | |
| Megatron-LM | 40 | 1536 | 16 | 1.2B | 174 GB | 64x V100 GPU |
| Megatron-LM | 54 | 1920 | 20 | 2.5B | 174 GB | 128x V100 GPU |
| Megatron-LM | 64 | 2304 | 24 | 4.2B | 174 GB | 256x V100 GPU (10 days) |
| Megatron-LM | 72 | 3072 | 32 | 8.3B | 174 GB | 512x V100 GPU (9 days) |

fùàglw=Mxvwlq Mrkqvrq

256

## *GPT1-2-3*

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding by generative pre-training.
Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 1(8), 9.
Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. Advances in neural information processing systems, 33, 1877-1901.

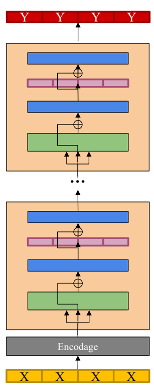


*Generative-Pre-Training*

*GTP 1,2,3* entraînent l'encodeur du transformer sur des données non annotée (d'où le « pre-training »)

**GPT3 a 96 blocks d'auto-attention!**

257

## *GPT1-2-3*

Pré-entraînement : le but est d'entraîner un réseau **à prédire le prochain mot**.

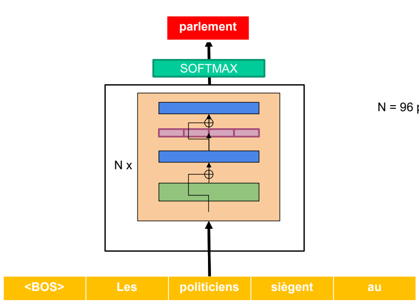


N = 96 pour GPT3

258

258

## *GPT1-2-3*

Et on recommence:

<BOS> Les politiciens siègent au → parlement

<BOS> Les politiciens siègent au parlement → les

<BOS> Les politiciens siègent au parlement les → jours

<BOS> Les politiciens siègent au parlement les jours → de

<BOS> Les politiciens siègent au parlement les jours de → semaine

<BOS> Les politiciens siègent au parlement les jours de semaine → <EOS>

259

259

## *Transformers*

Les transformers sont *vraiment bons* pour générer du texte

**SYSTEM PROMPT (HUMAN-WRITTEN)**

*Recycling is good for the world.*

*NO! YOU COULD NOT BE MORE WRONG!!*

**MODEL COMPLETION (MACHINE-WRITTEN, 25 TRIES)**

Recycling is NOT good for the world. It is bad for the environment, it is bad for our health, and it is bad for our economy. I'm not kidding. Recycling is not good for the environment. It is destructive to the earth and it is a major contributor to global warming. Recycling is not good for our health. It contributes to obesity and diseases like heart disease and cancer. Recycling is bad for our economy. It increases the cost of a product, and in turn, the price of everything that is made with that product. Recycling is not good for our nation. We pay a tremendous price for the privilege of having the world's most advanced and efficient recycling system. Recycling is a huge, colossal waste of time, energy, money, and resources. And THAT is why we need to get back to basics and get back to basics in our recycling efforts. One of the best ways to start is to look at the process of creating a paper product. When you make a paper product, it is basically a long chain of materials. Everything from the raw materials (wood, cardboard, paper, etc.), to the reagents (dyes, solvents, etc.) to the printing equipment (chemicals, glue, paper, ink, etc.), to the packaging, to the packaging materials (mercury, chemicals, etc.) to the processing equipment (heating, cooling, etc.), to the packaging materials, to the packaging materials that are shipped overseas and to the packaging materials that are used in the United States. Each step along the way creates tons of waste that we constantly have to clean up. The process of making a paper product is a very wasteful one. But the end result is something that all of us need to consume. And if we want to keep the recycling process running efficiently, then we really need to think about each and every step that goes into making a paper product.

https://openai.com/blog/better-language-models/#sample8

260

## *Transformers*

Les transformers sont *vraiment bons* pour générer du texte sémantiquement viable

**I really like the IFT780 course on neural networks offered at the Université de Sherbrooke, because**

the teacher uses examples from video games, which I find a nice contrast to the theory.

I think I would like a course on AI to really understand how it works, but when we are in class, the prof speaks in a rapid French, and I can't really process what he's saying.

Having started a course on it at a different time, I understand more this time, but I still don't know where I stand.

My "new" plan for next year is to do all of the tutorials and classes I've been wanting to take, but I'm still stuck on one big, heavy, headachey decision: how do I want to spend my post - masters year?

With a lot of math and statistics classes, it's not a hard choice.

I'm on the fence with what I want to spend my summer doing: a lot of analysis and research work or do some volunteering?

I've applied to several volunteer programs: naturis and Vert directeur de la santé, which are essentially summer internships for dentists and health care professionals to do a bit of volunteer work.

https://app.inferkit.com/demo

261

## *GPT-1-2-3*

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding by generative pre-training.
Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 1(8), 9.
Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. Advances in neural information processing systems, 33, 1877-1901.

GPT-2

| Parameters | Layers | $d_{model}$ |
|---|---|---|
| 117M | 12 | 768 |
| 345M | 24 | 1024 |
| 762M | 36 | 1280 |
| 1542M | 48 | 1600 |

*Table 2.* Architecture hyperparameters for the 4 model sizes.

GPT-3

| Model Name | $n_{params}$ | $n_{layers}$ | $d_{model}$ | $n_{heads}$ | $d_{head}$ | Batch Size | Learning Rate |
|---|---|---|---|---|---|---|---|
| GPT-3 Small | 125M | 12 | 768 | 12 | 64 | 0.5M | $6.0 \times 10^{-4}$ |
| GPT-3 Medium | 350M | 24 | 1024 | 16 | 64 | 0.5M | $3.0 \times 10^{-4}$ |
| GPT-3 Large | 760M | 24 | 1536 | 16 | 96 | 0.5M | $2.5 \times 10^{-4}$ |
| GPT-3 XL | 1.3B | 24 | 2048 | 24 | 128 | 1M | $2.0 \times 10^{-4}$ |
| GPT-3 2.7B | 2.7B | 32 | 2560 | 32 | 80 | 1M | $1.6 \times 10^{-4}$ |
| GPT-3 6.7B | 6.7B | 32 | 4096 | 32 | 128 | 2M | $1.2 \times 10^{-4}$ |
| GPT-3 13B | 13.0B | 40 | 5140 | 40 | 128 | 2M | $1.0 \times 10^{-4}$ |
| GPT-3 175B or "GPT-3" | 175.0B | 96 | 12288 | 96 | 128 | 3.2M | $0.6 \times 10^{-4}$ |

**Table 2.1:** Sizes, architectures, and learning hyper-parameters (batch size in tokens and learning rate) of the models which we trained. All models were trained for a total of 300 billion tokens.

262

## *GPT1-2-3*

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving language understanding by generative pre-training.
Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 1(8), 9.
Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. Advances in neural information processing systems, 33, 1877-1901.

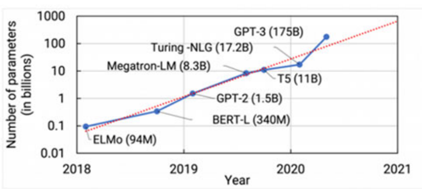


*Figure 1. Trend of state-of-the-art NLP model sizes with time.*

https://developer.nvidia.com/blog/scaling-language-model-training-to-a-trillion-parameters-using-megatron/

*"355 years on a V100 GPU server with 28 TFLOPS capacity and would cost **$4.6 million at $1.5 per hour**"*

https://bdtechtalks.com/2020/09/21/gpt-3-economy-business-model/

263

## *Vision Transformers (ViT)*

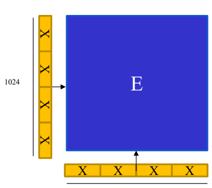


Opération (au moins) quadratique = $1024^2$ opérations et composantes à garder en mémoire

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

264

## *Vision Transformers (ViT)*

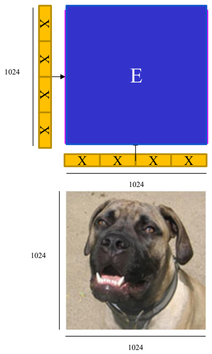


Opération (au moins) quadratique

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

265

## *Vision Transformers (ViT)*

Opération (au moins) quadratique

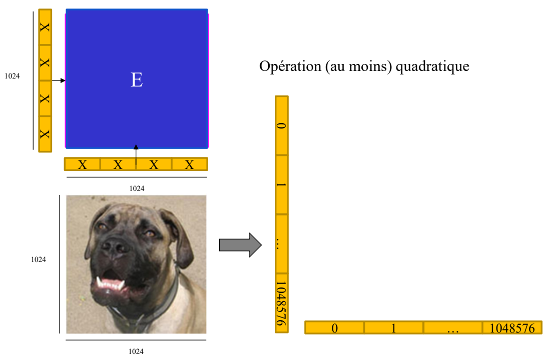


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

266

## *Vision Transformers (ViT)*

Opération (au moins) quadratique

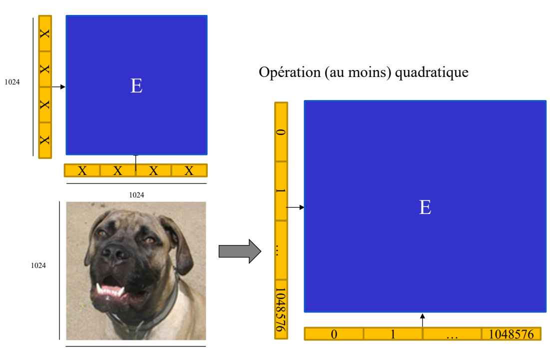


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

267

## *Vision Transformers (ViT)*

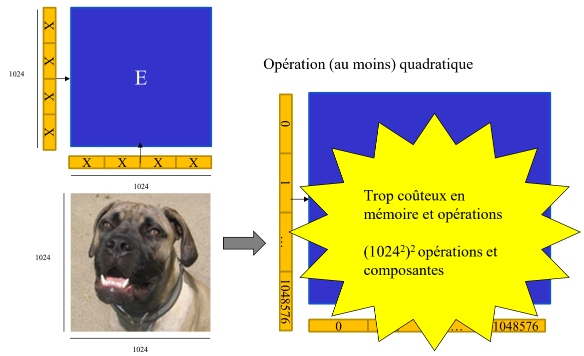


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

268

## *Vision Transformers (ViT)*

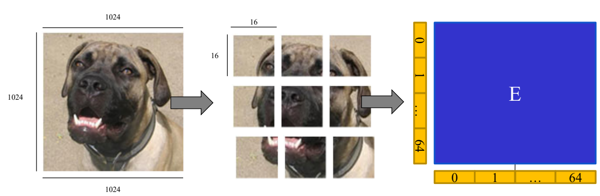


Chaque "patch" est un token de (par exemple) 256 composantes

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

269

## *Vision Transformers (ViT)*

- L'image est séparée en patch

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

270

## *Vision Transformers (ViT)*

- L'image est séparée en patch
- Chaque patch est linéarisée

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

271

## *Vision Transformers (ViT)*

- L'image est séparée en patch
- Chaque patch est linéarisée
- Un token spécial représentant la classe est ajouté

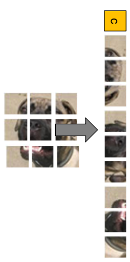


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

272

## *Vision Transformers (ViT)*

- L'image est séparée en patch
- Chaque patch est linéarisée
- Un token spécial représentant la classe est ajouté
- Un encodage de position est ajouté aux tokens

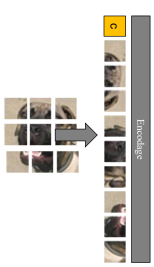


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

273

## Vision Transformers (ViT)

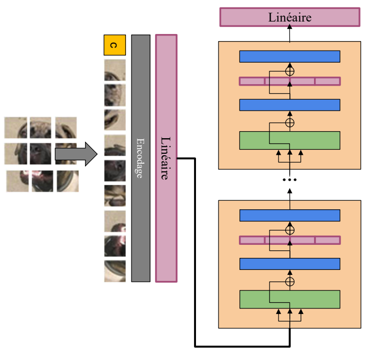


- L'image est séparée en patch
- Chaque patch est linéarisée
- Un token spécial représentant la classe est ajouté
- Un encodage de position est ajouté aux tokens
- Le reste de l'architecture est identique à *Attention is all you need*

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

274

## Vision Transformers (ViT)

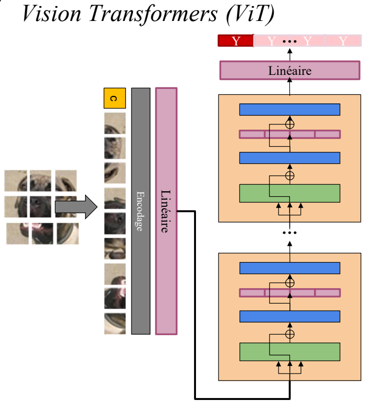


- L'image est séparée en patch
- Chaque patch est linéarisée
- Un token spécial représentant la classe est ajouté
- Un encodage de position est ajouté aux tokens
- Le reste de l'architecture est identique à *Attention is all you need*
- Seulement la prédiction correspondant au token de classe est faite

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

275

## Vision Transformers (ViT)

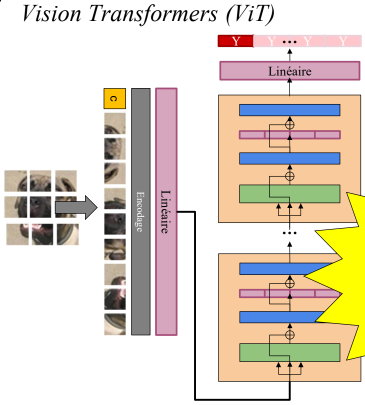


- L'image est séparée en patch
- Chaque patch est linéarisée
- Un token spécial représentant la classe est ajouté
- Un encodage de position est ajouté aux tokens
- L... rchitecture est ... *s all*

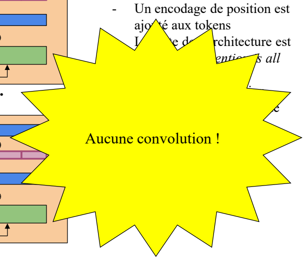


Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

276

## *Vision Transformers (ViT)*

| | Ours-JFT (ViT-H/14) | Ours-JFT (ViT-L/16) | Ours-I21k (ViT-L/16) | BiT-L (ResNet152x4) | Noisy Student (EfficientNet-L2) |
|---|---|---|---|---|---|
| ImageNet | **88.55** ± 0.04 | 87.76 ± 0.03 | 85.30 ± 0.02 | 87.54 ± 0.02 | 88.4/88.5* |
| ImageNet ReaL | **90.72** ± 0.05 | 90.54 ± 0.03 | 88.62 ± 0.05 | 90.54 | 90.55 |
| CIFAR-10 | **99.50** ± 0.06 | 99.42 ± 0.03 | 99.15 ± 0.03 | 99.37 ± 0.06 | – |
| CIFAR-100 | **94.55** ± 0.04 | 93.90 ± 0.05 | 93.25 ± 0.05 | 93.51 ± 0.08 | – |
| Oxford-IIIT Pets | **97.56** ± 0.03 | 97.32 ± 0.11 | 94.67 ± 0.15 | 96.62 ± 0.23 | – |
| Oxford Flowers-102 | 99.68 ± 0.02 | **99.74** ± 0.00 | 99.61 ± 0.02 | 99.63 ± 0.03 | – |
| VTAB (19 tasks) | **77.63** ± 0.23 | 76.28 ± 0.46 | 72.72 ± 0.21 | 76.29 ± 1.70 | – |
| TPUv3-core-days | 2.5k | 0.68k | 0.23k | 9.9k | 12.3k |

Table 2: Comparison with state of the art on popular image classification benchmarks. We report mean and standard deviation of the accuracies, averaged over three fine-tuning runs. Vision Transformer models pre-trained on the JFT-300M dataset outperform ResNet-based baselines on all datasets, while taking substantially less computational resources to pre-train. ViT pre-trained on the smaller public ImageNet-21k dataset performs well too. *Slightly improved 88.5% result reported in Touvron et al. (2020).

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.

277

## *Vision Transformers (ViT)*

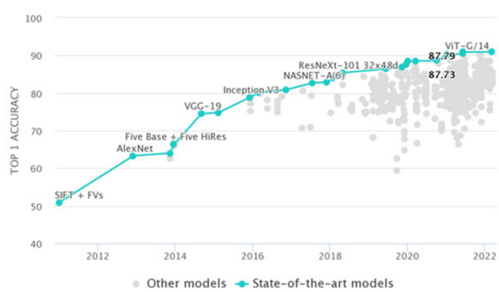


Les *vision transformers* dominent la classification depuis leur arrivée

https://paperswithcode.com/sota/image-classification-on-imagenet

278

## *Vision Transformers (ViT)*

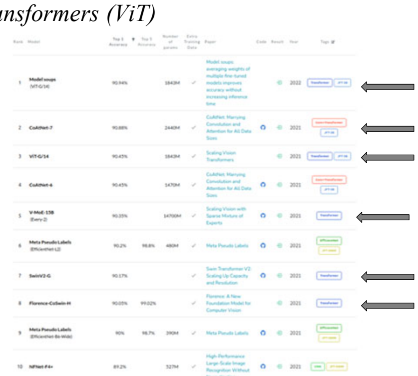

Les *vision transformers* dominent la classification depuis leur arrivée

https://paperswithcode.com/sota/image-classification-on-imagenet

279

## Sommaire

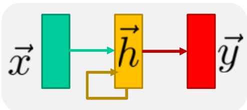


- Les réseaux récurrents peuvent traiter des séquences
- Ils ne requièrent que de légères modifications à des réseaux pleinement connectés
- Ils sont instables sur de longues séquences
- LSTM/GRU sont utilisés en pratique

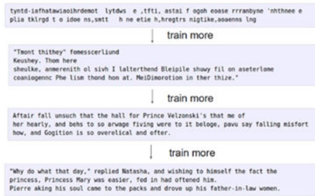


*Modélisation de langage*

280

## Sommaire

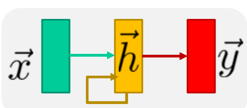


- Les réseaux récurrents peuvent traiter des séquences
- Ils ne requièrent que de légères modifications à des réseaux pleinement connectés
- Ils sont instables sur de longues séquences
- LSTM/GRU sont utilisés en pratique

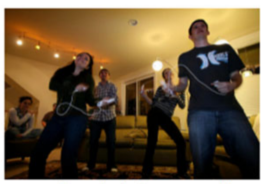

a group of people playing a game with nintendo wii controllers

*Description d'images*

281

## Sommaire

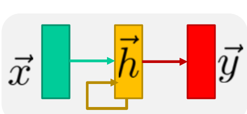


- Les réseaux récurrents peuvent traiter des séquences
- Ils ne requièrent que de légères modifications à des réseaux pleinement connectés
- Ils sont instables sur de longues séquences
- LSTM/GRU sont utilisés en pratique

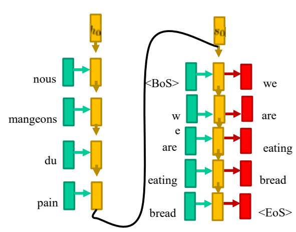


*Traduction*

282

## Sommaire

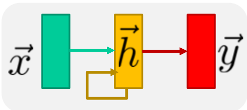

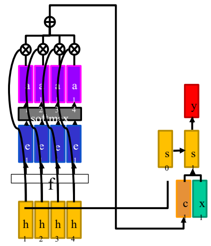

- Les réseaux récurrents peuvent traiter des séquences
- Ils ne requièrent que de légères modifications à des réseaux pleinement connectés
- Ils sont instables sur de longues séquences
- LSTM/GRU sont utilisés en pratique

- L'attention est un mécanisme très puissant permettant aux réseaux d'apprendre quelle partie des données utilisées pour faire une prédiction
- L'attention n'est pas limitée au texte, ou même aux séquences

283

## Sommaire

- Un *Transformer* sont un modèle puissant pour les tâches liées au *langage naturel et aux images*

- Les *transformers* n'utilisent *que* l'attention (pas un modèle récurrent)

- Les *transformers* sont demandant en ressources

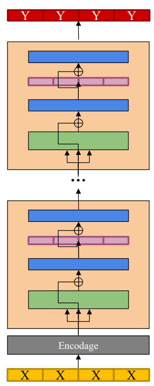


284