Réseaux de neurones

IFT 780

Modèles génératifs

Par

Pierre-Marc Jodoin

1

Jusqu'à présent : apprentissage supervisé

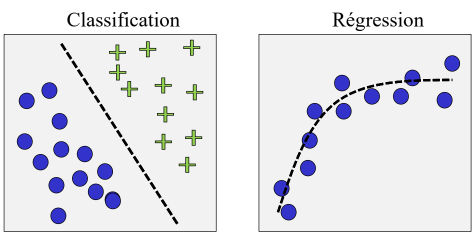

2

2

Inria person dataset

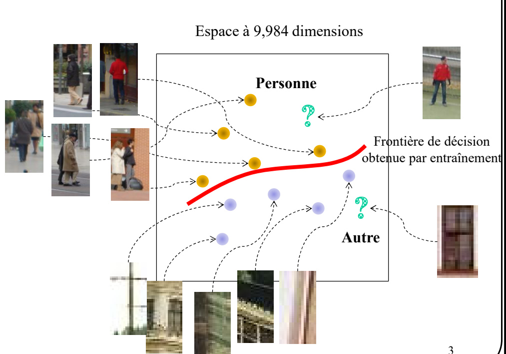

3

3

Apprentissage supervisé

Deux grandes familles d'applications

- **Classification :** la cible est un indice de classe $t \in \{1, \ldots, K\}$
  - Exemple : reconnaissance de caractères
    - ✓ $\vec{x}$: vecteur des intensités de tous les pixels de l'image
    - ✓ t : identité du caractère
- **Régression :** la cible est un nombre réel $t \in \mathbb{R}$
  - Exemple : prédiction de la valeur d'une action à la bourse
    - ✓ $\vec{x}$: vecteur contenant l'information sur l'activité économique de la journée
    - ✓ t : valeur d'une action à la bourse le lendemain

4

4

Apprentissage supervisé avec CNN

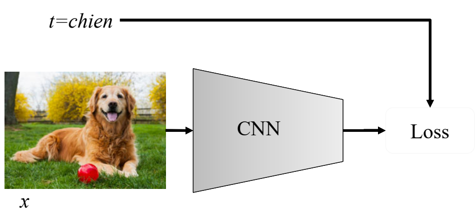

5

Supervisé vs non supervisé

Apprentissage supervisé : il y a une cible

$$D = \{(\vec{x}_1, t_1), (\vec{x}_2, t_2), \ldots, (\vec{x}_N, t_N)\}$$

Apprentissage non-supervisé : la cible n'est pas fournie

$$D = \{\vec{x}_1, \vec{x}_2, \ldots, \vec{x}_N\}$$

6

6

Apprentissage non supervisé

Comprendre la distribution sous-jacente de données **non-étiquettées**

Applications : clustering, visualization, comprehension, etc.

Exemple : visualization de la distribution des images MNIST

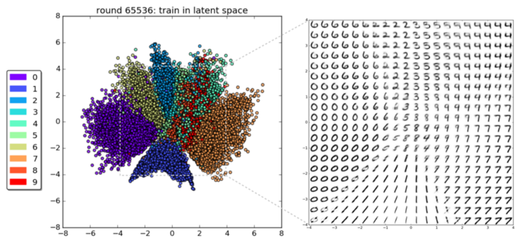

https://blog.fastforwardlabs.com/2016/08/12/introducing-variational-autoencoders-in-prose-and.html

7

7

Apprentissage non supervisé

Souvent, l'apprentissage non-supervisé inclut un (ou des) **variables latentes**.

Variable latente: variable aléatoire non observée mais sous-jacente à la distribution des données

Ex: clustering = retrouver la variable latente "cluster"

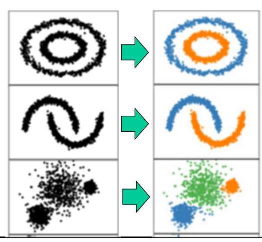

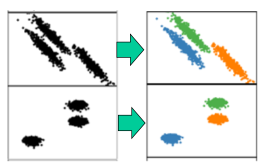

8

8

Pourquoi une variable latente?

Plus facile de représenter $p(\vec{x}, y), p(\vec{x} \mid y), p(y)$ que $p(\vec{x})$

Plus d'info au tableau.

9

L'apprentissage non-supervisé par
réseaux de neurones
s'appuie sur
2 propriétés

10

Propriété 1

Les réseaux de neurones sont d'excellentes machines pour projeter des données brutes vers un **espace dimensionnel plus faible** dont les propriétés dépendent de la *loss* (ici **espace linéaire car la sortie du réseau est un classifieur linéaire**).

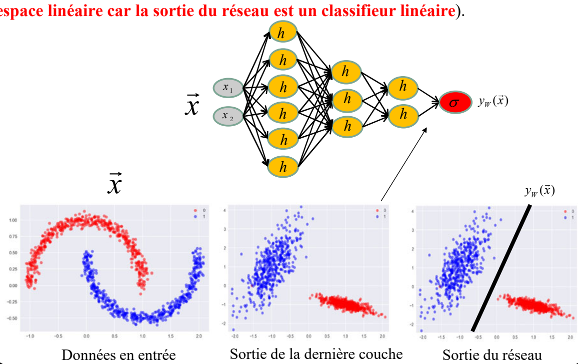

11

Propriété 2

Les réseaux de neurones sont d'excellentes machines pour estimer des **probabilités conditionnelles.**

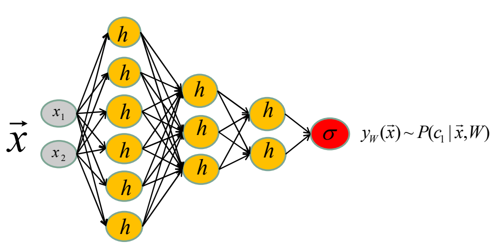

12

Propriété 2

Les réseaux de neurones sont d'excellentes machines pour estimer des **probabilités conditionnelles.**

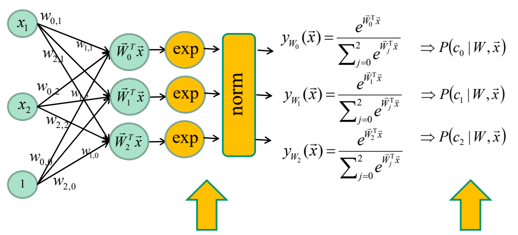

13

$$\vec{x} = \begin{bmatrix} -15 \\ 22 \\ -44 \\ 56 \end{bmatrix}, t = 2$$

Rappel

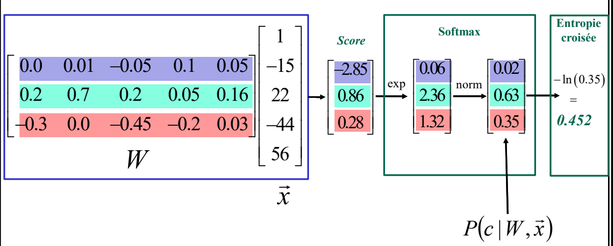

14

Comment utiliser un réseau de neurones pour apprendre la **configuration sous-jacente** de données non étiquetées?

15

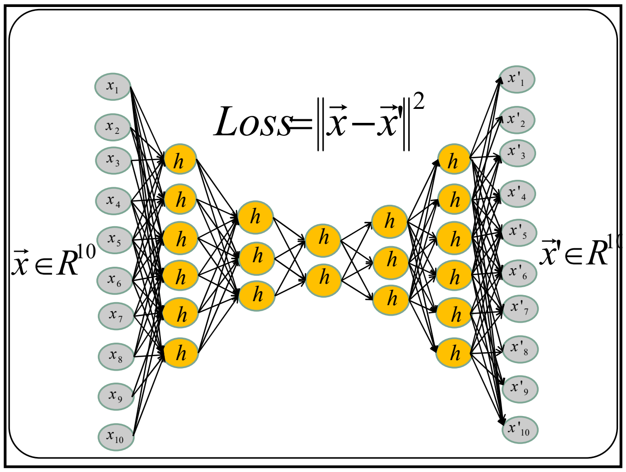

$Loss = \|\vec{x} - \vec{x}'\|^2$
$\vec{x} \in R^{10}$
$\vec{x}' \in R^{1}$

16

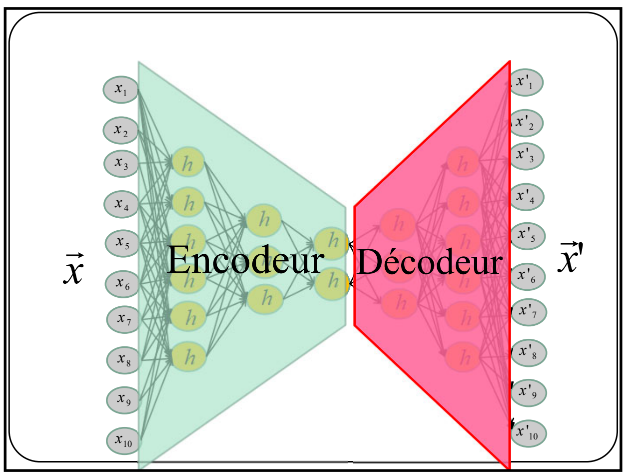

$\vec{x}$
Encodeur
Décodeur
$\vec{x}'$

17

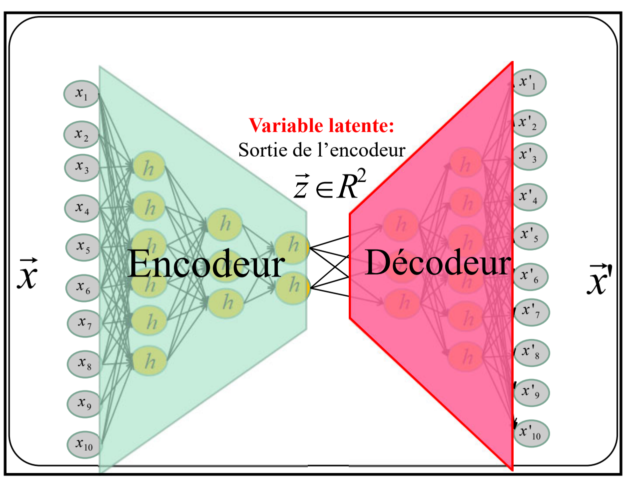

Variable latente:
Sortie de l'encodeur
$\vec{z} \in R^2$
$\vec{x}$
Encodeur
Décodeur
$\vec{x}'$

18

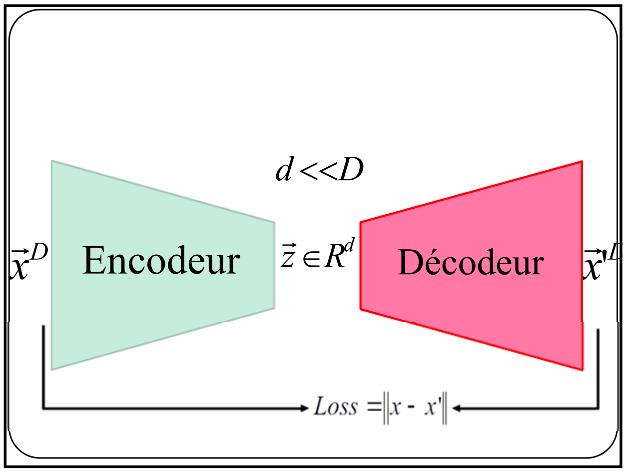

$d << D$
$\vec{x}^D$
Encodeur
$\vec{z} \in R^d$
Décodeur
$\vec{x}'^D$
$Loss = \|x - x'\|$

19

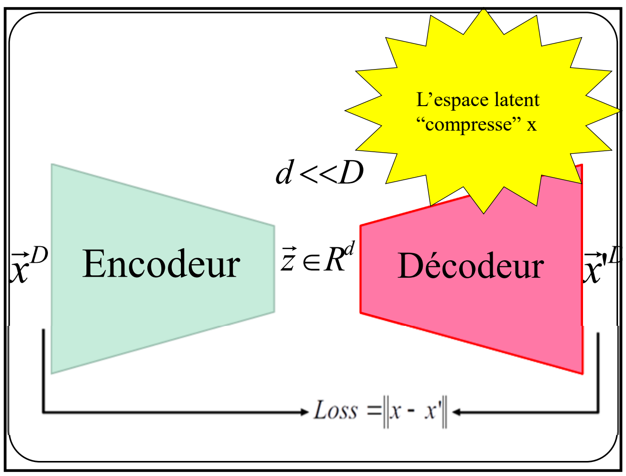

L'espace latent
"compresse" x
$d << D$
$\vec{x}^D$
Encodeur
$\vec{z} \in R^d$
Décodeur
$\vec{x}'^D$
$Loss = \|x - x'\|$

20

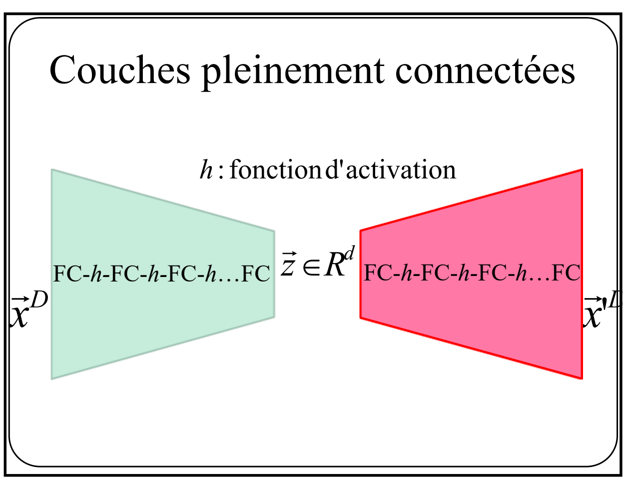

Couches pleinement connectées
h : fonction d'activation
$\vec{x}^D$
FC-h-FC-h-FC-h…FC
$\vec{z} \in R^d$
FC-h-FC-h-FC-h…FC
$\vec{x}'^D$

21

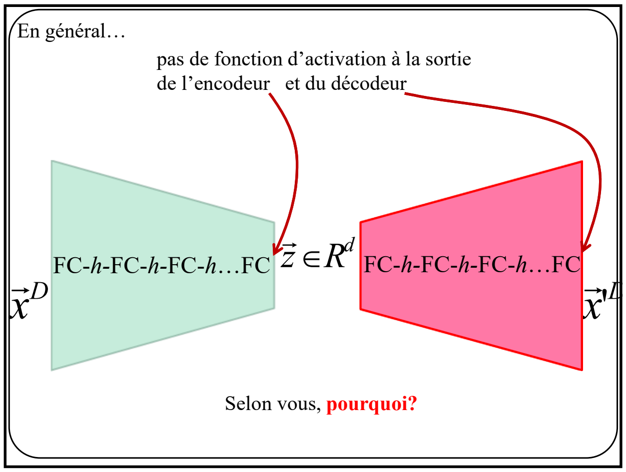
En général…
pas de fonction d'activation à la sortie
de l'encodeur et du décodeur
FC-*h*-FC-*h*-FC-*h*…FC
$\vec{z} \in R^d$
FC-*h*-FC-*h*-FC-*h*…FC
$\vec{x}^D$
$\vec{x}'^D$
Selon vous, **pourquoi?**

22

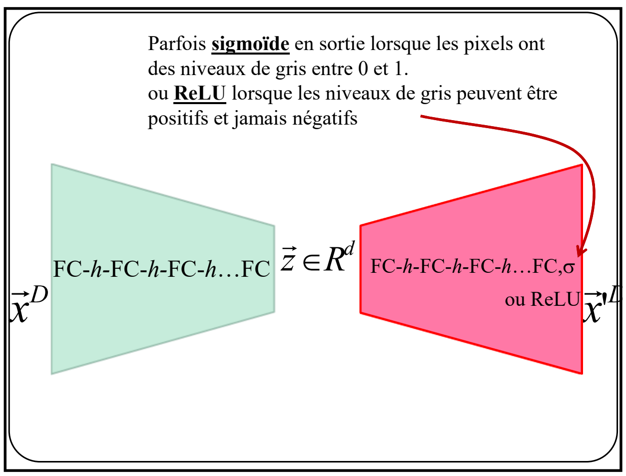
Parfois **sigmoïde** en sortie lorsque les pixels ont
des niveaux de gris entre 0 et 1.
ou **ReLU** lorsque les niveaux de gris peuvent être
positifs et jamais négatifs
FC-*h*-FC-*h*-FC-*h*…FC
$\vec{z} \in R^d$
FC-*h*-FC-*h*-FC-*h*…FC,σ
ou ReLU
$\vec{x}^D$
$\vec{x}'^D$

23

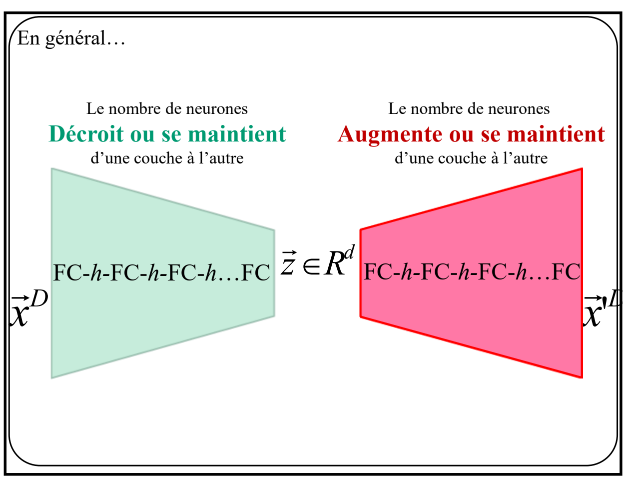
En général…
Le nombre de neurones
Décroit ou se maintient
d'une couche à l'autre
Le nombre de neurones
Augmente ou se maintient
d'une couche à l'autre
FC-*h*-FC-*h*-FC-*h*…FC
$\vec{z} \in R^d$
FC-*h*-FC-*h*-FC-*h*…FC
$\vec{x}^D$
$\vec{x}'^D$

24

En général…

Très souvent…
La structure de l’encodeur est le dual de celle du décodeur

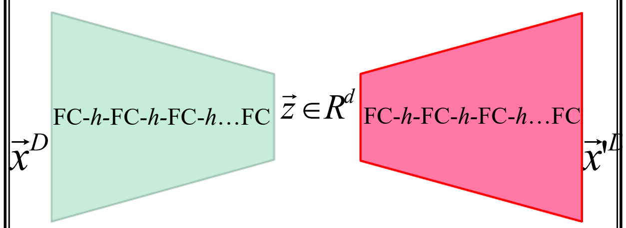

25

Autoencodeur jouet de MNIST

```
class autoencoder(nn.Module):
    def __init__(self):
        super(autoencoder, self).__init__()
        self.encoder = nn.Sequential(
            nn.Linear(28 * 28, 128), nn.ReLU(True),
            nn.Linear(128, 64), nn.ReLU(True),
            nn.Linear(64, 12), nn.ReLU(True),
            nn.Linear(12, 2))
        self.decoder = nn.Sequential(
            nn.Linear(2, 12), nn.ReLU(True),
            nn.Linear(12, 64), nn.ReLU(True),
            nn.Linear(64, 128), nn.ReLU(True),
            nn.Linear(128, 28 * 28))

    def forward(self, x):
        z = self.encoder(x)
        x_prime = self.decoder(z)
        return x_prime
```

Espace latent 2D

26

Autoencodeur jouet de MNIST

```
class autoencoder(nn.Module):
    def __init__(self):
        super(autoencoder, self).__init__()
        self.encoder = nn.Sequential(
            nn.Linear(28 * 28, 128), nn.ReLU(True),
            nn.Linear(128, 64), nn.ReLU(True),
            nn.Linear(64, 12), nn.ReLU(True),
            nn.Linear(12, 2))
        self.decoder = nn.Sequential(
            nn.Linear(2, 12), nn.ReLU(True),
            nn.Linear(12, 64), nn.ReLU(True),
            nn.Linear(64, 128), nn.ReLU(True),
            nn.Linear(128, 28 * 28))

    def forward(self, x):
        z = self.encoder(x)
        x_prime = self.decoder(z)
        return x_prime
```

symétrie

27

Visualisation de l’espace latent pour 1000 images MNIST
chaque image correspond à 1 point 2D

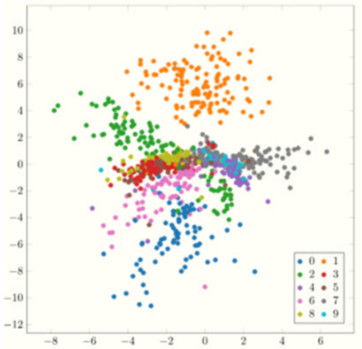

https://gertjanvandenburg.com/blog/autoencoder/

28

Générer des images avec le décodeur.

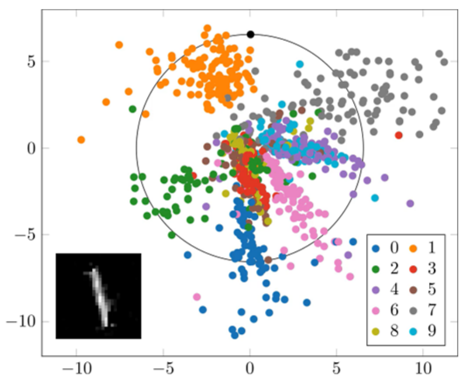

https://gertjanvandenburg.com/blog/autoencoder/

29

Couches convolutives

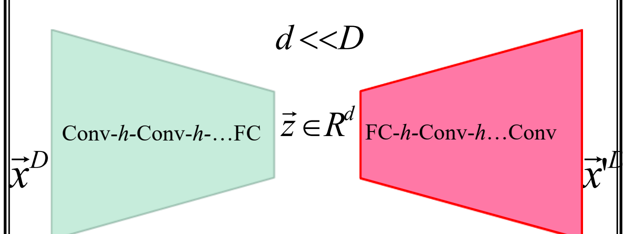

30

Autoencodeur pleinement convolutif

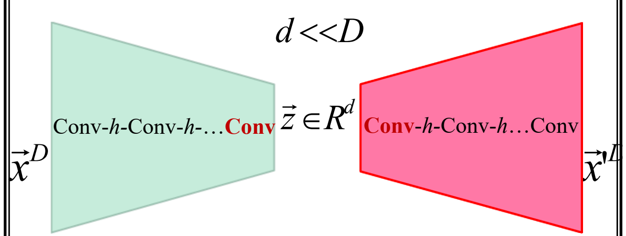

31

Autoencodeur de base

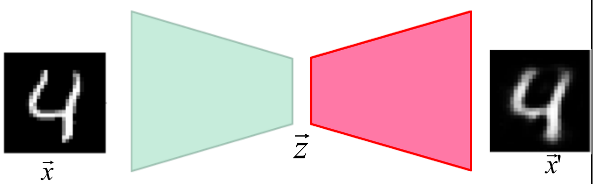

32

Autoencodeur pour débruitage

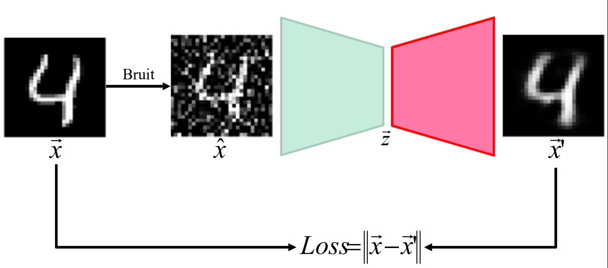

33

Une fois entraîné…

Signal bruité en entrée

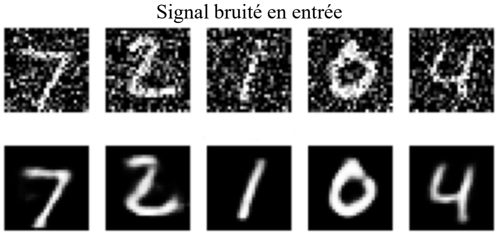

Signal reconstruit et débruité

34

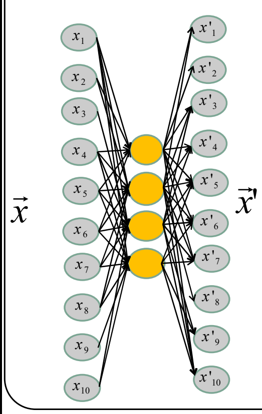

Autoencodeur à **une couche** et **sans fonction d'activation**

35

$W_1 \in R^{4\times 10}$

$W_2 \in R^{10\times 4}$

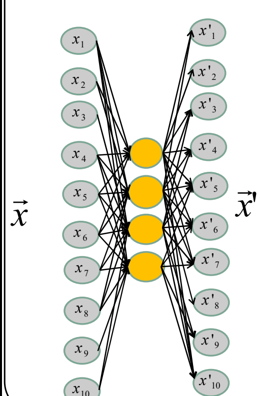

$$\vec{z} = W_1\vec{x}$$

$$\vec{x}' = W_2\vec{z}$$

36

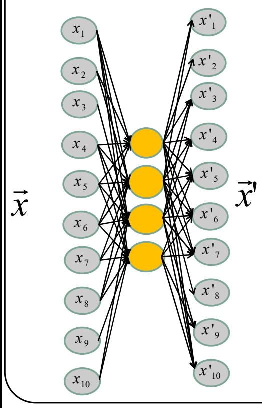

$$\left.\begin{array}{l}\vec{z} = W_1\vec{x} \\ \vec{x}' = W_2\vec{z}\end{array}\right\} \vec{x}' = W_2W_1\vec{x}$$

37

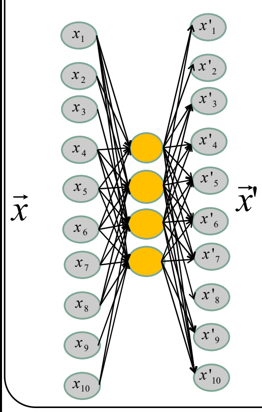

$$Loss = \left\|\vec{x} - W_2W_1\vec{x}\right\|^2$$

38

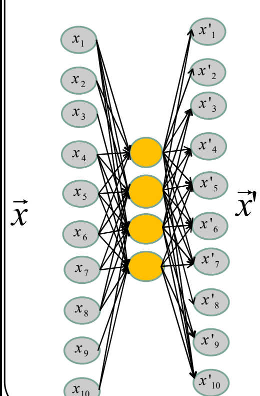

On peut démontrer que la solution est

$$W_1 = \left(W_2^T W_2\right)^{-1} W_2^T$$

39

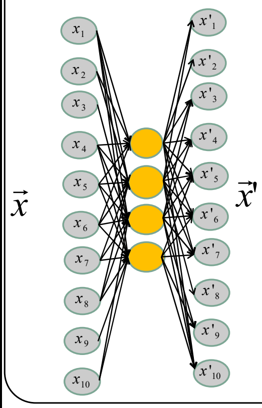

On peut démontrer que la solution est

$$W_1$$

Matrice constituée des principaux
vecteurs propres
de la matrice de
variance-covariance.
des données

40

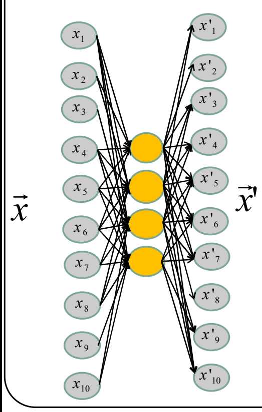

DONC

Autoencodeur linéaire

=

Analyse en composante principale (ACP)

E. Plaut, **From Principal Subspaces to Principal Components with Linear Autoencoders,** arXiv:1804.10253v3, 2018

41

En général, l'espace latent possède entre 16 et 128 dimensions.
Ça peut être parfois plus, parfois moins.

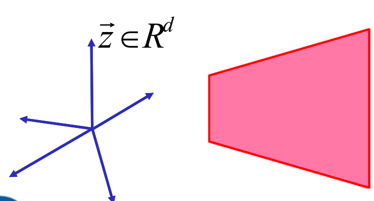

Comment, dans cet espace infini, trouver un point $\vec{z}$ qui donnera une image valable un fois décodée?

42

Avec de la chance, on peut sélectionner un point au hasard et reproduire une « bonne » image (ici une image « MNIST »)

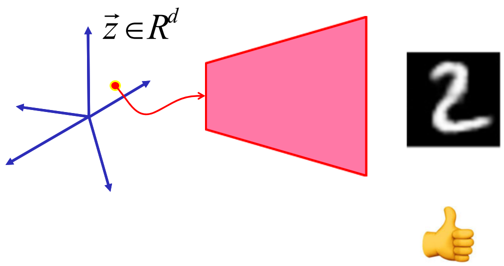

43

Malheureusement, la vaste majorité du temps, on reproduira du bruit

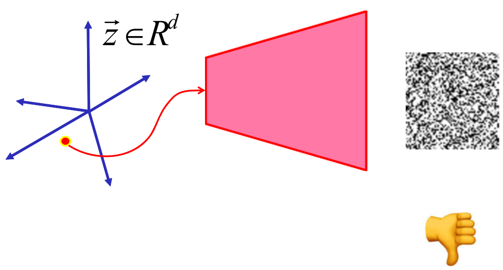

44

Au lieu d'apprendre à **reproduire un signal d'entrée**…

Apprendre à reproduire une **distribution** $p(\vec{z})$ **connue** de sorte qu'un **point échantillonné et décodé** de cette distribution correspond à un signal reconstruit valable

45

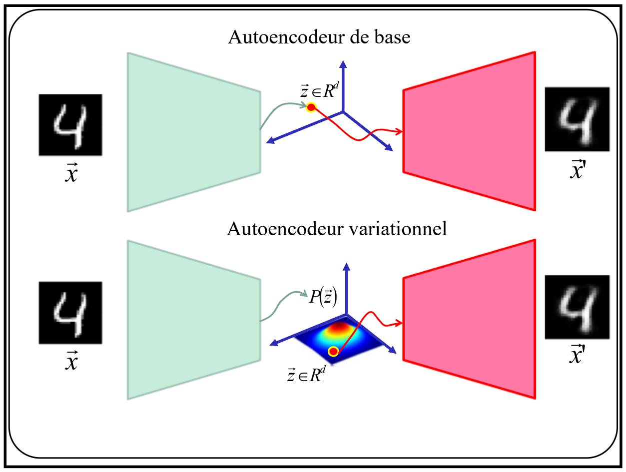
Autoencodeur de base
$\vec{z} \in R^d$
$\vec{x}$
$\vec{x}'$
Autoencodeur variationnel
$P(\vec{z})$
$\vec{z} \in R^d$
$\vec{x}$
$\vec{x}'$

46

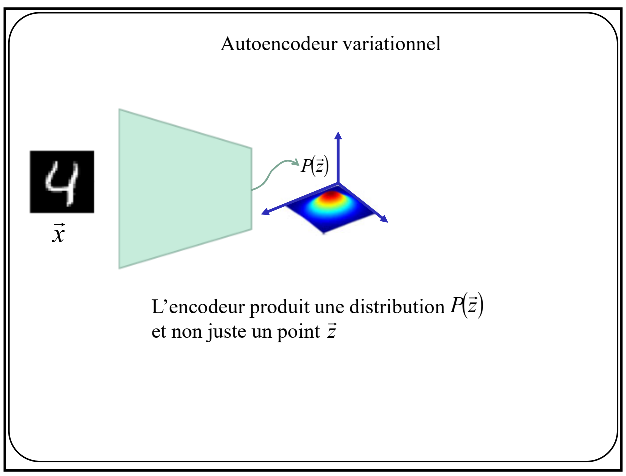
Autoencodeur variationnel
$P(\vec{z})$
$\vec{x}$
L'encodeur produit une distribution $P(\vec{z})$
et non juste un point $\vec{z}$

47

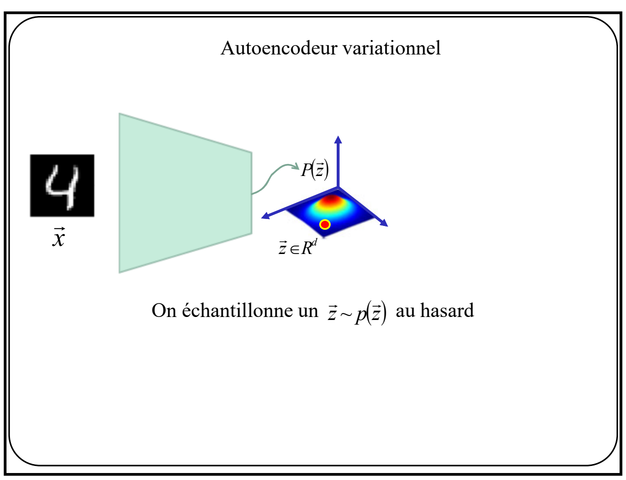
Autoencodeur variationnel
$P(\vec{z})$
$\vec{z} \in R^d$
$\vec{x}$
On échantillonne un $\vec{z} \sim p(\vec{z})$ au hasard

48

Autoencodeur variationnel

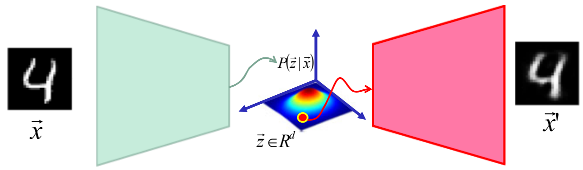

On reconstruit $\vec{x}'$

Autoencodeur variationnel

Remarque 1

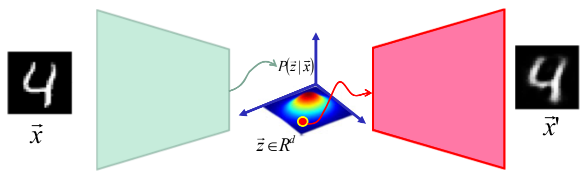

Puisque la distribution de $\vec{z}$ dépend de $\vec{x}$
on dira que la distribution apprise est

$$P(\vec{z}\,|\,\vec{x})$$

Autoencodeur variationnel

Remarque 2

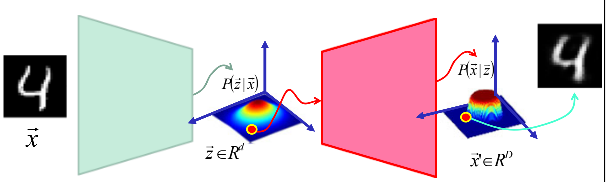

Le **décodeur** peut également produire une distribution de probabilités

$$P(\vec{x}\,|\,\vec{z})$$

et $\vec{x}'$ est un point échantillonné au hasard de $P(\vec{x}\,|\,\vec{z})$

Autoencodeur variationnel

Remarque 3

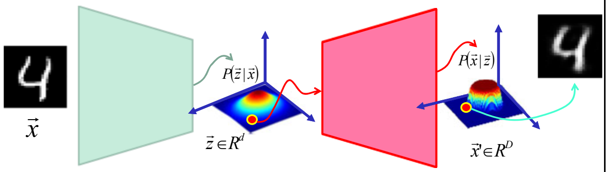

La distribution $P(\vec{z}|\vec{x})$ peut être très complexe et difficile à échantillonner, on va donc l'approximer par une distribution plus simple… une **gaussienne**

$$Q(\vec{z}|\vec{x}) \approx P(\vec{z}|\vec{x})$$

52

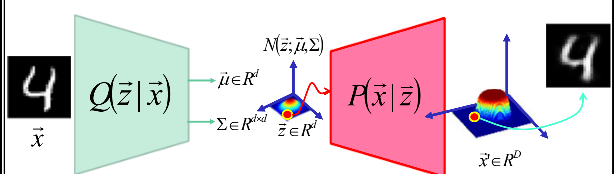

$$Q(\vec{z} \mid \vec{x}) \sim \text{Gaussienne}$$

53

Autoencodeur variationnel

Remarque 4

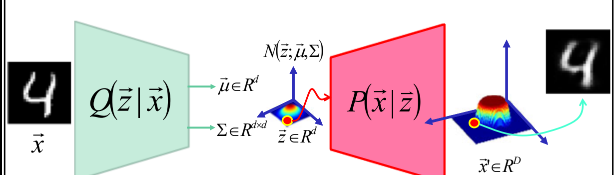

Pour simplifier les calculs, on va supposer que Σ est diagonale

$$\Sigma = \begin{pmatrix} \sigma_1^2 & 0 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 & 0 \\ 0 & 0 & \sigma_3^2 & 0 & 0 \\ 0 & 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & 0 & \sigma_d^2 \end{pmatrix}$$

On va donc **prédire un vecteur de variances et non une matrice**

54

Autoencodeur variationnel

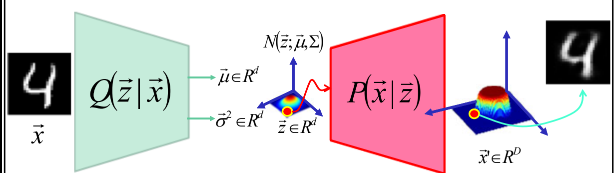

55

Autoencodeur variationnel

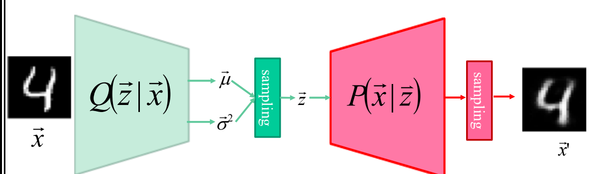

56

Autre façon de voir les choses…

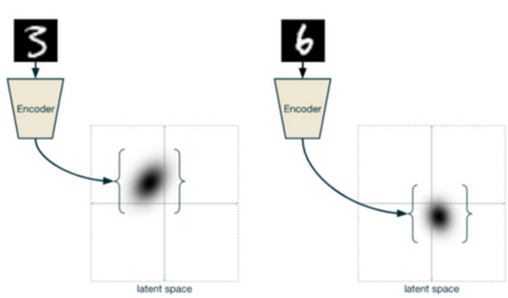

https://ijdykeman.github.io/ml/2016/12/21/cvae.html

57

Autre façon de voir les choses…

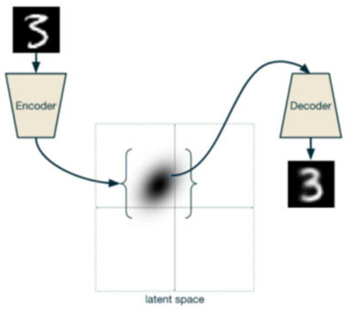

https://ijdykeman.github.io/ml/2016/12/21/cvae.html

58

Autoencodeur variationnel

Remarque 5

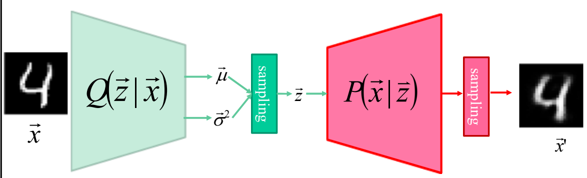

Distribution *a priori* de $\vec{z}$: gaussienne centrée à 0 et de variance 1

$$P(\vec{z}) = N(\vec{z};0,1)$$

59

Autre façon de voir les choses…

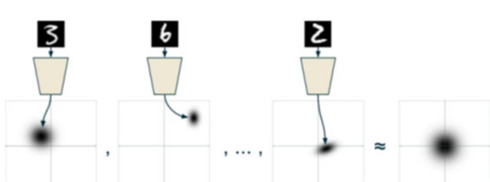

$N(\vec{z};0,1)$

https://ijdykeman.github.io/ml/2016/12/21/cvae.html

60

Autoencodeur variationnel

Preuve au tableau
(si le temps le permet)

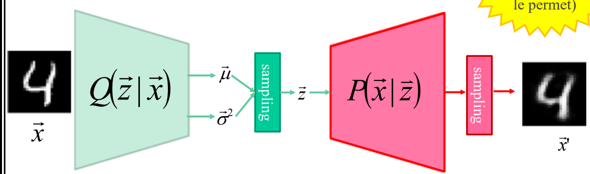

ELBO loss : Evidence Lower Bound

$$Loss = \underbrace{KL\left(N(\vec z;0,1), N(\vec z;\vec\mu,\Sigma)\right)}_{\text{Perte encodeur}} - \underbrace{\log\left(P(\vec x\,|\,\vec z)\right)}_{\text{Perte décodeur}}$$

61

Autoencodeur variationnel

D.Kingma, M.Welling, **Auto-Encoding Variational Bayes,** arXiv:1312.6114v10 (*Annexe B*)

ELBO loss : Evidence Lower Bound

$$Loss = \underbrace{KL\left(N(z;0,1), N(z;\mu,\Sigma)\right)}_{\text{Perte encodeur}} - \underbrace{\log\left(P(x\,|\,z)\right)}_{\text{Perte décodeur}}$$

Si on suppose que P(x|z) est gaussien

$$Loss = \underbrace{\frac{1}{2}\sum_{i=1}^{d}\left(1+\log\left(\sigma_i^2\right)-\mu_i^2-\sigma_i^2\right)}_{\text{Perte encodeur}} \underbrace{-\lambda\left\|\vec x-\vec x'\right\|^2}_{\text{Perte décodeur}}$$

62

Autoencodeur variationnel

D.Kingma, M.Welling, **Auto-Encoding Variational Bayes,** arXiv:1312.6114v10 (*Annexe B*)

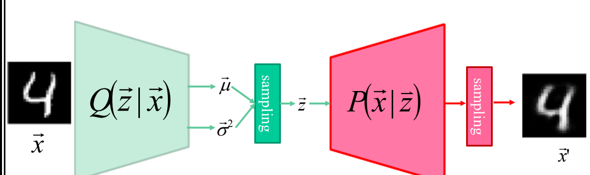

ELBO loss : Evidence Lower Bound

$$Loss = \frac{1}{2}\sum_{i=1}^{d}\underbrace{\left(1+\log\left(\sigma_i^2\right)-\mu_i^2-\sigma_i^2\right)}_{\text{Perte encodeur}} - \underbrace{\lambda\left\|\vec x-\vec x'\right\|^2}_{\text{Perte décodeur}}$$

63

Autoencodeur variationnel

D.Kingma, M.Welling, **Auto-Encoding Variational Bayes,** arXiv:1312.6114v10 (*Annexe B*)

Evidence Lower Bound

$$Loss = \underbrace{KL(N(z;0,1), N(z;\mu,\Sigma))}_{\text{Perte encodeur}} - \underbrace{\log(P(x \mid z))}_{\text{Perte décodeur}}$$

https://www.jeremyjordan.me/variational-autoencoders/

64

Autoencodeur variationnel

D.Kingma, M.Welling, **Auto-Encoding Variational Bayes,** arXiv:1312.6114v10 (*Annexe B*)

ELBO loss : Evidence Lower Bound

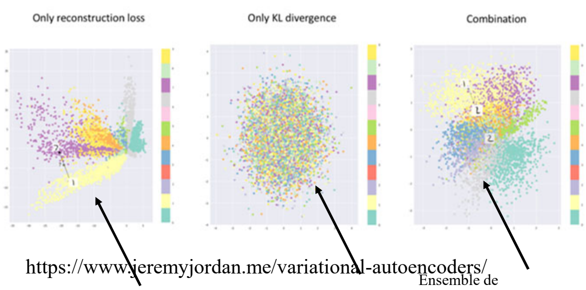

https://www.jeremyjordan.me/variational-autoencoders/

Pas gaussien, difficile à échantillonner

Trop gaussien, tout est indistinguable

Ensemble de distributions séparées qui forment une gaussienne

65

Autoencodeur variationnel

Remarque 6

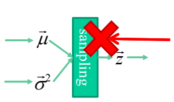

Pas de rétro-propagation à travers un processus d'échantionnage

$$\vec{z} \sim N(\vec{z}; \vec{\mu}, \Sigma)$$

66

Autoencodeur variationnel
Remarque 6

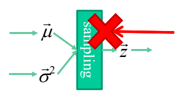

Pas de rétro-propagation à travers un processus d'échantionnage

$$\vec{z} \sim N(\vec{z}; \vec{\mu}, \Sigma)$$

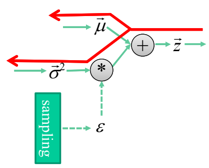

Reparameterization trick

$$\vec{z} = \vec{\mu} + \varepsilon\vec{\sigma}^2$$

67

Autoencodeur variationnel jouet MNIST : d=32 dim

```
class VAE(nn.Module):
    def __init__(self):
        super(VAE, self).__init__()

        self.encoder = nn.Sequential(
            nn.Linear(28 * 28, 128), nn.ReLU(True),
            nn.Linear(128, 64), nn.ReLU(True),
            nn.Linear(64, 32*2)
        self.decoder = nn.Sequential(
            nn.Linear(32, 64), nn.ReLU(True),
            nn.Linear(64, 128), nn.ReLU(True),
            nn.Linear(128, 28 * 28))

    def reparameterize(self, mu, logvar):
        std = torch.exp(0.5*logvar)
        eps = torch.randn_like(std)
        return mu + eps*std

    def forward(self, x):
        enc_x = self.encoder(x)
        mu = enc_x[:, :32]
        logvar = stats[:, 32:]
        z = self.reparameterize(mu, logvar)
        return self.decoder(z), mu, logvar
```

Reparameterization trick

68

Autoencodeur variationnel jouet MNIST : d=32 dim

```
def loss_function(recon_x, x, mu, logvar):
    L2 = nn.MSELoss()(recon_x, x)

    KLD = -0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())

    return KLD + self.lambda*L2
```

$$Loss = \overbrace{\frac{1}{2}\sum_{i=1}^{d}\left(1+\log\left(\sigma_i^2\right)-\mu_i^2-\sigma_i^2\right)}^{\texttt{KLD}} - \lambda\overbrace{\left\|\vec{x}-\vec{x}'\right\|^2}^{\texttt{L2}}$$

69

Ex.: base de données *CelebA*

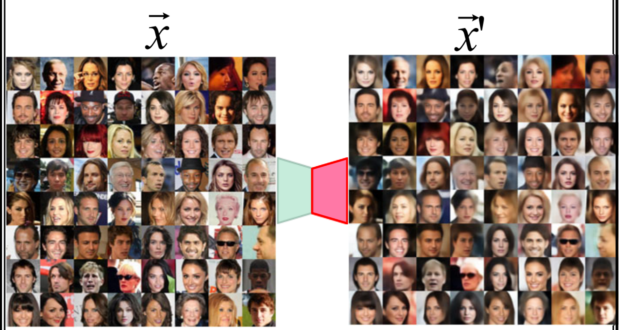

https://github.com/yzwxx/vae-celebA

70

Ex.: base de données *CelebA*

Décodage d'échantillons aléatoires $\vec{z}$

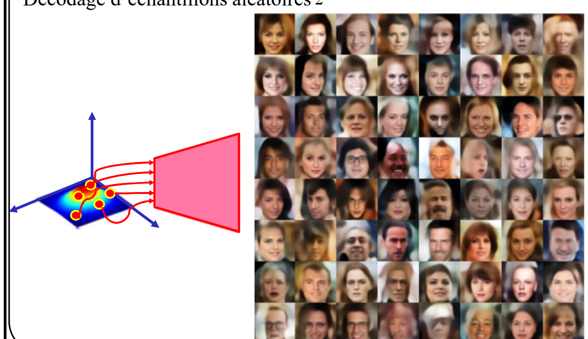

https://github.com/yzwxx/vae-celebA

71

données *CelebA*

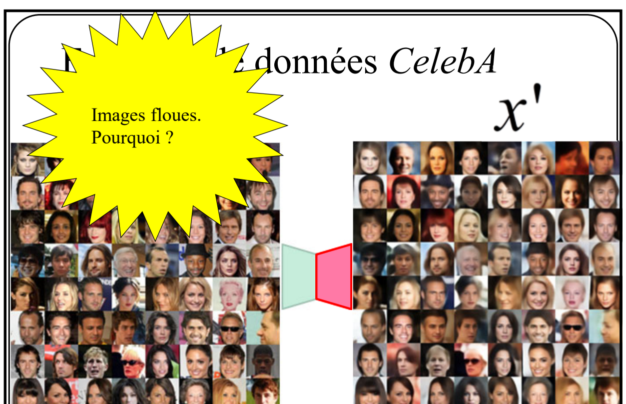

https://github.com/yzwxx/vae-celebA

72

Plusieurs tutoriels, VAE

- https://ijdykeman.github.io/ml/2016/12/21/cvae.html
- https://wiseodd.github.io/techblog/2016/12/10/variational-autoencoder/
- https://towardsdatascience.com/deep-latent-variable-models-unravel-hidden-structures-a5df0fd32ae2
- C. Doersch, **Tutorial on Variational Autoencoders,** arXiv:1606.05908

73

GAN

Generative Adversarial Nets

74

On voudrait générer des images $\vec{x}$ en échantillonnant $P(\vec{x})$

=> **TROP DIFFICILE** car $P(\vec{x})$ trop complexe

75

Comme précédemment, pour simplifier le problème, on pourrait introduire une variable latente $\vec{z}$ et ainsi modéliser

$$P(\vec{x},\vec{z}) = P(\vec{x} \mid \vec{z})P(\vec{z})$$

Modèle génératif

Distribution *a priori*

76

Comme pour les VAE, on utilisera une **distribution *a priori*** facile à échantillonner : une **gaussienne**!

$$P(\vec{z}) = N(\vec{z};0,1)$$

77

Comment estimer $P(\vec{x} \mid \vec{z})$?

À l'aide d'un réseau de neurones car ce sont **d'excellentes machines pour estimer des probabilités conditionnelles**

78

VAE

Dépendamment des performances du décodeur, les images générées **seront de qualité très variable.**

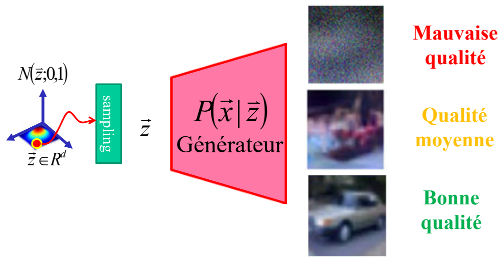

79

Pour entraîner un décodeur, il faut une **fonction de perte** (*loss*) qui **mesure la qualité (degré de réalisme) des images produites**

Pour un autoencodeur (variationnel ou non) c'est facile!
car on a un encodeur et une image de référence

$$Loss = \|\vec{x} - \vec{x}'\|^2$$

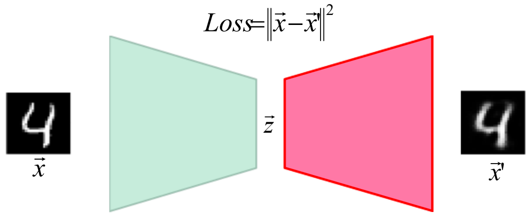

80

Pour entraîner un décodeur, il faut une **fonction de perte** (*loss*) qui **mesure la qualité (degré de réalisme) des images produites**

Comment faire pour un réseau **sans encodeur**?

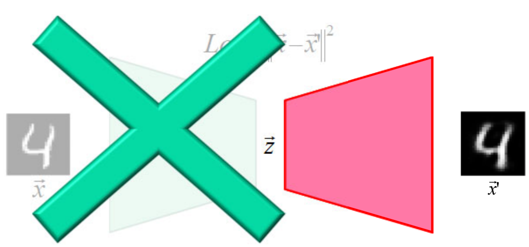

81

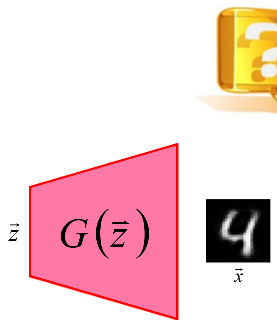

Loss sans cible de référence?

82

Approximer la perte à l'aide d'un

2e réseau de neurones

et d'une

Base de données de référence

$\vec{z}$ référence?

83

Pour entraîner un décodeur, il faut une **fonction de perte** (loss) qui **mesure la qualité des images produites**

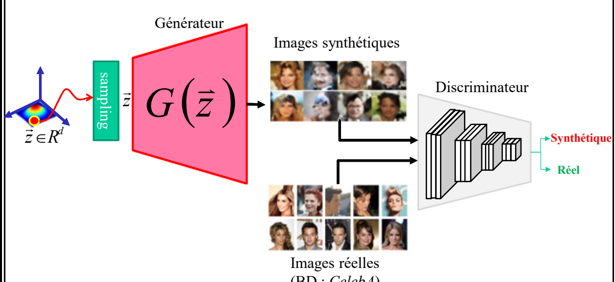

84

Pour entraîner un décodeur, il faut une **fonction de perte** (loss) qui **mesure la qualité des images produites**

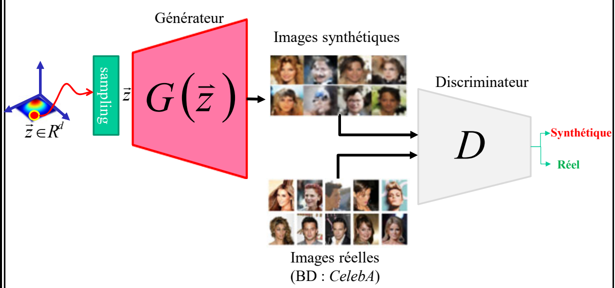

85

Données étiquetées

Produites par le générateur

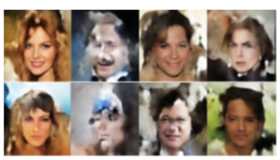

$t = 0 \quad ('synthétique')$

$t = 1 \quad ('réel')$

Issues d'une vraie BD

86

Deux réseaux aux **objectifs différents** :

Discriminateur : différentie les images synthétiques des images réelles

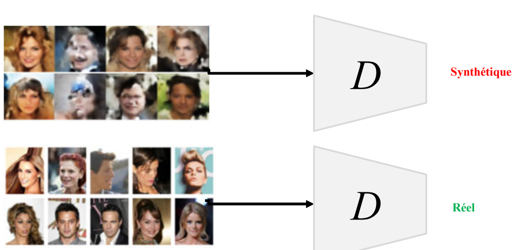

87

Discriminateur : classifieur binaire (régression logistique)

=> Perte **l'entropie croisée**

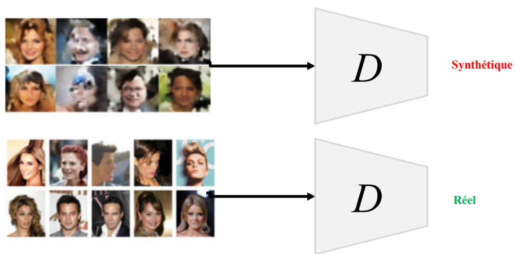

88

Rappel, entropie croisée pour une régression logistique binaire:

$$L_D = \frac{1}{N}\sum_i -t_i \ln\left(y\left(\vec{x}_i\right)\right) - \left(1-t_i\right)\ln\left(1-y\left(\vec{x}_i\right)\right)$$

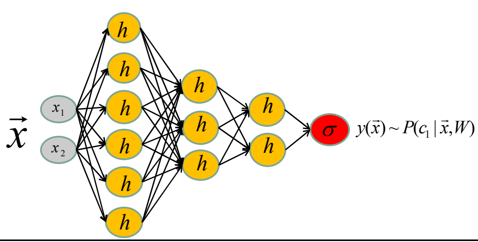

89

Le réseau discriminateur est représenté par la **lettre D**

$$L_D = \frac{1}{N}\sum_i -t_i \ln\left(D\left(\vec{x}_i\right)\right) - \left(1-t_i\right)\ln\left(1-D\left(\vec{x}_i\right)\right)$$

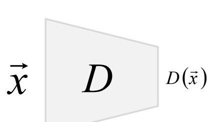

90

Puisque les images **synthétiques** ont été générées par le **générateur**

$$L_D = \frac{1}{N}\sum_i -t_i \ln\left(D(\vec{x}_i)\right) - (1-t_i)\ln\left(1 - D\left(G(\vec{z}_i)\right)\right)$$

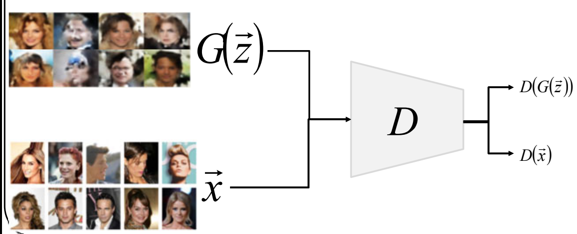

91

Sans perte de généralité, séparer la loss des images réelles et synthétiques

$$L_D = \underbrace{-\frac{1}{N_{reel}}\sum_i \ln\left(D(\vec{x}_i)\right)}_{\text{Perte images réelles}} \underbrace{-\frac{1}{N_{syn}}\sum_j \ln\left(1 - D\left(G(\vec{z}_j)\right)\right)}_{\text{Perte images synthétiques}}$$

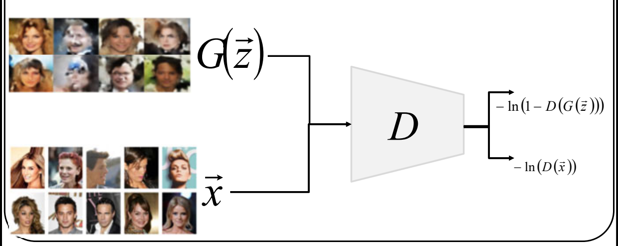

92

Rappel: Espérance mathématique et approximation Monte Carlo

$$IE[x] = \int x p(x) dx$$

$$IE[f(x)] = \int f(x) p(x) dx$$

93

Rappel: Espérance mathématique et approximation Monte Carlo

$$IE[x] = \int xp(x)dx$$
$$\approx \frac{1}{N}\sum_{i=1}^{N} x_i \qquad \text{où } x_i \sim p(x)$$

approximation Monte Carlo

$$IE[f(x)] = \int f(x)p(x)dx$$
$$\approx \frac{1}{N}\sum_{i=1}^{N} f(x_i) \qquad \text{où } x_i \sim p(x)$$

94

Rappel: Espérance mathématique et estimateur Monte Carlo

$$L_D = \underbrace{-\frac{1}{N_{reel}}\sum_i \ln(D(\vec{x}_i))}_{\text{Perte images réelles}} \underbrace{-\frac{1}{N_{syn}}\sum_j \ln(1 - D(G(\vec{z}_j)))}_{\text{Perte images synthétiques}}$$

$$L_D = -IE_{\vec{x}\sim P_{reel}}[\ln(D(\vec{x}))] - IE_{\vec{z}\sim P_z}[\ln(1 - D(G(\vec{z})))]$$

(Loss de GAN dans la littérature)

95

Objectif du discriminateur

Paramètres du discriminateur

$$W_D = \arg\min_{W_D} - IE_{\vec{x}\sim P_{reel}}[\ln(D(\vec{x}))] - IE_{\vec{z}\sim P_z}[\ln(1 - D(G(\vec{z})))]$$

Ou encore, de façon équivalente (mult par -1)

$$W_D = \arg\max_{W_D} IE_{\vec{x}\sim P_{reel}}[\ln(D(\vec{x}))] + IE_{\vec{z}\sim P_z}[\ln(1 - D(G(\vec{z})))]$$

96

Objectif du générateur

Produire des images aussi réalistes que celle de la BD de référence

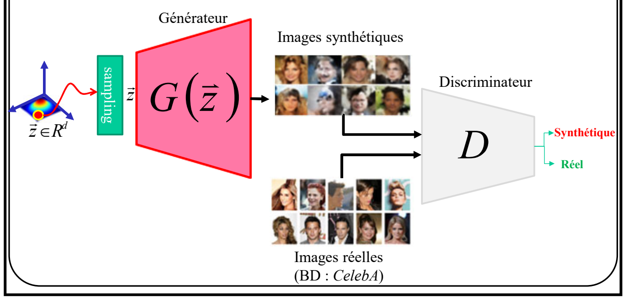

97

Objectif du générateur

S'il y parvient, le discriminateur ne pourra plus les distinguer des images réelles. La loss du discriminateur sera alors élevée.

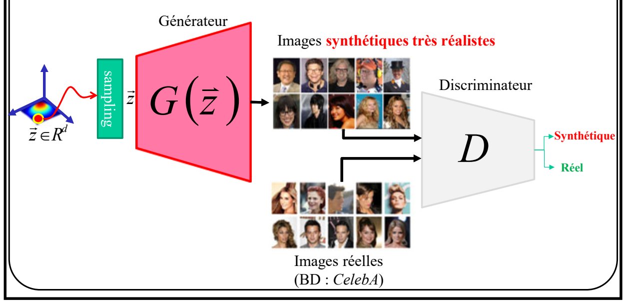

98

Objectif du discriminateur :

bien distinguer les images réelles des images synthétiques

$$W_D = \arg\max_{W_D} IE_{\vec{x}\sim P_{reel}}\left[\ln\left(D(\vec{x})\right)\right] + IE_{\vec{z}\sim P_z}\left[\ln\left(1 - D(G(\vec{z}))\right)\right]$$

Objectif du générateur :

produire des images synthétiques indistinguables des images réelles

$$W_G = \arg\min_{W_G} IE_{\vec{z}\sim P_z}\left[\ln\left(1 - D(G(\vec{z}))\right)\right]$$

99

« Two player » mini-max game

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))].$$

Ian Goodfellow et al., "Generative Adversarial Nets", NIPS 2014

100

« Two player » mini-max game

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}\overbrace{[\log D(\boldsymbol{x})]}^{\text{Discriminateur veux D(x) = 1 pour les vrais données}} + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - \underbrace{\overbrace{D(G(\boldsymbol{z}))}^{\text{Discriminateur veux D(G(x)) = 0 pour les données synthétiques}}}_{\text{Générateur veux D(G(x)) = 1 pour les données synthétiques}})].$$

Ian Goodfellow et al., "Generative Adversarial Nets", NIPS 2014

101

NOTE

dans les faits, on ne minimise pas cette loss

$$W_G = \arg \cancel{\min_{W_G} IE_{\vec{z}\sim P_z}} \left[\ln\left(1 - D\left(G\left(\vec{z}\right)\right)\right)\right]$$

on maximise plutôt celle-ci

$$W_G = \arg \max_{W_G} IE_{\vec{z}\sim P_z} \left[\ln\left(D\left(G\left(\vec{z}\right)\right)\right)\right]$$

102

Ian Goodfellow et al., "Generative Adversarial Nets", NIPS 2014

for number of training iterations **do**
  for k steps **do**
  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Sample minibatch of m examples $\{\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(m)}\}$ from data generating distribution $p_{\text{data}}(\boldsymbol{x})$.
  - Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} \left[\log D_{\theta_d}(x^{(i)}) + \log(1 - D_{\theta_d}(G_{\theta_g}(z^{(i)}))) \right]$$

  end for
  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Update the generator by ascending its stochastic gradient (improved objective):

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^{m} \log(D_{\theta_d}(G_{\theta_g}(z^{(i)})))$$

end for

103

Ian Goodfellow et al., "Generative Adversarial Nets", NIPS 2014

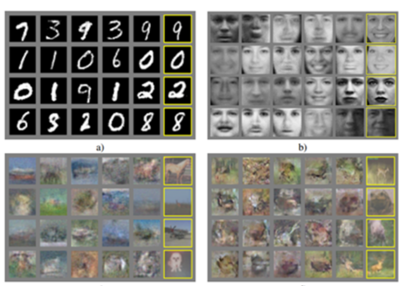

Figure 2: Visualization of samples from the model. Rightmost column shows the nearest training example of the neighboring sample, in order to demonstrate that the model has not memorized the training set. Samples are fair random draws, not cherry-picked. Unlike most other visualizations of deep generative models, these images show actual samples from the model distributions, not conditional means given samples of hidden units. Moreover, these samples are uncorrelated because the sampling process does not depend on Markov chain mixing. a) MNIST b) TFD c) CIFAR-10 (fully connected model) d) CIFAR-10 (convolutional discriminator and "deconvolutional" generator)

104

Deep Convolution Generative Adversarial Net (DCGAN)

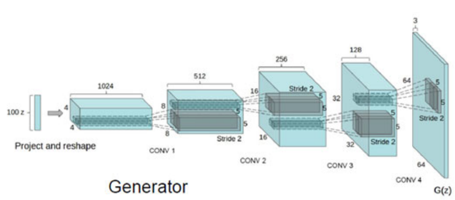

Radford et al, "Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks", ICLR 2016

105

Deep Convolution Generative Adversarial Net (DCGAN)

Recommandations discriminateur
- Conv stride>1 au lieu des couches de pooling
- ReLU partout sauf en sortie : tanh

Recommandations générateur
- Conv transpose au lieu de upsampling
- LeakyReLU partout

Autre recommandations
- BatchNorm partout
- Pas de FC, juste des conv

Radford et al, “Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks”, ICLR 2016

106

Deep Convolution Generative Adversarial Net (DCGAN)

Recommandations discriminateur
- C
- R

https://github.com/soumith/ganhacks

Rec
- C
- LeakyReLU partout

Autre recommandations
- BatchNorm partout
- Pas de FC, juste des conv

Radford et al, “Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks”, ICLR 2016

107

Deep Convolution Generative Adversarial Net (DCGAN)

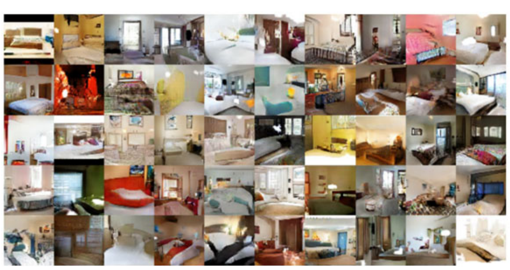

108

Interpolation entre 9 vecteurs latents aléatoires

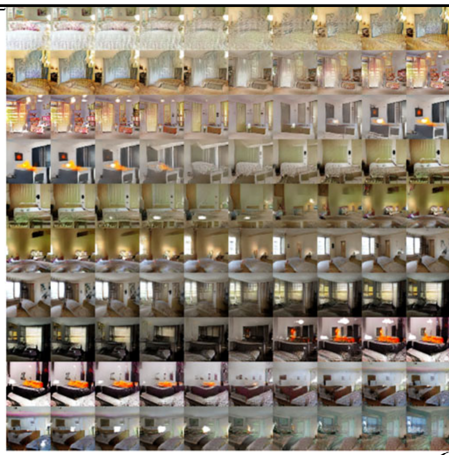

109

"Vector arithmetic for visual concepts"

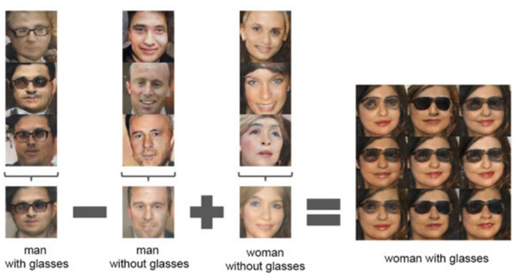

110

Problèmes d'instabilité

- Si discriminateur et générateur et n'apprennent pas ensemble:
  - disparition des gradients
  - effondrement des modes
  - on ne peut générer d'images à haute résolution
- Plusieurs solutions proposées:
  - *Wasserstein GAN (utilise "earth mover distance")*
  - *Least Squares GAN (utilise distance d'erreur quadratique)*
  - *Progressive GAN*
  - ….

111

111

Problèmes d’instabilité

- Si discriminateur et générateur et n'apprennent pas ensemble:
  - **disparition des gradients**
  - effondrement des modes
  - on ne peut générer d’images à haute résolution

Si le discriminateur apprend trop vite, le générateur sera systématiquement battu, et n’apprendra rien

112

112

Problèmes d’instabilité

- Si discriminateur et générateur et n'apprennent pas ensemble:
  - disparition des gradients
  - **effondrement des modes**
  - on ne peut générer d’images à haute résolution

Le générateur peut apprendre à toujours générer la même image et ainsi battre le discriminateur

113

113

Problèmes d’instabilité

- Si discriminateur et générateur et n'apprennent pas ensemble:

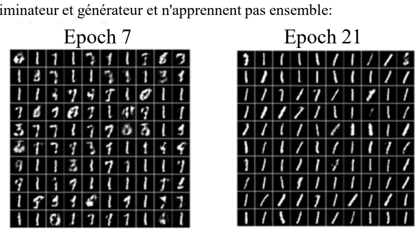

Le gén… bat
le disc…

https://datascience.stackexchange.com/questions/29485/gan-discriminator-converging-to-one-output

114

114

Problèmes d’instabilité

- Si discriminateur et générateur et n'apprennent pas ensemble:
  - disparition des gradients
  - effondrement des modes
  - **on ne peut générer d’images à haute résolution**

Solution: les progressive GANs

115

115

progressive GAN

On veut générer des images à **haute résolution**

On commence avec des images de **faible résolution : 4x4 pixels**

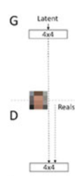

“Progessive GAN” Karras et al. ICLR’18

116

progressive GAN

Et progressivement, on augmente la résolution de l’image

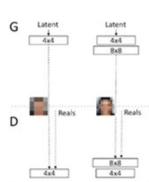

“Progessive GAN” Karras et al. ICLR’18

117

progressive GAN

Et progressivement, on augmente la résolution de l'image

"***Progressive Growing GAN requires that the capacity of both the generator and discriminator model be expanded by adding layers during the training process***"

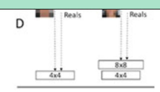

"Progessive GAN" Karras et al. ICLR'18

118

progressive GAN

Et progressivement, chaque couche qu'on ajoute vient bonifier la couche précédente : cela se fait à l'aide d'une **opération « résiduelle ».**

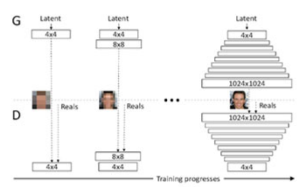

"Progessive GAN" Karras et al. ICLR'18

119

Ajout de couches

Lorsque **l'entraînement** d'une couche de résolution RxR (ici 16x16) est **terminé**…

"Progessive GAN" Karras et al. ICLR'18

120

Ajout de couches

… On **ajoute une nouvelle couche** de résolution 2Rx2D (ici 32x32) au générateur ET au discriminateur.

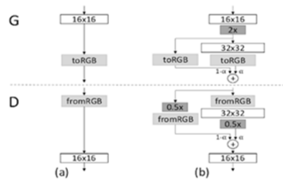

"Progessive GAN" Karras et al. ICLR'18

121

Ajout de couches

… mais pour éviter un choc, on ajoute une **composante résiduelle** comprenant un facteur α

Au début de l'entrainement, $\alpha=0$ et progressivemnt α augmente pour atteindre $\alpha=1$ à la fin

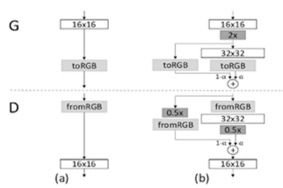

"Progessive GAN" Karras et al. ICLR'18

122

Ajout de couches

Lorsque l'entraînement est terminé, on enlève la composante résiduelle.

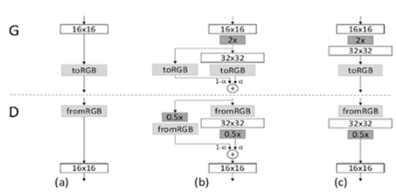

"Progessive GAN" Karras et al. ICLR'18

123

"Progessive GAN" Karras et al. ICLR'18

Generator	Act.	Output shape	Params
Latent vector	–	$512 \times 1 \times 1$	–
Conv 4×4	LReLU	$512 \times 4 \times 4$	4.2M
Conv 3×3	LReLU	$512 \times 4 \times 4$	2.4M
Upsample	–	$512 \times 8 \times 8$	–
Conv 3×3	LReLU	$512 \times 8 \times 8$	2.4M
Conv 3×3	LReLU	$512 \times 8 \times 8$	2.4M
Upsample	–	$512 \times 16 \times 16$	–
Conv 3×3	LReLU	$512 \times 16 \times 16$	2.4M
Conv 3×3	LReLU	$512 \times 16 \times 16$	2.4M
Upsample	–	$512 \times 32 \times 32$	–
Conv 3×3	LReLU	$512 \times 32 \times 32$	2.4M
Conv 3×3	LReLU	$512 \times 32 \times 32$	2.4M
Upsample	–	$512 \times 64 \times 64$	–
Conv 3×3	LReLU	$256 \times 64 \times 64$	1.2M
Conv 3×3	LReLU	$256 \times 64 \times 64$	590k
Upsample	–	$256 \times 128 \times 128$	–
Conv 3×3	LReLU	$128 \times 128 \times 128$	295k
Conv 3×3	LReLU	$128 \times 128 \times 128$	148k
Upsample	–	$128 \times 256 \times 256$	–
Conv 3×3	LReLU	$64 \times 256 \times 256$	74k
Conv 3×3	LReLU	$64 \times 256 \times 256$	37k
Upsample	–	$64 \times 512 \times 512$	–
Conv 3×3	LReLU	$32 \times 512 \times 512$	18k
Conv 3×3	LReLU	$32 \times 512 \times 512$	9.2k
Upsample	–	$32 \times 1024 \times 1024$	–
Conv 3×3	LReLU	$16 \times 1024 \times 1024$	4.6k
Conv 3×3	LReLU	$16 \times 1024 \times 1024$	2.3k
Conv 1×1	linear	$3 \times 1024 \times 1024$	51
Total trainable parameters			**23.1M**

Discriminator	Act.	Output shape	Params
Input image	–	$3 \times 1024 \times 1024$	–
Conv 1×1	LReLU	$16 \times 1024 \times 1024$	64
Conv 3×3	LReLU	$16 \times 1024 \times 1024$	2.3k
Conv 3×3	LReLU	$32 \times 1024 \times 1024$	4.6k
Downsample	–	$32 \times 512 \times 512$	–
Conv 3×3	LReLU	$32 \times 512 \times 512$	9.2k
Conv 3×3	LReLU	$64 \times 512 \times 512$	18k
Downsample	–	$64 \times 256 \times 256$	–
Conv 3×3	LReLU	$64 \times 256 \times 256$	37k
Conv 3×3	LReLU	$128 \times 256 \times 256$	74k
Downsample	–	$128 \times 128 \times 128$	–
Conv 3×3	LReLU	$128 \times 128 \times 128$	148k
Conv 3×3	LReLU	$256 \times 128 \times 128$	295k
Downsample	–	$256 \times 64 \times 64$	–
Conv 3×3	LReLU	$256 \times 64 \times 64$	590k
Conv 3×3	LReLU	$512 \times 64 \times 64$	1.2M
Downsample	–	$512 \times 32 \times 32$	–
Conv 3×3	LReLU	$512 \times 32 \times 32$	2.4M
Conv 3×3	LReLU	$512 \times 32 \times 32$	2.4M
Downsample	–	$512 \times 16 \times 16$	–
Conv 3×3	LReLU	$512 \times 16 \times 16$	2.4M
Conv 3×3	LReLU	$512 \times 16 \times 16$	2.4M
Downsample	–	$512 \times 8 \times 8$	–
Conv 3×3	LReLU	$512 \times 8 \times 8$	2.4M
Conv 3×3	LReLU	$512 \times 8 \times 8$	2.4M
Downsample	–	$512 \times 4 \times 4$	–
Minibatch stddev	–	$513 \times 4 \times 4$	–
Conv 3×3	LReLU	$512 \times 4 \times 4$	2.4M
Conv 4×4	LReLU	$512 \times 1 \times 1$	4.2M
Fully-connected	linear	$1 \times 1 \times 1$	513
Total trainable parameters			**23.1M**

Table 2: Generator and discriminator that we use with CELEBA-HQ to generate 1024×1024 images.

124

"Progessive GAN" Karras et al. ICLR'18

https://youtu.be/XOxxPcy5Gr4

125

125

Style GAN

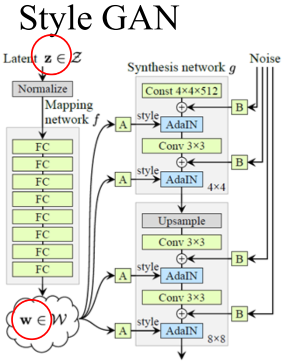

(b) Style-based generator

Le Générateur reçoit une version modifiée "w" par 8 couches FC du vecteur latent "z"

Karas et al. **A Style-Based Generator Architecture for Generative Adversarial Networks**, CVPR 2019

126

Style GAN

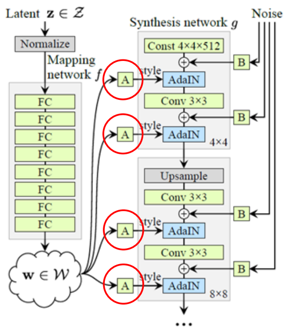

(b) Style-based generator

Le Générateur reçoit une version modifiée “w” par 8 couches FC du vecteur latent “z”

Et ce, à **chaque couche** du réseau

Karas et al. **A Style-Based Generator Architecture for Generative Adversarial Networks**, CVPR 2019

127

Style GAN

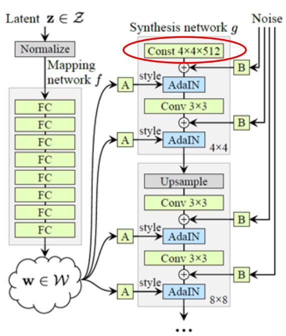

(b) Style-based generator

L’entrée du réseau est un **tenseur constant** appris par entraînement

Karas et al. **A Style-Based Generator Architecture for Generative Adversarial Networks**, CVPR 2019

128

Style GAN

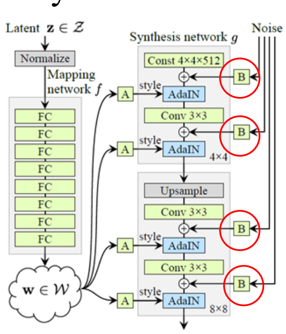

(b) Style-based generator

Du **bruit** est multiplié à chaque carte d’activation de **chaque couche** du réseau

129

129

Effet du bruit

(a) Generated image (b) Stochastic variation (c) Standard deviation

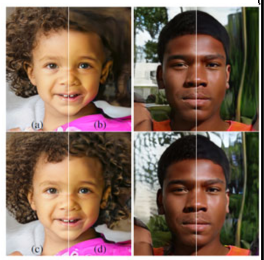

Figure 5. Effect of noise inputs at different layers of our generator. (a) Noise is applied to all layers. (b) No noise. (c) Noise in fine layers only ($64^2 - 1024^2$). (d) Noise in coarse layers only ($4^2 - 32^2$). We can see that the artificial omission of noise leads to featureless "painterly" look. Coarse noise causes large-scale curling of hair and appearance of larger background features, while the fine noise brings out the finer curls of hair, finer background detail, and skin pores.

Karas et al. **A Style-Based Generator Architecture for Generative Adversarial Networks**, CVPR 2019

130

Style GAN

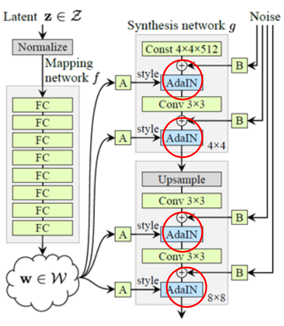

(b) Style-based generator

AdaIN: adaptive instance normalization

$$AdaIN\ (x, y) = \sigma(y)\frac{x - \mu(x)}{\sigma(x)} + \mu(y)$$

Comme du batchNorm, mais dont les 2 opérateurs sont fournis par **w**

131

131

Style GAN

AdaIN: adaptive instance normalisation

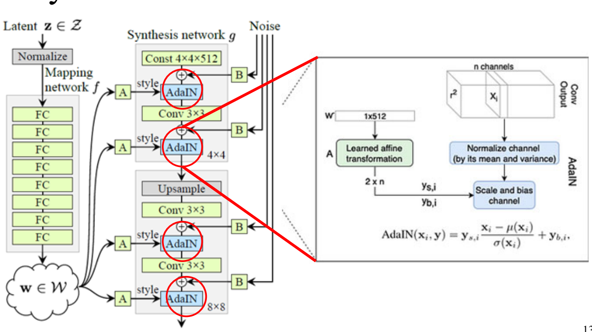

(b) Style-based generator

https://towardsdatascience.com/explained-a-style-based-generator-architecture-for-gans-generating-and-tuning-realistic-6cb2be0f431

132

132

Style GAN

Entraînement progressif comme pour **progressive GAN**

133

Style GAN

134

Défi avec les GAN

Soit un GAN entraîné sur MNIST, si je décode **10 vecteurs latents pris au hasard**, j'aurai les images de **10 caractères aléatoires**.

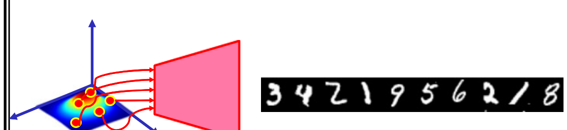

135

Défi avec les GAN

Question: comment générer des images de catégories prédéterminées? Ex. comment sélectionner 10 vecteurs latents qui produiront la séquence : 0,1,2,3,4,5,6,7,8,9?

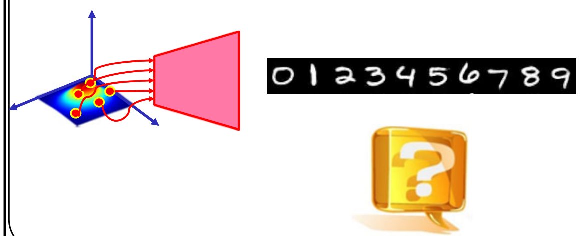

136

Gan conditionnel

L'idée est d'encoder un vecteur latent $\vec{z}$ ainsi qu'un **vecteur de classe** « one-hot » $\vec{y}$

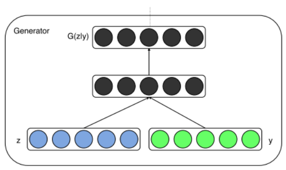

Mirza, Mehdi & Osindero, Simon. (2014). Conditional Generative Adversarial Nets. arXiv:1411.1784v1

137

Gan conditionnel

Et de discriminer une image $\vec{x}$

avec **le même « one-hot »** $\vec{y}$

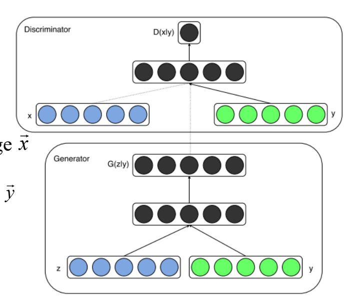

Mirza, Mehdi & Osindero, Simon. (2014). Conditional Generative Adversarial Nets. arXiv:1411.1784v1

138

Gan conditionnel

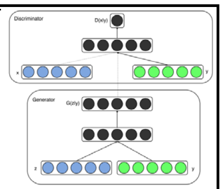

GAN de base

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{z}(\boldsymbol{z})}[\log(1-D(G(\boldsymbol{z})))].$$

GAN conditionnel

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x}|\boldsymbol{y})] + \mathbb{E}_{\boldsymbol{z}\sim p_{z}(\boldsymbol{z})}[\log(1-D(G(\boldsymbol{z}|\boldsymbol{y})))].$$

Mirza, Mehdi & Osindero, Simon. (2014). Conditional Generative Adversarial Nets. arXiv:1411.1784v1

139

Version convolutionnelle

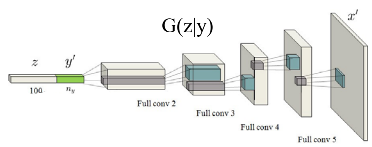

https://medium.com/@sam.maddrellmander/conditional-dcgan-in-tensorflow-336f8b03b7b6

140

Version convolutionnelle

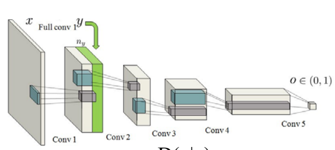

D(x|y)

https://medium.com/@sam.maddrellmander/conditional-dcgan-in-tensorflow-336f8b03b7b6

141

Version convolutionnelle

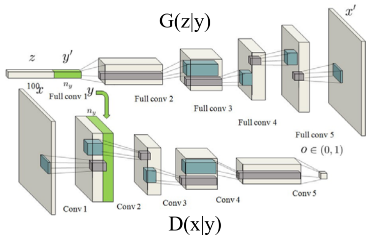

https://medium.com/@sam.maddrellmander/conditional-dcgan-in-tensorflow-336f8b03b7b6

142

"*t-shirt*", '*pants*', '*pullover*', '*dress*', '*coat*', '*sandal*', '*shirt*', '*sneaker*', '*bag*', '*ankle boot*'.

143

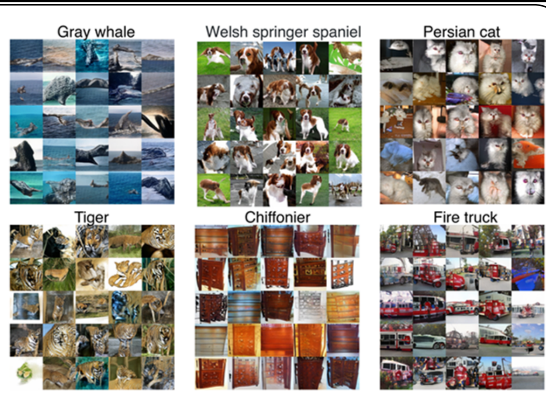

Miyato, T., Kataoka, T., Koyama, M., & Yoshida, Y. (2018). Spectral normalization for generative adversarial networks. *arXiv preprint arXiv:1802.05957*.

144

Code pytorch pour plus de 30 modèles de GANs

https://github.com/eriklindernoren/PyTorch-GAN

145

Belle vidéo sur les GANs montrant comment on peut manipuler l'espace latent et comment certains les utilise pour produire des « *deep fake* »

https://www.youtube.com/watch?v=dCKbRCUyop8

146