Réseaux de neurones

IFT 780

Réseaux à convolution avancés et architectures convolutives modernes

Par
Pierre-Marc Jodoin

1

Réseaux de neurones à convolution

Réseaux de neurones multicouches

Beaucoup de paramètres
Moins de neurones

CNN

- Paramètres partagés
- Connectivité locale

Moins de paramètres
Beaucoup de neurones
Architectures plus profondes

2

2

Réseaux de neurones à convolution

Convolution padding

Pas de *padding*
Stride = 1
Filtre 3x3

Carte d'activation plus petite
que le signal d'entrée

Zero padding
Stride = 1
Filtre 3x3

Carte d'activation de même taille
que le signal d'entrée

Images: http://deeplearning.net/software/theano/tutorial

3

3

Réseaux de neurones à convolution

Champ récepteur d'un neurone ("*receptive field*")

Région dans l'image d'entrée à l'intérieur de laquelle une variation pourrait avoir un effet sur la sortie d'un neurone.

Plus un neurone a un **champ récepteur large**, plus ce dernier encode du **contexe**.

4

4

Réseaux de neurones à convolution

Taille et convolution

- La **profondeur** du filter = le **nombre de canaux** en entrée (ici P)
- Le **nombre de cartes d'activation** = le **nombre de filtres** (ici K)
- Filtre convolutif 1D est un tenseur 2D (**F * P**)
- Filtre convolutif 2D est un tenseur 3D (**F1 * F2 * P**)
- K filtres convolutifs 2D est un tenseur 4D (**K * F1 * F2 * P**)

5

Réseaux de neurones à convolution

Taille et convolution

Taille du volume d'activation (2D) :

D1' = (D1-F1)/S+1

D2' = (D2-F2)/S+1

K = nb_filtres

6

Réseaux de neurones à convolution

Chaque couche convolutive contient une function d'activation

S'assure que tous les neurons sont activés

Sigmoid
$\sigma(x) = \frac{1}{1+e^{-x}}$

Leaky ReLU
$\max(0.1x, x)$

tanh
$\tanh(x)$

Maxout
$\max(w_1^T x + b_1, w_2^T x + b_2)$

ReLU
$\max(0, x)$

ELU
$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$

Réduit le problème de la disparition du gradient

Réseaux de neurones à convolution

Pooling

BUT

- Réduire la **résolution** des cartes d'activation
- Moins de **mémoire** et de **calculs**
- Augmente un peu la **robustess** à la rotation et au changement d'échelle

L' opération de *pooling* est généralement faite indépendamment sur chaque carte d'activation.

Images: https://pythonmachinelearning.pro/introduction-to-convolutional-neural-networks-for-vision-tasks/

Réseaux de neurones à convolution

CNN = suite d'opérations convolutives (et autres, *FC = fully connected*)

Image: http://cs231n.github.io

9

9

Autres types de couches convolutives

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

10

Convolution **séparée**

11

11

Convolution classique

Représentation classique d'une convolution 2D, ici un volume en entrée de taille **7x7xP convolué** par un **filtre 3x3xP** donne une **carte d'activation 5x5x1**

12

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

12

Convolution classique

Comme on le sait, une convolution « *valid* » avec **1 canal** en entrée et un filtre 2D s'opère ainsi:

Entrée Filtre 3x3 Carte d'activation

13

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

13

Convolution séparée

Les filtres 2D et 3D peuvent être **séparés** en filtres plus élémentaires

3 filtres 2D ayant **9 paramètres**

$$h=\begin{pmatrix}1 & 1 & 1\\ 1 & 1 & 1\\ 1 & 1 & 1\end{pmatrix}/9$$

$$h=\begin{pmatrix}1 & 2 & 1\\ 2 & 4 & 2\\ 1 & 2 & 1\end{pmatrix}/16$$

$$h=\begin{pmatrix}-1 & 0 & 1\\ -1 & 0 & 1\\ -1 & 0 & 1\end{pmatrix}/3$$

14

Convolution séparée

Les filtres 2D et 3D peuvent être **séparés** en filtres plus élémentaires

3 filtres 2D ayant **9 paramètres**

$$h=\begin{pmatrix}1&1&1\\1&1&1\\1&1&1\end{pmatrix}/9\rightarrow h_x=\begin{pmatrix}1&1&1\end{pmatrix}/3, h_y=\begin{pmatrix}1\\1\\1\end{pmatrix}/3$$

$$h=\begin{pmatrix}1&2&1\\2&4&2\\1&2&1\end{pmatrix}/16\rightarrow h_x=\begin{pmatrix}1&2&1\end{pmatrix}/4, h_y=\begin{pmatrix}1\\2\\1\end{pmatrix}/4$$

$$h=\begin{pmatrix}-1&0&1\\-1&0&1\\-1&0&1\end{pmatrix}/3\rightarrow h_x=\begin{pmatrix}-1&0&1\end{pmatrix}, h_y=\begin{pmatrix}1\\1\\1\end{pmatrix}/3$$

Ces filtres 2D peuvent être décomposés en 2 filtres de **3 paramètres** pour un total de **6 paramètres**

15

Convolution séparée

Les filtres 2D et 3D peuvent être **séparés** en filtres plus élémentaires

Bien que tous les filtres 2D (et 3D) ne soient pas tous mathématiquement séparables, on peut tout de même les **approximer** par des filtres 1D

$$\begin{pmatrix}a&b&c\\d&e&f\\g&h&i\end{pmatrix}\approx\begin{pmatrix}k&l&m\end{pmatrix}*\begin{pmatrix}n\\o\\p\end{pmatrix}$$

16

Convolution séparée

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

17

17

Convolution séparée

Réduction du nombre de paramètres

18

18

Convolution séparée en profondeur

(Depthwise Separable Convolution)

19

19

Convolution usuelle

3x3x3 x128 = **3456 params**

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

20

depth-wise convolution

3 cartes d'activation de taille **7x7**

3 filtres **3x3x1**

3 cartes d'activation de taille **5x5**

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

21

Depthwise Separable Convolution

Depth-wise convolution + conv 1x1

3 cartes d'activation de taille **7x7**

3 filtres **3x3x1**

3 cartes d'activation de taille **5x5**

1 filtre **1x1x3**

1 carte d'activation de taille **5x5**

22

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

22

Depthwise Separable Convolution

Depth-wise convolution + conv 1x1

3x3x3+3x128 = **411 params**

23

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

23

Depthwise Separable Convolution

Depth-wise convolution + conv 1x1

24

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

24

Depthwise Separable Convolution

Depth-wise convolution + conv 1x1

x 128

(3x1x1 + 1x3x1 + 1x1x3)x128 = **1158 params**

Jonghoon Jin, Aysegul Dundar, Eugenio Culurciello,
Flattened convolutional neural networks for feedforward acceleration, ICCV2017

25

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

25

Convolution 3D

26

26

Convolution 3D

Très utile en imagerie médicale

convolution 2D **usuelle**

Image « T2 »

32 filtres de taille 5x5x1

27

Convolution 3D

Souvent en imagerie médicale on utilise plusieurs « modalités »

« T2 » « T1 » « Flair » « DWI »

28

Convolution 3D

Très utile en imagerie médicale

32 filtres de taille 5x5x4

29

Convolution 3D

Souvent en imagerie médicale on utilise plusieurs « modalités » **et des acquisitions en 3D** (ici un cerveau au complet)

30

Convolution 3D

Souvent en imagerie médicale on utilise plusieurs « modalités » **et des acquisitions en 3D**

31

Convolution 3D

Très utile en imagerie médicale

convolution 3D

1 filtres de taille 5x5x5x4

32

Convolution *à trous*

33

33

Convolution *à trous*

*(*ou dilatée*)*

Champ récepteur=3x3 **Champ récepteur=5x5** **Champ récepteur=7x7**

34

34

Convolution *à trous* (ou dilatée)

- Augmentation "artificielle" de la taille du filtre en insérant des zéros entre les éléments non-nuls du noyau
- 1 hyper-paramètre *taux* (*taux* = 1 convolution ordinaire)

Images: http://deeplearning.net/software/theano/tutorial

35

35

Autres pratiques courantes

36

Prétraitement des données en entrée

```
X -= np.mean(X, axis = 0)
```

(réduction du biais)

```
X /= np.std(X, axis = 0)
```

(S'assurer que chaque dimension a le même poids)

Image: http://cs231n.github.io

37

Prétraitement des données en entrée

S'assurer que les dimensions ont les mêmes variances.

Exemple: âge maison (1 à 100) vs prix maison (100,000 à 2,000,000).

38

Prétraitement des données en entrée

Même contenu
Mais un biais
dans les niveaux
de gris.

Après recentrage
des niveaux de
gris.

Ex.: utile lorsqu'on traite des images avec de
forts décallage dans l'intensité des pixels.

39

Prétraitement des données en entrée

Pour des images RGB (ex. CIFAR10, CIFAR100, ImageNet, etc)

- Soustraire l'image moyenne des données d'entraînement (e.g AlexNet)
  - Soustraite une image 32x32x3 pour CIFAR10

$$x_{MOY} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

40

40

Prétraitement des données en entrée

Pour des images RGB (ex. CIFAR10, CIFAR100, ImageNet, etc)

- Soustraire l'image moyenne des N images d'entraînement (e.g AlexNet)
  - Soustraite une image moyenne 32x32x3 pour CIFAR10

$$x_{MOY} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

- Soustraire une moyenne par canal (e.g. VGGNet)
  - Soustraite **trois valeurs** : R, G, B

$$R = \frac{1}{N}\sum_{k=1}^{N}\sum_{i,j} x_k[i,j].R$$

$$G = \frac{1}{N}\sum_{k=1}^{N}\sum_{i,j} x_k[i,j].G$$

$$B = \frac{1}{N}\sum_{k=1}^{N}\sum_{i,j} x_k[i,j].B$$

41

41

Normalisation

Observation : Normaliser les données en entrée est une bonne chose.

Question : pourquoi ne pas normaliser les données à l'entrée de chaque couche?

42

42

Normalisation : Plusieurs options

Instance normalization

Layer normalization

Batch normalization

Group normalization

Pour plus de détails
https://medium.com/nerd-for-tech/overview-of-normalization-techniques-in-deep-learning-e12a79060daf

43

Normalisation : Plusieurs options

Instance normalization

Layer normalization

Batch normalization

Group normalization

Pour plus de détails
https://medium.com/nerd-for-tech/overview-of-normalization-techniques-in-deep-learning-e12a79060daf

44

Normalisation par couche (*Layer norm*)

Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton "Layer normalization" arXiv:1607.06450v1

45

45

Normalisation par couche (*Layer norm*)

Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton "Layer normalization" arXiv:1607.06450v1

46

46

Normalisation par couche (*Layer norm*)

Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton "Layer normalization" arXiv:1607.06450v1

47

47

Normalisation par couche (*Layer norm*)

Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton "Layer normalization" arXiv:1607.06450v1

48

48

Normalisation par couche (*Layer norm*)

Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton "Layer normalization" arXiv:1607.06450v1

49

49

Normalisation par couche (*Layer norm*)

```
def layernorm_forward_pass(x, eps):

    #step 1 : calculer la moyenne et la variance
    mu = np.mean(x, -1)[:, :, np.newaxis]
    var = np.var(x, -1)[:, :, np.newaxis]

    #step 2 : normaliser les données
    x_norm = (x - mu)/np.sqrt(var + eps)

    return x_norm
```

Question: est-ce pertinent de normaliser tous les neurones de toutes les couches? Pas toujours!

50

50

Normalisation par couche (*Layer norm*)

Solution: permettre au réseau **d'apprendre à *défaire*** la normalisation

$$\mu = \frac{1}{5}\sum_{i=1}^{5} x_i$$ → **Taille 26 x 26**

$$\sigma^2 = \frac{1}{5}\sum_{i=1}^{5} (x_i - \mu)^2$$ → **Taille 26 x 26**

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$ → **Taille 26 x 26**

$$\widetilde{x}_i = \gamma \circ \hat{x}_i + \beta$$ → **γ et β de taille 26 x 26**

Paramètres appris par le système. Ainsi, le réseau peut apprendre que $\gamma = \gamma$ et $\beta = \mu$ et ainsi annuler la normalisation au besoin.

51

51

Normalisation par couche (*Layer norm*)

NOTE: produit de Hadamar

$$\widetilde{x}_i = \gamma \circ \hat{x}_i + \beta$$

$$\begin{bmatrix} \gamma_1 & \gamma_2 & \gamma_3 & \gamma_4 \\ \gamma_5 & \gamma_6 & \gamma_7 & \gamma_8 \\ \gamma_9 & \gamma_{10} & \gamma_{11} & \gamma_{12} \\ \gamma_{13} & \gamma_{14} & \gamma_{15} & \gamma_{16} \end{bmatrix} \circ \begin{bmatrix} x_1 & x_2 & x_3 & x_4 \\ x_5 & x_6 & x_7 & x_8 \\ x_9 & x_{10} & x_{11} & x_{12} \\ x_{13} & x_{14} & x_{15} & x_{16} \end{bmatrix} = \begin{bmatrix} \gamma_1 x_1 & \gamma_2 x_2 & \gamma_3 x_3 & \gamma_4 x_4 \\ \gamma_5 x_5 & \gamma_6 x_6 & \gamma_7 x_7 & \gamma_8 x_8 \\ \gamma_9 x_9 & \gamma_{10} x_{10} & \gamma_{11} x_{11} & \gamma_{12} x_{12} \\ \gamma_{13} x_{13} & \gamma_{14} x_{14} & \gamma_{15} x_{15} & \gamma_{16} x_{16} \end{bmatrix}$$

52

52

Normalisation par couche (*Layer norm*)

```
def layernorm_forward_pass(x, eps):

    #step 1 : calculer la moyenne et la variance
    mu = np.mean(x, -1)[:, :, np.newaxis]
    var = np.var(x, -1)[:, :, np.newaxis]

    #step 2 : normaliser les données
    x_norm = (x - mu)/np.sqrt(var + eps)

    #step 3 : "dénormaliser" les données
    x_norm =  x_norm*self.gamma + self.beta

    return x_norm
```

53

53

[Ioffe and Szegedy, 2015]

Normalisation par lot (*Batch norm*)

Observation : Normaliser les données en entrée est une bonne chose.

Question : pourquoi ne pas normaliser les données à l'entrée de chaque couche?

Couche entrée : Image RGB
Couche 1 : 3 filtres de taille 7x7
Couche 2 : 5 filtres de taille 9x9
Couche 3 : 4 filtres de taille 11x11
Convolution « *valid* »

54

Image: Ioffe et al. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." arXiv, 2015.

54

[Ioffe and Szegedy, 2015]

Normalisation par lot (*Batch norm*)

55

Normalisation par lot (*Batch norm*)

Ex. : normalisation de la couche 1

x_i : les cartes d'activations du ième lot

Contient 26x26x5= 3380 neurones

$$\mu = \frac{1}{3}\sum_{i=1}^{3} x_i$$

$$\sigma^2 = \frac{1}{3}\sum_{i=1}^{3} (x_i - x_{MOY})^2$$

56

[Ioffe and Szegedy, 2015]

Normalisation par lot (*Batch norm*)

Ex. : normalisation de la couche 1

x_i : les cartes d'activations du ième lot

Contient 26x26x5= 3380 neurones

$$\mu = \frac{1}{3}\sum_{i=1}^{3} x_i$$ → **Taille 26 x 26 x 5**

$$\sigma^2 = \frac{1}{3}\sum_{i=1}^{3} (x_i - \mu)^2$$ → **Taille 26 x 26 x 5**

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$ → **Taille 26 x 26 x 5**

57

Normalisation par lot (*Batch norm*)

```
def batchnorm_forward_pass(x, eps):

    #step 1 : calculer la moyenne et la variance
    mu = np.mean(x, axis=0)
    var = np.var(x, axis=0)

    #step 2 : normaliser les données
    x_norm = (x - mu)/np.sqrt(var + eps)

    return x_norm
```

Question: est-ce pertinent de normaliser tous les neurones de toutes les couches? Pas toujours!

58

58

Normalisation par lot (*Batch norm*)

Solution: permettre au réseau **d'apprendre à *défaire*** la normalisation par lot

$$x_{MOY} = \frac{1}{3}\sum_{i=1}^{3} x_i$$

$$x_{VAR} = \frac{1}{3}\sum_{i=1}^{3} \left(x_i - x_{MOY}\right)^2$$

$$\hat{x}_i = \frac{x_i - x_{MOY}}{\sqrt{x_{VAR} + \varepsilon}}$$

$$\tilde{x}_i = \gamma \circ \hat{x}_i + \beta$$

Paramètres appris par le système. Ainsi, le réseau peut apprendre que $\gamma = \sqrt{x_{VAR}}$ et $\beta = x_{MOY}$ et ainsi annuler la normalisation au besoin.

59

59

Normalisation par lot (*Batch norm*)

Ex. : normalisation de la couche 1

x_i : les cartes d'activations du ième lot

Contient 26x26x5= 3380 neurones

$$\mu = \frac{1}{3}\sum_{i=1}^{3} x_i$$ → **Taille 26 x 26 x 5**

$$\sigma^2 = \frac{1}{3}\sum_{i=1}^{3} (x_i - \mu)^2$$ → **Taille 26 x 26 x 5**

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$ → **Taille 26 x 26 x 5**

$$\tilde{x}_i = \gamma \circ \hat{x}_i + \beta$$ → **γ et β de taille 26 x 26 x 5**

60

Normalisation par lot (*Batch norm*)

```
def batchnorm_forward_pass(x, eps):

#step 1 : calculer la moyenne et la variance
mu = np.mean(x, axis=0)
var = np.var(x, axis=0)

#step 2 : normaliser les données
x_norm = (x - mu)/np.sqrt(var + eps)

#step 3 : "dénormaliser" les données
x_norm =  x_norm*self.gamma + self.beta

return x_norm
```

61

61

Normalisation par lot (*Batch norm*)

En généralisation, lorsqu'on souhaite traiter une seule donnée (donc une taille de lot de 1), on remplace et par des constantes précalculées

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

c'est-à-dire

Nb_training_data

$$\mu = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N} (x_i - \mu)^2$$

Image: Ioffe et al. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." arXiv, 2015.

62

Normalisation (*Batch ou layer norm*)

Généralement **insérée entre la convolution** (ou la couche pleinement connectée) **et la non-linéarité**.

63

63

Normalisation

Avantages:

Accélère l'entraînement

Permet d'utiliser un plus gros *Learning rate*

Image: Ioffe et al. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." arXiv, 2015.

64

Normalisation (*Batch et layer norm*)

Pour plus d'information:

- https://medium.com/@ilango100/batch-normalization-speed-up-neural-network-training-245e39a62f85
- https://deepnotes.io/batchnorm
- Ioffe et al. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." arXiv, 2015.
- https://medium.com/nerd-for-tech/overview-of-normalization-techniques-in-deep-learning-e12a79060daf

65

65

Autre pratique courante : *Dropout*

Forcer à zéro certains neurones de façon aléatoire à chaque itération

Srivastava et al. "Dropout: a simple way to prevent neural networks from overfitting", JMLR 2014

66

Autre bonne pratique : *Dropout*

```
p = 0.5 # probability of keeping a unit active. higher = less dropout

def train_step(X):
  """ X contains the data """

  # forward pass for example 3-layer neural network
  H1 = np.maximum(0, np.dot(W1, X) + b1)
  U1 = np.random.rand(*H1.shape) < p # first dropout mask
  H1 *= U1 # drop!
  H2 = np.maximum(0, np.dot(W2, H1) + b2)
  U2 = np.random.rand(*H2.shape) < p # second dropout mask
  H2 *= U2 # drop!
  out = np.dot(W3, H2) + b3

  # backward pass: compute gradients... (not shown)
  # perform parameter update... (not shown)
```

Crédit http://cs231n.stanford.edu/

67

Autre bonne pratique : *Dropout*

Dans le cas d'un réseau à convolution, dropout revient à appliquer un **masque binaire aléatoire** à chaque carte d'activation.

Jonathan Tompson, Ross Goroshin, Arjun Jain, Yann LeCun, Christoph Bregler
"Efficient Object Localization Using Convolutional Networks", in proc of CVPR 2015

68

Spatial dropout, une variante du *dropout*

Au lieu de forcer à zéro des neurones,
on peut forcer à zéro des **cartes d'activation.**

Jonathan Tompson, Ross Goroshin, Arjun Jain, Yann LeCun, Christoph Bregler
"Efficient Object Localization Using Convolutional Networks", in proc of CVPR 2015

69

69

Drop connect, autre variante de *dropout*

Dropout :
forcer des neurones à zéro

Dropconnect :
forcer des **poids** à zéro

Li Wan, Matthew Zeiler, Sixin Zhang, Yann LeCun, Rob Fergus Regularization of Neural Networks using DropConnect, ICML 2013

70

Drop connect, autre variante de *dropout*

Dans le cas d'une convolution

X0	X1	X2	X3
X4	X5	X6	X7
X8	X9	X10	X11
X12	X13	X14	X15

*

W0	W1	W2
W3	W4	W5
W6	W7	W8

=

Y0	Y1
Y2	Y3

Li Wan, Matthew Zeiler, Sixin Zhang, Yann LeCun, Rob Fergus Regularization of Neural Networks using DropConnect, ICML 2013

71

Drop connect, autre variante de *dropout*

Dans le cas d'une convolution

Dropout force les **neurones** à zéro

X0		X2	X3
	X5	X6	
X8	X9		X11
	X13	X14	

*

W0	W1	W2
W3	W4	W5
W6	W7	W8

=

Y0	Y1
Y2	Y3

Li Wan, Matthew Zeiler, Sixin Zhang, Yann LeCun, Rob Fergus Regularization of Neural Networks using DropConnect, ICML 2013

72

Drop connect, autre variante de *dropout*

Dans le cas d'une convolution

Dropconnect force les **paramètres** à zéro

Li Wan, Matthew Zeiler, Sixin Zhang, Yann LeCun, Rob Fergus Regularization of Neural Networks using DropConnect, ICML 2013

73

Ensemble de modèles

1- Entraîner indépendamment différents modèles
2- En généralisation, **faire voter** ces modèles

Permet d'améliorer les performances de 2-3%

NOTE Même entraîner N-fois le même modèle fonctionne!

Li Wan, Matthew Zeiler, Sixin Zhang, Yann LeCun, Rob Fergus Regularization of Neural Networks using DropConnect, ICML 2013

74

Ensemble de modèles

Entraîner plusieurs modèles (ou plusieurs fois le même modèle)

75

75

Ensemble de modèles

Une fois les modèles entraînés, on combine leur sortie

76

76

Ensemble de modèles

On peut également calculer leur **incertitude** avec une variance

77

77

Monte-Carlo Dropout *(MCDropout)*

Une façon simple de **combiner plusieurs modèles** et de calculer une **incertitude** est de mélanger la sortie d'un réseau avec différents masques de *dropout*.

Sans *dropout*, la sortie $y_W(x)$ est toujours la même pour un x donné

Avec *dropout*, la sortie $y_W(x)$ n'est PAS toujours la même pour un x donné

78

78

Monte-Carlo Dropout *(MCDropout)*

Une façon simple de **combiner plusieurs modèles** et de calculer une **incertitude** est de mélanger la sortie d'un réseau avec différents masques de *dropout*.

Avec *dropout*, la sortie $y_W(x)$ n'est PAS toujours la même pour un x donné

Si on fait M *propagations avants* pour un x donné, on aura M résultats différents.

$$\hat{y}_W(x) = \frac{1}{M}\sum_{m=1}^{M} y_W^m(x) \longrightarrow$$ **Prédictions moyennées** (ensemble de modèles)

$$\hat{y}_W^{VAR}(x) = \frac{1}{M}\sum_{m=1}^{M}\left(y_W^m(x) - \hat{y}_W(x)\right)^2 \longrightarrow$$ **Incertitude**

79

Transfert d'apprentissage

(Transfer learning)

Question : il faut un très grand nombre de données annotées pour entraîner un réseaux de neurones profonds?

Réponse : **Faux**, si on dispose d'un modèle pré-entraîné sur une base de données similaire.

80

Transfert d'apprentissage

(Transfer learning)

Crédit : http://cs231n.stanford.edu

81

Transfert d'apprentissage

(Transfer learning)

Crédit : http://cs231n.stanford.edu

82

Transfert d'apprentissage

(Transfer learning)

Crédit : http://cs231n.stanford.edu

83

Transfert d'apprentissage

(Transfer learning)

	very similar dataset	very different dataset
very little data	Use Linear Classifier on top layer	You're in trouble… Try linear classifier from different stages
quite a lot of data	Finetune a few layers	Finetune a larger number of layers

Crédit : http://cs231n.stanford.edu

84

À retenir pour vos projets:

Vous avez une BD qui a un nombre limité de données annotées?

1. Trouvez une grosse BD contenant des données similaires
2. Entraînez un réseau de neurones
3. Transférez le modèle à votre projet
4. Réentraînez votre modèle (ou une partie de votre modèle)

Plusieurs bibliothèques ont un "Model Zoo" avec des modèles pré-entraînés

TensorFlow: https://github.com/tensorflow/models
PyTorch: https://github.com/pytorch/vision

85

Augmentation de données

(Data augmentation)

On peut artificiellement augmenter le nombre de données en transformant les données sans pour autant affecter leur cible.

86

Augmentation de données

(Data augmentation)

Exemple de transformation : **flip**

87

Augmentation de données

(Data augmentation)

Exemple de transformation : **rotation aléatoire de +/- 5 degrés**

88

Augmentation de données

(Data augmentation)

Exemple de transformation : **changement aléatoire de la dynamique des couleurs**

89

Augmentation de données

(Data augmentation)

Exemple de transformation : **crop aléatoire + redimension**

90

Augmentation de données

(Data augmentation)

Exemple de transformation : **transformation de lentille**

91

L'augmentation de données n'est pas une exception

c'est la norme

Il n'y a *a priori* **aucune raison pour ne pas l'utiliser dans vos projets.**

92

CLASSIFICATION D'IMAGE

93

Classification d'image

Chien: 85%
Chat: 10%
Cheval: 5%
Chaise: 0%

But: prédire une étiquette de classe (ou une distribution de probabilités) pour une image donnée.

94

94

Classification d'image

Défi

37	49	43	43	63	45	51	56	65	59
47	64	68	37	48	56	37	47	61	47
56	67	64	39	80	66	31	48	49	33
38	49	32	75	48	49	71	35	47	27
61	62	33	64	60	49	35	40	70	49
52	32	31	56	34	32	34	27	43	36
34	77	26	36	46	27	62	76	70	65
69	36	49	37	34	41	75	61	69	46
31	40	62	30	67	43	54	77	72	72
42	69	65	76	73	61	64	34	53	66
39	52	55	64	45	78	34	76	60	57
55	68	31	56	63	77	78	69	78	35
31	47	60	43	42	51	55	57	50	78
48	41	32	35	55	39	63	50	29	40
31	28	33	60	71	68	28	40	73	76
32	63	31	80	58	67	70	67	60	38
69	49	33	35	44	66	67	38	45	46
42	50	35	40	42	66	32	29	80	30
59	59	36	47	50	31	54	68	38	61
79	29	43	30	49	63	43	62	61	35

Ce que l'humain voit

Ce que l'ordinateur voit

95

95

Classification d'image

Autres défis

Facile pour les humains mais difficile pour les ordinateurs.

Image: http://cs231n.github.io

96

96

LeNet-1

Une des plus vieilles architectures faite pour la reconnaissance de caractères.

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes

Input
|
CONV
|
POOL
|
CONV
|
POOL
|
FC
|
SOFTMAX

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

97

LeNet-1

Une des plus vieilles architectures faite pour la reconnaissance de caractères.

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes

Input
|
CONV
|
POOL
|
CONV
|
POOL
|
FC
|
SOFTMAX

Combien de neurones?
Combien de paramètres?

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

98

LeNet-5

Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
FC
FC
SOFTMAX

LeCun, Y.; Bottou, L.; Bengio, Y. & Haffner, P. (1998).
Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11): 2278 - 232

99

LeNet-5

Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
FC
FC
SOFTMAX

Combien de neurones?
Combien de paramètres?

100

Classification d'images

Image: http://cs231n.stanford.edu/slides/2018

101

101

Classification d'images

AlexNet **[Krizhevsky et al, 2012]**

Image: http://cs231n.stanford.edu/slides/2018

102

102

AlexNet

- Premier CNN à bien performer sur ImageNet (amélioration de 10% par rapport aux autres)
- Utilisation de techniques aujourd'hui fréquemment utilisées: **ReLU, data augmentation** and **dropout**
- Utilisation de **GPUs** (2 dans leur cas)
- Point de départ de la **révolution du "deep learning"** en vision par ordinateur

Image: Krizhevsky et al. "Imagenet classification with deep convolutional neural networks," NIPS 2012.

103

AlexNet

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Quelle est la taille des cartes d'activation?

Réponse: (227-11)/4+1 = 55

104

AlexNet

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Cartes d'activation : 96 x 55 x 55

Q: Quel est le nombre de paramètres?

105

AlexNet

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Cartes d'activation : 96 x 55 x 55
Paramètres : 11 x 11 x 96 x 3 = 34,848

106

AlexNet

ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55

Couche 2 MaxPool : 3x3 stride stride 2

Quelle est la taille des cartes d'activation?

Réponse: (55-3)/2+1 = 27

107

AlexNet

ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55

Couche 2 MaxPool : 3x3 stride stride 2
27 x 27 x 96

Combien y a-t-il de paramètres?

Réponse: 0!

108

AlexNet

ENTRÉE : 227x227x3
CONV1: 55 x 55 x 96
MAX POOL1: 27 x 27 x 96
…

109

AlexNet

ENTRÉE	227 x 227 x 3
96 filtres 11x11, stride 4, pad 0, **CONV1**	55 x 55 x 96
filtre 3x3, stride 2, **MAX POOL1**	27 x 27 x 96
normalisation par couche, **NORM1**	27 x 27 x 96
256 filtres 5x5, stride 1, pad 2, **CONV2**	27 x 27 x 256
filtre 3x3, stride 2, **MAX POOL2**	13 x 13 x 256
normalisation par couche, **NORM2**	13 x 13 x 256
384 filtres 3x3, stride 1, pad 1, **CONV3**	13 x 13 x 384
384 filtres 3x3, stride 1, pad 1, **CONV4**	13 x 13 x 384
256 filtres 3x3, stride 1, pad 1, **CONV5**	13 x 13 x 256
filtre 3x3, stride 2, **MAX POOL3**	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

110

AlexNet

ENTRÉE	227 x 227 x 3
CONV1	55 x 55 x 96
MAX POOL1	27 x 27 x 96
NORM1	27 x 27 x 96
CONV2	27 x 27 x 256
MAX POOL2	13 x 13 x 256
NORM2	13 x 13 x 256
CONV3	13 x 13 x 384
CONV4	13 x 13 x 384
CONV5	13 x 13 x 256
MAX POOL3	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

Notes additionnelles:

Fonction d'activation **ReLU**
Augmentation de données
LayerNorm : peu utilisé aujourd'hui
Dropout 0.5
Batch_size 128
SGD + momentum
Taux d'apprentissage 0.01 avec réduction par plateau d'un facteur 10
~68 millions de paramètres

111

AlexNet

ENTRÉE	227 x 227 x 3
CONV1	55 x 55 x 96
MAX POOL1	27 x 27 x 96
NORM1	27 x 27 x 96
CONV2	27 x 27 x 256
MAX POOL2	13 x 13 x 256
NORM2	13 x 13 x 256
CONV3	13 x 13 x 384
CONV4	13 x 13 x 384
CONV5	13 x 13 x 256
MAX POOL3	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

Notes additionnelles:

Utilisation de **2 GPUs**
Ensemble de 7 CNN: 18.2% -> 15.4

112

Classification d'images

VGGNet **[Simonyan and Zisserman, 2014]**

Karen Simonyan, Andrew Zisserman "Very Deep Convolutional Networks for Large-Scale Image Recognition", ICLR 2015

Image: http://cs231n.stanford.edu/slides/2018

113

113

VGGNet

Ce qui caractérise VGGNet par rapport à ses prédécesseurs:

- Uniquement des **filtres 3x3, stride 1, pad 1**
- **Plus profond**

AlexNet : 8 couches
VGGNet : 16 ou 19 couches

7.3% d'erreur contre 11.7% pour ZFNet

114

114

VGGNet

Pourquoi utiliser des filtres 3x3?

Indice1 : quel est le **champ récepteur** (***receptive field***) d'une série de 3 couches 3x3?

Indice2 : combien de paramètres pour ces 3 couches?

115

115

VGGNet

Pourquoi utiliser des filtres 3x3?

Le champ récepteur de 3 filtres 3x3 consécutifs est **7x7**

nb_params pour 3 filtres consécutifs **3x3x3xNb_Canaux**

Vs

nb_params pour 1 couche**: 7x7xNb_Canaux**

116

116

VGGNet

Pourquoi utiliser des filtres 3x3?

Le champ récepteur de 3 filtres 3x3 est **7x7**

nb_params pour 3 couches **27xNb_Canaux**
Vs
nb_params pour 1 couche**: 49xNb_Canaux**

117

117

VGGNet

Conclusion :

Plus de couches de plus petits filtres
=>
Moins de paramètres et **plus de non-linéarités**

118

118

VGG16

ENTRÉE
CONV-3x3-64
CONV-3x3-64
POOL-2x2
CONV-3x3-128
CONV-3x3-128
POOL-2x2
CONV-3x3-256
CONV-3x3-256
CONV-3x3-256
POOL-2x2
CONV-3x3-512
CONV-3x3-512
CONV-3x3-512
POOL-2x2
CONV-3x3-512
CONV-3x3-512
CONV-3x3-512
POOL-2x2
FC-4096
FC-4096
FC-4096

Combien de paramètres?
Combien de neurones?

VGG16

119

Image: http://cs231n.stanford.edu/slides/20

119

VGG16

	Cartes d'activation
ENTRÉE	[224x224x3]
CONV-3x3-64	[224x224x64]
CONV-3x3-64	[224x224x64]
POOL-2x2	[112x112x64]
CONV-3x3-128	[112x112x128]
CONV-3x3-128	[112x112x128]
POOL-2x2	[56x56x128]
CONV-3x3-256	[56x56x256]
CONV-3x3-256	[56x56x256]
CONV-3x3-256	[56x56x256]
POOL-2x2	[28x28x256]
CONV-3x3-512	[28x28x512]
CONV-3x3-512	[28x28x512]
CONV-3x3-512	[28x28x512]
POOL-2x2	[14x14x512]
CONV-3x3-512	[14x14x512]
CONV-3x3-512	[14x14x512]
CONV-3x3-512	[14x14x512]
POOL-2x2	[7x7x512]
FC-4096	[1x1x4096]
FC-4096	[1x1x4096]
FC-4096	[1x1x1000]

VGG16

120

Image: http://cs231n.stanford.edu/slides/20

120

VGG16	Cartes d'activation	Nb Neurones
ENTRÉE	[224x224x3]	150 K
CONV-3x3-64	[224x224x64]	3.2 M
CONV-3x3-64	[224x224x64]	3.2 M
POOL-2x2	[112x112x64]	800 k
CONV-3x3-128	[112x112x128]	1.6 M
CONV-3x3-128	[112x112x128]	1.6 M
POOL-2x2	[56x56x128]	400 K
CONV-3x3-256	[56x56x256]	800 K
CONV-3x3-256	[56x56x256]	800 K
CONV-3x3-256	[56x56x256]	800 K
POOL-2x2	[28x28x256]	200 K
CONV-3x3-512	[28x28x512]	400 K
CONV-3x3-512	[28x28x512]	400 K
CONV-3x3-512	[28x28x512]	400 K
POOL-2x2	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
POOL-2x2	[7x7x512]	25 K
FC-4096	[1x1x4096]	4094
FC-4096	[1x1x4096]	4096
FC-4096	[1x1x1000]	1000

VGG16

121

Image: http://cs231n.stanford.edu/slides/20

121

VGG16	Cartes d'activation	Nb Neurones	Nb Paramètres
ENTRÉE	[224x224x3]	150 K	0
CONV-3x3-64	[224x224x64]	3.2 M	(3*3*3)*64 = 1,728
CONV-3x3-64	[224x224x64]	3.2 M	(3*3*64)*64 = 36,864
POOL-2x2	[112x112x64]	800 k	0
CONV-3x3-128	[112x112x128]	1.6 M	(3*3*64)*128 = 73,728
CONV-3x3-128	[112x112x128]	1.6 M	(3*3*128)*128 = 147,456
POOL-2x2	[56x56x128]	400 K	0
CONV-3x3-256	[56x56x256]	800 K	(3*3*128)*256 = 294,912
CONV-3x3-256	[56x56x256]	800 K	(3*3*256)*256 = 589,824
CONV-3x3-256	[56x56x256]	800 K	(3*3*256)*256 = 589,824
POOL-2x2	[28x28x256]	200 K	0
CONV-3x3-512	[28x28x512]	400 K	(3*3*256)*512 = 1,179,648
CONV-3x3-512	[28x28x512]	400 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[28x28x512]	400 K	(3*3*512)*512 = 2,359,296
POOL-2x2	[14x14x512]	100 K	0
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
POOL-2x2	[7x7x512]	25 K	0
FC-4096	[1x1x4096]	4094	7*7*512*4096 = 102,760,448
FC-4096	[1x1x4096]	4096	4096*4096 = 16,777,216
FC-4096	[1x1x1000]	1000	4096*1000 = 4,096,000

VGG16

122

Image: http://cs231n.stanford.edu/slides/20

122

VGGNet

Nb neurones totaux : ~15 M
Mémoire totale neurones (4 octets par neurones) : ~60 Mo
Nb paramètres totaux : 138 M
Mémoire total paramètres (4 octets par paramètres) : 552 Mo

~ 612 Mo pour la propagation avant d'une image

VGG16

123

Image: http://cs231n.stanford.edu/slides/20

123

VGGNet

Nb neurones totaux : ~15 M
Mémoire totale neurones (4 octets par neurones) : ~60 Mo
Nb paramètres totaux : ~138 M
Mémoire total paramètres (4 octets par paramètres) : ~552 Mo

~612 Mo pour la propagation avant d'une image

>1.1 Go si on inclut la rétro-propagation

VGG16

124

Image: http://cs231n.stanford.edu/slides/20

124

GoogLeNet (Inception V1)

[Szegedy et al., 2014]

Christian Szegedy,Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, Andrew Rabinovi, Going Deeper with Convolutions, CVPR 2015

Image: http://cs231n.stanford.edu/slides/2018

125

125

GoogLeNet (Inception v1)

CNN "Classique"

GoogLeNet – 21 couches

126

GoogLeNet (Inception v1)

Lorsqu'on design un CNN, il faut déterminer la taille des filtres à chaque couche. 1x1? 3x3? 5x5? 7x7?...

127

GoogLeNet (Inception v1)

Lorsqu'on design un CNN, il faut déterminer la taille des filtres à chaque couche. 1x1? 3x3? 5x5? 7x7?...

"**Inception module**": combine le résultat de plusieurs filtres.

128

GoogLeNet (Inception v1)

Module d'inception « naïf »

- Appliquer 4 filtres différents et « same »
- Concaténation des cartes d'activation

129

GoogLeNet (Inception v1)

Problème : trop d'opérations

130

GoogLeNet (Inception v1)

Problème : trop d'opérations

131

GoogLeNet (Inception v1)

Problème : trop d'opérations

132

GoogLeNet (Inception v1)

Problème : trop d'opérations

Nombre total d'opérations:
[1x1 conv, 128] 28x28x128x1x1x256
[3x3 conv, 192] 28x28x192x3x3x256
[5x5 conv, 96] 28x28x96x5x5x256
Total: ~854M opérations

Très coûteux

133

GoogLeNet (Inception v1)

Module d'inception avec « **bottleneck layers** »

134

Classification d'images

RAPPEL : 1x1 convolution

Permet de réduire le nombre de cartes d'activation

135

135

GoogLeNet (Inception v1)

Module d'inception avec « **bottleneck layers** »

Nombre total d'opérations:
[1x1 conv, 64] 28x28x64x1x1x256
[1x1 conv, 64] 28x28x64x1x1x256
[1x1 conv, 128] 28x28x128x1x1x256
[3x3 conv, 192] 28x28x192x3x3x64
[5x5 conv, 96] 28x28x96x5x5x64
[1x1 conv, 64] 28x28x64x1x1x256
Total: ~271M opérations

136

GoogLeNet (Inception v1)

Modèle complet

137

GoogLeNet (Inception v1)

Modèle complet

138

GoogLeNet (Inception v1)

Modèle complet

Injection de gradients
(AvgPool-1x1Conv-FC-FC-Softmax)

139

139

Classification d'images

Taille des réseaux

AlexNet

8 couches
~68M paramètres

VGG16

16 couches
~138M paramètres

GoogLeNet

22 couches
~5M paramètres

140

Classification d'images

ResNet **[He et al, 2016]**

K.He, X.Zhang, S. Ren, J.Sun, Deep Residual Learning for Image Recognition, CVPR 2016

Image: http://cs231n.stanford.edu/slides/2018

141

Classification d'images

Qu'arrive-t-il lorsqu'on rend très profond un CNN?

- À la fois **l'erreur** de test et d'entraînement vont **augmenter**.
- **HYPOTHÈSE** : Ceci n'est pas du sur-apprentissage (*overfitting*) c'est un **problème d'optimisation**.

142

142

Classification d'image

Couches conventionnelles

Bloc résiduel

143

Rétro-propagation et gradients

Couches conventionnelles

Bloc résiduel

144

2 types de blocs résiduels (détails)

145

Autre illustration

146

146

Exemple de code simple

```python
def forward(self, x):

    identity = x.clone()

    x = self.conv1(x)
    x = self.bn1(x)
    x = self.relu(x)
    x = self.conv2(x)
    x = self.bn2(x)

    x += identity
    x = self.relu(x)

    return x
```

147

147

ResNet - 34

ImageNet 1.4M images
1000 classes.

ResNet **[He et al, 2016]**

34 couches

64 cartes d'activation

128 cartes d'activation

256 cartes d'activation

512 cartes d'activation

148

148

ResNet - 34

Réduction d'un facteur 2 de la resolution des cartes d'activation par **conv stride 2**

ResNet **[He et al, 2016]**

34 couches

149

149

ResNet - 34

ResNet **[He et al, 2016]**

34 couches

Les filtres convolutifs font 3x3

sauf pour la première couche

150

150

ResNet - 34

Pour les versions à 50, 101 et 152 couches, on utilise des « **bottleneck layers** »

151

151

ResNet – 50,101, 152

Pour les versions à plus de 50, 101 et 152 couches, utiliser des « **bottleneck layers** »

Convolution 3x3 appliquée sur 64 canaux au lieu de 256

152

ResNet

" model zoo "

Autres types de connexions résiduelles

(a) original (b) BN after addition (c) ReLU before addition (d) ReLU-only pre-activation (e) **full pre-activation**

https://towardsdatascience.com/an-overview-of-resnet-and-its-variants-5281e2f56035

153

ResNeXt [Xie et al. 2017]

De la part des mêmes auteurs, une « version améliorée »

inspiré du "inception Net" "GoogleNet"

Bloc ResNet
50 couches et +

Bloc ResNeXt

S. Xie, R. Girshick, P. Dollar, Z. Tu, K. He
Aggregated Residual Transformations for Deep Neural Networks, CVPR 2017

154

154

ResNeXt

stage	output	ResNet-50	**ResNeXt-50 (32×4d)**
conv1	112×112	7×7, 64, stride 2	7×7, 64, stride 2
conv2	56×56	3×3 max pool, stride 2	3×3 max pool, stride 2
		$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128, C{=}32 \\ 1\times1, 256 \end{bmatrix}\times3$
conv3	28×28	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256, C{=}32 \\ 1\times1, 512 \end{bmatrix}\times4$
conv4	14×14	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512, C{=}32 \\ 1\times1, 1024 \end{bmatrix}\times6$
conv5	7×7	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 1024 \\ 3\times3, 1024, C{=}32 \\ 1\times1, 2048 \end{bmatrix}\times3$
	1×1	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax
# params.		$\mathbf{25.5}\times10^6$	$\mathbf{25.0}\times10^6$
FLOPs		$\mathbf{4.1}\times10^9$	$\mathbf{4.2}\times10^9$

Bottleneck Residual layers

S. Xie, R. Girshick, P. Dollar, Z. Tu, K. He
Aggregated Residual Transformations for Deep Neural Networks, CVPR 2017

155

155

ResNeXt

Figure 6. **ImageNet-5K** experiments. Models are trained on the 5K set and evaluated on the original 1K validation set, plotted as a 1K-way classification task. ResNeXt and its ResNet counterpart have similar complexity.

S. Xie, R. Girshick, P. Dollar, Z. Tu, K. He
Aggregated Residual Transformations for Deep Neural Networks, CVPR 2017

156

156

MobileNet

[Howard et al.'17]

Objectif : proposer un réseau efficace et sobre en calculs

Rappel *Depth-wise convolution* + conv 1x1

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017

157

157

MobileNet

[Howard et al.'17]

Objectif : proposer un réseau efficace et sobre en calculs

Rappel *Depth-wise convolution* + N filtres conv 1x1

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017

158

158

MobileNet

[Howard et al.'17]

Conv traditionnel

3x3x3x5x5x4 = 2700 opérations

DW Conv

3x3x1x5x5x3 + 1x1x3x5x5x4 = 975 opérations

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017 159

159

MobileNet

[Howard et al.'17]

DW Conv de MobileNet inclut deux **batch norm**

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017 160

160

MobileNet

[Howard et al.'17]

Tirés de l'article

Conv dw

(autre illustration de la page précédente)

Table 1. MobileNet Body Architecture

Type / Stride	Filter Shape	Input Size
Conv / s2	$3 \times 3 \times 3 \times 32$	$224 \times 224 \times 3$
Conv dw / s1	$3 \times 3 \times 32$ dw	$112 \times 112 \times 32$
Conv / s1	$1 \times 1 \times 32 \times 64$	$112 \times 112 \times 32$
Conv dw / s2	$3 \times 3 \times 64$ dw	$112 \times 112 \times 64$
Conv / s1	$1 \times 1 \times 64 \times 128$	$56 \times 56 \times 64$
Conv dw / s1	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 128$	$56 \times 56 \times 128$
Conv dw / s2	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 256$	$28 \times 28 \times 128$
Conv dw / s1	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 256$	$28 \times 28 \times 256$
Conv dw / s2	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 512$	$14 \times 14 \times 256$
$5\times$ Conv dw / s1	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
Conv / s1	$1 \times 1 \times 512 \times 512$	$14 \times 14 \times 512$
Conv dw / s2	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
Conv / s1	$1 \times 1 \times 512 \times 1024$	$7 \times 7 \times 512$
Conv dw / s2	$3 \times 3 \times 1024$ dw	$7 \times 7 \times 1024$
Conv / s1	$1 \times 1 \times 1024 \times 1024$	$7 \times 7 \times 1024$
Avg Pool / s1	Pool 7×7	$7 \times 7 \times 1024$
FC / s1	1024×1000	$1 \times 1 \times 1024$
Softmax / s1	Classifier	$1 \times 1 \times 1000$

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017

161

161

MobileNet

[Howard et al.'17]

Tiré de l'article

Meilleurs résultats
Moins de calculs
Moins de paramètres.

Table 8. MobileNet Comparison to Popular Models

Model	ImageNet Accuracy	Million Mult-Adds	Million Parameters
1.0 MobileNet-224	70.6%	569	4.2
GoogleNet	69.8%	1550	6.8
VGG 16	71.5%	15300	138

Table 9. Smaller MobileNet Comparison to Popular Models

Model	ImageNet Accuracy	Million Mult-Adds	Million Parameters
0.50 MobileNet-160	60.2%	76	1.32
Squeezenet	57.5%	1700	1.25
AlexNet	57.2%	720	60

Howard et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications", arxiv 1704.04861, 2017

162

162

XceptionNet

[Chollet'17]

Amélioration de ResNet et GoogleNet, similaire à MobileNet. Ici aussi on utilise des

« *Depth-wise separable convolutions* »

Rappel

F.Chollet, Xception: Deep Learning with Depthwise Separable Convolutions, CVPR 2017

163

163

XceptionNet

[Chollet'17]

Amélioration de ResNet et GoogleNet, similaire à MobileNet. Ici aussi on utilise des

« *Depth-wise separable convolutions* »

Autre illustration

https://towardsdatascience.com/review-xception-with-depthwise-separable-convolution-better-than-inception-v3-image-dc967dd42568

F.Chollet, Xception: Deep Learning with Depthwise Separable Convolutions, CVPR 2017

164

164

XceptionNet

Image tirée de l'article

DWConv
+
Connexions résiduelles

F.Chollet, Xception: Deep Learning with Depthwise Separable Convolutions, CVPR 2017

165

165

XceptionNet

Image tirée de l'article

Table 1. Classification performance comparison on ImageNet (single crop, single model). VGG-16 and ResNet-152 numbers are only included as a reminder. The version of Inception V3 being benchmarked does not include the auxiliary tower.

	Top-1 accuracy	Top-5 accuracy
VGG-16	0.715	0.901
ResNet-152	0.770	0.933
Inception V3	0.782	0.941
Xception	**0.790**	**0.945**

F.Chollet, Xception: Deep Learning with Depthwise Separable Convolutions, CVPR 2017

166

166

DenseNet

[Huang et al, 2017]

Idée d'un bloc dense:

- Les cartes d'activation à chaque couche sont concaténées aux couches subséquentes

Image: http://cs231n.stanford.edu/slides/2018

Huang et al. "Densely connected convolutional networks." CVPR, 2017.

169

169

Bloc de 4 couches convolutives ordinaires avec 3 filtres chaque (fonctions d'activation omises pour alléger la figure)

170

170

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque
(fonctions d'activation omises pour alléger la figure)

171

171

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque
(fonctions d'activation omises pour alléger la figure)

172

172

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque
(fonctions d'activation omises pour alléger la figure)

173

173

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque
(fonctions d'activation omises pour alléger la figure)

174

174

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque (fonctions d'activation omises pour alléger la figure)

175

175

Bloc dense

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque (fonctions d'activation omises pour alléger la figure)

Image: http://cs231n.stanford.edu/slides/2018

176

176

Bloc dense

Bloc de 4 couches convolutives **denses** avec 3 filtres chaque
(fonctions d'activation omises pour alléger la figure)

Image: http://cs231n.stanford.edu/slides/2018

177

177

DenseNet

https://towardsdatascience.com/review-densenet-image-classification-b6631a8ef803

178

178

DenseNet

Avantages:

1. Les gradients circulent directement dans chaque couche lors de la retro-propagation (moins de *vanishing gradient*).

Propagation avant

Rétro-propagation

https://towardsdatascience.com/review-densenet-image-classification-b6631a8ef803

179

179

DenseNet

Avantages:

2. Peu de paramètres

Resnet

DenseNet

CxCx3x3 paramètres

L*k*k*3*3 paramètres

k<<C

180

DenseNet

Avantages:

2. Peu de paramètres

181

DenseNet

Avantages:

3. Le classificateur utilise des caractéristiques de bas et de haut niveau

Avec un CNN conventionnel, le classificateur base sa prédiction sur les caractéristiques de la dernière couche, c-à-d des **caractéristiques de haut niveau**

182

DenseNet

Avantages:

3. Le classificateur utilise des caractéristiques de bas et de haut niveau

Avec DenseNet, le classifieur utilise des **caractéristiques de bas et de haut niveau**

183

Squeeze-and-Excite Net (SENet)

[Hu et al. 2018]

Idée : améliorer les **blocs résiduels** en permettant au réseau de mettre **plus d'importance** sur les **cartes d'activation** les plus informatives.

Bloc résiduel

J. Hu, L. Shen, G. Sun Squeeze-and-Excitation Networks, CVPR 2018

184

184

Squeeze-and-Excite Net (SENet)

[Hu et al. 2018]

Idée : améliorer les **blocs résiduels** en permettant au réseau de mettre **plus d'importance** sur les **cartes d'activation** les plus informatives.

Bloc résiduel

Par simplicité on appelle cette partie le « résiduel »

J. Hu, L. Shen, G. Sun Squeeze-and-Excitation Networks, CVPR 2018

185

Squeeze-and-Excite Net (SENet)

[Hu et al. 2018]

Idée : améliorer les **blocs résiduels** en permettant au réseau de mettre **plus d'importance** sur les **cartes d'activation** les plus informatives.

Bloc résiduel

(avec illustration des cartes d'activation)

Avant et après le résiduel : cartes d'activation de taille N*M*C
Après l'addition : cartes d'activation de taille N*M*C

186

186

Squeeze-and-Excite Net (SENet)

J. Hu, L. Shen, G. Sun Squeeze-and-Excitation Networks, CVPR 2018

187

187

Squeeze-and-Excite Net (SENet)

r: « squeeze rate »

Sigmoid force les valeurs du vecteur de sortie entre 0-1

188

Rappel

Global pooling

Max ou *Mean pooling* « *valid* » avec un filtre de la taille des canaux

Résultat : un **vecteur** de la taille du nombre de canaux

189

Squeeze-and-Excite Net (SENet)

[Hu et al. 2018]

Autre illustration

J. Hu, L. Shen, G. Sun Squeeze-and-Excitation Networks, CVPR 2018

190

190

Squeeze-and-Excite Net (SENet)

[Hu et al. 2018]

Autre illustration

J. Hu, L. Shen, G. Sun Squeeze-and-Excitation Networks, CVPR 2018

191

191

Squeeze-and-Excite Net (SENet)

Fonctionne également avec les **modules d'inception**.

192

192

Meilleur que ResNet, ResNeXt et InceptionNet

193

193

Inclure les bonnes pratiques permet d'améliorer la performance des réseaux, même les plus vieux (ResNet – 2015)

Irwan Bello, William Fedus, Xianzhi Du, Ekin Dogus Cubuk, Aravind Srinivas, Tsung-Yi Lin, Jonathon Shlens, Barret Zoph

Revisiting ResNets: Improved Training and Scaling Strategies, NeuRIPS 2021

https://arxiv.org/pdf/2103.07579.pdf

Figure 4. **Speed-Accuracy Pareto curve comparing ResNets-RS to EfficientNet.** Properly scaled ResNets (ResNet-RS) are **1.7x - 2.7x** faster than the popular EfficientNets when closely

Improvements	Top-1	Δ
ResNet-200	79.0	—
+ Cosine LR Decay	79.3	**+0.3**
+ Increase training epochs	78.8 †	-0.5
+ EMA of weights	79.1	**+0.3**
+ Label Smoothing	80.4	**+1.3**
+ Stochastic Depth	80.6	**+0.2**
+ RandAugment	81.0	**+0.4**
+ Dropout on FC	80.7 ‡	-0.3
+ Decrease weight decay	82.2	**+1.5**
+ Squeeze-and-Excitation	82.9	**+0.7**
+ ResNet-D	83.4	**+0.5**

Table 1. **Additive study of the ResNet-RS training recipe.** The colors refer to **Training Methods**, **Regularization Methods** and **Architecture Improvements**. The baseline ResNet-200 was trained for the standard 90 epochs using a stepwise learning rate decay schedule. The image resolution is 256×256. All numbers are reported on the ImageNet `validation-set` and averaged over 2 runs. † Increasing training duration to 350 epochs only becomes useful once the regularization methods are used, otherwise the accuracy drops due to over-fitting. ‡ dropout hurts as we have not yet decreased the weight decay (See Table 2 for more details).

194

194

Improvements	Top-1	Δ
ResNet-200	79.0	—
+ Cosine LR Decay	79.3	**+0.3**
+ Increase training epochs	78.8 †	-0.5
+ EMA of weights	79.1	**+0.3**
+ Label Smoothing	80.4	**+1.3**
+ Stochastic Depth	80.6	**+0.2**
+ RandAugment	81.0	**+0.4**
+ Dropout on FC	80.7 ‡	-0.3
+ Decrease weight decay	82.2	**+1.5**
+ Squeeze-and-Excitation	82.9	**+0.7**
+ ResNet-D	83.4	**+0.5**

Méthodes d'entraînement

Méthodes de régularisation

Améliorations de l'architecture de base

Table 1. **Additive study of the ResNet-RS training recipe.** The colors refer to **Training Methods**, **Regularization Methods** and **Architecture Improvements**. The baseline ResNet-200 was trained for the standard 90 epochs using a stepwise learning rate decay schedule. The image resolution is 256×256. All numbers are reported on the ImageNet `validation-set` and averaged over 2 runs. † Increasing training duration to 350 epochs only becomes useful once the regularization methods are used, otherwise the accuracy drops due to over-fitting. ‡ dropout hurts as we have not yet decreased the weight decay (See Table 2 for more details).

195

195

ConvNeXt : autre exemple d'un ResNet amélioré en fonction des bonnes pratiques

Z. Liu et al. **A ConvNet for the 2020s**, in proc of CVPR 2022

196

196

ConvNeXt : autre exemple d'un ResNet amélioré en fonction des bonnes pratiques

	output size	• ResNet-50	• ConvNeXt-T
stem	56×56	7×7, 64, stride 2 3×3 max pool, stride 2	4×4, 96, stride 4
res2	56×56	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} d7\times7, 96 \\ 1\times1, 384 \\ 1\times1, 96 \end{bmatrix} \times 3$
res3	28×28	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} d7\times7, 192 \\ 1\times1, 768 \\ 1\times1, 192 \end{bmatrix} \times 3$
res4	14×14	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} d7\times7, 384 \\ 1\times1, 1536 \\ 1\times1, 384 \end{bmatrix} \times 9$
res5	7×7	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} d7\times7, 768 \\ 1\times1, 3072 \\ 1\times1, 768 \end{bmatrix} \times 3$
FLOPs		4.1×10^9	4.5×10^9
# params.		25.6×10^6	28.6×10^6

7x7 Depth-wise Conv

197

197

ConvNeXt : autre exemple d'un ResNet amélioré en fonction des bonnes pratiques

Autres améliorations

198

198