Réseaux de neurones

IFT 603

Réseaux à convolution

Par
Pierre-Marc Jodoin

1

kD, 4 Classes, Réseau à 4 couches cachées

Couche d'entrée | Couche cachée 1 | Couche cachée 2 | Couche cachée 3 | Couche cachée 4 | Couche de sortie

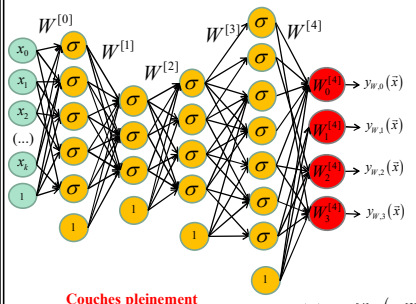

Hinge loss

Couches pleinement connectées
(fully-connected layers)

$$y_W(\vec{x}) = W^{[4]}\sigma\left(W^{[3]}\sigma\left(W^{[2]}\sigma\left(W^{[1]}\sigma\left(W^{[0]}\vec{x}\right)\right)\right)\right)$$

2

kD, 4 Classes, Réseau à 4 couches cachées

Couche d'entrée | Couche cachée 1 | Couche cachée 2 | Couche cachée 3 | Couche cachée 4 | Couche de sortie

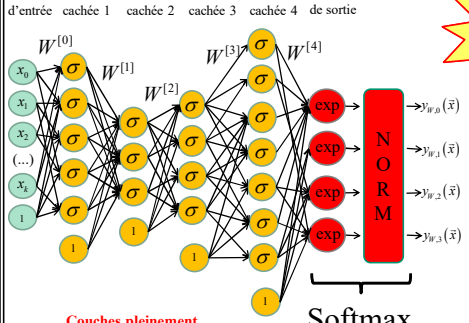

Entropie Croisée

Softmax

$$y_{W,i}(x) = \frac{f_{W,i}}{\sum_k f_{W,k}}$$

Softmax

Couches pleinement connectées
(fully-connected layers)

$$y_W(\vec{x}) = \text{softmax}\left(W^{[4]}\sigma\left(W^{[3]}\sigma\left(W^{[2]}\sigma\left(W^{[1]}\sigma\left(W^{[0]}\vec{x}\right)\right)\right)\right)\right)$$

3

kD, 4 Classes, Réseau à 4 couches cachées

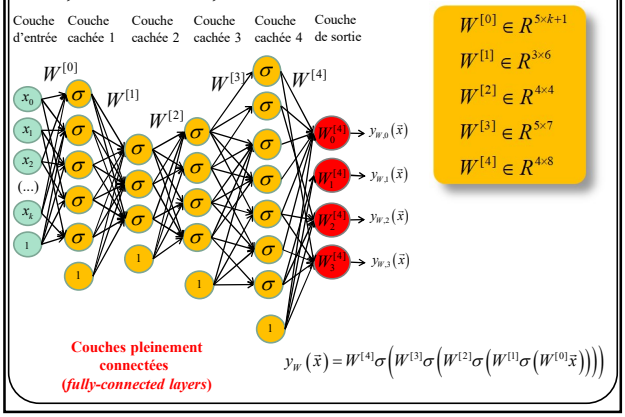

4

kD, 4 Classes, Réseau à 4 couches cachées

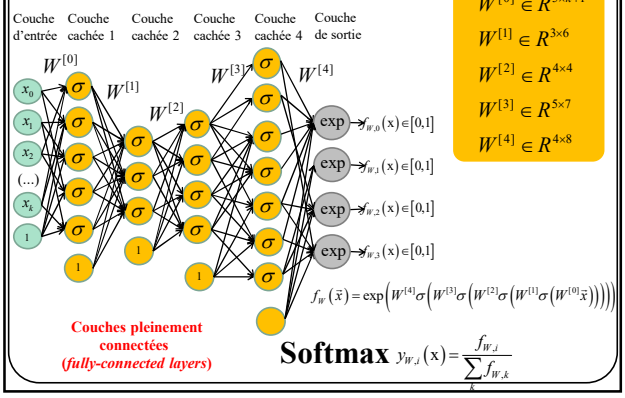

5

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]}\nabla E$$

→ Gradient de la function de coût

→ Taux d'apprentissage ou *"learning rate"*.

Descente de gradient stochastique	Optimisation par *Batch*
Initialiser **w** k=0 FAIRE k=k+1 FOR n = 1 to N $\mathbf{w} = \mathbf{w} - \eta^{[k]}\nabla E(\vec{x}_n)$ JUSQU'À ce que toutes les données soient bien classées ou k== MAX_ITER	Initialiser **w** k=0 FAIRE k=k+1 $\mathbf{w} = \mathbf{w} - \eta^{[k]}\sum_i \nabla E(\vec{x}_i)$ JUSQU'À ce que toutes les données soient bien classées ou k==MAX_ITER

Parfois $\eta^{[k]} = cst / k$

6

Les bonnes pratiques

7

Optimisation

Essentiel au TP4

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

∇E → Gradient de la function de coût

$\eta^{[k]}$ → Taux d'apprentissage ou "*learning rate*".

Optimisation par **mini-batch**

Initialiser **w**
k=0
FAIRE k=k+1

FAIRE n=0 à N par sauts de ***MBS /*Mini-batch size*/***

$$w = w - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\vec{x}_i)$$

JUSQU'À ce que toutes les données soient bien classées ou k==MAX_ITER

Itération

8

Optimisation

Descente de gradient

$$\mathbf{w}^{[k+1]} = \mathbf{w}^{[k]} - \eta^{[k]} \nabla E$$

∇E → Gradient de la function de coût

$\eta^{[k]}$ → Taux d'apprentissage ou "*learning rate*".

Optimisation par ***mini-batch***

Initialiser **w**
k=0
FAIRE k=k+1

FAIRE n=0 à N par sauts de ***MBS /*Mini-batch size*/***

$$w = w - \eta^{[k]} \sum_{i=n}^{n+MBS} \nabla E(\vec{x}_i)$$

JUSQU'À ce que toutes les données sont bien classées ou k==MAX_ITER

Epoch

9

Mini-batch = **vectorisation** de la propagation avant et de la rétro-propagation

10

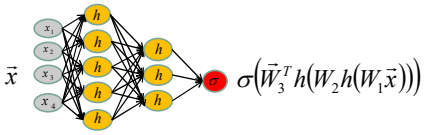

Propagation avant pour un réseau à **2 couches cachées** (7 étapes)

	$\vec{x}$	$\in IR^4$
Étape 2 →	$W_1\vec{x}$	$\in IR^5$
	$h(W_1\vec{x})$	$\in IR^5$
	$W_2 h(W_1\vec{x})$	$\in IR^3$
	$h(W_2 h(W_1\vec{x}))$	$\in IR^3$
Étape 6 →	$\vec{W}_3^T\left(h(W_2 h(W_1\vec{x}))\right)$	$\in IR$
	$\sigma\left(\vec{W}_3^T\left(h\left(\vec{W}_2 h(W_1\vec{x})\right)\right)\right)$	$\in IR$

11

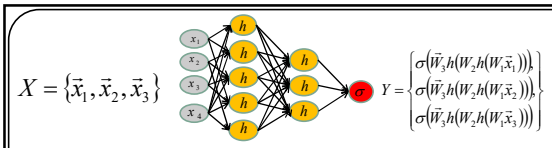

Propagation avant pour un réseau à **2 couches cachées** (7 étapes)

POUR i allant de 0 à 2

$\vec{x} = X[i]$	$\in IR^4$
$W_1\vec{x}$	$\in IR^5$
$h(W_1\vec{x})$	$\in IR^5$
$W_2 h(W_1\vec{x})$	$\in IR^3$
$h(W_2 h(W_1\vec{x}))$	$\in IR^3$
$\vec{W}_3^T\left(h(W_2 h(W_1\vec{x}))\right)$	$\in IR$
$Y[i] = \sigma\left(\vec{W}_3^T\left(h\left(\vec{W}_2 h(W_1\vec{x})\right)\right)\right)$	$\in IR$

Solution naïve et peu efficace

TP3

12

Solution

Il est plus efficace d'effectuer **UNE multiplication matricielle** que **PLUSIEURS multiplications matrice-vecteur** **(exemple de la 2e étape, batch de 3)**

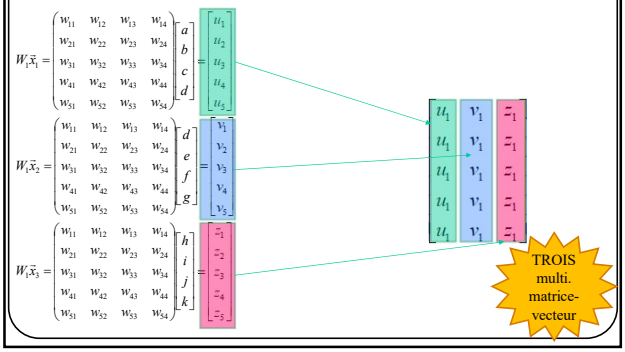

13

Solution

Il est plus efficace d'effectuer **UNE multiplication matricielle** que **PLUSIEURS matrice-vecteur** **(exemple de la 2e étape, batch de 3)**

$$W_1 X = \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \\ w_{41} & w_{42} & w_{43} & w_{44} \\ w_{51} & w_{52} & w_{53} & w_{54} \end{pmatrix} \begin{bmatrix} a & d & h \\ b & e & i \\ c & f & j \\ d & g & k \end{bmatrix} = \begin{bmatrix} u_1 & v_1 & z_1 \\ u_2 & v_2 & z_2 \\ u_3 & v_3 & z_3 \\ u_4 & v_4 & z_4 \\ u_5 & v_5 & z_5 \end{bmatrix}$$

UNE
multiplication
matricielle

14

Solution

$\vec{W}_3^T(h(W_2 h(W_1 \vec{x})))$

Il est plus efficace d'effectuer UNE multiplication matricielle que **PLUSIEURS produits scalaires** **(exemple de la 6e étape, batch de 3)**

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = (w_1 a + w_2 b + w_3 c)$$

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} d \\ e \\ f \end{pmatrix} = (w_1 d + w_2 e + w_3 f)$$

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \begin{pmatrix} g \\ h \\ i \end{pmatrix} = (w_1 g + w_2 h + w_3 i)$$

$$\begin{pmatrix} w_1 a + w_2 b + w_3 c \\ w_1 d + w_2 e + w_3 f \\ w_1 g + w_2 h + w_3 i \end{pmatrix} = Y$$

TROIS
produits
scalaires

15

Solution

Il est plus efficace d'effectuer **UNE multiplication matricielle** que PLUSIEURS produits scalaires **(exemple de la 6e étape, batch de 3)**

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & i \end{pmatrix} = \begin{pmatrix} w_1 a + w_2 b + w_3 c \\ w_1 d + w_2 e + w_3 f \\ w_1 g + w_2 h + w_3 i \end{pmatrix} = Y$$

UNE multiplication matricielle

16

Conclusion

100% du temps, on combine ensemble les données dans des **mini-batch** de 2 à 32 données.

17

Les réseaux à convolution

18

Comment classifier des images?

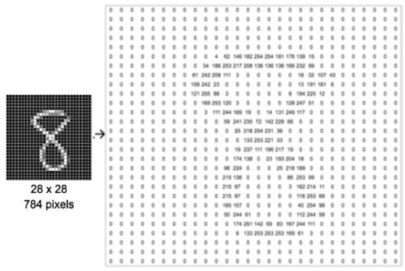

https://mlr4a.github.io/ml4a/neural_networks/

19

Comment classifier des images?

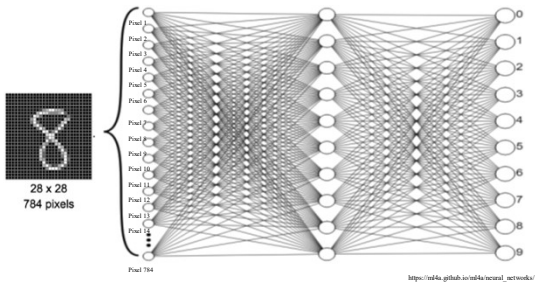

https://mlr4a.github.io/ml4a/neural_networks/

20

Beaucoup de paramètres (7850 dans la couche 1)

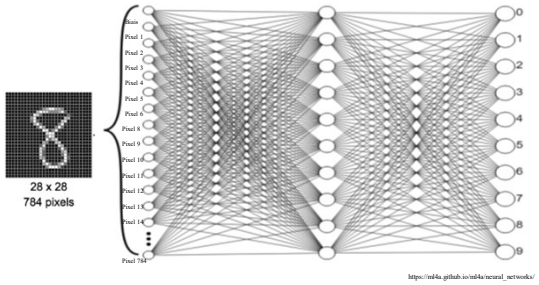

https://mlr4a.github.io/ml4a/neural_networks/

21

Beaucoup trop de paramètres (655,370 dans la couche 1)

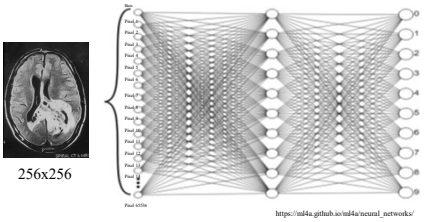

Image médicale (IRM de cerveau)

22

Beaucoup **TROP** de paramètres (160M dans la couche 1)

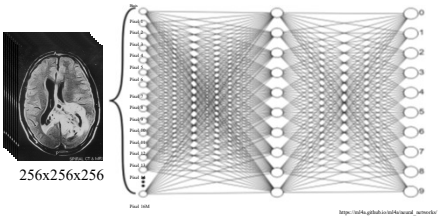

Image médicale 3D (IRM de cerveau)

23

Comment réduire le nombre de connections?

24

24

Comment réduire le nombre de connections?

Les **couches pleinement connectées (*fully-connected layers*)** sont problématiques lorsque le **nombre de neurones est élevé.**

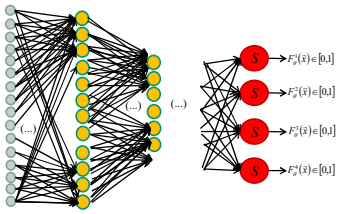

150-D en entrée avec **150 neurones** dans la 1ère couche => **22,200 parametres dans la couche d'entrée!!**

25

Solution : connexions partielles

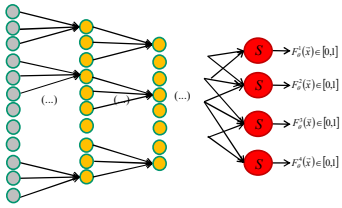

150-D en entrée avec **148 neurones** dans la 1ère couche => **444 paramètres dans la première couche!!**

26

Paramètres partagés : **les neurones de la couche 1 partagent les mêmes poids**

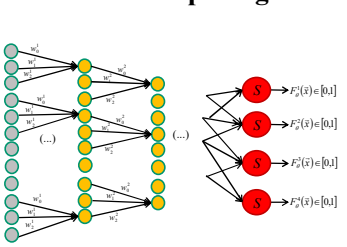

Convolution

150-D en entrée avec 148 neurones dans la 1ère couche => **3 paramètres dans la couche d'entrée!!**

Faible nombre de paramètres = on peut augmenter la profondeur!

27

Convolution
et
couche convolutionnelle
1D

28

Exemple 1D de la convolution

$$(f * W)(v) = \sum_{u=-\infty}^{\infty} f(u)W(v-u)$$

(signal d'entrée) f(u): 10 20 -30 40 -50

(filtre) W(u): .1 .2 .3

(filtre) W(-u): .3 .2 .1

(f*W)(1): 10 20 -30 40 -50 × × × .3 .2 .1 → 3+4+-3 → 4

(f*W)(2): 10 20 -30 40 -50 × × × .3 .2 .1 → 6-6+4 → 4 4

(f*W)(3): 10 20 -30 40 -50 × × × .3 .2 .1 → -9+8+-5 → 4 4 -6

29

29

En gros

convolution = **produit scalaire** + **translation**

30

La convolution des réseaux de neurones = corrélation

$$(f * W)(v) = \sum_{u=-\infty}^{\infty} f(u)W(v+u)$$

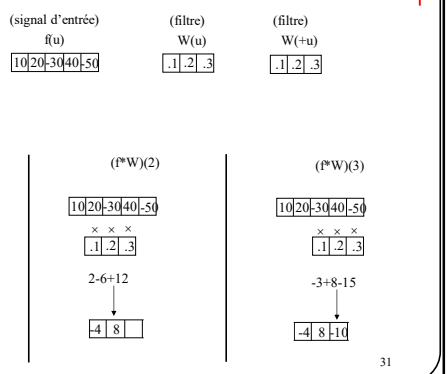

31

31

L'opération de la page précédente est équivalente à

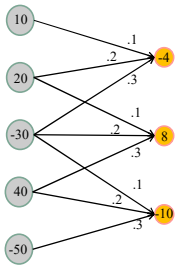

32

32

L'opération de la page précédente est équivalente à

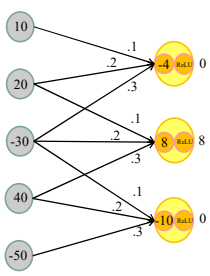

Fonction d'activation (ex. ReLU)

33

33

Représentation graphique courante (simple)

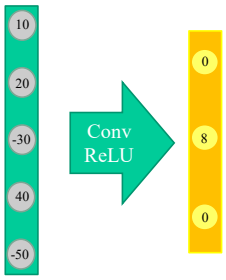

34

34

Représentation graphique courante (encore plus simple)

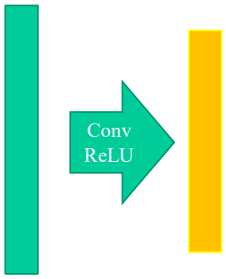

35

35

Représentation graphique courante (vraiment ultra simple)

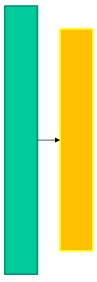

36

36

Représentation graphique courante (eehhh…)

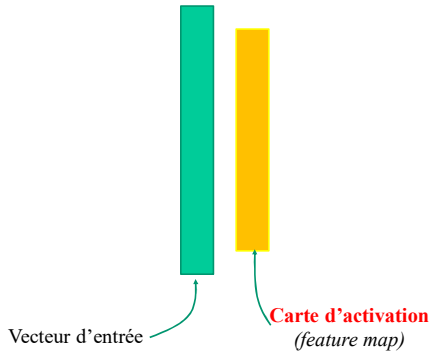

37

37

Apprentissage = apprendre les **poids** w_i **des filtres convolutifs**

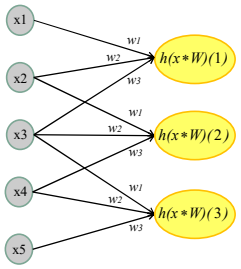

h: fonction d'activation
(tanh, ReLU, elu, etc.)

38

38

Stride et calcul de la taille de la carte d'activation

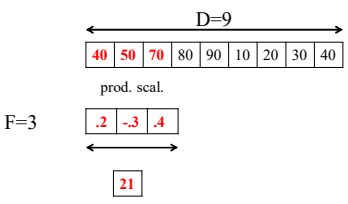

39

39

Stride et calcul de la taille de la carte d'activation

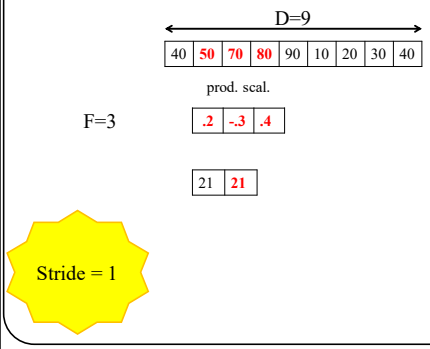

40

40

Stride et calcul de la taille de la carte d'activation

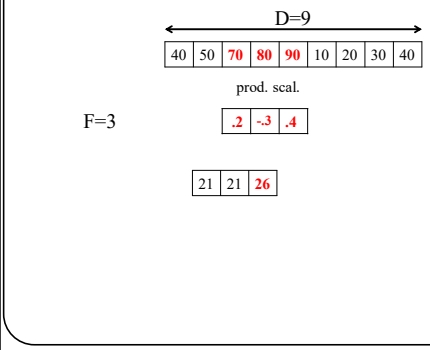

41

41

Stride et calcul de la taille de la carte d'activation

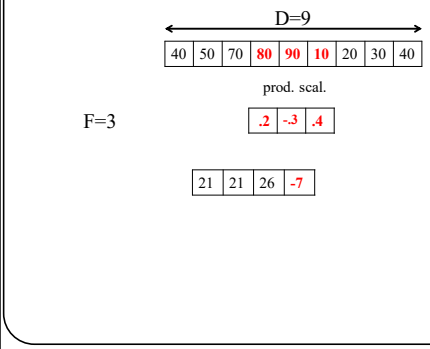

42

42

Stride et calcul de la taille de la carte d'activation

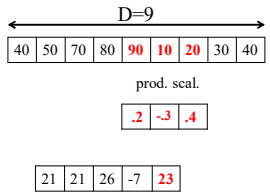

43

43

Stride et calcul de la taille de la carte d'activation

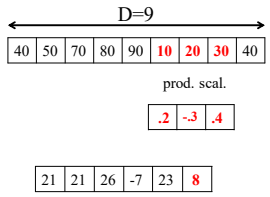

44

44

Stride et calcul de la taille de la carte d'activation

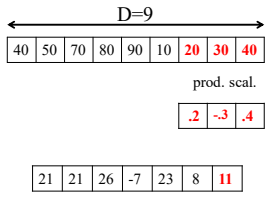

Taille de la carte d'activation = 7

45

45

Stride et calcul de la taille de la carte d'activation

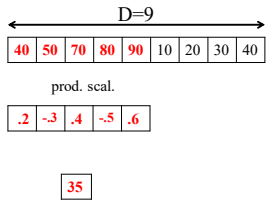

46

46

Stride et calcul de la taille de la carte d'activation

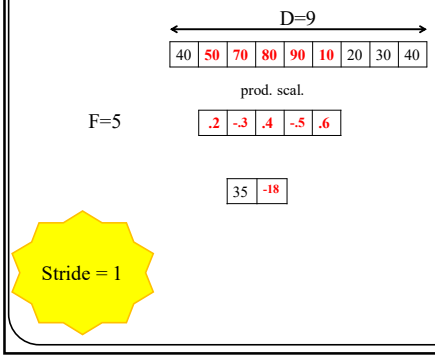

47

47

Stride et calcul de la taille de la carte d'activation

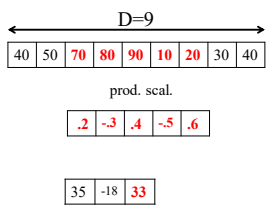

48

48

Stride et calcul de la taille de la carte d'activation

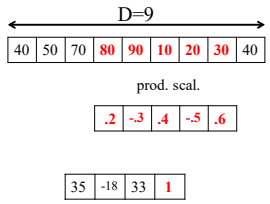

49

49

Stride et calcul de la taille de la carte d'activation

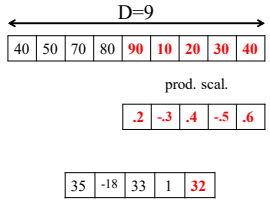

Taille de la carte d'activation = **5**

50

50

Stride et calcul de la taille de la carte d'activation

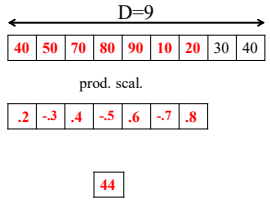

51

51

Stride et calcul de la taille de la carte d'activation

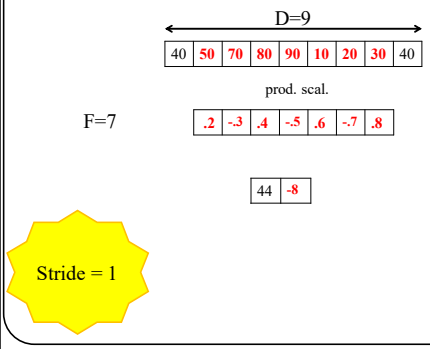

52

52

Stride et calcul de la taille de la carte d'activation

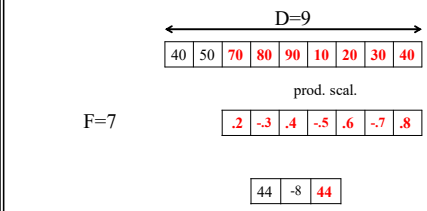

Taille de la carte d'activation = **3**

53

53

Stride et calcul de la taille de la carte d'activation

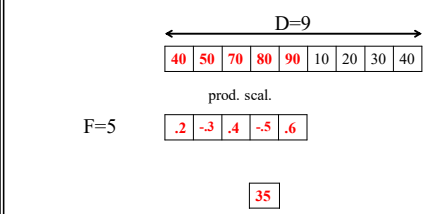

54

54

Stride et calcul de la taille de la carte d'activation

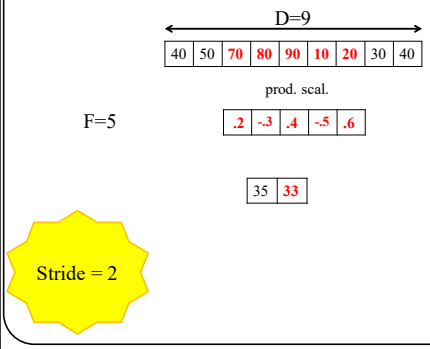

55

55

Stride et calcul de la taille de la carte d'activation

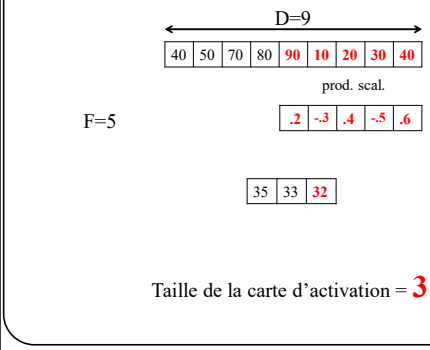

Taille de la carte d'activation = **3**

56

56

Stride et calcul de la taille de la carte d'activation

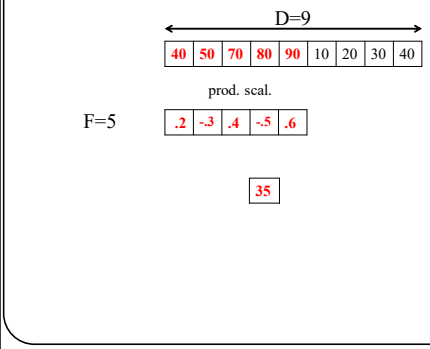

57

57

Stride et calcul de la taille de la carte d'activation

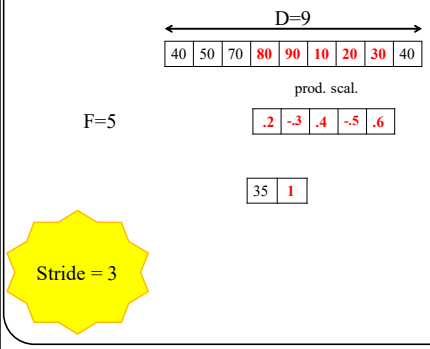

58

58

Stride et calcul de la taille de la carte d'activation

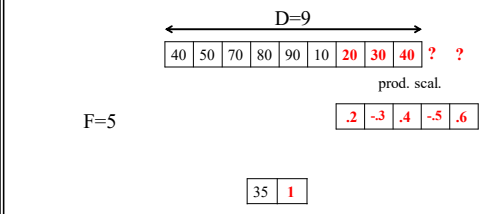

ERREUR! Combinaison D-F-S invalide

59

59

Stride et calcul de la taille de la carte d'activation

Taille de la carte d'activation = **(D-F)/S+1**

60

60

Parfois on souhaite que le **nombre de neurones** dans la carte d'activation soit **le même** que la couche précédente

Comment gérer les bords?

? 10 20 -30 40 -50
× × ×
.1 .2 .3

Option 1 : Ajout de zéros (« *zero padding* » remplacer ? par 0)

f(u): 0 10 20 -30 40 -50 0

(f*W)(u): 8 -4 8 -10 -6

Option 2 : Réflexion (« *reflexion padding* »)

f(u): 20 10 20 -30 40 -50 40

(f*W)(u): 10 -4 8 -10 2

Option 3 : Étirement (« *stretching padding* »)

f(u): 10 10 20 -30 40 -50 -50

(f*W)(u): 9 -4 8 -10 -21

61

61

Parfois on souhaite que le **nombre de neurones** dans la carte d'activation soit **le même** que la couche précédente

Comment gérer les bords?

? 10 20 -30 40 -50
× × ×
.1 .2 .3

Option 1 : Ajout de zéros (« ***zero padding*** » remplacer ? par 0)

f(u): 0 10 20 -30 40 -50 0

(f*W)(u): 8 -4 8 -10 -6

Option 2 : Réflexion (« *reflexion padding* »)

De loin l'option la plus utilisée

f(u): 10 10 20 -30 40 -50 -50

(f*W)(u): 9 -4 8 -10 -21

62

62

Couche convolutionnelle sans « padding »

signal d'entrée

Carte d'activation
(feature map)

Couche convolutionnelle avec « padding »

signal d'entrée

Carte d'activation
(feature map)

63

Exemple : taille de filtre = 5, stride=1

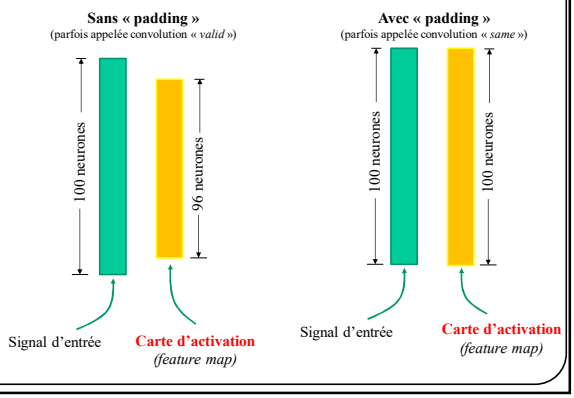

64

Il est possible d'apprendre **plusieurs filtres par couche**

(ex. 5 filtres donnant 5 cartes d'activation)

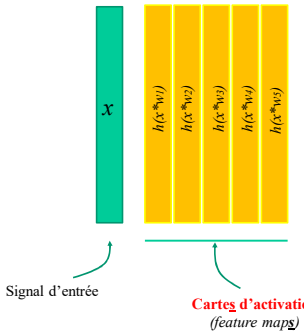

65

Taille de filtre = 5

(ex. 5 filtres donnant 5 cartes d'activation)

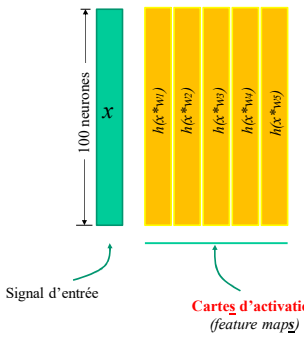

Avec « *padding* »

Combien de neurones et de paramètres au total?

66

Taille de filtre = 5

(ex. 5 filtres donnant 5 cartes d'activation)

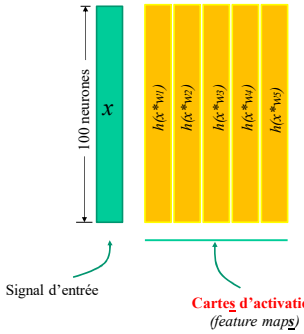

Avec « *padding* »

- 100 neurones par carte d'activation
- 500 neurones au total
- 25 (5x5) paramètres au total

Signal d'entrée

Cartes d'activation
(feature maps)

67

Convolution et couche convolutionnelle **2D**

68

Filtage 2D

(sans flip de filtre)

$$(x * W)(i,j) = \sum_u \sum_v f(i+u, j+v) W(u,v)$$

$x(i,j)$

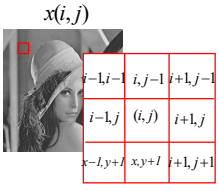

$W(u,v)$

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

$$\begin{aligned}(x*W)(i,j) = {} & w_1 x(i-1,j-1) + w_2 x(i,j-1) + w_3 x(i+1,j-1) \\ & + w_4 x(i-1,j) \quad + w_5 x(i,j) \quad + w_6 x(i+1,j) \\ & + w_7 x(i-1,j+1) + w_8 x(i,j+1) + w_9 x(i+1,j+1)\end{aligned}$$

69

Convolution 2D

Filtre = 3x3
Stride = 1

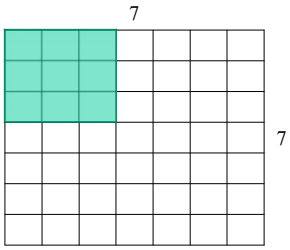

70

Convolution 2D

Filtre = 3x3
Stride = 1

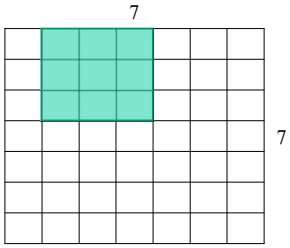

71

Convolution 2D

Filtre = 3x3
Stride = 1

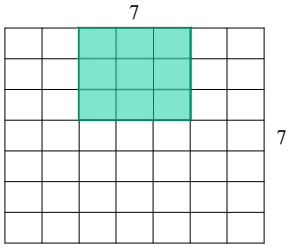

72

Convolution 2D

Filtre = 3x3
Stride = 1

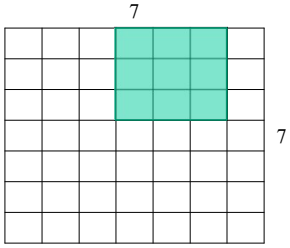

73

Convolution 2D

Filtre = 3x3
Stride = 1

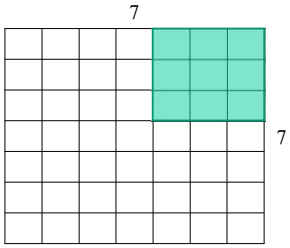

Taille de la carte d'activation (pour stride 1) = **5x5**

74

Convolution 2D

Filtre = 3x3
Stride = 2

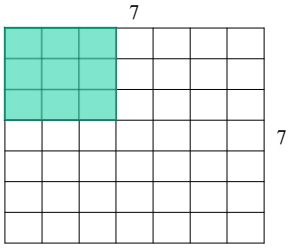

75

Convolution 2D

Filtre = 3x3
Stride = 2

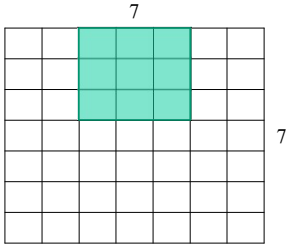

76

Convolution 2D

Filtre = 3x3
Stride = 2

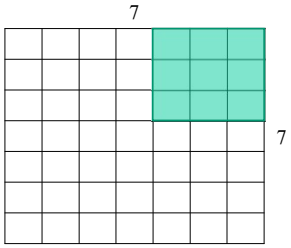

Taille de la carte d'activation (pour stride 2) = **3x3**

77

Convolution 2D

Filtre = 3x3
Stride = 3

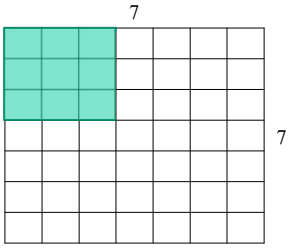

78

Convolution 2D

Filtre = 3x3
Stride = 3

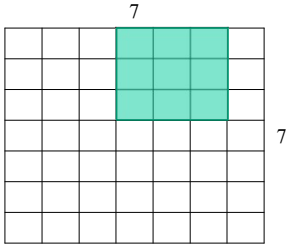

79

Convolution 2D

Filtre = 3x3
Stride = 2

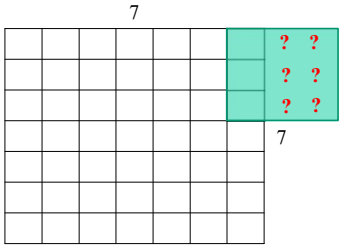

Combinaison D-F-S invalide!

80

Convolution 2D

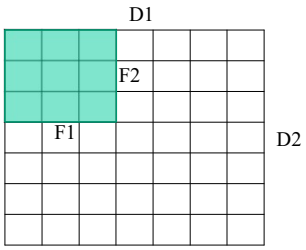

Taille de la carte d'activation :

(D1-F1)/S+1 x (D2-F2)/S+1

81

Différents filtres = différentes cartes d'activation

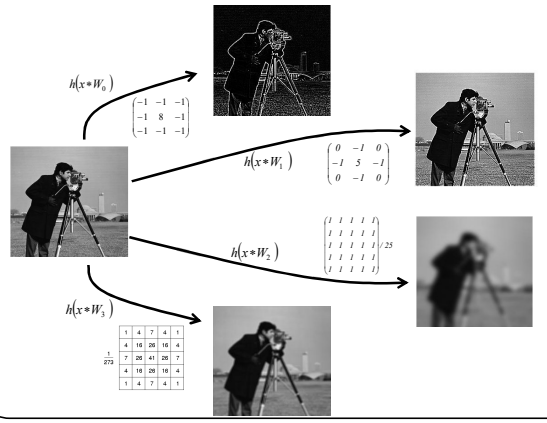

82

4 filtres = Couche convolutive avec **4 cartes d'activation**

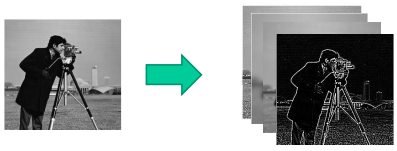

83

K filtres = Couche convolutive avec **K cartes d'activation**

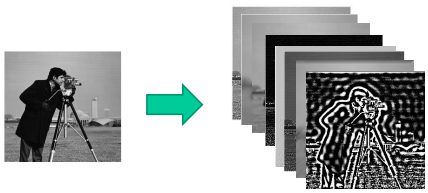

84

Ex.: taille de filtre : 5x5, 5 cartes d'activation, convolution « same »

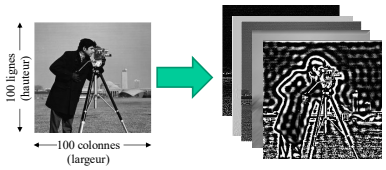

- 10,000 neurones par carte d'activation
- 50,000 neurones au total
- 5x5x5 = 125 paramètres au total

85

Représentation schématique
(1 filtre et 1 carte d'activation, convolution « same »)

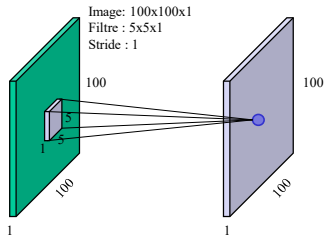

86

Représentation schématique
(2 filtres et 2 cartes d'activation, convolution « *same* »)

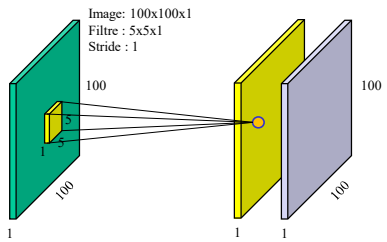

87

Représentation schématique
(6 filtres et 6 cartes d'activation, convolution « same »)

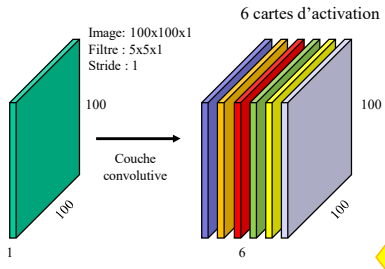

Combien de neurones et de paramètres au total?

88

Représentation schématique
(6 filtres et 6 cartes d'activation, convolution « *same* »)

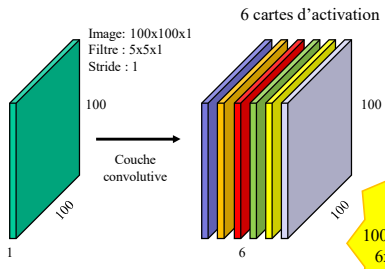

100x100x6=60,000 neurones
6x5x5x1=150 paramètres

89

Représentation schématique **simplifiée**
(6 filtres et 6 cartes d'activation, convolution « ***same*** »)

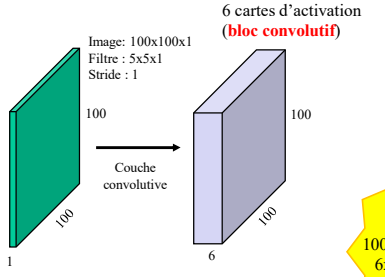

100x100x6=60,000 neurones
6x5x5x1=150 paramètres

90

Représentation schématique simplifiée
(6 filtres et 6 cartes d'activation, convolution « ***valid*** »)

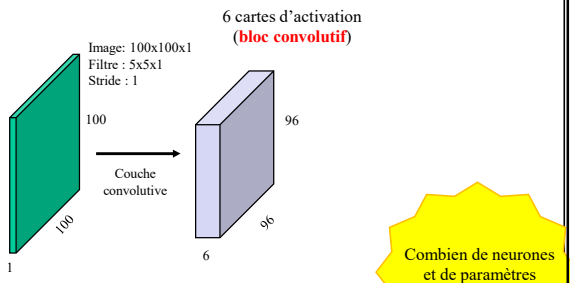

91

Représentation schématique simplifiée
(6 filtres et 6 cartes d'activation, convolution « ***valid*** »)

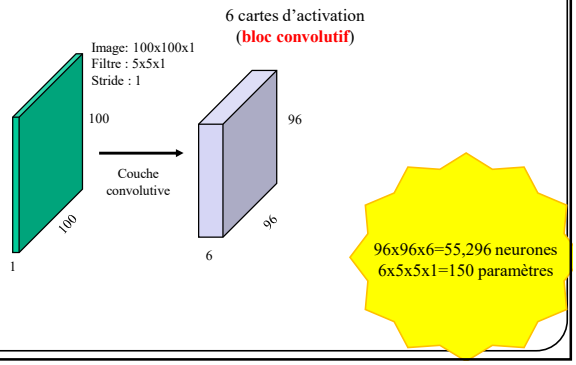

92

Représentation schématique **images couleur**
(ex.: images RGB de CIFAR10
convolution « *same* »)


Exemples cifar10

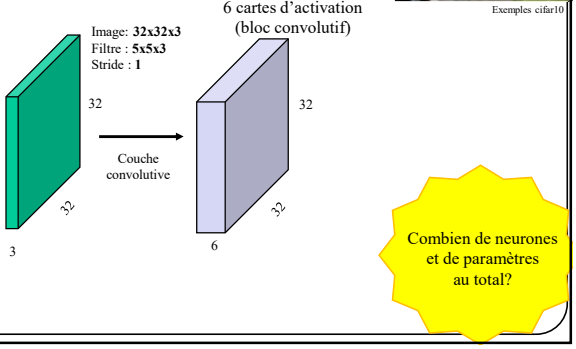

93

Représentation schématique **images couleur**
(ex.: images RGB de CIFAR10
convolution « *same* »)

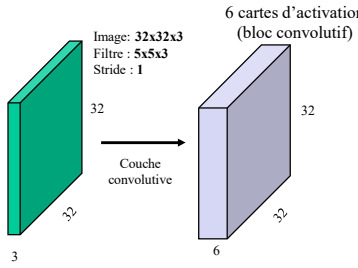

32x32x6=6,144 neurones
6x5x5x**3**=**450** paramètres

94

Représentation schématique **images couleur**
(ex.: images RGB de CIFAR10
convolution « *same* »)

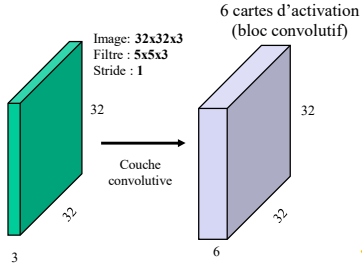

Qu'arrivera-t-il si on
utilise une **stride de 3?**

95

Représentation schématique **images couleur**
(ex.: images RGB de CIFAR10
convolution « *same* »)

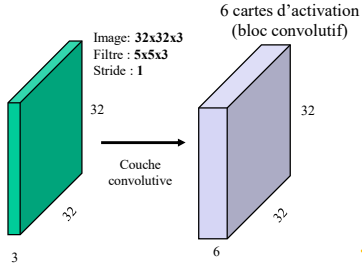

(D-F)/S+1
=
(32-5)/3+1=10

96

Représentation schématique **images couleur**
(ex.: images RGB de CIFAR10
convolution « valid »)

6 cartes d'activation
(bloc convolutif)

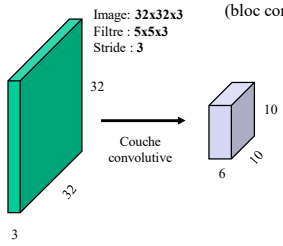

10x10x6=**600 neurones**
6x5x5x**3**=**450** paramètres

97

Exemple

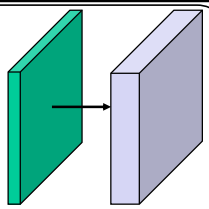

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***same*** »

Combien y a-t-il de paramètres dans cette couche?

98

Exemple

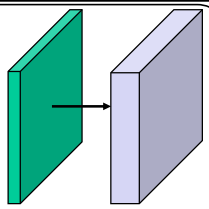

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***same*** »

Combien y a-t-il de paramètres dans cette couche?

Chaque filtre a **5x5x3** = **75** paramètres
Comme il y a **10 filtres** : **750** paramètres

99

Exemple

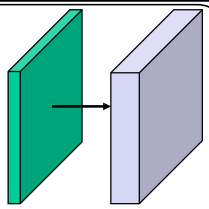

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***same*** ».

Combien y a-t-il de paramètres dans cette couche **si on ajoute un biais**?

Chaque filtre a **5x5x3+1** = **76** paramètres (+1 pour le biais)
Comme il y a **10 filtres** : **760** paramètres

100

Exemple

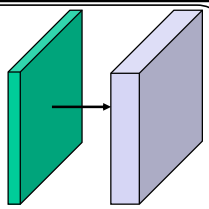

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***valid*** »

Combien de paramètres dans cette couche?

101

Exemple

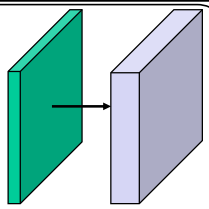

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***valid*** »

Combien de paramètres dans cette couche?

Même chose, cela ne change pas la conformité des filtres

102

Exemple

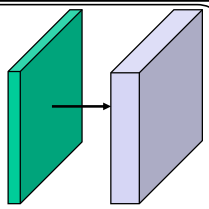

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***valid*** »

Combien de **neurones** dans les cartes d'activations?

103

Exemple

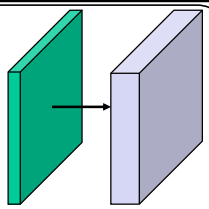

Volume en entrée : **32 x 32 x 3**
10 filtres 5x5 avec **stride = 1**
et convolution « ***valid*** »

Combien de **neurones** dans les cartes d'activations?

(32-5+1) x (32-5+1) x 10 = 7,840

104

Des filtres 1x1? Oui ça marche

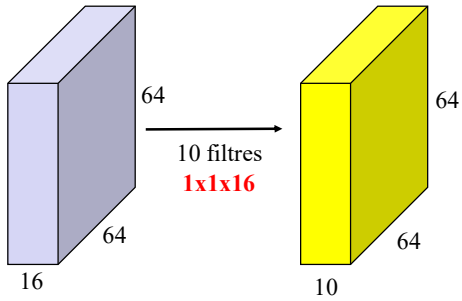

105

Exemple simple d'un filtre 1x1

$$\left[\frac{1}{3},\frac{1}{3},\frac{1}{3}\right]$$

Filtre moyennant les canaux **rouge**, **vert**, **bleu** d'une image couleur.
Résultat, une image en **niveau de gris**.

106

Tout comme un Perceptron multi-couches, un réseau à convolution contient **plusieurs couches consécutives**

107

Exemple : 3 filtres couche 1 : taille 7
5 filtres couche 2 : taille 7
4 filtres couche 3 : taille 5

Convolution « *same* »
Stride 1

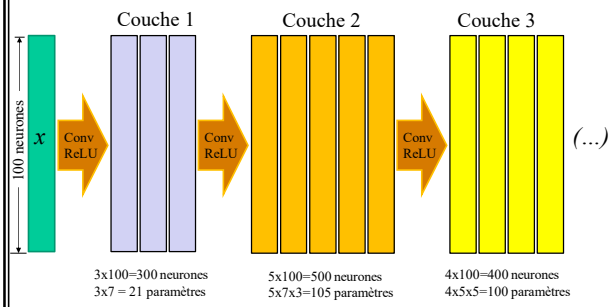

108

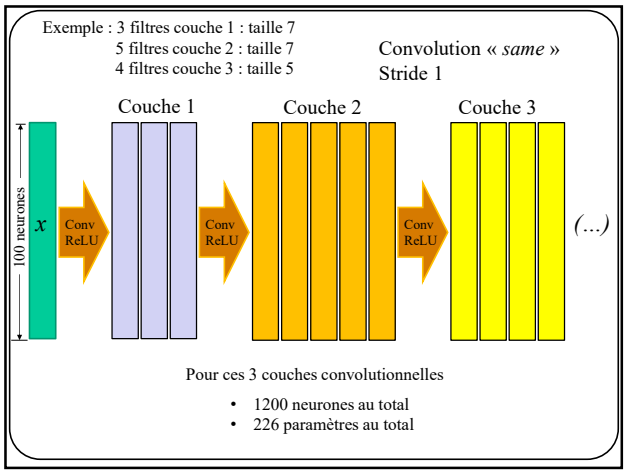
Exemple : 3 filtres couche 1 : taille 7
5 filtres couche 2 : taille 7
4 filtres couche 3 : taille 5
Convolution « same »
Stride 1
Couche 1
Couche 2
Couche 3
100 neurones
x
Conv ReLU
Conv ReLU
Conv ReLU
(…)
Pour ces 3 couches convolutionnelles
• 1200 neurones au total
• 226 paramètres au total

109

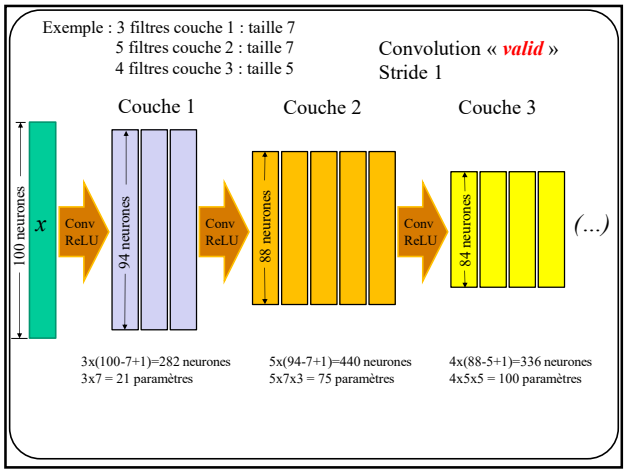
Exemple : 3 filtres couche 1 : taille 7
5 filtres couche 2 : taille 7
4 filtres couche 3 : taille 5
Convolution « valid »
Stride 1
Couche 1
Couche 2
Couche 3
100 neurones
x
Conv ReLU
94 neurones
Conv ReLU
88 neurones
Conv ReLU
84 neurones
(…)
3x(100-7+1)=282 neurones
3x7 = 21 paramètres
5x(94-7+1)=440 neurones
5x7x3 = 75 paramètres
4x(88-5+1)=336 neurones
4x5x5 = 100 paramètres

110

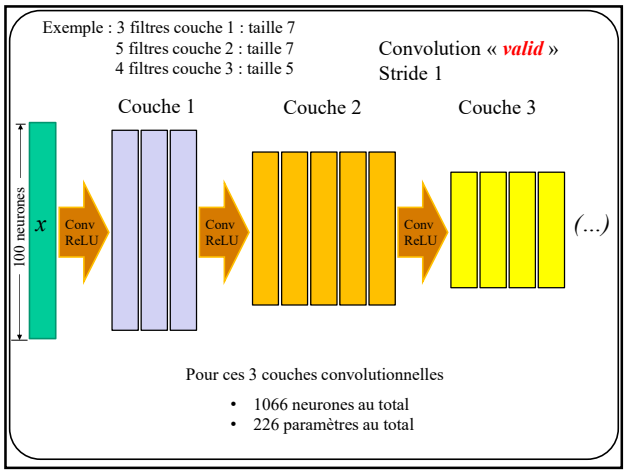
Exemple : 3 filtres couche 1 : taille 7
5 filtres couche 2 : taille 7
4 filtres couche 3 : taille 5
Convolution « valid »
Stride 1
Couche 1
Couche 2
Couche 3
100 neurones
x
Conv ReLU
Conv ReLU
Conv ReLU
(…)
Pour ces 3 couches convolutionnelles
• 1066 neurones au total
• 226 paramètres au total

111

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *same* »

Image: **32x32x3**
Stride : **1**

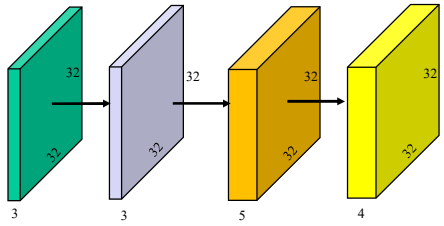

3x(32x32)=3,072 neurones 5x(32x32)=5,120 neurones 4x(32x32)=4,096 neurones
3x7x7x3 = 441 paramètres 5x9x9x3 = 1,215 paramètres 4x11x11x5 = 2,420 paramètres

112

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *same* »

Image: **32x32x3**
Stride : **1**

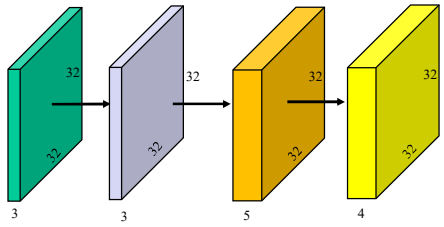

12,288 neurones au total
4,076 paramètres au total

113

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »

Image: **32x32x3**
Stride : **1**

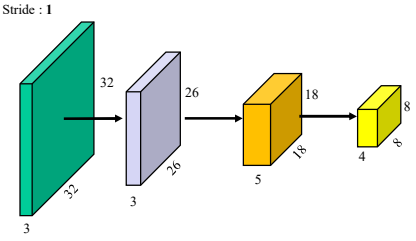

3x(26x26)=2,028 neurones 5x(18x18)=1,620 neurones 4x(8x8)=256 neurones
3x7x7x3 = 441 paramètres 5x9x9x3 = 1,215 paramètres 4x11x11x5 = 2,420 paramètres

114

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »

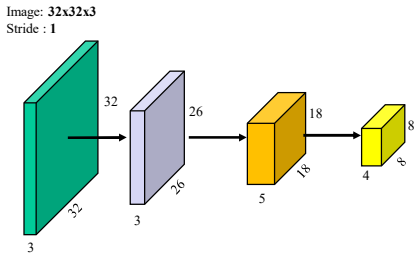

3,904 neurones au total
4,076 paramètres au total

115

Tout comme un perceptron multi-couches, un réseau à convolution se termine par une **couche de sortie** avec **1 neurone par variable prédite**

116

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

Hinge loss

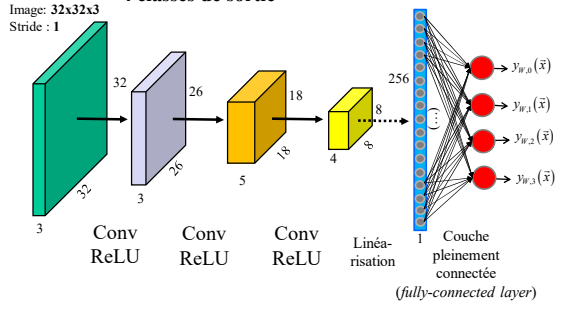

117

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

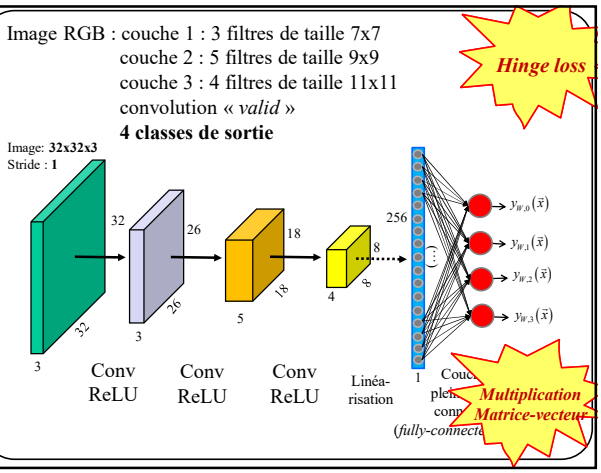

118

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

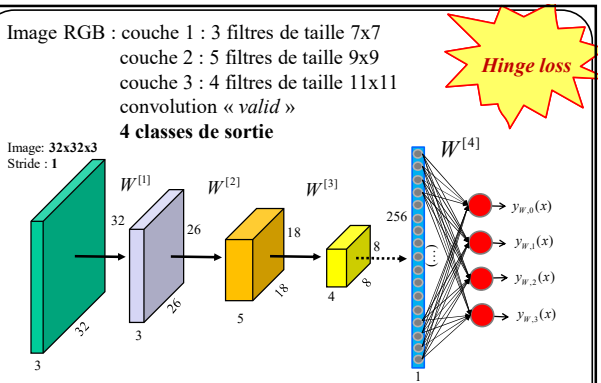

$$y_W(x) = W^{[4]} h\left(W^{[3]} * h\left(W^{[2]} * h\left(W^{[1]} * x\right)\right)\right)$$

119

$$y_W(x) = W^{[4]} h\left(W^{[3]} * h\left(W^{[2]} * h\left(W^{[1]} * x\right)\right)\right)$$

Filtres convolutifs

Matrice 4x256

120

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

Cross-entropy loss

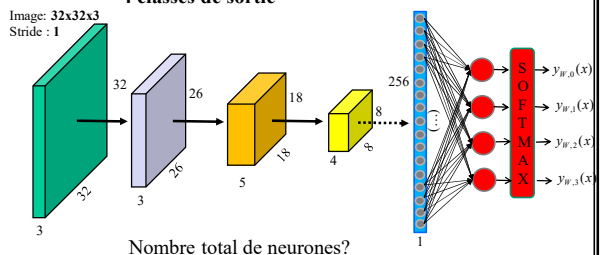

Nombre total de neurones?

121

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

Cross-entropy loss

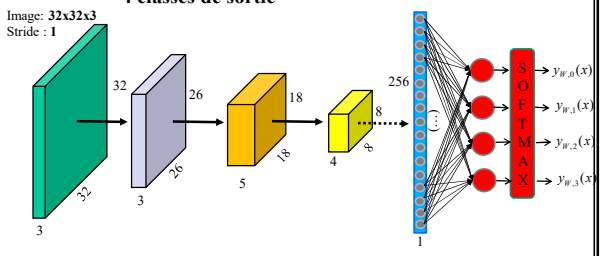

26x26x3 + 18x18x5 + 8x8x4 + 4

122

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

Cross-entropy loss

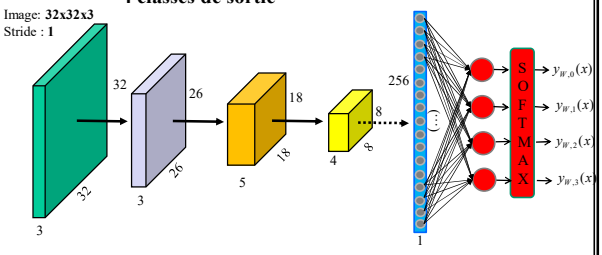

3,908 neurones

123

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

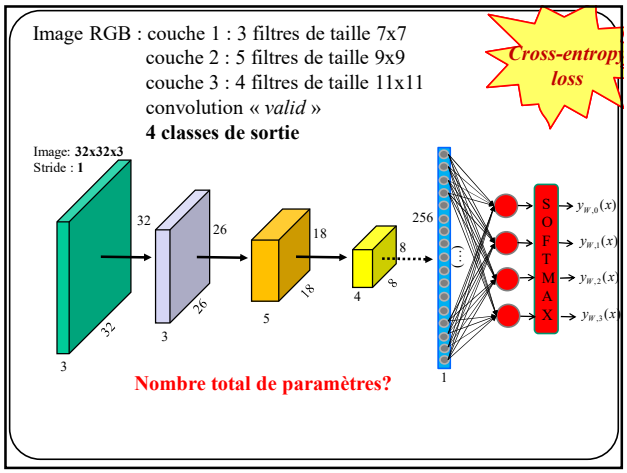

Nombre total de paramètres?

124

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

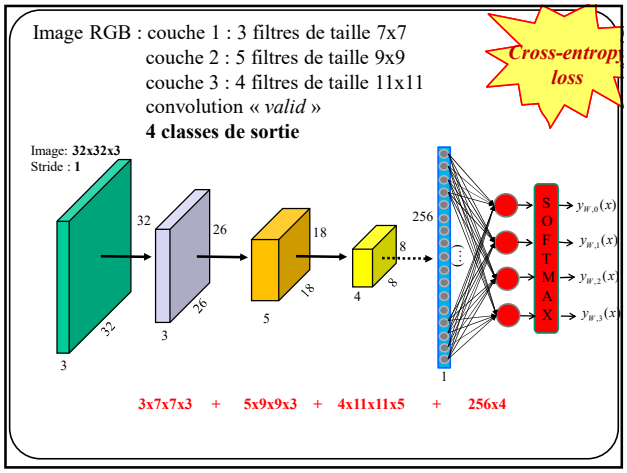

3x7x7x3 + 5x9x9x3 + 4x11x11x5 + 256x4

125

Image RGB : couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
convolution « *valid* »
4 classes de sortie

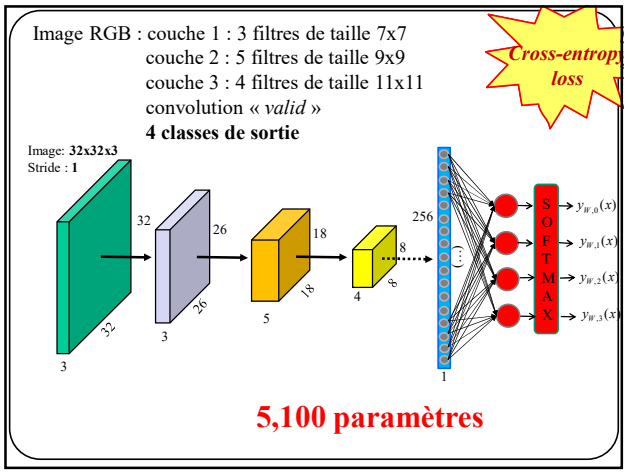

5,100 paramètres

126

Réseaux à convolution
vs
Réseaux **pleinement** convolutifs

127

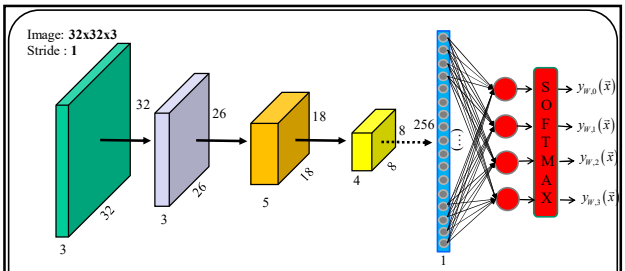

$$y_W(x) = W^{[4]}h\left(W^{[3]} * h\left(W^{[2]} * h\left(W^{[1]} * x\right)\right)\right)$$

Il est possible de **remplacer la multiplication matrice-vecteur** de la fin par une **convolution**

128

Exemple 1d
(convolution « valid »)

9									*	3			=	7						
40	50	70	80	90	10	20	30	40	*	.2	-.3	.4	=	21	21	26	-7	23	8	11

129

Exemple 1d
(convolution « valid »)

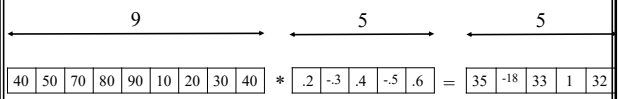

130

Exemple 1d
(convolution « valid »)

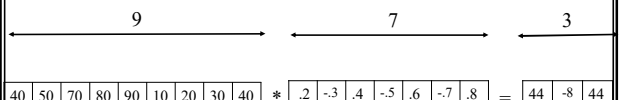

131

Taille filtre = nb de neurones couche précédente

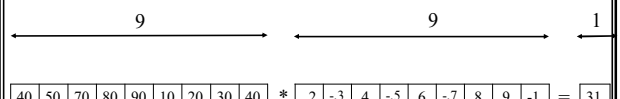

132

Signal d'entrée de **taille 9** convolué avec un filtre « same » de **taille 9** correspond à une **couche pleinement connectée**

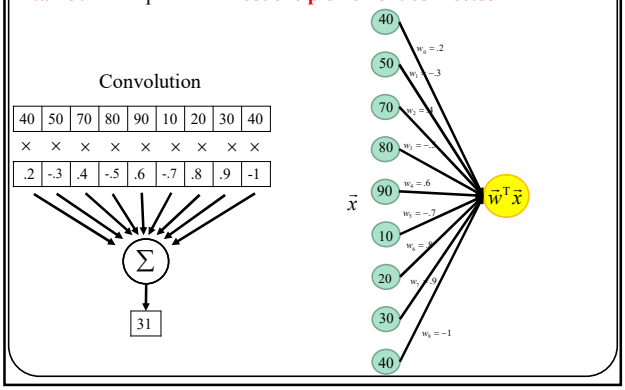

133

Même chose pour une **convolution 2D**

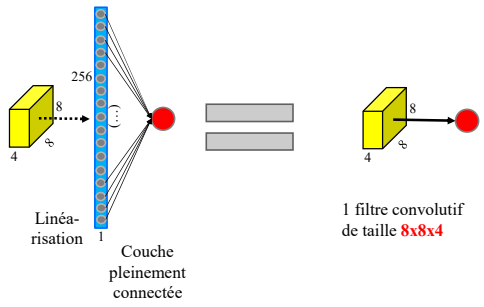

134

Même chose pour une **convolution 2D**

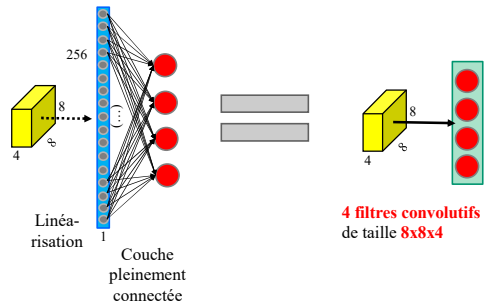

135

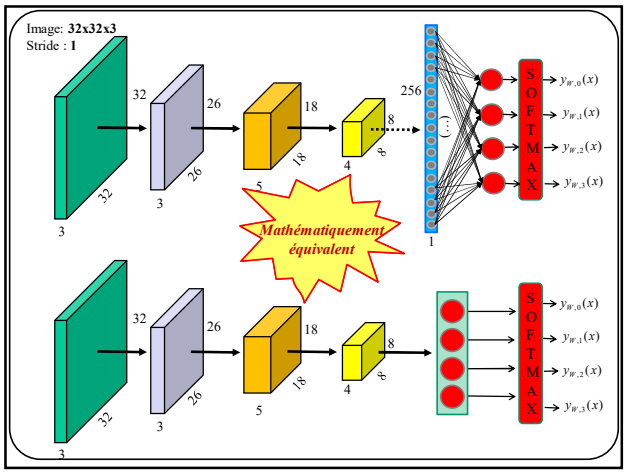

136

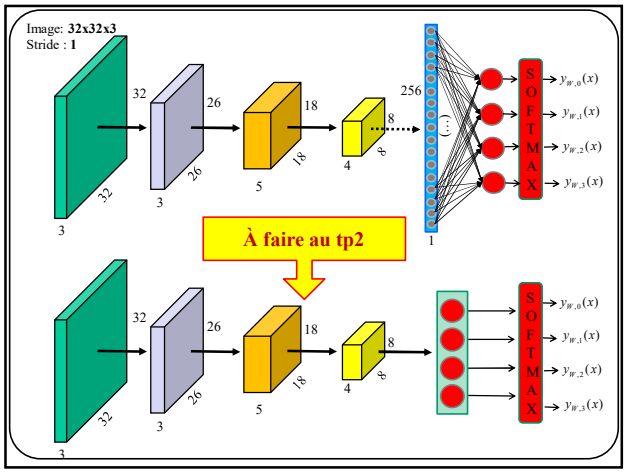

137

Configurations équivalentes

couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
couche 4 pleinement connectée 256x4
Softmax

couche 1 : 3 filtres de taille 7x7
couche 2 : 5 filtres de taille 9x9
couche 3 : 4 filtres de taille 11x11
couche 4 : 4 filtres de taille 8x8
Softmax

En fait, presque équivalent …

Question : qu'arrive-t-il si on remplace l'image 32x32x3 par une image 64x64x3?

138

Pooling

139

Réduction de la taille des cartes d'activation

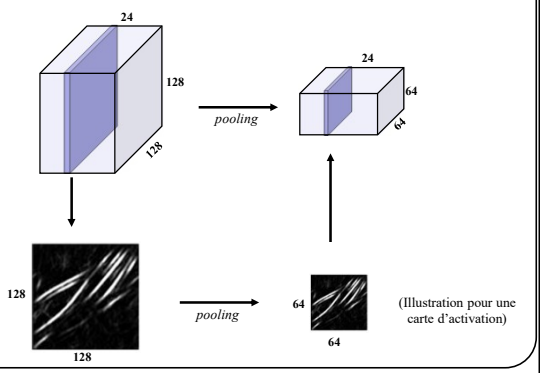

140

Max pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2

Max pool par filtre « valid » 2x2 avec stride =2

7	8	9	6
9	9	5	3
0	6	9	8
9	8	7	4

141

Mean pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2

Moyenne par filtre « valid » 2x2 avec stride =2

4	5	3	4
0	1	5	1
-1	8	8	7
5	4	4	1

142

Max pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2

Max pooling 2x2 avec **stride =1**

?

143

Max pooling

1	2	4	4	9	3	1	2
6	7	8	4	-3	-3	6	3
9	-9	8	-4	5	5	3	0
8	-8	9	-9	5	5	0	1
0	0	1	2	7	9	7	8
-1	-3	3	6	8	8	7	6
9	9	8	2	1	5	-1	-1
1	1	-2	8	3	7	4	-2

Max pooling **3x3** avec **stride =2**

?

144

Illustration d'un CNN complet

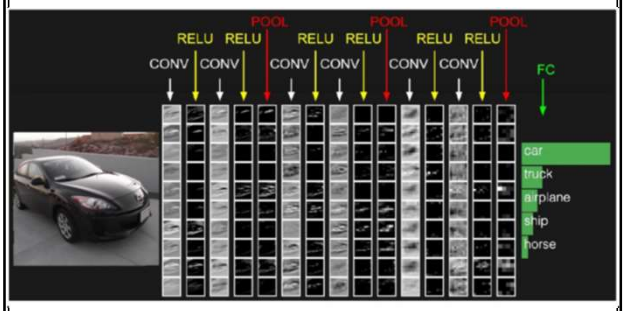

Crédit : cs231 Stanford

145

Multiplication matricielle parcimonieuse

https://towardsdatascience.com/a-comprehensive-introduction-to-different-types-of-convolutions-in-deep-learning-669281e58215

147

Il est **plus rapide** de multiplier des matrices que de les convoluer.

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

Entrée

X0	X1	X2	X3
X4	X5	X6	X7
X8	X9	X10	X11
X12	X13	X14	X15

*

Filtre

W0	W1	W2
W3	W4	W5
W6	W7	W8

=

Y1	Y2
Y3	Y4

148

Il est **plus rapide** de multiplier des matrices que de les convoluer.

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

Entrée

X0	X1	X2	X3
X4	X5	X6	X7
X8	X9	X10	X11
X12	X13	X14	X15

*

Filtre

W0	W1	W2
W3	W4	W5
W6	W7	W8

=

Y0	Y1
Y2	Y3

On peut **remplacer** une **convolution** par une **multiplication matrice-matrice** ou **matrice-vecteur**

en **linéarisant** le filtre et en « **matriçant** » l'entrée

149

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

W0	W1	W2	X3
W3	W4	W5	X7
W6	W7	W8	X11
X12	X13	X14	X15

Y0	Y1
Y2	Y3

Y0=W0.X0+W1.X1+W2.X2+W3.X4+W4.X5+W5.X6+W6.X8+W7.X9+W8.X10

150

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

X0	W0	W1	W2
X4	W3	W4	W5
X8	W6	W7	W8
X12	X13	X14	X15

Y0	**Y1**
Y2	Y3

Y1=W0.X1+W1.X2+W2.X3+W3.X5+W4.X6+W5.X7+W6.X9+W7.X10+W8.X11

151

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

Y2=W0.X4+W1.X5+W2.X6+W3.X8+W4.X9+W5.X10+W6.X12+W7.X13+W8.X14

152

Rappel

Ex.: convolution « *valid* », un canal d'entrée et une carte d'activation, filtre 3x3

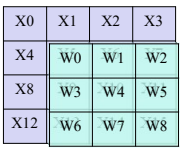

Y3=W0.X5+W1.X6+W2.X7+W3.X9+W4.X10+W5.X11+W6.X13+W7.X14+W8.X15

153

Autrement dit…

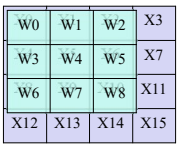

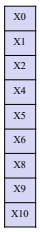

154

Autrement dit…

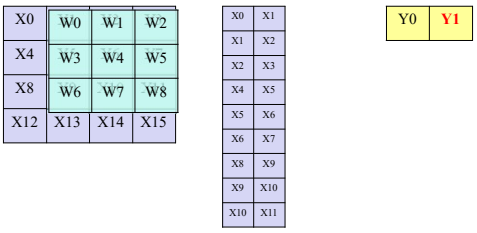

155

Autrement dit…

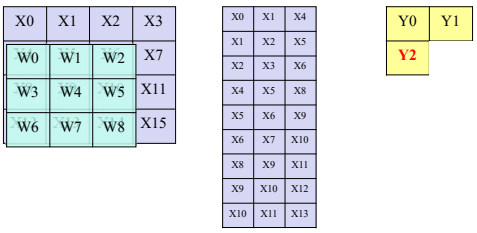

156

Autrement dit…

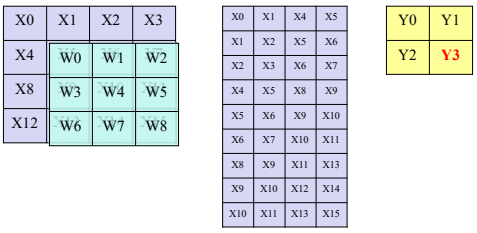

157

Convolution « valid » en **linéarisant le filtre** et en **« matriçant » l'entrée**

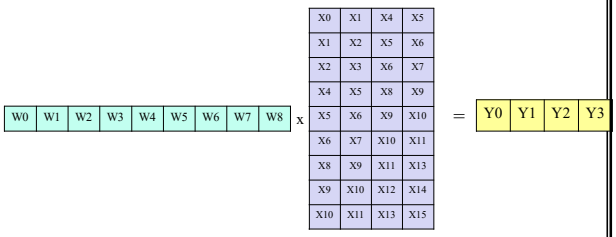

158

Autre exemple

conv « valid », mini-batch de 2 entrées

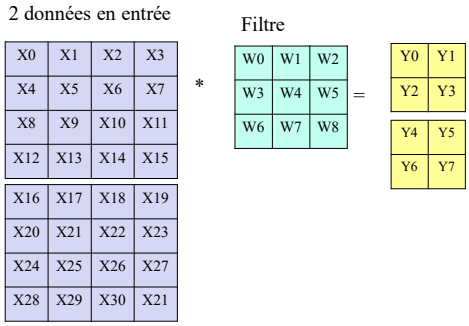

159

Autre exemple

conv « valid », mini-batch de 2 entrées

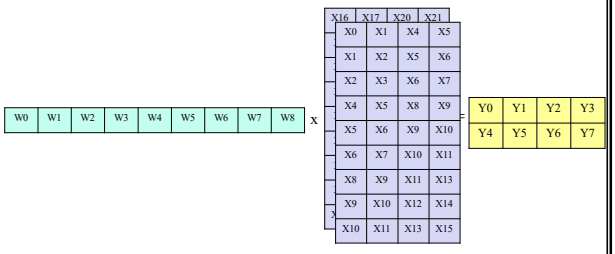

160

Autre exemple

conv « valid », une entrée, deux filtres

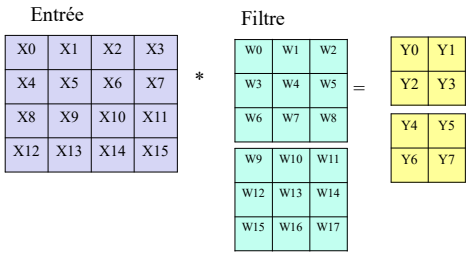

161

Autre exemple

conv « valid », une entrée, deux filtres

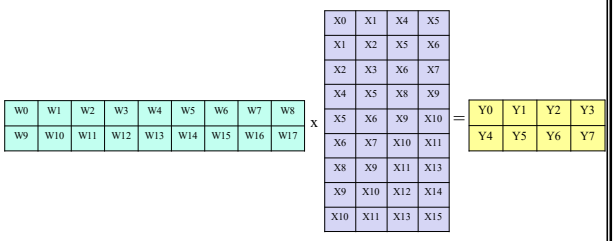

162

Autre exemple

conv « valid », une entrée avec deux canaux, un filtre

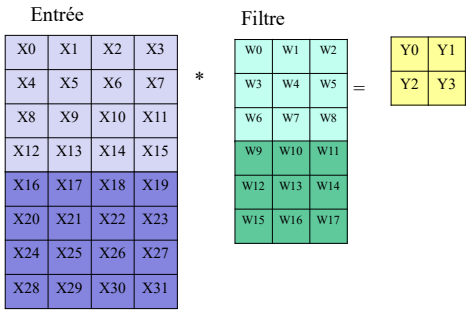

163

Autre exemple

conv « valid », une entrée avec deux canaux, un filtre

W0	W1	W2	W3	(…)	W5	W6	W7	W8	W9	W10	W11	W12	W13	W14	W15	W16	W17

x

X0	X1	X4	X5
X1	X2	X5	X6
X2	X3	X6	X7
X4	X5	X8	X9
(…)	(…)	(…)	(…)
X22	X23	X26	X27
X24	X25	X27	X29
X25	X26	X28	X30
X26	X27	X29	X31

= | Y0 | Y1 | Y2 | Y3 |

164

Exemples d'architectures connues

165

LeNet-1

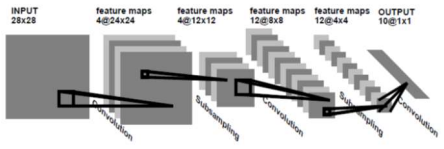

Une des plus vieilles architectures faites pour la reconnaissance de caractères.

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes

Input
|
CONV
|
POOL
|
CONV
|
POOL
|
FC
|
SOFTMAX

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

166

LeNet-1

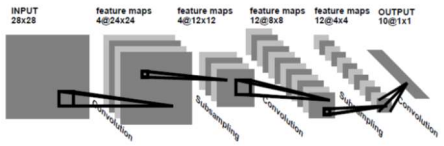

Une des plus vieilles architectures faites pour la reconnaissance de caractères.

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 4 et 12 filtres)
- 2 *average pooling*
- 1 couche pleinement connectée
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
SOFTMAX

Combien de neurones?
Combien de paramètres?

LeCun, Y.; Boser, B.; Denker, J. S.; Henderson, D.; Howard, R. E.; Hubbard, W. & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. Neural Computation, 1(4):541-551

167

LeNet-5

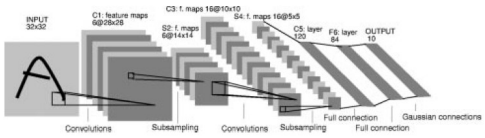

Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
FC
FC
SOFTMAX

LeCun, Y.; Bottou, L.; Bengio, Y. & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11): 2278 - 232

168

LeNet-5

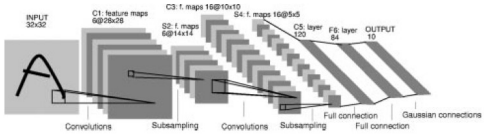

Version améliorée:

- Image d'entrée : 28x28x1
- Filtres convolutionnels : 5x5
- Conv « valid » + tanh
- 2 couches convolutionnelles (avec 6 et 16 filtres)
- 2 *average pooling*
- 3 couches pleinement connectées (120, 84 et 10 neurones)
- 10 classes

Input
CONV
POOL
CONV
POOL
FC
FC
FC
SOFTMAX

Combien de neurones?
Combien de paramètres?

169

Classification d'images

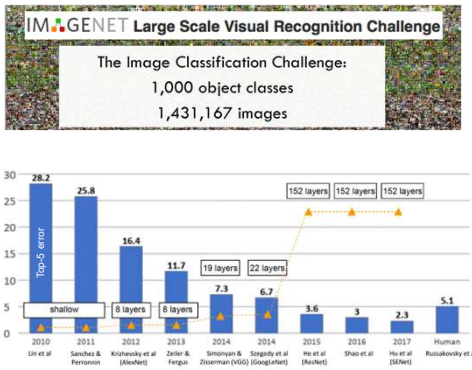

Image: http://cs231n.stanford.edu/slides/2018

170

170

Classification d'images

AlexNet [Krizhevsky et al, 2012]

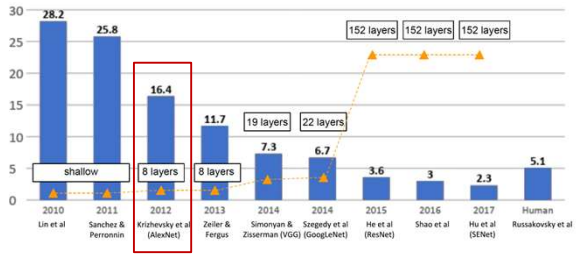

Image: http://cs231n.stanford.edu/slides/2018

171

171

AlexNet

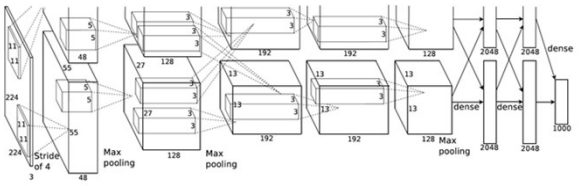

- Premier CNN à bien performer sur ImageNet (amélioration de 10% par rapport aux autres)
- Utilisation de techniques aujourd'hui fréquemment utilisées: **ReLU, data augmentation** and **dropout**
- Utilisation de **GPUs** (2 dans leur cas)
- Point de départ de la **révolution du "deep learning"** en vision par ordinateur

Image: Krizhevsky et al. "Imagenet classification with deep convolutional neural networks," NIPS 2012.

172

AlexNet

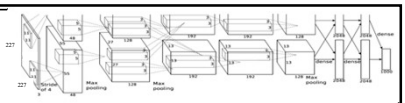

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Quelle est la taille des cartes d'activation?

Réponse: (227-11)/4+1 = 55

173

AlexNet

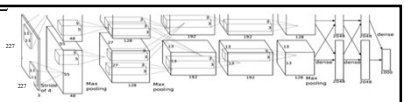

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Cartes d'activation : 96 x 55 x 55

Q: Quel est le nombre de paramètres?

174

AlexNet

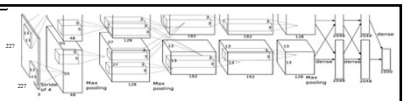

Architecture:

CONV1
MAX POOL1
NORM1
CONV2
MAX POOL2
NORM2
CONV3
CONV4
CONV5
Max POOL3
FC6
FC7
FC8

Entrée : image RGB: 227x227x3
Couche 1 (CONV1): 96 filtres de taille 11x11 avec **stride de 4** et conv **"valid"**

Cartes d'activation : 96 x 55 x 55
Paramètres : 11 x 11 x 96 x 3 = 34,848

175

AlexNet

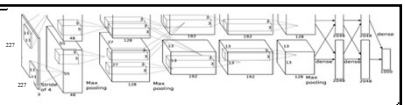

ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55

Couche 2 MaxPool : 3x3 stride stride 2

Quelle est la taille des cartes d'activation?

Réponse: (55-3)/2+1 = 27

176

AlexNet

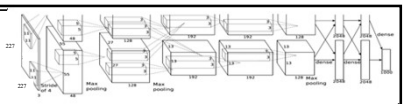

ENTRÉE : 227x227x3
CONV1: 96 x 55 x 55

Couche 2 MaxPool : 3x3 stride stride 2
27 x 27 x 96

Combien y a-t-il de paramètres?

Réponse: 0!

177

AlexNet

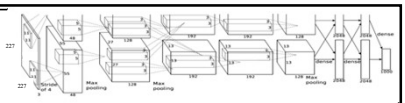

ENTRÉE : 227x227x3
CONV1: 55 x 55 x 96
MAX POOL1: 27 x 27 x 96
…

178

AlexNet

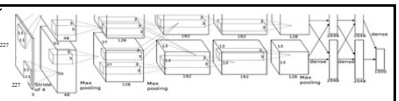

ENTRÉE	227 x 227 x 3
96 filtres 11x11, stride 4, pad 0, **CONV1**	55 x 55 x 96
filtre 3x3, stride 2, **MAX POOL1**	27 x 27 x 96
normalisation par couche, **NORM1**	27 x 27 x 96
256 filtres 5x5, stride 1, pad 2, **CONV2**	27 x 27 x 256
filtre 3x3, stride 2, **MAX POOL2**	13 x 13 x 256
normalisation par couche, **NORM2**	13 x 13 x 256
384 filtres 3x3, stride 1, pad 1, **CONV3**	13 x 13 x 384
384 filtres 3x3, stride 1, pad 1, **CONV4**	13 x 13 x 384
256 filtres 3x3, stride 1, pad 1, **CONV5**	13 x 13 x 256
filtre 3x3, stride 2, **MAX POOL3**	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

179

AlexNet

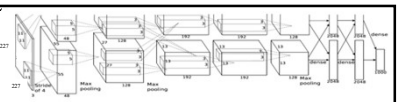

ENTRÉE	227 x 227 x 3
CONV1	55 x 55 x 96
MAX POOL1	27 x 27 x 96
NORM1	27 x 27 x 96
CONV2	27 x 27 x 256
MAX POOL2	13 x 13 x 256
NORM2	13 x 13 x 256
CONV3	13 x 13 x 384
CONV4	13 x 13 x 384
CONV5	13 x 13 x 256
MAX POOL3	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

Notes additionnelles:

Fonction d'activation **ReLU**
Augmentation de données
LayerNorm : peu utilisé aujourd'hui
Dropout 0.5
Batch_size 128
SGD + momentum
Taux d'apprentissage 0.01 avec réduction par plateau d'un facteur 10
~68 millions de paramètres

180

AlexNet

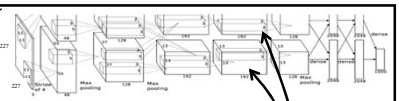

ENTRÉE	227 x 227 x 3
CONV1	55 x 55 x 96
MAX POOL1	27 x 27 x 96
NORM1	27 x 27 x 96
CONV2	27 x 27 x 256
MAX POOL2	13 x 13 x 256
NORM2	13 x 13 x 256
CONV3	13 x 13 x 384
CONV4	13 x 13 x 384
CONV5	13 x 13 x 256
MAX POOL3	6 x 6 x 256
FC6	4096
FC7	4096
FC8	1000

Notes additionnelles:

Utilisation de **2 GPUs**
Fait voter un ensemble de 7 CNN:
18.2% -> 15.4

181

Classification d'images

VGGNet [Simonyan and Zisserman, 2014]

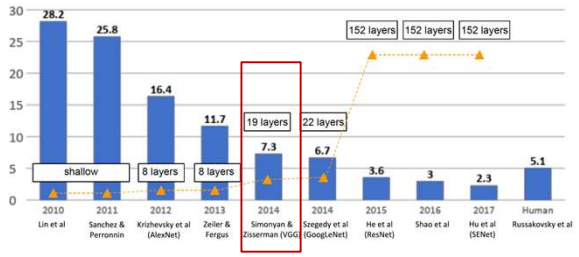

Karen Simonyan, Andrew Zisserman "Very Deep Convolutional Networks for Large-Scale Image Recognition", ICLR 2015

Image: http://cs231n.stanford.edu/slides/2018

182

VGGNet

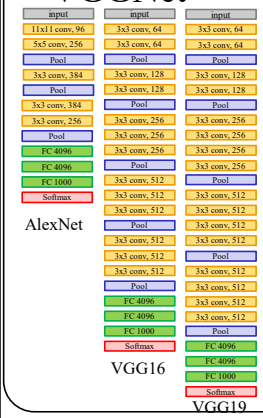

Ce qui caractérise VGGNet par rapport à ses prédécesseurs:

- Uniquement des **filtres 3x3, stride 1, pad 1**
- **Plus profond**

AlexNet : 8 couches
VGGNet : 16 ou 19 couches

7.3% d'erreur contre 11.7% pour ZFNet

183

VGGNet

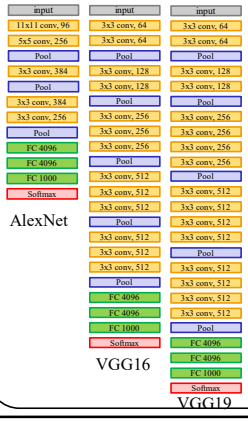

Pourquoi utiliser des filtres 3x3?

Indice1 : quel est le **champ récepteur** (***receptive field***) d'une série de 3 couches 3x3?

Indice2 : combien de paramètres pour ces 3 couches?

184

VGGNet

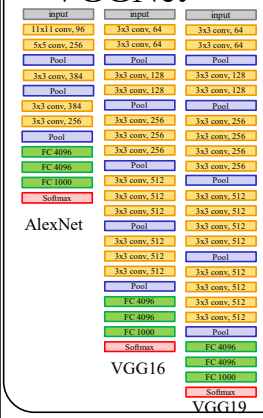

AlexNet

VGG16

VGG19

Pourquoi utiliser des filtres 3x3?

Le champ récepteur de 3 filtres 3x3 consécutifs est **7x7**

nb_params pour 3 filtres consécutifs **3x3x3xNb_Canaux**
Vs
nb_params pour 1 couche: **7x7xNb_Canaux**

185

185

VGGNet

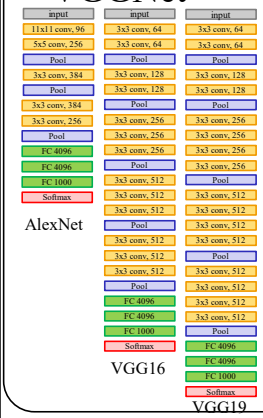

AlexNet

VGG16

VGG19

Pourquoi utiliser des filtres 3x3?

Le champ récepteur de 3 filtres 3x3 est **7x7**

nb_params pour 3 couches **27xNb_Canaux**
Vs
nb_params pour 1 couche**: 49xNb_Canaux**

186

186

VGGNet

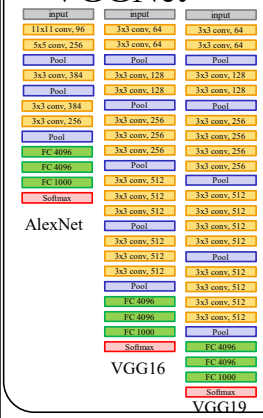

AlexNet

VGG16

VGG19

Conclusion :

Plus de couches de plus petits filtres
=>
Moins de paramètres et **plus de non-linéarités**

187

187

VGG16

ENTRÉE	
CONV-3x3-64	
CONV-3x3-64	
POOL-2x2	
CONV-3x3-128	
CONV-3x3-128	
POOL-2x2	
CONV-3x3-256	
CONV-3x3-256	
CONV-3x3-256	
POOL-2x2	
CONV-3x3-512	
CONV-3x3-512	
CONV-3x3-512	
POOL-2x2	
CONV-3x3-512	
CONV-3x3-512	
CONV-3x3-512	
POOL-2x2	
FC-4096	
FC-4096	
FC-4096	

Combien de paramètres?
Combien de neurones?

VGG16

188

Image: http://cs231n.stanford.edu/slides/20

188

VGG16

	Cartes d'activation
ENTRÉE	[224x224x3]
CONV-3x3-64	[224x224x64]
CONV-3x3-64	[224x224x64]
POOL-2x2	[112x112x64]
CONV-3x3-128	[112x112x128]
CONV-3x3-128	[112x112x128]
POOL-2x2	[56x56x128]
CONV-3x3-256	[56x56x256]
CONV-3x3-256	[56x56x256]
CONV-3x3-256	[56x56x256]
POOL-2x2	[28x28x256]
CONV-3x3-512	[28x28x512]
CONV-3x3-512	[28x28x512]
CONV-3x3-512	[28x28x512]
POOL-2x2	[14x14x512]
CONV-3x3-512	[14x14x512]
CONV-3x3-512	[14x14x512]
CONV-3x3-512	[14x14x512]
POOL-2x2	[7x7x512]
FC-4096	[1x1x4096]
FC-4096	[1x1x4096]
FC-4096	[1x1x1000]

VGG16

189

Image: http://cs231n.stanford.edu/slides/20

189

VGG16

	Cartes d'activation	Nb Neurones
ENTRÉE	[224x224x3]	150 K
CONV-3x3-64	[224x224x64]	3.2 M
CONV-3x3-64	[224x224x64]	3.2 M
POOL-2x2	[112x112x64]	800 k
CONV-3x3-128	[112x112x128]	1.6 M
CONV-3x3-128	[112x112x128]	1.6 M
POOL-2x2	[56x56x128]	400 K
CONV-3x3-256	[56x56x256]	800 K
CONV-3x3-256	[56x56x256]	800 K
CONV-3x3-256	[56x56x256]	800 K
POOL-2x2	[28x28x256]	200 K
CONV-3x3-512	[28x28x512]	400 K
CONV-3x3-512	[28x28x512]	400 K
CONV-3x3-512	[28x28x512]	400 K
POOL-2x2	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
CONV-3x3-512	[14x14x512]	100 K
POOL-2x2	[7x7x512]	25 K
FC-4096	[1x1x4096]	4094
FC-4096	[1x1x4096]	4096
FC-4096	[1x1x1000]	1000

VGG16

190

Image: http://cs231n.stanford.edu/slides/20

190

VGG16	Cartes d'activation	Nb Neurones	Nb Paramètres
ENTRÉE	[224x224x3]	150 K	0
CONV-3x3-64	[224x224x64]	3.2 M	(3*3*3)*64 = 1,728
CONV-3x3-64	[224x224x64]	3.2 M	(3*3*64)*64 = 36,864
POOL-2x2	[112x112x64]	800 k	0
CONV-3x3-128	[112x112x128]	1.6 M	(3*3*64)*128 = 73,728
CONV-3x3-128	[112x112x128]	1.6 M	(3*3*128)*128 = 147,456
POOL-2x2	[56x56x128]	400 K	0
CONV-3x3-256	[56x56x256]	800 K	(3*3*128)*256 = 294,912
CONV-3x3-256	[56x56x256]	800 K	(3*3*256)*256 = 589,824
CONV-3x3-256	[56x56x256]	800 K	(3*3*256)*256 = 589,824
POOL-2x2	[28x28x256]	200 K	0
CONV-3x3-512	[28x28x512]	400 K	(3*3*256)*512 = 1,179,648
CONV-3x3-512	[28x28x512]	400 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[28x28x512]	400 K	(3*3*512)*512 = 2,359,296
POOL-2x2	[14x14x512]	100 K	0
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
CONV-3x3-512	[14x14x512]	100 K	(3*3*512)*512 = 2,359,296
POOL-2x2	[7x7x512]	25 K	0
FC-4096	[1x1x4096]	4094	7*7*512*4096 = 102,760,448
FC-4096	[1x1x4096]	4096	4096*4096 = 16,777,216
FC-4096	[1x1x1000]	1000	4096*1000 = 4,096,000

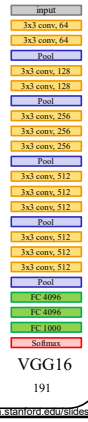

VGG16

191

Image: http://cs231n.stanford.edu/slides/20

191

VGGNet

Nb neurones totaux : ~15 M
Mémoire totale neurones (4 octets par neurones) : ~60 Mo
Nb paramètres totaux : 138 M
Mémoire total paramètres (4 octets par paramètres) : 552 Mo

~ 612 Mo pour la propagation avant d'une image

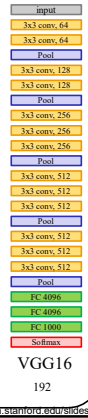

VGG16

192

Image: http://cs231n.stanford.edu/slides/20

192

VGGNet

Nb neurones totaux : ~15 M
Mémoire totale neurones (4 octets par neurones) : ~60 Mo
Nb paramètres totaux : ~138 M
Mémoire total paramètres (4 octets par paramètres) : ~552 Mo

~612 Mo pour la propagation avant d'une image

>1.1 Go si on inclut la rétro-propagation

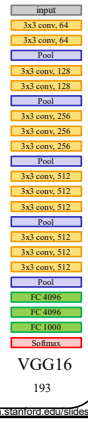

VGG16

193

Image: http://cs231n.stanford.edu/slides/20

193